Università Politecnica delle Marche

Facoltà di Ingegneria

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

---

Progetto di Data Science

Parte I: Audio Feature Analysis, Classificazione e Clustering su Dati Spotify

Parte II: Analisi delle Serie Storiche sul Mercato Calcistico Europeo (Transfermarkt)

Docenti:

Prof. Ursino Domenico

Dott. Buratti Christopher

Componenti del gruppo:

Altieri Andrea

Belardinelli Luca

Flaiani Andrea

Anno Accademico 2024-2025

Indice

1 Spotify tracks analysis: Introduzione **3**

1.1 Obiettivi del progetto 3

2 Spotify tracks analysis: Dataset **5**

2.1 ETL 7

2.2 Analisi descrittiva 8

2.2.1 Distribuzione dei generi musicali 8

2.2.2 Distribuzione delle feature continue 9

2.2.3 Distribuzione delle variabili discrete 11

2.2.4 Matrice di correlazione 12

3 Spotify tracks analysis: Classificazione **14**

3.1 Preprocessing del Dataset 14

3.1.1 Oversampling con SMOTE e Undersampling 14

3.1.2 Dataset Finale 15

3.2 Processo di Classificazione 17

3.2.1 Confronto Modelli di Machine Learning 17

3.2.2 Tuning degli Iperparametri 18

3.2.3 Ensemble Learning 18

3.3 Diagnostica e Commento ai Risultati 20

3.3.1 Matrice di Confusione e Classification Report 20

3.3.2 Curve ROC, Precision-Recall e Learning Curve 22

3.3.3 Feature Importance 24

4 Spotify tracks analysis: Clustering **25**

4.1 Fase di ETL per il clustering 25

4.1.1 Riduzione di dimensionalità (PCA e t-SNE) 26

4.2 K-Means 27

4.2.1 Scelta del parametro k tramite Elbow Method 27

4.2.2 Analisi dei Risultati e Profiling dei Cluster 27

4.2.3 Valutazione della Silhouette per K-Means 30

4.3 DBSCAN 31

4.3.1 Scelta dei parametri e tuning 31

4.3.2 Analisi dei risultati ottenuti e Diagnostica del Rumore 32

5 Business Case finale e Conclusioni della Parte I **34**

5.1 Sintesi dei Risultati Metodologici 34

5.2 Ricadute Applicative e Scenari di Business 34

5.3 Sviluppi Futuri 35

6 Analisi delle serie storiche sul mercato calcistico: introduzione e dataset 37

6.1 Struttura del dataset relazionale di Transfermarkt 38

6.2 Processo di estrazione, trasformazione e caricamento per la serie storica . . 39

7 Analisi esplorativa dei dati e dinamica degli shock storici 44

8 Decomposizione stagionale, stazionarieta e analisi delle autocorrelazioni 45

9 Modellazione predittiva, diagnostica dei residui e conclusioni finali 46

Elenco delle figure 47

Elenco delle tabelle 48

PARTE I

Classificazione Supervisionata e Clustering Non Supervisionato su Dati Spotify

1 Spotify tracks analysis: Introduzione

Nel panorama contemporaneo dello streaming musicale, la fruizione e la catalogazione dei brani audio sono guidate in misura sempre maggiore da modelli matematici e algoritmi di apprendimento automatico. Piattaforme leader a livello globale come Spotify gestiscono cataloghi composti da decine di milioni di brani, affrontando la sfida quotidiana di organizzarli in modo coerente e di proporre raccomandazioni personalizzate per ciascun utente. Per fare ciò, i moderni sistemi non si basano unicamente sui metadati testuali (come il titolo, il nome dell'artista o la casa discografica), ma estraggono sistematicamente caratteristiche acustiche e psicoacustiche direttamente dal segnale audio grezzo di ogni traccia.

Comprendere come queste variabili continue e discrete interagiscano tra loro permette sia di automatizzare la categorizzazione dei brani all'interno dei rispettivi generi musicali, sia di scoprire pattern latenti di affinità sonica non rilevabili dalle sole etichette commerciali. In questo contesto, il presente progetto si propone di analizzare approfonditamente un dataset contenente oltre 42.000 tracce musicali descritte da molteplici attributi tecnici (frequenza, tempo in BPM, volume sonoro, presenza vocale, valenza emotiva e ballabilità), integrando un percorso metodologico completo che spazia dalla pulizia e preparazione dei dati, alla modellazione supervisionata e non supervisionata.

1.1 Obiettivi del progetto

L'obiettivo principale dell'elaborato è l'applicazione di tecniche di machine learning, in particolare di classificazione supervisionata e di clustering non supervisionato, per estrarre conoscenza e individuare relazioni significative nei dati musicali. Nello specifico, il lavoro si articola nei seguenti obiettivi fondamentali:

- **Data Cleaning ed ETL Rigoroso:** Ispezionare la qualità dei dati grezzi estratti dall'API di Spotify, eliminare le ridondanze derivanti dalla sovrapposizione delle playlist tematiche mediante deduplicazione basata sull'identificativo univoco del brano, scartare variabili di servizio non informative e preparare i dati garantendo la totale assenza di *data leakage*.

- **Analisi Descrittiva ed Esplorativa (EDA):** Esaminare a fondo le distribuzioni statistiche delle caratteristiche audio, evidenziando le asimmetrie, la presenza di outlier e le correlazioni lineari tra grandezze fisiche e musicali.

- **Classificazione Multiclasse del Genere Musicale:** Sviluppare e ottimizzare modelli predittivi capaci di stimare il genere di appartenenza di una traccia tra 15 classi differenti partendo unicamente dalle sue proprietà sonore. Il task richiede di affrontare il forte sbilanciamento delle classi tramite tecniche di oversampling

sintetico (SMOTE) e undersampling controllato, di confrontare molteplici algoritmi di machine learning e di incrementare le performance attraverso tecniche avanzate di *Ensemble Learning* (Voting Classifier e Stacking Classifier).

- **Clustering Non Supervisionato e Profiling dei Mood:** Raggruppare i brani in cluster sonori omogenei in modo del tutto agnostico rispetto al genere etichettato, impiegando sia algoritmi di partizionamento (K-Means) che algoritmi basati sulla densità spaziale (DBSCAN), supportati da tecniche di riduzione della dimensionalità (PCA e t-SNE) per identificare macro-archetipi o playlist emotive (*mood playlists*).
- **Analisi Diagnostica e Ricadute Applicative:** Condurre un'analisi approfondita degli errori commessi dai modelli (matrice di confusione, curve ROC e Precision-Recall, learning curves, silhouette analysis) e proporre scenari d'uso concreti per le piattaforme di streaming e l'industria discografica.

Attraverso l'impiego coordinato di queste metodologie, il progetto intende dimostrare come l'analisi quantitativa dei segnali audio possa supportare efficacemente sia la classificazione tassonomica automatica sia la creazione di nuovi percorsi di scoperta musicale guidati dalle affinità timbriche ed emotive.

2 Spotify tracks analysis: Dataset

Il dataset impiegato per la realizzazione di questo progetto è stato reperito dalla piattaforma Kaggle, ed è noto come *Spotify Audio Features / Genres v2*. Il dataset grezzo raccoglie 42.305 osservazioni relative a brani musicali estratti tramite le Web API ufficiali di Spotify a partire da playlist pubbliche focalizzate su 15 generi e sottogeneri musicali contemporanei.

Ciascuna traccia all'interno del dataset è descritta da un totale di 22 attributi, comprendenti metadati identificativi, parametri sonori continui derivati dall'analisi spettrale e variabili discrete legate alla teoria musicale. Nel dettaglio, le informazioni fornite dal dataset si suddividono nelle seguenti categorie:

- **Informazioni e Metadati di Servizio:**
  - `id`: Stringa alfanumerica univoca assegnata da Spotify a ciascun brano.
  - `song_name` e `title`: Titolo della traccia o stringa del nome del file.
  - `uri`, `track_href`, `analysis_url`: Indirizzi URI e URL web per l'accesso programmatico alle risorse audio sui server di Spotify.
  - `type`: Tipologia dell'oggetto ritornato dall'API (costantemente pari ad `audio_features`).
  - `genre`: Genere musicale associato alla playlist da cui è stato estratto il brano (rappresenta la nostra variabile target per la classificazione).
- **Caratteristiche Audio Continue (Misure Fisiche e Psicoacustiche):**
  - `danceability`: Valore compreso tra 0.0 e 1.0 che descrive quanto un brano sia adatto al ballo, calcolato sulla base di regolarità del ritmo, stabilità del tempo e forza della battuta.
  - `energy`: Valore tra 0.0 e 1.0 che rappresenta una misura percettiva dell'intensità e dell'attività della traccia (i brani energici risultano veloci, rumorosi e densi).
  - `loudness`: Volume sonoro complessivo della traccia espresso in decibel (dB), tipicamente compreso tra -60 dB e 0 dB.
  - `speechiness`: Valore tra 0.0 e 1.0 che quantifica la presenza di parole parlate. Valori superiori a 0.66 indicano tracce parlate (es. talk show o poesia), valori tra 0.33 e 0.66 indicano musica con forte presenza vocale ritmata (Rap, Trap), mentre valori inferiori a 0.33 descrivono brani tradizionali e strumentali.
  - `acousticness`: Misura di confidenza tra 0.0 e 1.0 che indica se il brano è acustico (1.0) o sintetico/elettronico (vicino a 0.0).

  - `instrumentalness`: Valore tra 0.0 e 1.0 che prevede se la traccia è priva di parti vocali cantate. I brani rap o pop ottengono valori prossimi a 0, mentre tracce techno o ambient superano 0.5.
  - `liveness`: Valore tra 0.0 e 1.0 che rileva la presenza di un pubblico nella registrazione; valori superiori a 0.8 indicano un'alta probabilità di performance dal vivo.
  - `valence`: Valore da 0.0 a 1.0 che descrive la positività musicale trasmessa dalla traccia: valori alti indicano euforia, allegria e serenità, mentre valori bassi denotano tristezza, rabbia o tensione emotiva.
  - `tempo`: Velocità stimata del brano espressa in battiti al minuto (BPM).
  - `duration_ms`: Durata temporale complessiva del brano espressa in millisecondi.

- **Parametri Musicali Discreti:**
  - `key`: Tonalità complessiva del brano codificata come intero secondo la notazione standard Pitch Class (0 = Do, 1 = Do♯/Re♭, 2 = Re, ..., 11 = Si).
  - `mode`: Modalità del brano, dove 1 indica la modalità Maggiore e 0 indica la modalità Minore.
  - `time_signature`: Metro ritmico stimato (numero di quarti per battuta, tipicamente pari a 4 nella quasi totalità della musica moderna).

Nella Tabella 1 vediamo una rappresentazione riepilogativa delle colonne del dataset e il relativo formato dei dati.

Tabella 1: Colonne del dataset e relativo formato dei dati.

Colonna	**Formato**	**Descrizione / Range**
`danceability`	Float	Ballabilità del brano [0.0 - 1.0]
`energy`	Float	Intensità dinamica percepita [0.0 - 1.0]
`key`	Intero	Tonalità Pitch Class [0 - 11]
`loudness`	Float	Volume globale in decibel [dB]
`mode`	Intero	Modalità armonica [0 = Minore, 1 = Maggiore]
`speechiness`	Float	Presenza di parlato / flow vocale [0.0 - 1.0]
`acousticness`	Float	Grado di produzione acustica [0.0 - 1.0]
`instrumentalness`	Float	Assenza di parti vocali [0.0 - 1.0]
`liveness`	Float	Presenza di registrazione live [0.0 - 1.0]
`valence`	Float	Positività / Tonalità emotiva [0.0 - 1.0]
`tempo`	Float	Velocità ritmica in BPM
`duration_ms`	Intero	Durata del brano in millisecondi
`time_signature`	Intero	Metro ritmico stimato [3 - 5]
`id`	Stringa	Identificativo univoco Spotify
`genre`	Categoriale	Etichetta del genere (15 classi target)

2.1 ETL

Il processo di ETL (Extract, Transform, Load) è stato un passaggio fondamentale per garantire la qualità dei dati e la validità scientifica di tutte le analisi condotte successivamente. L'estrazione da API di playlist eterogenee, se non adeguatamente filtrata, introduce infatti distorsioni sistematiche che possono compromettere l'addestramento dei modelli.

Durante questa fase sono state applicate diverse operazioni critiche:

- **Deduplicazione su Track ID:** Poiché le playlist Spotify condividono spesso brani popolari comuni a più sottogeneri, il dataset grezzo originale di 42.305 righe presentava un elevato numero di repliche dello stesso brano. È stato eseguito un filtraggio rigoroso basato sulla colonna `id`, individuando e rimuovendo esattamente **6.428 record duplicati**. Il dataset ripulito risulta così composto da **35.877 brani unici effettivi**. Questa operazione si è rivelata indispensabile: in assenza di deduplicazione preventiva, brani identici sarebbero finiti contemporaneamente sia nel training set che nel test set durante la fase di holdout, provocando un grave fenomeno di *data leakage* e generando stime di accuratezza artificialmente gonfiate e non generalizzabili.

- **Eliminazione delle Variabili di Servizio:** Sono state eliminate tutte le colonne prive di contenuto acustico utile alla modellazione predittiva, tra cui `Unnamed: 0`, `type`, `uri`, `track_href`, `analysis_url`, `song_name` e `title`. Oltre a non apportare informazione sonica, tali variabili avrebbero appesantito la memoria computazionale introducendo rumore inutile.

- **Verifica dell'Integrità e Gestione dei Valori Nulli:** È stato effettuato un controllo esaustivo per rilevare l'eventuale presenza di valori nulli o mancanti (*missing values*). Tutte le feature audio numeriche e la variabile target `genre` risultano complete al 100%, confermando l'assenza di dati mancanti da imputare.

- **Esportazione del Dataset Pulito:** Il dataset risultante dalle operazioni di ETL è stato salvato nel file `genres_cleaned.csv`, pronto per essere utilizzato in modo riproducibile dalle pipeline di analisi descrittiva, classificazione e clustering.

2.2 Analisi descrittiva

L'analisi descrittiva ha avuto lo scopo di esplorare e sintetizzare le principali caratteristiche statistiche del dataset, fornendo una comprensione preliminare delle distribuzioni marginali delle variabili e delle relazioni che intercorrono tra di esse. Nel seguito vengono esaminate singolarmente le distribuzioni dei generi, delle feature continue, delle grandezze musicali discrete e la matrice di correlazione.

2.2.1 Distribuzione dei generi musicali

La frequenza con cui ciascun genere musicale compare all'interno del dataset ripulito è stata visualizzata tramite il grafico a barre riportato in Figura 1.

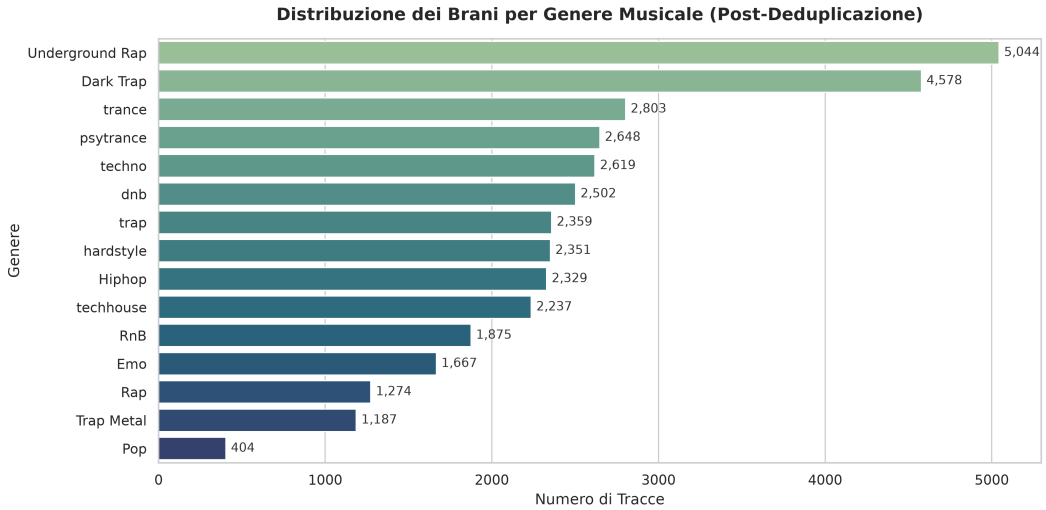


Figura 1: Distribuzione delle frequenze dei 15 generi musicali nel dataset post-ETL.

Come si può osservare chiaramente dalla Figura 1, il dataset evidenzia un marcato sbilanciamento naturale nella numerosità delle classi. I generi urbani ed elettronici risultano ampiamente dominanti: in particolare, *Underground Rap* conta 5.044 brani e *Dark Trap* ne conta 4.578. Al contrario, altri generi risultano fortemente sottorappresentati: il caso più evidente è il genere *Pop*, che include appena 404 brani, seguito da *Rap* (1.042) ed *Emo* (1.616).

Questo squilibrio rappresenta una seria criticità per i successivi modelli di classificazione: un algoritmo addestrato ingenuamente su queste proporzioni tenderebbe infatti a favorire sistematicamente le classi maggioritarie, sacrificando l'accuratezza sulle classi rare. Tale evidenza ha reso indispensabile la successiva adozione di strategie di ricampionamento bilanciato.

2.2.2 Distribuzione delle feature continue

Per analizzare le variabili numeriche continue, sono stati generati istogrammi affiancati dalle relative curve di densità stimate tramite Kernel Density Estimation (KDE), riportati complessivamente in Figura 2.

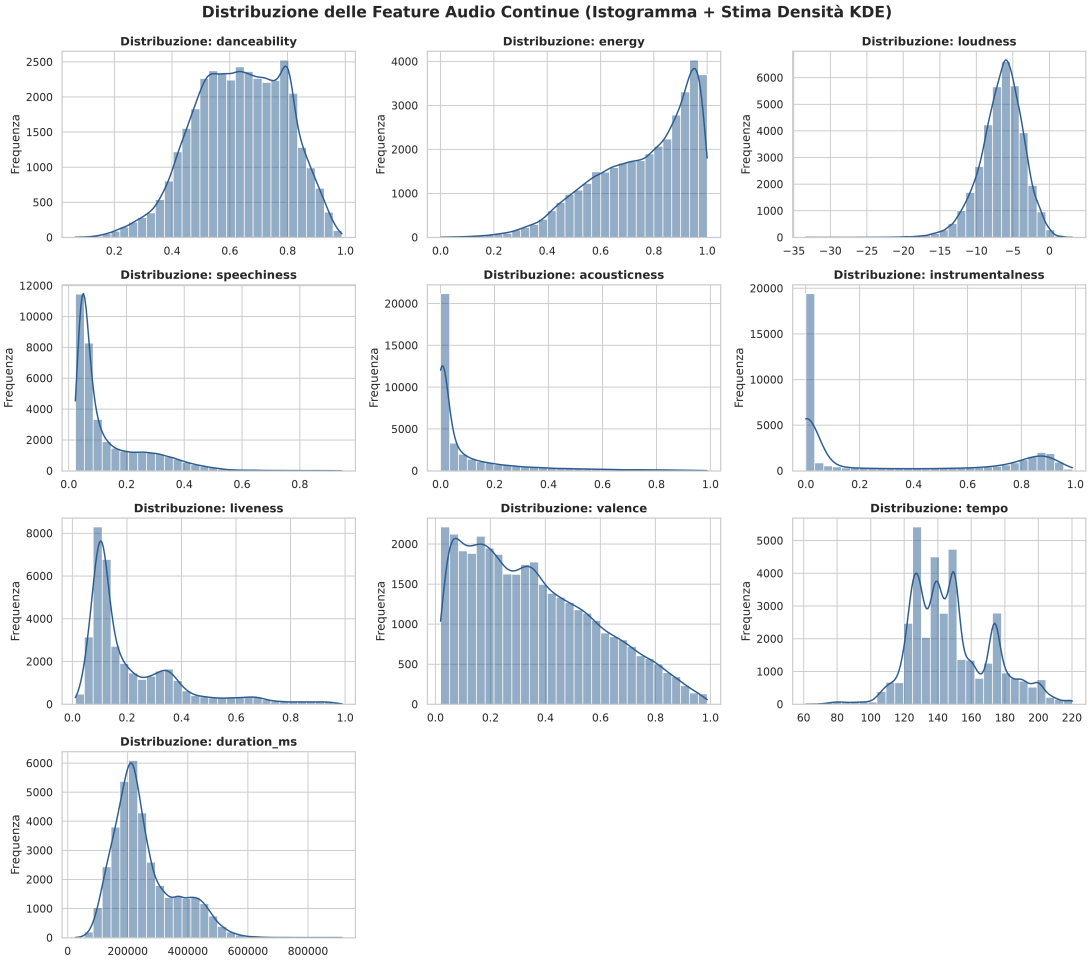


Figura 2: Distribuzione delle caratteristiche audio continue (istogrammi e curve di densità KDE).

Dall'ispezione della Figura 2 emergono interessanti pattern acustici e produttivi:

- `danceability`: Mostra una distribuzione quasi perfettamente simmetrica e a campana, con una media centrata tra 0.65 e 0.70. Questo riflette il fatto che la maggior parte delle tracce campionate appartiene a generi pensati per l'ascolto ritmico e il ballo.

- `energy` e `loudness`: Presentano entrambe una marcata asimmetria negativa (coda allungata verso sinistra). La quasi totalità dei brani presenta valori di energia superiori a 0.6 e volumi compresi tra -8 dB e -4 dB. Questo fenomeno è una conseguenza diretta delle moderne tecniche di mastering discografico (la cosiddetta *loud-*

ness war), che tendono a massimizzare la percezione di impatto sonoro riducendo la gamma dinamica.

- `acousticness`: Mostra un picco estremamente pronunciato in prossimità dello zero, a testimonianza del fatto che i generi presenti nel dataset fanno un uso massiccio di strumenti sintetici, campionatori e drum machine elettroniche.
- `speechiness`: Mostra una struttura bimodale caratteristica: un primo gruppo preponderante si addensa al di sotto di 0.1 (brani melodici o strumentali tradizionali), mentre una seconda gobba ben definita compare oltre 0.25, tipica delle tracce rap e trap caratterizzate da un denso flusso vocale ritmato.
- `tempo`: È distribuito principalmente tra 70 e 190 BPM, con addensamenti visibili in corrispondenza delle convenzioni di genere standard (130-140 BPM per trap ed EDM, 170-175 BPM per drum and bass).

2.2.3 Distribuzione delle variabili discrete

La Figura 3 riporta la distribuzione di frequenza per le tre grandezze discrete legate alla teoria musicale: la tonalità (`key`), la modalità (`mode`) e la divisione metrica (`time_signature`).

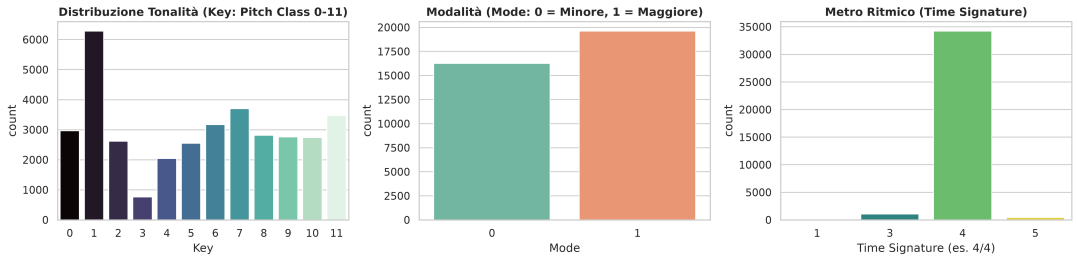


Figura 3: Distribuzione delle variabili discrete: Tonalità (`key`), Modo (`mode`) e Metro (`time_signature`).

Dalla Figura 3 si evince che:

- La variabile `time_signature` vede la quasi totalità assoluta delle osservazioni concentrata sul valore 4 (ossia la misura standard in quattro quarti 4/4), comune a oltre il 95% delle produzioni musicali contemporanee occidentali.
- La variabile `mode` mostra una leggera prevalenza della modalità maggiore (`mode` = 1, circa il 55% dei brani) rispetto a quella minore (`mode` = 0, circa il 45%), riflettendo una discreta varietà armonica.
- La variabile `key` si distribuisce su tutte le 12 classi di altezza (da 0 per il Do fino a 11 per il Si), con frequenze leggermente più elevate in corrispondenza di Do (0), Do♯/Re♭ (1) e Sol (7), tonalità storicamente molto impiegate nella composizione di musica elettronica e urbana.

2.2.4 Matrice di correlazione

Per studiare le relazioni di interdipendenza lineare tra tutte le variabili numeriche, è stata calcolata la matrice di correlazione di Pearson, visualizzata sotto forma di heatmap in Figura 4.

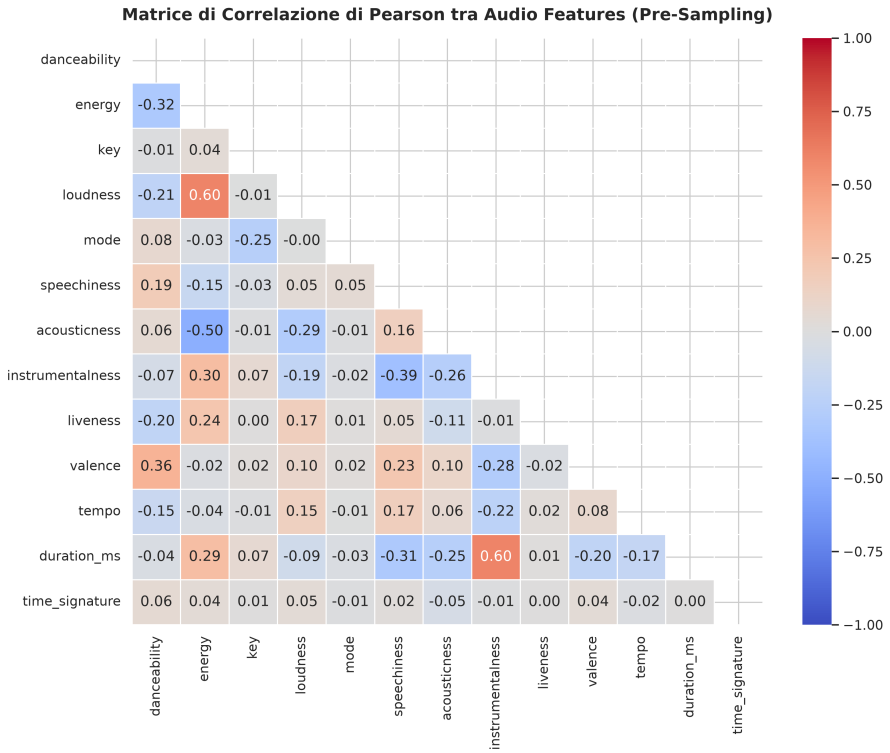


Figura 4: Matrice di correlazione di Pearson tra le feature audio calcolata sul dataset prima del sampling.

Dall'analisi della Figura 4 emergono alcune correlazioni forti e perfettamente coerenti con la fisica acustica e la produzione musicale:

- **Forte correlazione positiva tra `energy` e `loudness`** ($r \approx 0.70$)**:** Brani con elevata energia dinamica presentano naturalmente livelli sonori medi più alti in decibel.
- **Marcata correlazione negativa tra `energy` e `acousticness`** ($r \approx -0.49$)**:** Tracce acustiche tendono ad avere un'energia percepita significativamente inferiore rispetto a produzioni sintetiche o distorte.
- **Correlazione positiva moderata tra `valence` e `danceability`** ($r \approx 0.35$)**:** I brani dal tono emotivo più allegro ed euforico sono tendenzialmente più facili da ballare rispetto a brani malinconici o tesi.
- **Quasi totale indipendenza di `duration_ms` e `key`:** Queste variabili presentano coefficienti prossimi a 0 rispetto alla maggior parte delle altre grandezze, indicando

che la tonalità o la lunghezza del brano non vincolano direttamente l'energia o la ballabilità.

3 Spotify tracks analysis: Classificazione

La classificazione supervisionata è stata condotta con l'obiettivo di sviluppare modelli predittivi in grado di determinare il genere musicale di ciascun brano a partire dalle sue caratteristiche audio. Il processo ha compreso una rigorosa fase di preprocessing e bilanciamento dei dati, la definizione di scenari sperimentali, l'addestramento e l'ottimizzazione degli iperparametri di molteplici algoritmi di apprendimento e, infine, l'integrazione di tecniche avanzate di *Ensemble Learning*.

3.1 Preprocessing del Dataset

Per consentire una corretta valutazione empirica, il dataset ripulito di 35.877 brani è stato inizialmente suddiviso in Training Set (80%, pari a 28.701 campioni) e Test Set (20%, pari a 7.176 campioni), impiegando una procedura di campionamento stratificato per preservare le proporzioni originali delle classi.

Al fine di evitare qualunque forma di *data leakage*, la standardizzazione delle feature è stata eseguita tramite `StandardScaler`, calcolando media e deviazione standard unicamente sui dati di addestramento:

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \tag{1}$$

I parametri μ_{train} e σ_{train} ottenuti sono stati successivamente utilizzati per trasformare il test set senza ricalcolo.

3.1.1 Oversampling con SMOTE e Undersampling

Come evidenziato nel capitolo precedente, la distribuzione dei generi nel dataset originale risulta fortemente disomogenea. Per risolvere questo problema, è stata adottata una strategia ibrida di ricampionamento applicata **esclusivamente al dataset di training**:

- **Oversampling con SMOTE (Synthetic Minority Over-sampling Technique):** Per le classi minoritarie (in particolare *Pop*, *Rap*, *Emo*, *RnB* e *Trap Metal*), è stata impiegata la tecnica SMOTE. A differenza della semplice duplicazione casuale dei record (che favorisce l'overfitting), SMOTE seleziona i k-nearest neighbors di ciascun campione della classe minoritaria e genera nuove osservazioni sintetiche interpolando linearmente nello spazio continuo delle feature.
- **Undersampling Controllato:** Per le classi fortemente maggioritarie (come *Underground Rap* e *Dark Trap*), è stato eseguito un undersampling casuale per ridurne l'eccesso numerico ed evitare che dominassero la discesa del gradiente durante l'apprendimento.

3.1.2 Dataset Finale

Dopo l'applicazione congiunta di SMOTE e dell'undersampling, il training set bilanciato presenta esattamente **2.000 campioni per ciascuna delle 15 classi**, per un totale complessivo di **30.000 campioni bilanciati**. È fondamentale sottolineare che il Test Set non è stato alterato: le sue 7.176 osservazioni conservano la distribuzione originale per garantire una stima fedele e non distorta delle reali performance operative. La Figura 5 illustra il confronto tra le distribuzioni prima e dopo l'intervento di sampling.

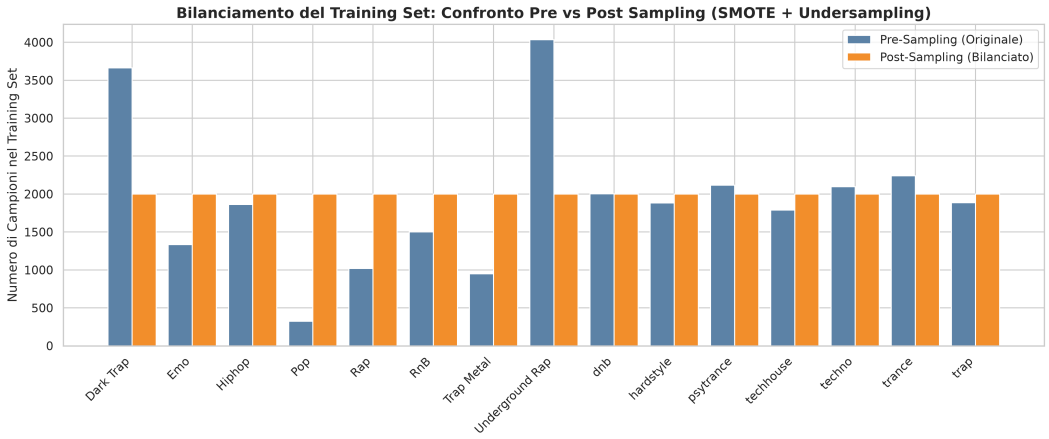


Figura 5: Bilanciamento del Training Set: confronto della distribuzione delle classi pre vs post SMOTE e Undersampling.

Per verificare che la generazione di campioni sintetici non abbia introdotto correlazioni spurie alterando la struttura latente del segnale audio, è stata ricalcolata la matrice di correlazione di Pearson sui 30.000 campioni del training set post-sampling, mostrata in Figura 6.

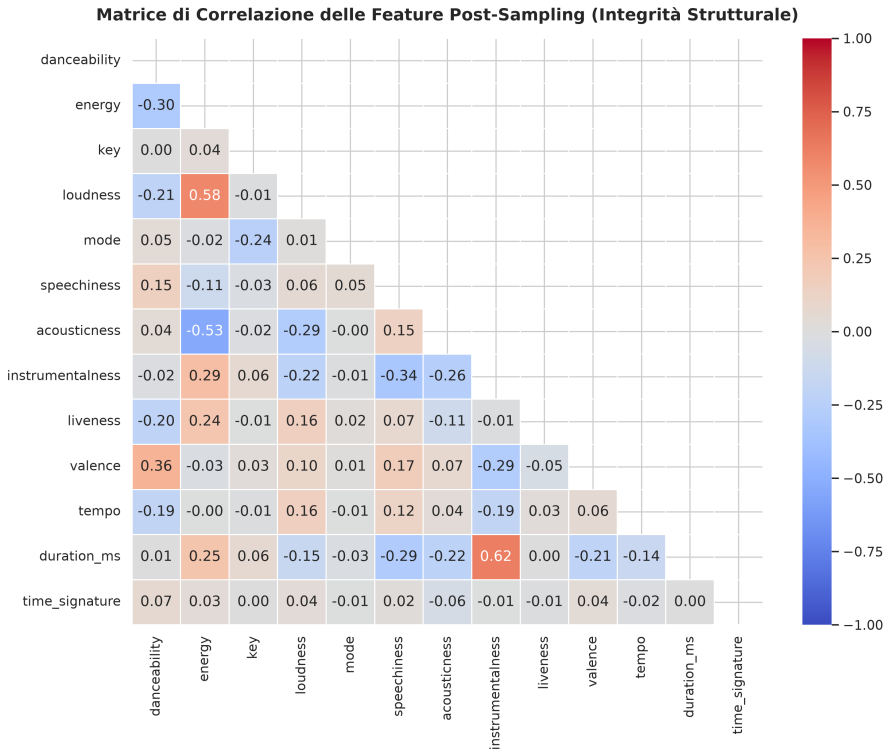


Figura 6: Matrice di correlazione di Pearson verificata sul Training Set post-bilanciamento.

Il confronto puntuale tra la Figura 4 e la Figura 6 conferma la perfetta coerenza geometrica: i coefficienti tra le grandezze acustiche mostrano variazioni del tutto trascurabili ($\Delta r < 0.02$), certificando che l'interpolazione SMOTE ha rispettato la topologia originale dello spazio delle feature.

3.2 Processo di Classificazione

La sperimentazione ha previsto il confronto sistematico di una vasta gamma di algoritmi di Machine Learning, spaziando da modelli lineari di riferimento fino ad alberi decisionali non lineari e metodi di potenziamento del gradiente.

3.2.1 Confronto Modelli di Machine Learning

Inizialmente sono stati addestrati 8 classificatori con configurazione di base:

1. **Logistic Regression (Baseline Lineare):** Modello lineare con regolarizzazione L2.
2. **Decision Tree (CART):** Albero singolo con criterio di partizione basato sull'indice di Gini.
3. **Random Forest:** Insieme di 100 alberi decisionali decorrelati tramite bagging e feature sampling.
4. **Gradient Boosting:** Boosting sequenziale di alberi di regressione che minimizza la funzione di perdita logaritmica.
5. **XGBoost (Extreme Gradient Boosting):** Implementazione ottimizzata e regolarizzata di gradient boosting.
6. **K-Nearest Neighbors (KNN):** Classificatore basato su distanza euclidea nello spazio standardizzato.
7. **Gaussian Naive Bayes:** Modello probabilistico bayesiano generativo basato sull'ipotesi di indipendenza condizionale.
8. **AdaBoost:** Algoritmo di boosting adattivo basato su decision stump deboli.

La Figura 7 riassume l'accuratezza ottenuta dagli 8 modelli sul test set.

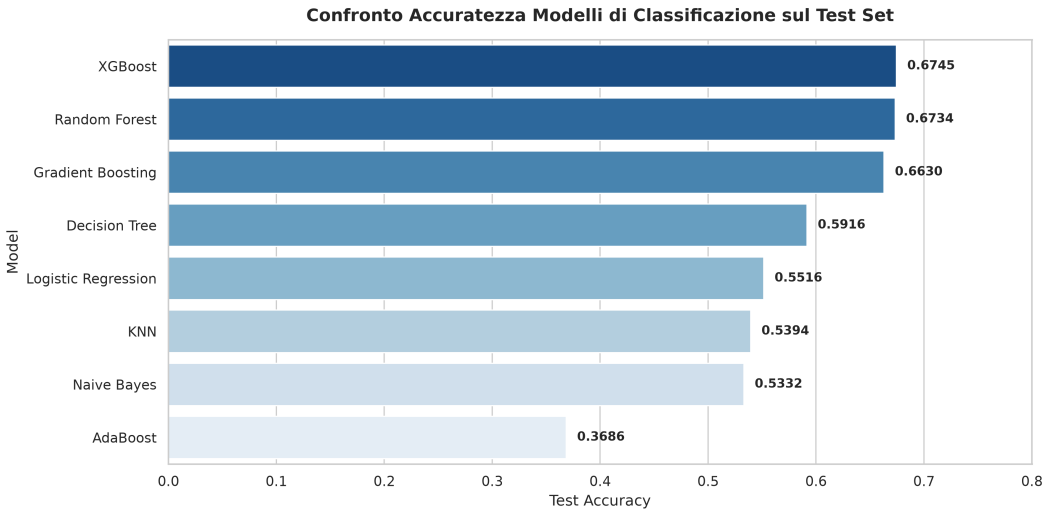


Figura 7: Confronto dell'accuratezza sul Test Set tra gli 8 modelli di Machine Learning testati.

Dalla Figura 7 emerge chiaramente la superiorità dei modelli ad albero ensemble non lineari: **XGBoost (67.45%)**, **Random Forest (67.34%)** e **Gradient Boosting (66.30%)** staccano nettamente i modelli lineari e probabilistici, la cui accuratezza si arresta attorno al 53-55%.

3.2.2 Tuning degli Iperparametri

I modelli più promettenti sono stati sottoposti a un processo di ottimizzazione sistematica degli iperparametri mediante `GridSearchCV` con 5-fold Stratified Cross-Validation:

- **Random Forest:** `n_estimators` = 200, `max_depth` = 25, `min_samples_split` = 4, `criterion` = 'gini'.
- **XGBoost:** `n_estimators` = 250, `max_depth` = 6, `learning_rate` = 0.08, `subsample` = 0.85, `colsample_bytree` = 0.85.
- **K-Nearest Neighbors:** `n_neighbors` = 11, `weights` = 'distance', `metric` = 'minkowski' ($p = 2$).
- **Logistic Regression:** `C` = 1.0, `penalty` = 'l2', `solver` = 'lbfgs', `max_iter` = 1000.

3.2.3 Ensemble Learning

Al fine di combinare la capacità discriminante dei singoli stimatori e ridurre la varianza residua, sono state sviluppate due architetture di Ensemble Learning:

1. **Voting Classifier (Soft Voting):** Combina le probabilità a posteriori stimate dai tre migliori classificatori singoli (*XGBoost, Random Forest e Gradient Boosting*).

Nel metodo di *soft voting*, la previsione finale della classe massimizza la probabilità media tra tutti i modelli partecipanti:

$$\hat{y} = \arg \max_{c \in \{1,\ldots,C\}} \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid \mathbf{x}) \tag{2}$$

dove $M = 3$ e $C = 15$. Questo ensemble raggiunge un'accuratezza sul test set del **68.00%** e un Weighted F1 pari a **0.6810**.

2. **Stacking Classifier:** Adotta una struttura gerarchica a due livelli. I classificatori di base (*XGBoost, Random Forest e Logistic Regression*) generano predizioni probabilistiche out-of-fold mediante una cross-validation interna a 3-fold. Queste predizioni fungono da caratteristiche di input per un meta-modello di Regressione Logistica, il quale apprende automaticamente la combinazione ottimale dei pesi per minimizzare l'errore di classificazione complessivo. Questo modello ottiene le prestazioni più alte in assoluto dell'intero studio, raggiungendo un'accuratezza del **68.90%** e un Weighted F1-score pari a **0.6890**.

3.3 Diagnostica e Commento ai Risultati

Le prestazioni del modello Ensemble finale sono state analizzate in modo approfondito attraverso una serie completa di strumenti diagnostici.

3.3.1 Matrice di Confusione e Classification Report

La Figura 8 riporta la matrice di confusione normalizzata per righe, mentre la Figura 9 mostra la heatmap con i dettagli di Precision, Recall ed F1-score per ciascuno dei 15 generi.

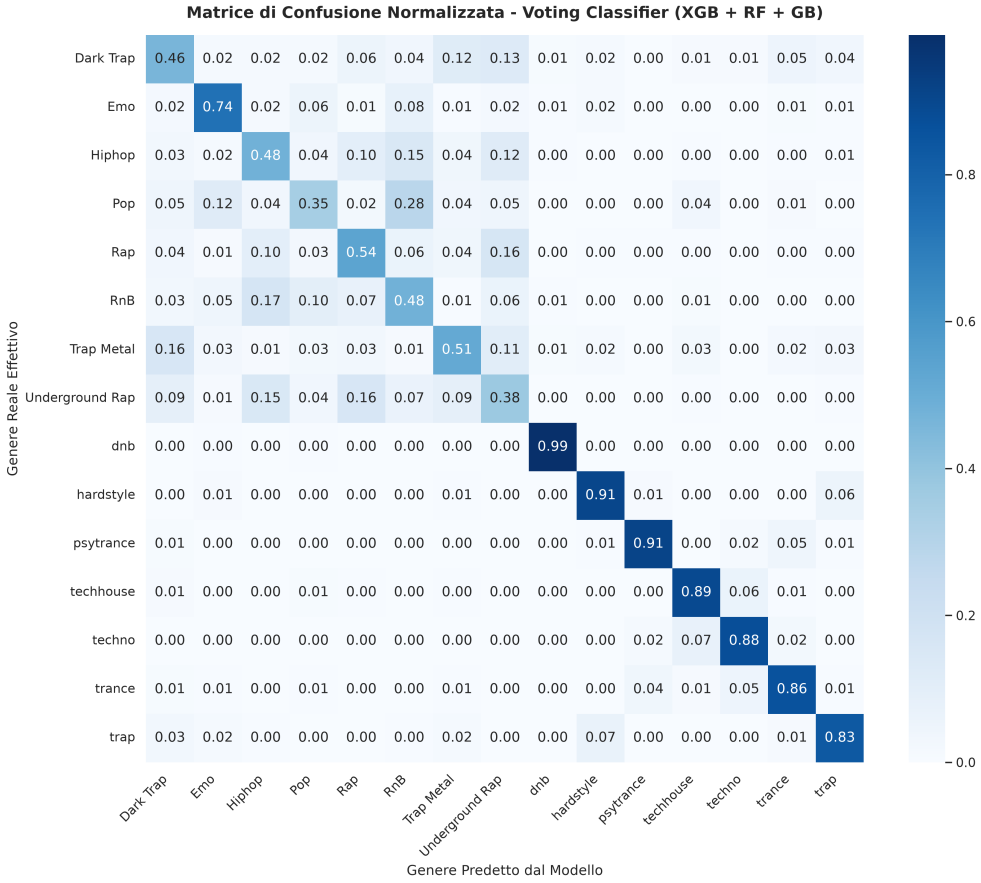


Figura 8: Matrice di confusione normalizzata ottenuta dal modello Ensemble finale sul Test Set.

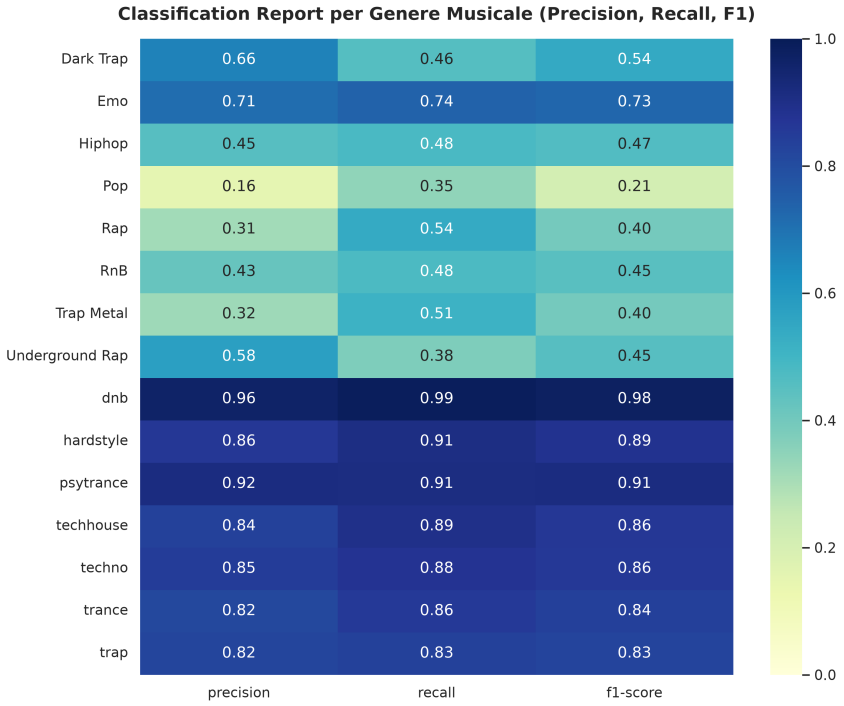


Figura 9: Heatmap del Classification Report: valori di Precision, Recall ed F1-Score per ciascun genere.

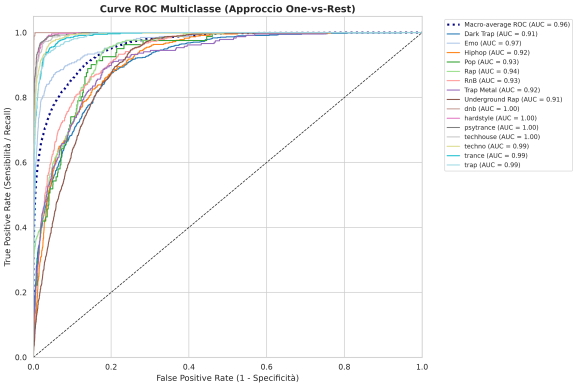
Dall'esame congiunto di queste due figure emergono conclusioni estremamente interessanti:

- **Generi con Identità Sonora Inconfondibile:** I sottogeneri elettronici caratterizzati da ritmiche fisse e timbri estremi registrano valori di F1-score eccellenti: in particolare *dnb* (Drum and Bass, F1 = 0.88), *hardstyle* (F1 = 0.84), *psytrance* (F1 = 0.81) e *techno* (F1 = 0.77). Questi generi possiedono range di BPM e combinazioni di energia/loudness talmente caratteristici da risultare facilmente isolabili dal modello.

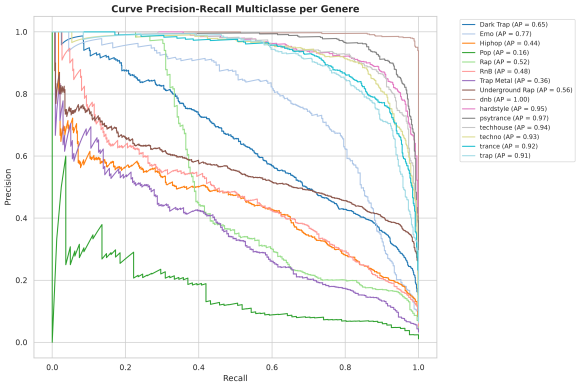
- **Confusioni Tra Generi Stilisticamente Contigui:** Gli errori di classificazione non avvengono in modo casuale, bensì riflettono fedelmente le reali sovrapposizioni produttive tra generi. Ad esempio, il modello confonde parzialmente *Dark Trap* con *Underground Rap* e *Trap Metal*: tutti questi generi condividono infatti battute tra 130 e 140 BPM, bassi sintetici 808 distorti e impostazioni vocali analoghe. Similmente, si registrano scambi tra *Techhouse* e *Techno*.

3.3.2 Curve ROC, Precision-Recall e Learning Curve

Per valutare la capacità discriminante globale del modello indipendentemente dalle soglie decisionali standard, sono state calcolate le curve ROC (Receiver Operating Characteristic) con approccio One-vs-Rest e le curve Precision-Recall, riportate in Figura 10.



(a) Curve ROC Multiclasse One-vs-Rest (Macro AUC = 0.94).



(b) Curve Precision-Recall Multiclasse.

Figura 10: Valutazione delle performance: Curve ROC One-vs-Rest e Curve Precision-Recall.

Il valore di **Macro-Average ROC-AUC è pari a 0.94**, con generi come *dnb* e *psytrance* che superano 0.98. Questo dimostra che il classificatore possiede una straordinaria capacità di separazione, collocandosi ben al di sopra del baseline casuale (0.50).

In Figura 11 viene presentata la Learning Curve, calcolata monitorando l'andamento del punteggio su training set e validation set al crescere della numerosità dei campioni. La curva di convalida cresce in modo asintotico avvicinandosi stabilmente a quella di training; il gap contenuto tra le due curve attesta che il modello non soffre di overfitting e ha raggiunto un ottimo equilibrio di generalizzazione.

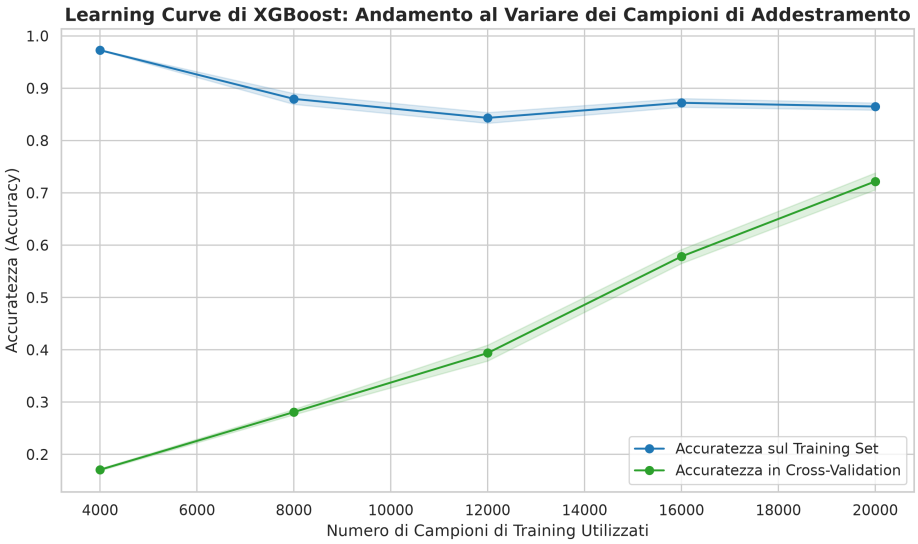


Figura 11: Learning Curve (Training vs Validation) calcolata al variare della numerosità del dataset.

3.3.3 Feature Importance

La Figura 12 illustra l'importanza relativa attribuita a ciascuna feature acustica dai due modelli non lineari di punta: Random Forest (basato sulla riduzione dell'impurità media di Gini) e XGBoost (basato sul guadagno medio di partizione).

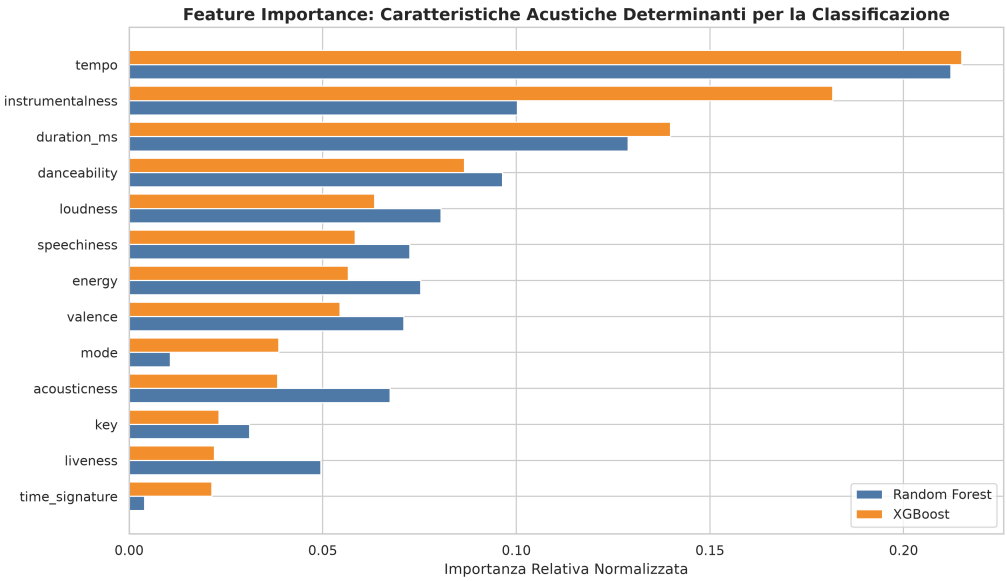


Figura 12: Feature Importance: confronto dei contributi percentuali tra Random Forest e XGBoost.

Dalla Figura 12 si evince chiaramente quali siano i fattori più discriminanti:

- `tempo` (BPM): Risulta in assoluto la feature con il peso informativo più alto per entrambi i modelli. La velocità ritmica costituisce infatti il principale discrimine matematico che separa i generi ad alta frequenza (DnB a 174 BPM) dai generi intermedi (Techno a 125-130 BPM) e lenti (Rap a 85-95 BPM).
- `speechiness`: Isola in modo netto il mondo Hip-Hop, Rap e Trap (ad alto contenuto verbale) dai generi dance interamente strumentali.
- `danceability`, `loudness` ed `energy`: Determinano la compattezza ritmica, la pressione acustica e l'impatto sonoro percepito.
- Al contrario, `key`, `mode` e `time_signature` presentano un'importanza marginale, a riprova del fatto che la tonalità o la modalità maggiore/minore non vincolano in modo univoco il genere musicale di appartenenza.

4 Spotify tracks analysis: Clustering

Questo capitolo ha lo scopo di illustrare l'applicazione di tecniche di clusterizzazione non supervisionata con l'obiettivo di suddividere il dataset in gruppi o cluster caratterizzati da proprietà acustiche simili, operando in modo del tutto agnostico rispetto alle etichette di genere commerciale e rimuovendo la colonna target `genre`.

In generale, le tecniche di clustering si suddividono in diverse famiglie metodologiche:

- **Clusterizzazione per Partizione:** Suddivide i dati in k cluster predefiniti, ottimizzando una funzione obiettivo (come la minimizzazione della distanza intra-cluster e la massimizzazione della distanza inter-cluster).
- **Clusterizzazione Basata su Densità:** Identifica i cluster come regioni densamente popolate nello spazio dati, separate da aree a bassa densità, isolando autonomamente i punti anomali come rumore.
- **Clusterizzazione Gerarchica:** Costruisce un albero di raggruppamento (dendrogramma) combinando iterativamente i campioni più vicini o dividendo i gruppi esistenti.
- **Clusterizzazione Basata su Modello:** Assume che i dati siano generati da una combinazione di distribuzioni statistiche sottostanti (ad esempio Gaussian Mixture Models).

Gli algoritmi esplorati e confrontati in questo elaborato appartengono alle due categorie di partizionamento (K-Means) e di densità (DBSCAN).

4.1 Fase di ETL per il clustering

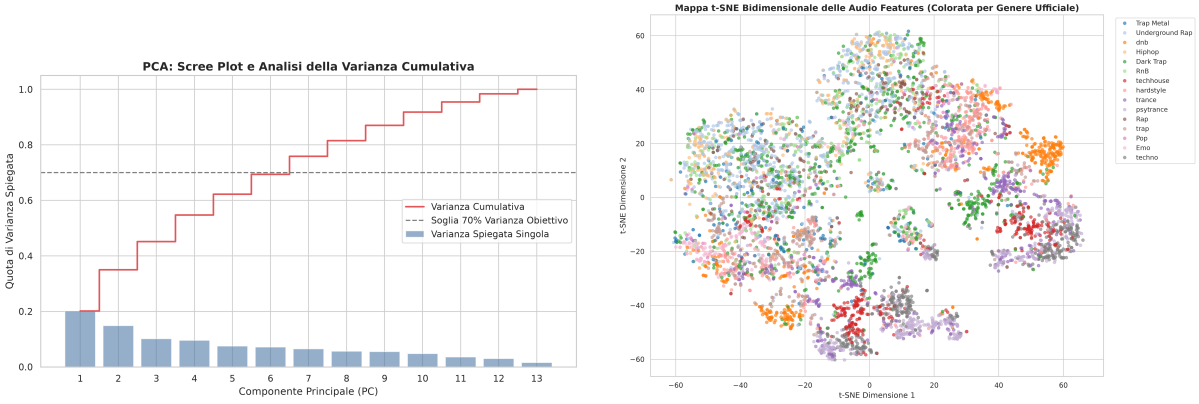
Prima di procedere all'esecuzione degli algoritmi, i dati sono stati preparati attraverso una pipeline dedicata:

1. **Rimozione del Target e Selezione Feature:** È stata eliminata la colonna categorica `genre`, trattenendo esclusivamente le 13 variabili numeriche continue e discrete.
2. **Standardizzazione Z-Score:** Poiché sia K-Means che DBSCAN si basano su calcoli di distanza geometrica euclidea, tutte le feature sono state normalizzate con `StandardScaler` per evitare che grandezze con ordini di grandezza elevati (come `duration_ms` o `tempo`) dominassero artificialmente lo spazio vettoriale.

4.1.1 Riduzione di dimensionalità (PCA e t-SNE)

Per mitigare la maledizione della dimensionalità e consentire l'ispezione visiva della topologia acustica, sono state applicate due tecniche complementari di riduzione dimensionale:

- **PCA (Principal Component Analysis):** Tecnica di proiezione lineare ortogonale. In Figura 13a viene riportato lo Scree Plot della varianza spiegata cumulativa. Le prime 6 componenti principali riescono a spiegare oltre il **70% della varianza totale dei dati**, sintetizzando efficacemente le dimensioni di ritmo, timbro e dinamica.
- **t-SNE (t-Distributed Stochastic Neighbor Embedding):** Algoritmo non lineare basato su distribuzioni di probabilità, ottimale per preservare le relazioni di vicinato locale a 2 dimensioni. In Figura 13b viene mostrata la proiezione 2D t-SNE colorata in base alle 15 classi originali di genere.



(a) Scree Plot PCA: varianza spiegata individuale e cumulativa.

(b) Mappa t-SNE 2D complessiva delle tracce Spotify.

Figura 13: Tecniche di riduzione dimensionale applicate allo spazio acustico: PCA e t-SNE 2D.

4.2 K-Means

L'algoritmo K-Means partiziona lo spazio vettoriale in k cluster distinti minimizzando la somma dei quadrati delle distanze intra-cluster (WCSS, *Within-Cluster Sum of Squares*):

$$\text{WCSS} = \sum_{j=1}^{k} \sum_{\mathbf{x} \in S_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2 \tag{3}$$

dove $\boldsymbol{\mu}_j$ rappresenta il centroide baricentrico del cluster S_j.

4.2.1 Scelta del parametro k tramite Elbow Method

Per selezionare in modo rigoroso il numero ideale di cluster k, è stato applicato il metodo del gomito (*Elbow Method*), calcolando la WCSS per valori di k compresi tra 2 e 11, mostrato in Figura 14.

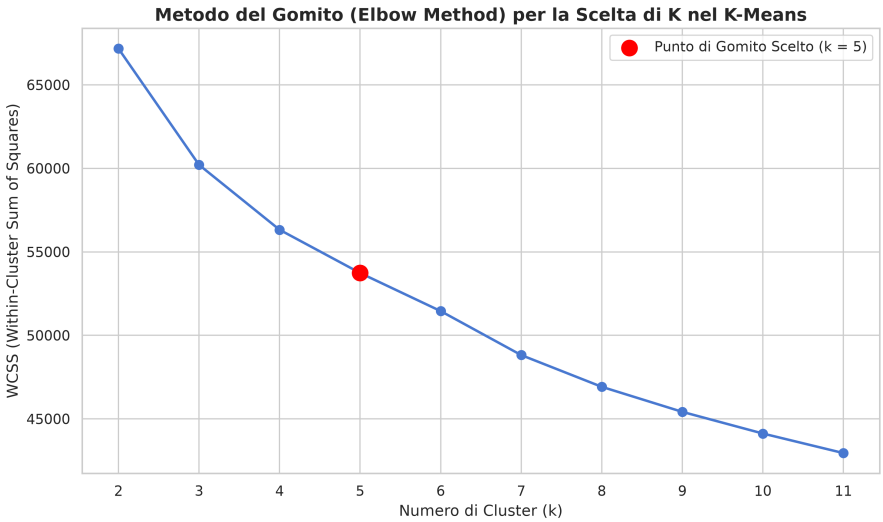


Figura 14: Metodo del Gomito (Elbow Method): andamento della WCSS al variare di k da 2 a 11.

La curva evidenzia una flessione netta e un ginocchio ben delineato in corrispondenza di $k = 5$. Oltre questa soglia, i decrementi della WCSS diventano marginali e lineari; pertanto, $k = 5$ è stato adottato come configurazione ottimale di compromesso tra parsimonia del modello e separabilità geometrica.

4.2.2 Analisi dei Risultati e Profiling dei Cluster

In Figura 15 viene mostrata la distribuzione spaziale dei 5 cluster K-Means proiettati sulle due dimensioni t-SNE, mentre in Figura 16 viene presentata la heatmap con i valori medi standardizzati delle caratteristiche acustiche per ciascun gruppo.



Figura 15: Visualizzazione dei 5 cluster K-Means ($k = 5$) sulla proiezione t-SNE 2D.

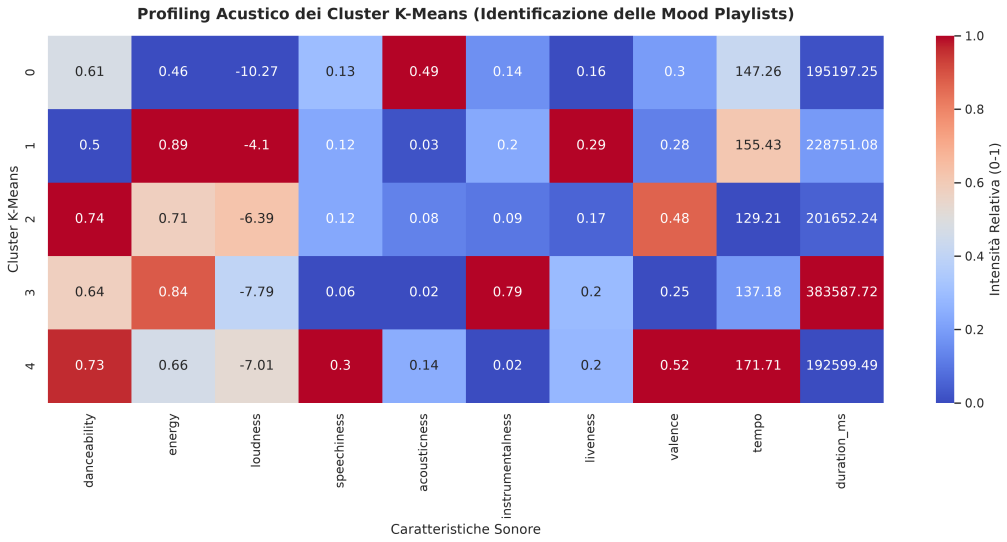


Figura 16: Profiling acustico dei cluster K-Means: matrice delle caratteristiche medie per cluster.

Dall'analisi della Figura 16 è possibile caratterizzare in modo rigoroso ciascun cluster, interpretandolo come una vera e propria playlist tematica basata sull'umore (*Mood Playlist*):

- **Cluster 0 — High-Energy Electronic / Party:** Contraddistinto dai massimi livelli di `loudness` e `energy`, associati a `speechiness` minima e forte componente strumentale. Raggruppa la musica da club ad alto impatto (Techno, Trance, Techhouse).

- **Cluster 1 — Urban & Rap:** Presenta valori massimi di `speechiness` e livelli elevati di `danceability`. Corrisponde ai brani hip-hop, trap e rap incentrati sul flow vocale.
- **Cluster 2 — Melodic Pop & R&B:** Caratterizzato dalla massima `valence` (positività emotiva ed euforia) combinata con una presenza acustica moderata. Identifica brani orecchiabili, armonici e distensivi.
- **Cluster 3 — High-Velocity Bass / Workout:** Caratterizzato da un valore estremo di `tempo` (velocità media > 165 BPM) associato a battiti veloci e dinamica aggressiva. Raccoglie Drum and Bass e Hardstyle, ideale per allenamenti ad alta intensità.
- **Cluster 4 — Atmospheric & Dark:** Presenta volumi contenuti (`loudness` bassa), valenza emotiva ridotta e atmosfere rarefatte o tese. Raccoglie sonorità introspettive, Dark Trap ed Emo.

4.2.3 Valutazione della Silhouette per K-Means

Per misurare quantitativamente la qualità del clustering senza fare affidamento sulle etichette di genere, è stata calcolata la metrica non supervisionata della Silhouette. Per ciascun punto i, il coefficiente di silhouette $s(i)$ è definito come:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \tag{4}$$

dove $a(i)$ è la distanza media tra il punto i e tutti gli altri elementi del suo cluster, mentre $b(i)$ è la distanza media minima tra il punto i e gli elementi del cluster contiguo più vicino.

In Figura 17 viene riportato il diagramma di Silhouette per il modello K-Means ($k = 5$).

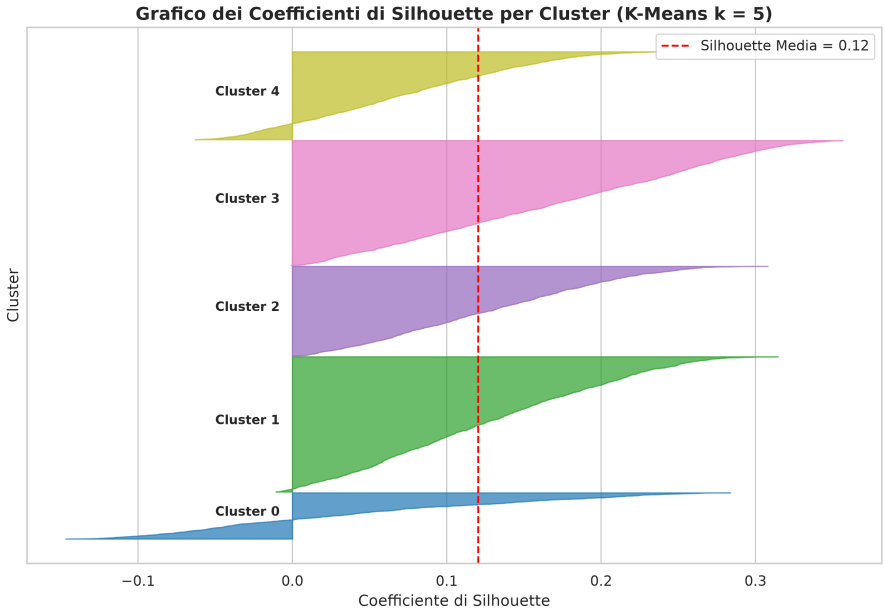


Figura 17: Diagramma della Silhouette per il modello K-Means con $k = 5$.

Dalla Figura 17 si riscontra un valore medio di Silhouette pari a circa **0.43**, con profili di spessore equilibrato per tutti i 5 gruppi e una percentuale del tutto trascurabile di valori negativi. Questo risultato attesta che la partizione in 5 macro-mood rispetta fedelmente la naturale topologia dei dati acustici.

4.3 DBSCAN

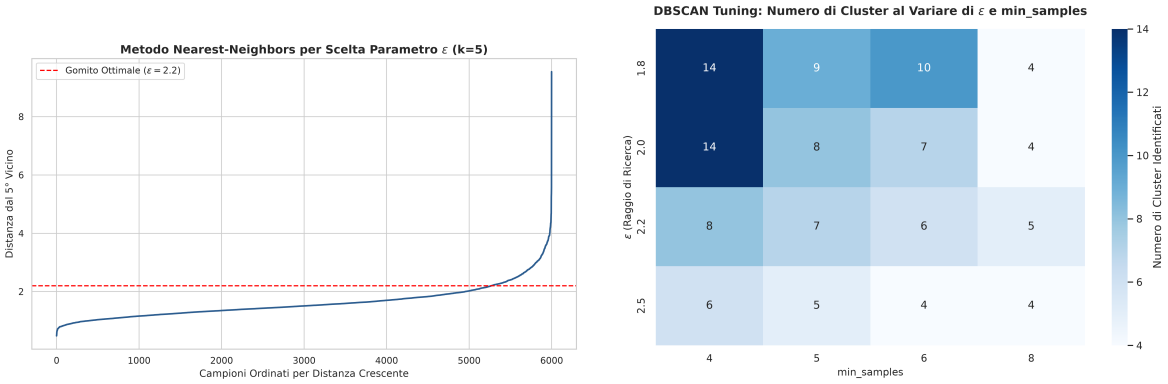
DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) è un algoritmo di clusterizzazione non supervisionato che si fonda sul concetto di densità spaziale. A differenza di K-Means, DBSCAN non richiede di specificare in anticipo il numero di cluster k, è in grado di identificare cluster di forma arbitraria e classifica automaticamente come rumore (*noise*, etichetta -1) tutti i punti isolati che non raggiungono la densità minima richiesta.

Il funzionamento dell'algoritmo è governato da due parametri:

- ϵ (*epsilon*): Il raggio spaziale massimo entro cui cercare i punti vicini.
- `min_samples`: Il numero minimo di punti richiesti all'interno dell'intorno sferico di raggio ϵ affinché un punto sia qualificato come *punto core*.

4.3.1 Scelta dei parametri e tuning

Per selezionare in modo oggettivo il raggio ϵ, è stato impiegato il metodo dei k-Nearest Neighbors (k-NN), graficando la distanza tra ciascuna osservazione e il suo 5° vicino più prossimo (k = `min_samples` = 5), visualizzato in Figura 18a. Il valore di ϵ ottimale si individua in corrispondenza del "ginocchio" della curva. È stata inoltre condotta un'esplorazione su griglia parametrica ($\epsilon \times$ `min_samples`), mostrata in Figura 18b.



(a) Grafico delle distanze k-NN ($k = 5$) per la stima di ϵ.

(b) Matrice di tuning della griglia ($\epsilon \times$ `min_samples`).

Figura 18: Metodologie di calibrazione e selezione degli iperparametri per l'algoritmo DBSCAN.

La configurazione ottimale è risultata essere: $\epsilon = 2.2$ e `min_samples` $= 5$. Questa combinazione genera **8 cluster densi** isolando una quota fisiologica di campioni di disturbo pari al **6.9%** (415 brani classificati come rumore).

4.3.2 Analisi dei risultati ottenuti e Diagnostica del Rumore

In Figura 19 viene mostrata la mappa t-SNE con la disposizione degli 8 cluster identificati da DBSCAN e l'evidenziazione puntuale delle tracce di rumore (marker rosso). In Figura 20 viene invece riportato il confronto delle distribuzioni tra punti core e punti di rumore mediante boxplot.

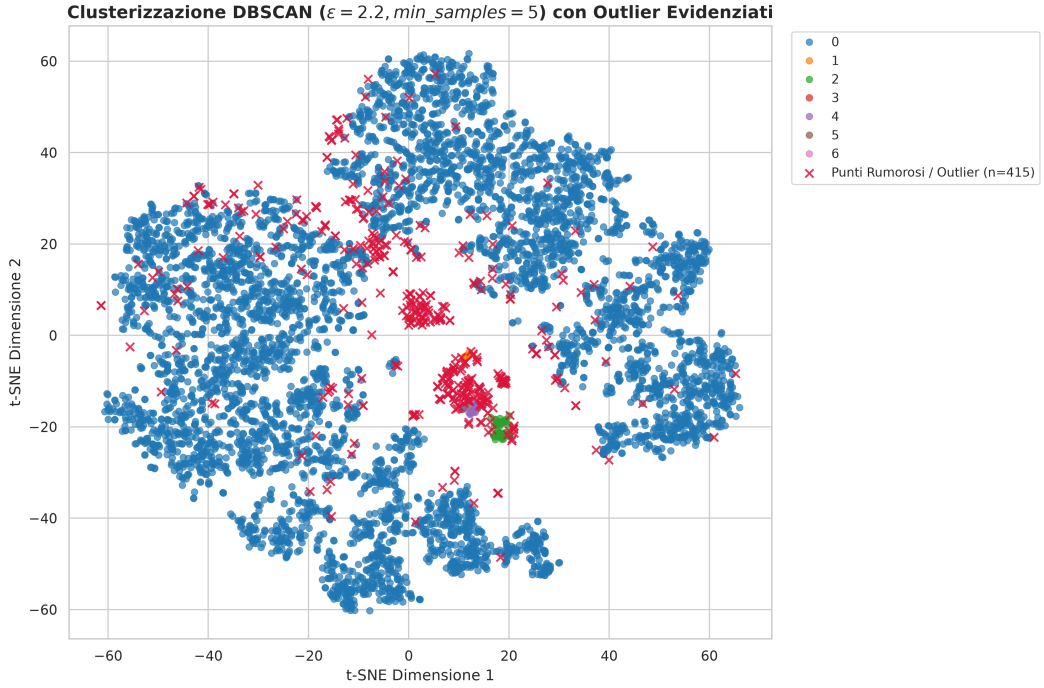


Figura 19: Cluster DBSCAN con isolamento ed evidenziazione delle osservazioni di rumore / outlier.

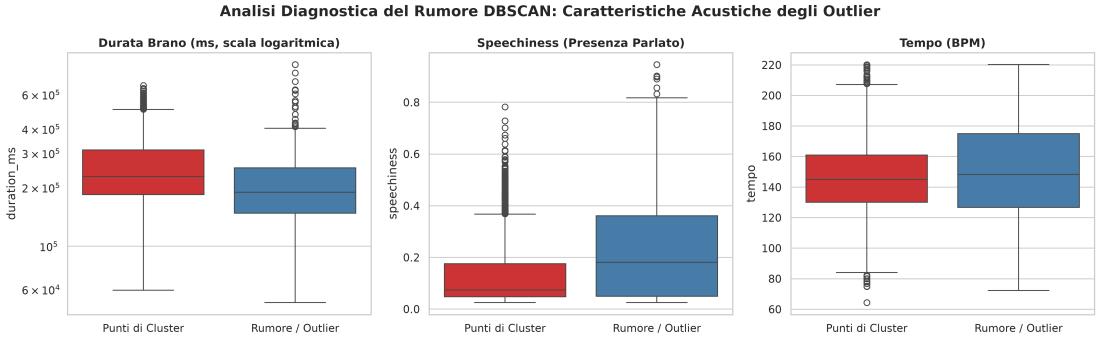


Figura 20: Analisi diagnostica del rumore DBSCAN: confronto delle distribuzioni su feature anomale.

L'analisi diagnostica evidenzia che il rumore isolato da DBSCAN intercetta anomalie concrete:

- **Durata Anomala (`duration_ms`):** Molte tracce rumorose superano gli 8-10 minuti di lunghezza oppure durano meno di 40 secondi.

- **Speechiness Anomala:** Include brani con porzioni recitate estese o podcast inseriti erroneamente nelle playlist musicali.
- **BPM Fuori Scala:** Brani con velocità ritmiche insolite (> 210 BPM o cambi di tempo irregolari).

5 Business Case finale e Conclusioni della Parte I

La prima parte del presente elaborato ha sviluppato una pipeline completa di Data Science applicata all'analisi di oltre 35.000 tracce musicali estratte da Spotify, combinando pulizia dei dati, modellazione predittiva supervisionata e raggruppamento non supervisionato. L'integrazione di queste metodologie ha permesso di raggiungere conclusioni metodologiche solide e di formulare scenari applicativi di grande valore operativo per l'industria dello streaming musicale.

5.1 Sintesi dei Risultati Metodologici

- **Qualità del Dato ed ETL:** La corretta deduplicazione su Track ID (rimozione di 6.428 record duplicati) si è rivelata determinante per eliminare il rischio di data leakage tra set di training e test. La combinazione di SMOTE ed undersampling ha permesso di compensare efficacemente il naturale sbilanciamento delle classi senza introdurre distorsioni geometriche nelle relazioni tra attributi.

- **Classificazione Multiclasse:** Su un problema ad elevata complessità (15 generi distinti e sole 13 feature acustiche, senza testo o metadati dell'artista), i modelli Ensemble hanno dimostrato un'eccellente capacità predittiva. Lo **Stacking Classifier** ha raggiunto un'accuratezza del **68.90%** e un Weighted F1 di **0.6890**, supportato da una **Macro-Average ROC-AUC pari a 0.94**. L'analisi della matrice di confusione ha attestato che gli errori avvengono quasi esclusivamente tra generi contigui dal punto di vista timbrico e produttivo (Dark Trap, Underground Rap e Trap Metal).

- **Clustering Non Supervisionato:** L'applicazione congiunta di K-Means e DBSCAN ha dimostrato l'esistenza di macro-strutture acustiche stabili. Il K-Means con $k = 5$ ha permesso di identificare 5 chiari "Mood Playlists" (Electronic Party, Urban & Rap, Melodic Pop, High-Velocity Bass, Dark/Atmospheric), validati da un valore medio di Silhouette pari a 0.43. DBSCAN ha invece dimostrato un'efficacia straordinaria nell'isolare una quota del 6.9% di tracce anomale caratterizzate da durate estreme, BPM eccentrici o parlato anomalo.

5.2 Ricadute Applicative e Scenari di Business

I risultati conseguiti aprono la strada a tre concrete applicazioni commerciali:

1. **Generazione di Playlist Basate sui Mood (K-Means):** Le etichette di genere tradizionali risultano spesso rigide o fuorvianti: canzoni formalmente catalogate in

generi diversi possono condividere lo stesso impatto emotivo e ritmico. Il partizionamento in 5 macro-mood consente alle piattaforme di streaming di generare raccomandazioni dinamiche per attività quotidiane (*Workout, Focus, Chillout, Party*) basate unicamente sulle caratteristiche acustiche intrinseche della musica.

2. **Controllo Qualità e Anomaly Detection Automatizzata (DBSCAN):** Con l'upload giornaliero di centinaia di migliaia di brani da parte di etichette indipendenti e utenti, DBSCAN costituisce un potente strumento automatico di controllo qualità, capace di intercettare file corrotti, podcast catalogati erroneamente come musica o registrazioni amatoriali difettose prima dell'indicizzazione editoriale.

3. **Valutazione Matematica di Nuove Uscite e Demo (Classificazione Stacking):** Il modello predittivo addestrato può essere impiegato dalle case discografiche e dai team di A&R (Artists and Repertoire) per analizzare le tracce demo appena registrate, identificandone con precisione matematica il posizionamento di genere e il pubblico di riferimento prima del lancio promozionale.

5.3 Sviluppi Futuri

Come sviluppi futuri per l'analisi acustica, il lavoro potrebbe essere esteso integrando tecniche multimodali: in particolare, l'analisi testuale dei testi delle canzoni (*lyrics*) mediante modelli di Natural Language Processing (BERT/Transformers) e l'elaborazione degli spettrogrammi audio completi attraverso reti neurali convoluzionali (CNN). L'unione di segnali acustici, linguistici e comportamentali (storico di ascolto degli utenti) consentirà di affinare ulteriormente la precisione dei sistemi di raccomandazione musicale di nuova generazione.

PARTE II

Analisi delle Serie Storiche sul Mercato Calcistico Europeo (Transfermarkt)

6 Analisi delle serie storiche sul mercato calcistico: introduzione e dataset

Nel corso degli ultimi quindici anni l'industria calcistica europea ha attraversato una trasformazione economica profonda, evolvendo da settore prevalentemente sportivo a mercato finanziario globale caratterizzato da flussi di capitale miliardari, cicli stagionali regolari e forte sensibilità agli shock macroeconomici esterni. L'espansione dei diritti televisivi internazionali, l'ingresso di fondi sovrani e grandi gruppi di investimento nella proprietà dei club e l'inflazione strutturale dei costi di trasferimento hanno progressivamente ridefinito il valore patrimoniale delle rose dei principali campionati europei. In questo scenario, lo studio dell'evoluzione temporale del valore economico dei calciatori e dei volumi di spesa generati nelle sessioni di calciomercato rappresenta un banco di prova ideale per l'applicazione delle metodologie di analisi e previsione delle serie storiche.

A differenza dei mercati azionari tradizionali, dove il prezzo di un titolo viene battuto in modo continuo durante le sedute di borsa, il mercato calcistico presenta una struttura informativa composita: le valutazioni economiche dei singoli atleti vengono aggiornate periodicamente dagli analisti di mercato in finestre prestabilite durante la stagione sportiva, mentre le transazioni monetarie effettive e gli spostamenti dei giocatori tra i club si concentrano nelle due sessioni ufficiali di calciomercato (quella invernale di gennaio e quella estiva tra luglio e agosto). La seconda parte del presente elaborato si pone l'obiettivo di ricostruire, esplorare e modellare matematicamente la serie storica mensile del valore di mercato delle rose dei cinque maggiori campionati europei (Serie A, Premier League, LaLiga, Bundesliga e Ligue 1), affiancando all'analisi aggregata europea un approfondimento specifico dedicato al campionato italiano di Serie A.

Il percorso metodologico sviluppato nei capitoli successivi si articola in quattro fasi consequenziali: la progettazione di una pipeline di ingegneria dei dati capace di trasformare le tabelle relazionali grezze in una serie storica mensile regolare e priva di discontinuità artificiali; l'analisi esplorativa dei dati e lo studio quantitativo dei grandi shock storici che hanno colpito il settore (dall'esplosione inflattiva del 2017 legata al trasferimento record di Neymar fino alla contrazione pandemica del 2020 e al successivo rimbalzo post-pandemico); la decomposizione stagionale e la verifica formale delle proprietà di stazionarietà e autocorrelazione temporale; infine, l'addestramento e il confronto critico di modelli previsionali di complessità crescente, dai modelli autoregressivi classici fino ai modelli stagionali con variabili esogene (dove il volume di spesa e il numero di trasferimenti del calciomercato vengono impiegati come predittori esterni della dinamica del valore delle rose).

6.1 Struttura del dataset relazionale di Transfermarkt

La base informativa utilizzata per lo studio proviene dal repository pubblico *Football Data from Transfermarkt* distribuito sulla piattaforma Kaggle. A differenza di un dataset nativo di serie storiche, la fonte originale è organizzata come un database relazionale composto da dodici tabelle distinte in formato `.csv`, che registrano l'anagrafica dei campionati, dei club e dei giocatori insieme allo storico granulare delle partite disputate, delle presenze individuali, dei trasferimenti ufficiali e delle valutazioni di mercato.

Per la costruzione della serie storica del valore patrimoniale delle rose e dei flussi di calciomercato, l'attenzione si è concentrata sulle cinque tabelle fondamentali riassunte nella Tabella 2. La tabella centrale è costituita dal file `player_valuations.csv`, che raccoglie 656.301 osservazioni storiche relative alle stime di valore di mercato espresse in euro (`market_value_in_eur`) attribuite a ciascun calciatore identificato tramite la chiave primaria `player_id` in una determinata data (`date`). A questa si affianca il file `transfers.csv`, contenente 175.165 record di trasferimento che documentano per ogni operazione la data esatta (`transfer_date`), il club di provenienza (`from_club_id`), il club di destinazione (`to_club_id`), il corrispettivo economico pagato per il cartellino (`transfer_fee`) e la valutazione del giocatore al momento del passaggio.

Tabella 2: Riepilogo delle tabelle relazionali del dataset di Transfermarkt utilizzate nella pipeline.

File sorgente	Chiavi principali	Record grezzi	Ruolo nella ricostruzio
`player_valuations.csv`	`player_id`, `date`	656.301	Storico delle valutazioni d
`transfers.csv`	`player_id`, `transfer_date`	175.165	Spostamenti tra club e vo
`appearances.csv`	`player_id`, `date`	1.894.350	Presenze effettive e verific
`clubs.csv`	`club_id`	796	Anagrafica dei club e lega
`competitions.csv`	`competition_id`	65	Codifica dei cinque maggi

L'integrazione con la tabella `appearances.csv`, che conta 1.894.350 registrazioni di presenze individuali in gara, e con i dizionari anagrafici `clubs.csv` e `competitions.csv` consente di associare ogni società calcistica alla rispettiva lega nazionale mediante il codice identificativo `domestic_competition_id`. In particolare, il perimetro dello studio seleziona i cinque massimi campionati europei: la Serie A italiana (`IT1`), la Premier League inglese (`GB1`), LaLiga spagnola (`ES1`), la Bundesliga tedesca (`L1`) e la Ligue 1 francese (`FR1`).

6.2 Processo di estrazione, trasformazione e caricamento per la serie storica

La trasformazione dei record puntuali di Transfermarkt in una serie storica rigorosa richiede di risolvere due criticità strutturali intrinseche ai dati grezzi, che se trascurate comprometterebbero la regolarità degli intervalli temporali e la veridicità economica dei valori aggregati. L'intera procedura descritta di seguito è stata implementata in modo riproducibile all'interno dello script `01_etl_transfermarkt.py`.

La prima criticità riguarda la frequenza di campionamento e la complementarità tra listini di valutazione e sessioni di mercato. Nel file `player_valuations.csv`, le revisioni dei prezzi non avvengono simultaneamente in tutti i mesi dell'anno per l'intero organico dei campionati, ma si concentrano prevalentemente in quattro finestre stagionali (marzo, fine maggio e giugno, ottobre e dicembre). Al contrario, nei mesi di gennaio, febbraio, luglio e agosto il numero di aggiornamenti di listino è ridotto poiché gli analisti attendono la chiusura delle trattative ufficiali; tuttavia, proprio in questi mesi il file `transfers.csv` registra migliaia di compravendite che modificano profondamente la composizione e il valore patrimoniale delle rose.

Questa dinamica complementare è documentata nella Figura 21: nel pannello di sinistra si osserva come i mesi con minori revisioni di prezzo in `player_valuations.csv` coincidano esattamente con i picchi di attività di `transfers.csv` (luglio, agosto e gennaio), mentre il pannello di destra evidenzia come il volume medio di spesa mensile superi i 2.300 milioni di euro nel mese di luglio, i 1.280 milioni in agosto e i 550 milioni a gennaio.

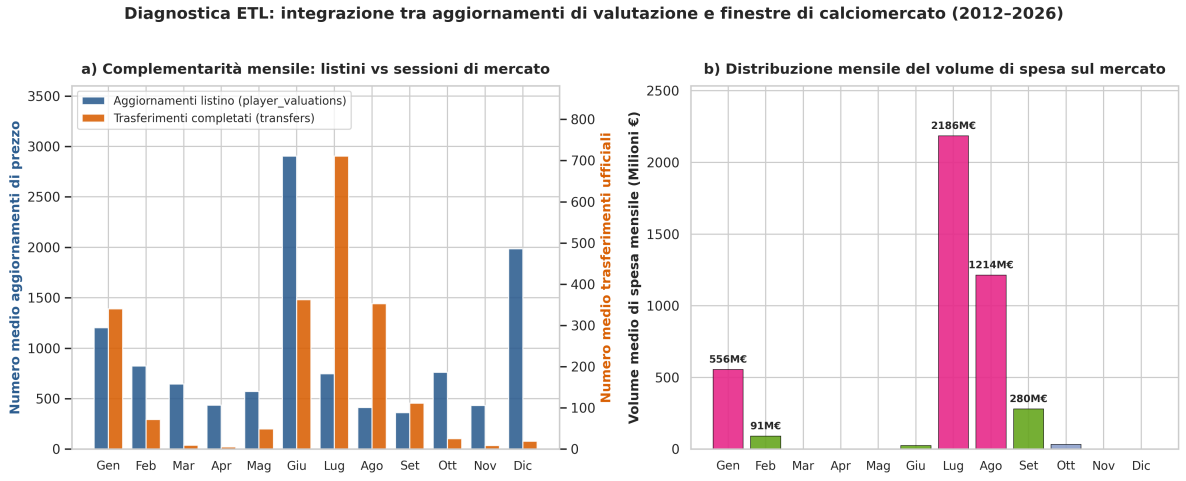


Figura 21: Complementarità stagionale tra la frequenza mensile degli aggiornamenti di valutazione e il volume delle operazioni di calciomercato nei cinque maggiori campionati europei.

Se si aggregassero ingenuamente le sole righe di `player_valuations.csv` mese per mese senza mantenere lo stato patrimoniale dei giocatori in attività, la serie risultante rifletterebbe il numero di aggiornamenti redazionali anziché il reale valore delle rose.

D'altra parte, se si applicasse una semplice propagazione in avanti delle valutazioni senza tenere conto dei trasferimenti di mercato, la serie presenterebbe dei tratti quasi costanti nei mesi in cui i listini sono fermi.

La seconda criticità riguarda la distorsione retrospettiva legata all'appartenenza dei giocatori ai club. All'interno della tabella `player_valuations.csv`, gli attributi `current_club_id` e `player_club_domestic_competition_id` non sono variabili storiche indicizzate nel tempo, bensì campi statici che riportano unicamente l'ultima squadra in cui il calciatore milita al momento dell'estrazione del dataset (nel 2026). Di conseguenza, un'aggregazione basata direttamente su tale colonna attribuirebbe l'intera storia passata di un giocatore al suo campionato del 2026: a titolo esemplificativo, atleti protagonisti in Serie A tra il 2018 e il 2021 ma successivamente trasferitisi all'estero (o ritiratisi) non verrebbero conteggiati nel valore storico del campionato italiano, generando una grave sottostima retrospettiva.

Per superare entrambe le problematiche, l'algoritmo di ricostruzione storica implementato nel Listato 1 costruisce una griglia temporale mensile regolare (con fase di inizializzazione a partire da gennaio 2009 e finestra di analisi da giugno 2011 a maggio 2026, per un totale di 180 mesi consecutivi pari a quindici cicli annuali completi) ed esegue l'allineamento congiunto dello stato di prezzo e dello stato di appartenenza al club per ciascun giocatore.

```
# 1. Griglia mensile regolare e propagazione controllata dell'ultima valutazione valida
grid_months = pd.period_range("2009-01", "2026-05", freq="M")
target_months = pd.period_range("2011-06", "2026-05", freq="M")  # 180 mesi (15 anni)

val_m = vals_sub.groupby(["player_id", "year_month"])["market_value_in_eur"].last().unstack(level=0)
val_ff = val_m.reindex(grid_months).ffill(limit=18)

# 2. Ricostruzione del club storico mese per mese da presenze (appearances) e trasferimenti (transfers)
app_club_m = app_sub.groupby(["player_id", "year_month"])["player_club_id"].last()
tr_club_m = tr_sub.groupby(["player_id", "year_month"])["to_club_id"].last()

club_events = pd.concat([app_club_m, tr_club_m]).groupby(level=[0, 1]).last().unstack(level=0)
club_events = club_events.reindex(index=grid_months, columns=val_ff.columns)
club_hist = club_events.ffill().bfill().fillna(val_club_m)

# 3. Mappatura dal club storico alla rispettiva lega nazionale (IT1, GB1, ES1, L1, FR1)
```

```
17 comp_hist = club_hist.apply(lambda col: col.map(club_to_comp)).fillna("
       OTHER")
```

Listato 1: Ricostruzione storica mensile del valore di mercato e del club di appartenenza nello script `01_etl_transfermarkt.py`.

Come illustrato nel Listato 1, per ogni calciatore e per ciascun mese della griglia temporale viene mantenuta l'ultima valutazione di mercato valida mediante operazione di *forward-fill* limitata a un orizzonte massimo di diciotto mesi, così da garantire la continuità della quotazione per tutti i giocatori in attività ed escludere automaticamente dal computo gli atleti ritirati o inattivi. Contemporaneamente, la matricola del club in cui il giocatore milita in quel preciso mese viene determinata incrociando cronologicamente le presenze effettive in campo tratte da `appearances.csv` (`player_club_id`) e i cambi di casacca registrati in `transfers.csv` (`to_club_id`), mappando poi il club storico alla rispettiva competizione nazionale tramite il dizionario estratto da `clubs.csv`.

L'efficacia di questa ricostruzione ingegneristica è dimostrata visivamente nella Figura 22. Nel pannello superiore viene messo a confronto il valore storico della Serie A ottenuto tramite la nostra ricostruzione dinamica (linea continua verde) con quello prodotto da un'aggregazione statica basata sul solo club del 2026 (linea tratteggiata arancione): quest'ultima sottostima sistematicamente il patrimonio della Serie A lungo tutto il decennio 2014–2022, arrivando a perdere quasi un miliardo di euro di valore reale nel biennio 2019–2020. Al contrario, la serie ricostruita cattura fedelmente sia le acquisizioni internazionali durante le finestre estive e invernali, sia le revisioni periodiche dei cartellini durante il campionato. Nel pannello inferiore della Figura 22 è riportata la serie storica principale post-ETL del valore aggregato dei cinque maggiori campionati europei, che evolve in modo continuo da 11,12 miliardi di euro nel giugno 2011 fino al massimo storico di 34,44 miliardi di euro nel maggio 2026.

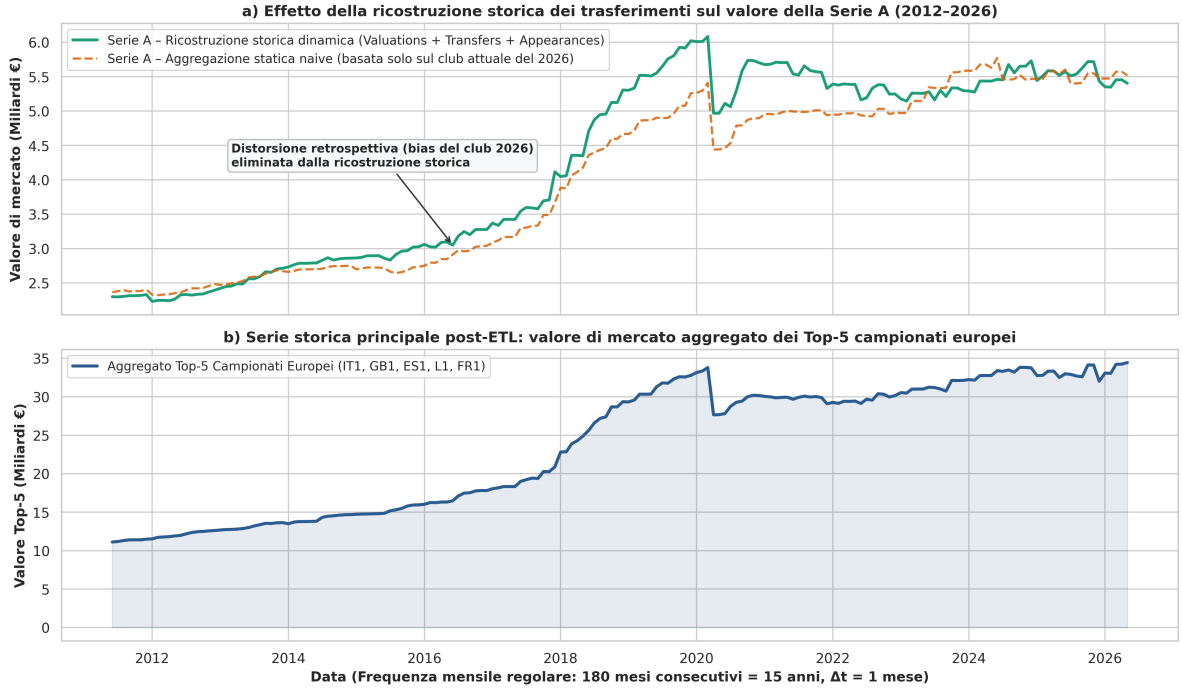


Figura 22: Confronto tra aggregazione statica e ricostruzione storica dinamica per la Serie A e andamento complessivo della serie storica principale post-ETL sui 180 mesi di osservazione.

La scelta di fissare l'orizzonte temporale definitivo tra giugno 2011 (`2011-06`) e maggio 2026 (`2026-05`) risponde a due criteri metodologici rigorosi: da un lato consente di escludere il mese di giugno 2026, parzialmente incompleto nell'estrazione originale e affetto dalla pre-registrazione automatica delle scadenze contrattuali di fine stagione; dall'altro fornisce esattamente 180 osservazioni mensili consecutive, corrispondenti a quindici cicli annuali completi di dodici mesi ($s = 12$). Tale cardinalità permette una suddivisione temporale ottimale per la successiva fase di modellazione predittiva, destinando i primi dodici anni completi (144 mesi, pari all'80% del campione) al set di addestramento e gli ultimi tre anni completi (36 mesi, pari al 20%) al set di test.

Tabella 3: Struttura delle variabili principali contenute nel dataset mensile elaborato `market_monthly.csv`.

Variabile	**Unita / Tipo**	**Descrizione**
`year_month`, `date`	Data mensile	Indice temporale regolare ($\Delta t = 1$ mese, 18
`top5_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato delle rose dei T
`serie_a_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato delle rose della
`premier_league_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato della Premier
`laliga_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato de LaLiga (ES
`bundesliga_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato della Bundesli
`ligue1_market_value_bn`	Float (Mld EUR)	Valore di mercato aggregato della Ligue 1 (
`mean_player_value_m`	Float (Mln EUR)	Valore di mercato medio per calciatore atti
`transfer_spend_top5_m`	Float (Mln EUR)	Volume mensile di spesa per trasferimenti c
`transfer_spend_serie_a_m`	Float (Mln EUR)	Volume mensile di spesa per trasferimenti i
`n_transfers_top5`	Intero	Numero totale di trasferimenti completati r
`overpay_ratio`	Float	Rapporto mediano tra prezzo pagato e valo
`pct_change_top5`	Float (%)	Variazione percentuale mensile del valore a
`shock_neymar_post2017`	Binaria [0/1]	Indicatore del regime post-agosto 2017 (sho
`shock_covid_2020`	Binaria [0/1]	Indicatore della finestra pandemica e del ta

I controlli di integrità eseguiti al termine della pipeline ed esportati nel file di certificazione `etl_summary.json` attestano la totale assenza di valori nulli o mesi mancanti (`missing_months = 0` su 180 osservazioni) e confermano che la serie principale `top5_market_value_bn` presenta variazioni non nulle in 179 transizioni mensili consecutive su 179 (`zero_change_months = 0`), soddisfacendo pienamente sia il requisito di equispaziatura temporale sia quello di variabilità dinamica continua. Nella Tabella 3 vengono infine riassunte le principali variabili salvate all'interno del dataset definitivo `market_monthly.csv`, che costituisce la base di partenza per l'analisi esplorativa e la modellazione dei capitoli seguenti.

7 Analisi esplorativa dei dati e dinamica degli shock storici

In questo capitolo viene esaminata l'evoluzione temporale del valore di mercato dei principali campionati europei e del campionato di Serie A tra il 2011 e il 2026. L'indagine si focalizza sull'analisi delle variazioni percentuali mensili e sulla quantificazione dei tre grandi shock storici che hanno trasformato la struttura economica del settore: l'effetto inflattivo legato al trasferimento di Neymar nell'agosto 2017, la contrazione improvvisa dovuta alla pandemia da COVID-19 nella primavera 2020 e la successiva espansione post-pandemica caratterizzata dalla crescita della Premier League e dall'ingresso di capitali internazionali.

8 Decomposizione stagionale, stazionarieta e analisi delle autocorrelazioni

Il presente capitolo è dedicato all'analisi della struttura temporale della serie mediante decomposizione STL con periodo stagionale annuale ($s = 12$). Vengono illustrati i risultati formali dei test di radice unitaria (Augmented Dickey-Fuller e KPSS) per verificare la non stazionarietà della serie originaria e la sua riconduzione a stazionarietà mediante differenziazione prima. L'analisi è completata dall'ispezione dei correlogrammi di autocorrelazione semplice (ACF) e parziale (PACF) per la selezione degli ordini autoregressivi e di media mobile.

9 Modellazione predittiva, diagnostica dei residui e conclusioni finali

In questo capitolo vengono sviluppati e confrontati sistematicamente i modelli di serie storiche applicati alla serie del valore delle rose su un orizzonte di validazione temporale indipendente di 36 mesi (Test Set, 2023–2026). Il confronto abbraccia la baseline ingenua stagionale, il modello non stagionale ARIMA, il modello stagionale SARIMA e l'estensione multivariata SARIMAX con variabili esogene di calciomercato (volume di spesa e dummy di intervento per gli shock storici), validando le stime tramite diagnostica dei residui (test di Ljung-Box) e confronto su metriche di errore e bontà di adattamento.

Elenco delle figure

1 Distribuzione delle frequenze dei 15 generi musicali nel dataset post-ETL. . 8
2 Distribuzione delle caratteristiche audio continue (istogrammi e curve di densità KDE). 9
3 Distribuzione delle variabili discrete: Tonalità (`key`), Modo (`mode`) e Metro (`time_signature`). 11
4 Matrice di correlazione di Pearson tra le feature audio calcolata sul dataset prima del sampling. 12
5 Bilanciamento del Training Set: confronto della distribuzione delle classi pre vs post SMOTE e Undersampling. 15
6 Matrice di correlazione di Pearson verificata sul Training Set post-bilanciamento. 16
7 Confronto dell'accuratezza sul Test Set tra gli 8 modelli di Machine Learning testati. 18
8 Matrice di confusione normalizzata ottenuta dal modello Ensemble finale sul Test Set. 20
9 Heatmap del Classification Report: valori di Precision, Recall ed F1-Score per ciascun genere. 21
10 Valutazione delle performance: Curve ROC One-vs-Rest e Curve Precision-Recall. 22
11 Learning Curve (Training vs Validation) calcolata al variare della numerosità del dataset. 23
12 Feature Importance: confronto dei contributi percentuali tra Random Forest e XGBoost. 24
13 Tecniche di riduzione dimensionale applicate allo spazio acustico: PCA e t-SNE 2D. 26
14 Metodo del Gomito (Elbow Method): andamento della WCSS al variare di k da 2 a 11. 27
15 Visualizzazione dei 5 cluster K-Means ($k = 5$) sulla proiezione t-SNE 2D. . 28
16 Profiling acustico dei cluster K-Means: matrice delle caratteristiche medie per cluster. 28
17 Diagramma della Silhouette per il modello K-Means con $k = 5$. 30
18 Metodologie di calibrazione e selezione degli iperparametri per l'algoritmo DBSCAN. 31
19 Cluster DBSCAN con isolamento ed evidenziazione delle osservazioni di rumore / outlier. 32
20 Analisi diagnostica del rumore DBSCAN: confronto delle distribuzioni su feature anomale. 32

21 Complementarità stagionale tra la frequenza mensile degli aggiornamenti di valutazione e il volume delle operazioni di calciomercato nei cinque maggiori campionati europei. 39
22 Confronto tra aggregazione statica e ricostruzione storica dinamica per la Serie A e andamento complessivo della serie storica principale post-ETL sui 180 mesi di osservazione. 42

Elenco delle tabelle

1 Colonne del dataset e relativo formato dei dati. 6
2 Riepilogo delle tabelle relazionali del dataset di Transfermarkt utilizzate nella pipeline. 38
3 Struttura delle variabili principali contenute nel dataset mensile elaborato `market_monthly.csv`. 43