UNIVERSITÀ POLITECNICA DELLE MARCHE

FACOLTÀ DI INGEGNERIA

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

---

PROGETTO DI DATA SCIENCE

Parte 1: Audio Feature Analysis, Classificazione e Clustering

Studio avanzato su dati Spotify: Data Cleaning, EDA, Modelli di Classificazione Multiclasse ed Ensemble, Clustering e Profiling dei Mood

Docenti:

Prof. Ursino Domenico

Dott. Buratti Christopher

A cura di:

Altieri Andrea

Belardinelli Luca

Contursi Andrea

Flaiani Andrea

ANNO ACCADEMICO 2024–2025

Indice

1 Spotify tracks analysis: introduzione 3

1.1 Obiettivi del progetto . . . 3

2 Spotify tracks analysis: dataset 5

2.1 ETL . . . 7

2.2 Analisi descrittiva . . . 8

2.2.1 Distribuzione dei generi musicali . . . 8

2.2.2 Distribuzione delle feature continue . . . 9

2.2.3 Distribuzione delle variabili discrete . . . 11

2.2.4 Matrice di correlazione . . . 12

3 Spotify tracks analysis: classificazione 14

3.1 Preprocessing del dataset . . . 14

3.1.1 Oversampling con SMOTE e Undersampling . . . 14

3.1.2 Dataset Finale . . . 15

3.2 Processo di Classificazione . . . 17

3.2.1 Confronto Modelli di Machine Learning . . . 17

3.2.2 Tuning degli Iperparametri . . . 18

3.2.3 Ensemble Learning . . . 18

3.3 Diagnostica e Commento ai Risultati . . . 20

3.3.1 Matrice di Confusione e Classification Report . . . 20

3.3.2 Curve ROC, Precision-Recall e Learning Curve . . . 22

3.3.3 Feature Importance . . . 24

3.4 Evoluzione del Modello: Classificazione Gerarchica e Modelli Specialisti . . . 25

3.4.1 Livello 1: Classificazione delle Macro-Famiglie . . . 25

3.4.2 Livello 2: Modelli Specialisti Intra-Famiglia . . . 29

3.4.3 Conclusione Diagnostica e Considerazioni sulla Natura delle Etichette . . . 31

4 Spotify tracks analysis: clustering 33

4.1 Fase di ETL per il clustering . . . 33

4.1.1 Operazioni preliminari e selezione delle feature . . . 33

4.1.2 Riduzione di dimensionalità: PCA e t-SNE . . . 35

4.2 K-Means nello Spazio PCA . . . 40

4.2.1 Applicazione dell'algoritmo, Elbow Method e Coefficiente di Silhouette . . . 40

4.2.2 Analisi dei risultati ottenuti e proiezioni spaziali . . . 41

4.2.3 Profiling acustico dei Cluster e Mood Playlists . . . 42

4.2.4 Valutazione della Silhouette per K-Means . . . 44

4.2.5 Evoluzione probabilistica di K-Means: Gaussian Mixture Model . . . 45

4.3 DBSCAN nello Spazio PCA 47
4.3.1 Scelta dei parametri e tuning nello spazio PCA 47
4.3.2 Analisi dei risultati ottenuti e interpretazione topologica 49
4.3.3 Diagnostica del Rumore 50
4.3.4 Evoluzione di DBSCAN: HDBSCAN e affiliazioni dei brani periferici 51
5 Business case finale e conclusioni della Parte 1 53
5.1 Sintesi dei risultati metodologici 53
5.2 Ricadute applicative e scenari di business 54
5.3 Sviluppi futuri 54
Elenco delle figure 55
Elenco delle tabelle 56

1 Spotify tracks analysis: introduzione

Nel panorama contemporaneo dello streaming musicale, la fruizione e la catalogazione dei brani audio sono guidate in misura sempre maggiore da modelli matematici e algoritmi di apprendimento automatico. Piattaforme leader a livello globale come Spotify gestiscono cataloghi composti da decine di milioni di brani, affrontando la sfida quotidiana di organizzarli in modo coerente e di proporre raccomandazioni personalizzate per ciascun utente. Per fare ciò, i moderni sistemi non si basano unicamente sui metadati testuali (come il titolo, il nome dell'artista o la casa discografica), ma estraggono sistematicamente caratteristiche acustiche e psicoacustiche direttamente dal segnale audio grezzo di ogni traccia.

Comprendere come queste variabili continue e discrete interagiscano tra loro permette sia di automatizzare la categorizzazione dei brani all'interno dei rispettivi generi musicali, sia di scoprire pattern latenti di affinità sonica non rilevabili dalle sole etichette commerciali. In questo contesto, il presente progetto si propone di analizzare approfonditamente un dataset contenente oltre **42.000 tracce musicali** descritte da molteplici attributi tecnici (frequenza, tempo in BPM, volume sonoro, presenza vocale, valenza emotiva e ballabilità), integrando un percorso metodologico completo che spazia dalla pulizia e preparazione dei dati, alla modellazione supervisionata e non supervisionata.

1.1 Obiettivi del progetto

L'obiettivo principale dell'elaborato è l'applicazione di tecniche di machine learning, in particolare di **classificazione supervisionata** e di **clustering non supervisionato**, per estrarre conoscenza e individuare relazioni significative nei dati musicali. Nello specifico, il lavoro si articola nei seguenti obiettivi fondamentali:

- **Data cleaning ed ETL rigoroso:** Ispezionare la qualità dei dati grezzi estratti dall'API di Spotify, eliminare le ridondanze derivanti dalla sovrapposizione delle playlist tematiche mediante deduplicazione basata sull'identificativo univoco del brano, scartare variabili di servizio non informative e preparare i dati garantendo la totale assenza di *data leakage*.
- **Analisi descrittiva ed esplorativa (EDA):** Esaminare a fondo le distribuzioni statistiche delle caratteristiche audio, evidenziando le asimmetrie, la presenza di outlier e le correlazioni lineari tra grandezze fisiche e musicali.
- **Classificazione multiclasse del genere musicale:** Sviluppare e ottimizzare modelli predittivi capaci di stimare il genere di appartenenza di una traccia tra 15 classi differenti partendo unicamente dalle sue proprietà sonore. Il

task richiede di affrontare il forte sbilanciamento delle classi tramite tecniche di oversampling sintetico (SMOTE) e undersampling controllato, di confrontare molteplici algoritmi di machine learning e di incrementare le performance attraverso tecniche avanzate di *Ensemble Learning* (Voting Classifier e Stacking Classifier).

- **Clustering non supervisionato e profiling dei mood:** Raggruppare i brani in cluster sonori omogenei in modo del tutto agnostico rispetto al genere etichettato, impiegando sia algoritmi di partizionamento (K-Means) che algoritmi basati sulla densità spaziale (DBSCAN), supportati da tecniche di riduzione della dimensionalità (PCA e t-SNE) per identificare macro-archetipi o playlist emotive (*mood playlists*).
- **Analisi diagnostica e ricadute applicative:** Condurre un'analisi approfondita degli errori commessi dai modelli (matrice di confusione, curve ROC e Precision-Recall, learning curves, silhouette analysis) e proporre scenari d'uso concreti per le piattaforme di streaming e l'industria discografica.

Attraverso l'impiego coordinato di queste metodologie, il progetto intende dimostrare come l'analisi quantitativa dei segnali audio possa supportare efficacemente sia la classificazione tassonomica automatica sia la creazione di nuovi percorsi di scoperta musicale guidati dalle affinità timbriche ed emotive.

2 Spotify tracks analysis: dataset

Il dataset impiegato per la realizzazione di questo progetto è stato reperito dalla piattaforma Kaggle, ed è noto come *Spotify Audio Features / Genres v2*. Il dataset grezzo raccoglie **42.305 osservazioni** relative a brani musicali estratti tramite le Web API ufficiali di Spotify a partire da playlist pubbliche focalizzate su **15 generi e sottogeneri** musicali contemporanei.

Ciascuna traccia all'interno del dataset è descritta da un totale di **22 attributi**, comprendenti metadati identificativi, parametri sonori continui derivati dall'analisi spettrale e variabili discrete legate alla teoria musicale. Nel dettaglio, le informazioni fornite dal dataset si suddividono nelle seguenti categorie:

- **Informazioni e metadati di servizio:**
  - `id`: Stringa alfanumerica univoca assegnata da Spotify a ciascun brano.
  - `song_name` e `title`: Titolo della traccia o stringa del nome del file.
  - `uri`, `track_href`, `analysis_url`: Indirizzi URI e URL web per l'accesso programmatico alle risorse audio sui server di Spotify.
  - `type`: Tipologia dell'oggetto ritornato dall'API (pari ad `audio_features`).
  - `genre`: Genere musicale associato alla playlist da cui è stato estratto il brano (rappresenta la nostra variabile target per la classificazione).
- **Caratteristiche audio continue (misure fisiche e psicoacustiche):**
  - `danceability`: Valore compreso tra 0.0 e 1.0 che descrive quanto un brano sia adatto al ballo, calcolato sulla base di regolarità del ritmo, stabilità del tempo e forza della battuta.
  - `energy`: Valore tra 0.0 e 1.0 che rappresenta una misura percettiva dell'intensità e dell'attività della traccia (i brani energici risultano veloci, rumorosi e densi).
  - `loudness`: Volume sonoro complessivo della traccia espresso in decibel (dB), tipicamente compreso tra -60 dB e 0 dB.
  - `speechiness`: Valore tra 0.0 e 1.0 che quantifica la presenza di parole parlate. Valori superiori a 0.66 indicano tracce parlate (es. talk show o poesia), valori tra 0.33 e 0.66 indicano musica con forte presenza vocale ritmata (Rap, Trap), mentre valori inferiori a 0.33 descrivono brani tradizionali e strumentali.
  - `acousticness`: Misura di confidenza tra 0.0 e 1.0 che indica se il brano è acustico (1.0) o sintetico/elettronico (vicino a 0.0).

  - `instrumentalness`: Valore tra 0.0 e 1.0 che prevede se la traccia è priva di parti vocali cantate. I brani rap o pop ottengono valori prossimi a 0, mentre tracce techno o ambient superano 0.5.
  - `liveness`: Valore tra 0.0 e 1.0 che rileva la presenza di un pubblico nella registrazione; valori superiori a 0.8 indicano un'alta probabilità di performance dal vivo.
  - `valence`: Valore da 0.0 a 1.0 che descrive la positività musicale trasmessa dalla traccia: valori alti indicano euforia, allegria e serenità, mentre valori bassi denotano tristezza, rabbia o tensione emotiva.
  - `tempo`: Velocità stimata del brano espressa in battiti al minuto (BPM).
  - `duration_ms`: Durata temporale complessiva del brano espressa in millisecondi.

- **Parametri musicali discreti:**
  - `key`: Tonalità complessiva del brano codificata come intero secondo la notazione standard Pitch Class (0 = Do, 1 = Do♯/Re♭, 2 = Re, ..., 11 = Si).
  - `mode`: Modalità del brano, dove 1 indica la modalità Maggiore e 0 indica la modalità Minore.
  - `time_signature`: Metro ritmico stimato (numero di quarti per battuta, tipicamente pari a 4 nella quasi totalità della musica moderna).

Nella Tabella **??** vediamo una rappresentazione riepilogativa delle colonne del dataset e il relativo formato dei dati.

Tabella 1: Colonne del dataset e relativo formato dei dati.

Colonna	Formato	Descrizione / Range
`danceability`	Float	Ballabilità del brano [0.0 - 1.0]
`energy`	Float	Intensità dinamica percepita [0.0 - 1.0]
`key`	Intero	Tonalità Pitch Class [0 - 11]
`loudness`	Float	Volume globale in decibel [dB]
`mode`	Intero	Modalità armonica [0 = Minore, 1 = Maggiore]
`speechiness`	Float	Presenza di parlato / flow vocale [0.0 - 1.0]
`acousticness`	Float	Grado di produzione acustica [0.0 - 1.0]
`instrumentalness`	Float	Assenza di parti vocali [0.0 - 1.0]
`liveness`	Float	Presenza di registrazione live [0.0 - 1.0]
`valence`	Float	Positività / Tonalità emotiva [0.0 - 1.0]
`tempo`	Float	Velocità ritmica in BPM
`duration_ms`	Intero	Durata del brano in millisecondi
`time_signature`	Intero	Metro ritmico stimato [3 - 5]
`id`	Stringa	Identificativo univoco Spotify
`genre`	Categoriale	Etichetta del genere (15 classi target)

2.1 ETL

Il processo di ETL (Extract, Transform, Load) è stato un passaggio fondamentale per garantire la qualità dei dati e la validità scientifica di tutte le analisi condotte successivamente. L'estrazione da API di playlist eterogenee, se non adeguatamente filtrata, introduce infatti distorsioni sistematiche che possono compromettere l'addestramento dei modelli.

Durante questa fase sono state applicate diverse operazioni critiche:

- **Deduplicazione su Track ID:** Poiché le playlist Spotify condividono spesso brani popolari comuni a più sottogeneri, il dataset grezzo originale di 42.305 righe presentava un elevato numero di repliche dello stesso brano. È stato eseguito un filtraggio rigoroso basato sulla colonna `id`, individuando e rimuovendo esattamente **6.428 record duplicati**. Il dataset ripulito risulta così composto da **35.877 brani unici effettivi**. Questa operazione si è rivelata indispensabile: in assenza di deduplicazione preventiva, brani identici sarebbero finiti contemporaneamente sia nel training set che nel test set durante la fase di holdout, provocando un grave fenomeno di *data leakage* e generando stime di accuratezza artificialmente gonfiate e non generalizzabili.
- **Eliminazione delle Variabili di Servizio:** Sono state eliminate tutte le colonne prive di contenuto acustico utile alla modellazione predittiva, tra cui `Unnamed: 0`, `type`, `uri`, `track_href`, `analysis_url`, `song_name` e `title`. Oltre a non apportare informazione sonica, tali variabili avrebbero appesantito la memoria computazionale introducendo rumore inutile.
- **Verifica dell'Integrità e Gestione dei Valori Nulli:** È stato effettuato un controllo esaustivo per rilevare l'eventuale presenza di valori nulli o mancanti (*missing values*). Tutte le feature audio numeriche e la variabile target `genre` risultano complete al 100%, confermando l'assenza di dati mancanti da imputare.
- **Esportazione del Dataset Pulito:** Il dataset risultante dalle operazioni di ETL è stato salvato nel file `genres_cleaned.csv`, pronto per essere utilizzato in modo riproducibile dalle pipeline di analisi descrittiva, classificazione e clustering.

2.2 Analisi descrittiva

L'analisi descrittiva ha avuto lo scopo di esplorare e sintetizzare le principali caratteristiche statistiche del dataset, fornendo una comprensione preliminare delle distribuzioni marginali delle variabili e delle relazioni che intercorrono tra di esse. Nel seguito vengono esaminate singolarmente le distribuzioni dei generi, delle feature continue, delle grandezze musicali discrete e la matrice di correlazione.

2.2.1 Distribuzione dei generi musicali

La frequenza con cui ciascun genere musicale compare all'interno del dataset ripulito è stata visualizzata tramite il grafico a barre riportato in Figura **??**.

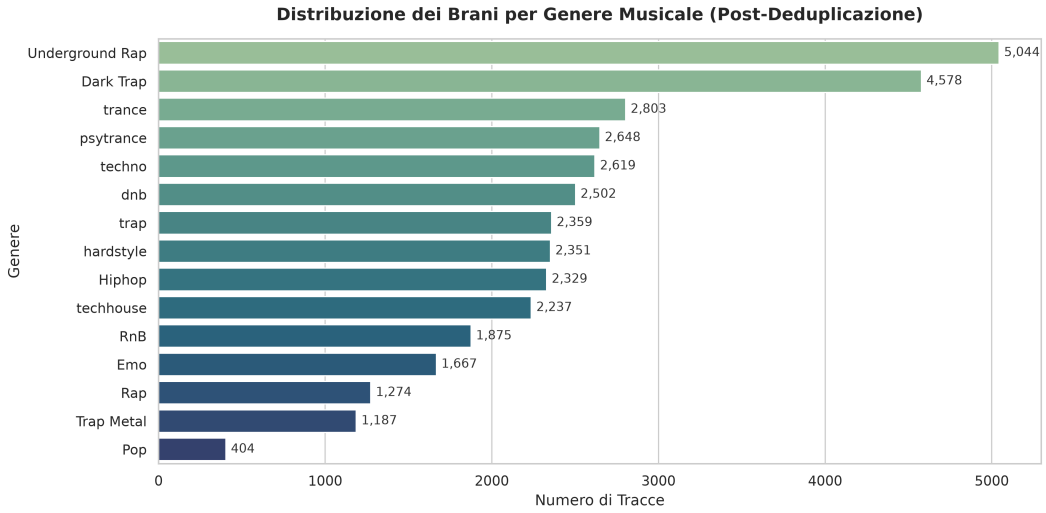

Figura 1: Distribuzione delle frequenze dei 15 generi musicali nel dataset post-ETL.

Come si può osservare chiaramente dalla Figura **??**, il dataset evidenzia un marcato sbilanciamento naturale nella numerosità delle classi. I generi urbani ed elettronici risultano ampiamente dominanti: in particolare, *Underground Rap* conta 5.044 brani e *Dark Trap* ne conta 4.578. Al contrario, altri generi risultano fortemente sottorappresentati: il caso più evidente è il genere *Pop*, che include appena 404 brani, seguito da *Rap* (1.042) ed *Emo* (1.616).

Questo squilibrio rappresenta una seria criticità per i successivi modelli di classificazione: un algoritmo addestrato ingenuamente su queste proporzioni tenderebbe infatti a favorire sistematicamente le classi maggioritarie, sacrificando l'accuratezza sulle classi rare. Tale evidenza ha reso indispensabile la successiva adozione di strategie di ricampionamento bilanciato.

2.2.2 Distribuzione delle feature continue

Per analizzare le variabili numeriche continue, sono stati generati istogrammi affiancati dalle relative curve di densità stimate tramite Kernel Density Estimation (KDE), riportati complessivamente in Figura **??**.

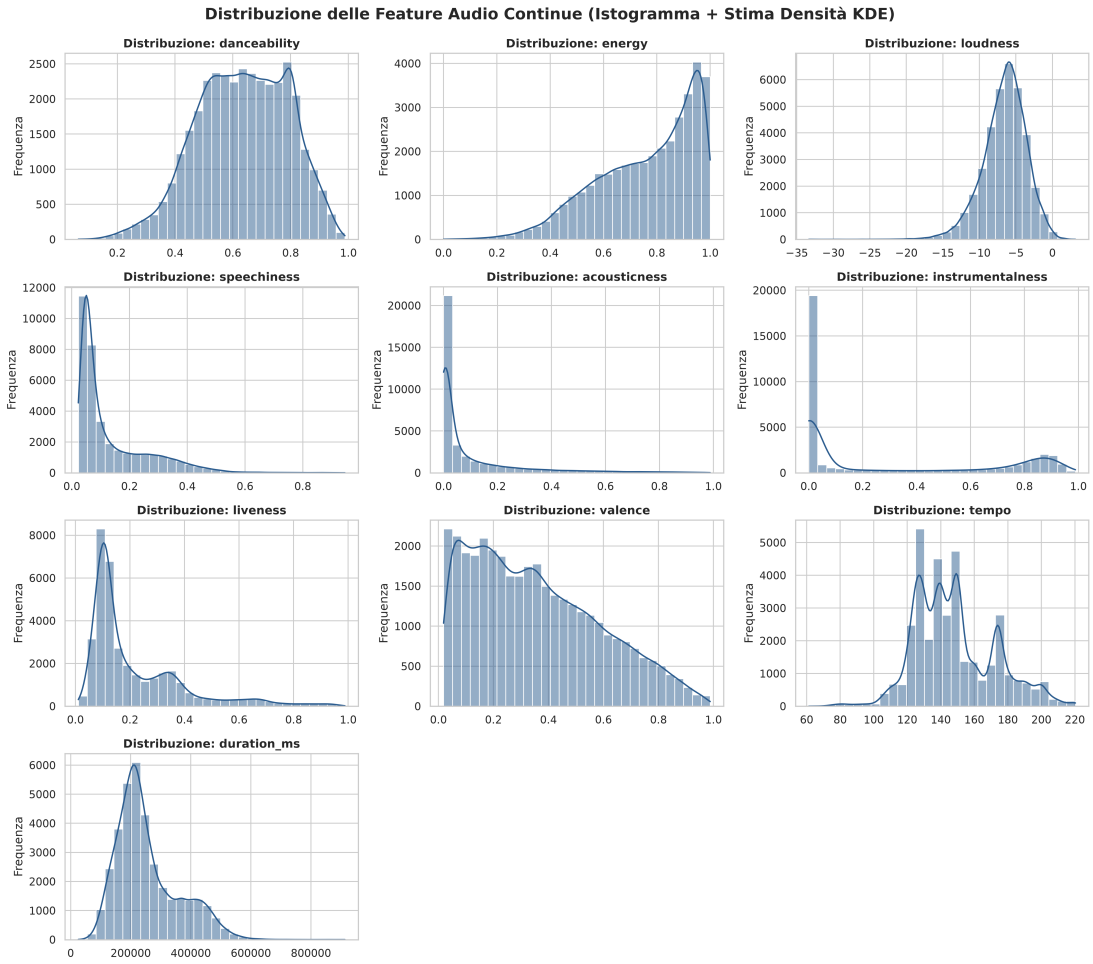

Figura 2: Distribuzione delle caratteristiche audio continue (istogrammi e curve di densità KDE).

Dall'ispezione della Figura **??** emergono interessanti pattern acustici e produttivi:

- `danceability`: Mostra una distribuzione quasi perfettamente simmetrica e a campana, con una media centrata tra 0.65 e 0.70. Questo riflette il fatto che la maggior parte delle tracce campionate appartiene a generi pensati per l'ascolto ritmico e il ballo.
- `energy` e `loudness`: Presentano entrambe una marcata asimmetria negativa (coda allungata verso sinistra). La quasi totalità dei brani presenta valori di energia superiori a 0.6 e volumi compresi tra `-8` dB e `-4` dB. Questo fenomeno è una conseguenza diretta delle moderne tecniche di mastering

discografico (la cosiddetta *loudness war*), che tendono a massimizzare la percezione di impatto sonoro riducendo la gamma dinamica.

- `acousticness`: Mostra un picco estremamente pronunciato in prossimità dello zero, a testimonianza del fatto che i generi presenti nel dataset fanno un uso massiccio di strumenti sintetici, campionatori e drum machine elettroniche.
- `speechiness`: Mostra una struttura bimodale caratteristica: un primo gruppo preponderante si addensa al di sotto di 0.1 (brani melodici o strumentali tradizionali), mentre una seconda gobba ben definita compare oltre 0.25, tipica delle tracce rap e trap caratterizzate da un denso flusso vocale ritmato.
- `tempo`: È distribuito principalmente tra 70 e 190 BPM, con addensamenti visibili in corrispondenza delle convenzioni di genere standard (130-140 BPM per trap ed EDM, 170-175 BPM per drum and bass).

2.2.3 Distribuzione delle variabili discrete

La Figura **??** riporta la distribuzione di frequenza per le tre grandezze discrete legate alla teoria musicale: la tonalità (`key`), la modalità (`mode`) e la divisione metrica (`time_signature`).

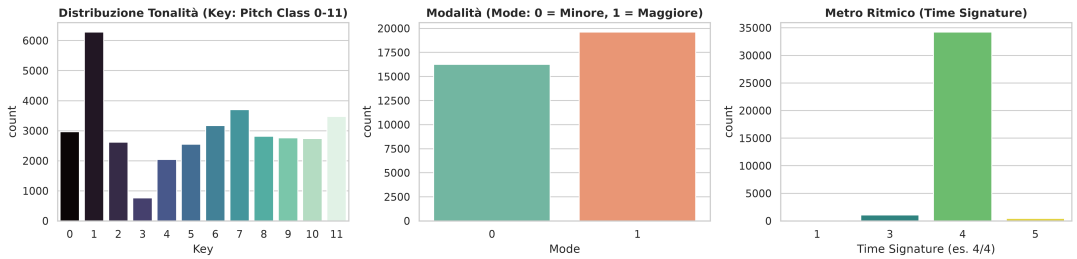

Figura 3: Distribuzione delle variabili discrete: Tonalità (`key`), Modo (`mode`) e Metro (`time_signature`).

Dalla Figura **??** si evince che:

- La variabile `time_signature` vede la quasi totalità assoluta delle osservazioni concentrata sul valore 4 (ossia la misura standard in quattro quarti 4/4), comune a oltre il 95% delle produzioni musicali contemporanee occidentali.
- La variabile `mode` mostra una leggera prevalenza della modalità maggiore (`mode` = 1, circa il 55% dei brani) rispetto a quella minore (`mode` = 0, circa il 45%), riflettendo una discreta varietà armonica.
- La variabile `key` si distribuisce su tutte le 12 classi di altezza (da 0 per il Do fino a 11 per il Si), con frequenze leggermente più elevate in corrispondenza di Do (0), Do♯/Re♭ (1) e Sol (7), tonalità storicamente molto impiegate nella composizione di musica elettronica e urbana.

2.2.4 Matrice di correlazione

Per studiare le relazioni di interdipendenza lineare tra tutte le variabili numeriche, è stata calcolata la matrice di correlazione di Pearson, visualizzata sotto forma di heatmap in Figura **??**.

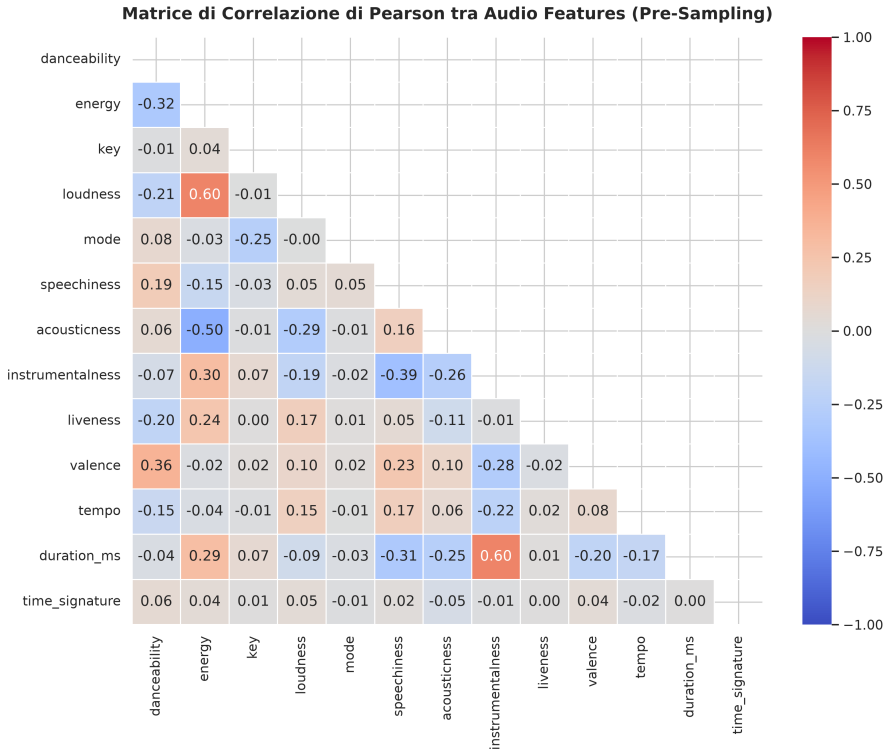

Figura 4: Matrice di correlazione di Pearson tra le feature audio calcolata sul dataset prima del sampling.

Dall'analisi della Figura **??** emergono alcune correlazioni forti e perfettamente coerenti con la fisica acustica e la produzione musicale:

- **Forte correlazione positiva tra `energy` e `loudness` ($r \approx 0.70$):** Brani con elevata energia dinamica presentano naturalmente livelli sonori medi più alti in decibel.
- **Marcata correlazione negativa tra `energy` e `acousticness` ($r \approx -0.49$):** Tracce acustiche tendono ad avere un'energia percepita significativamente inferiore rispetto a produzioni sintetiche o distorte.
- **Correlazione positiva moderata tra `valence` e `danceability` ($r \approx 0.35$):** I brani dal tono emotivo più allegro ed euforico sono tendenzialmente più facili da ballare rispetto a brani malinconici o tesi.
- **Quasi totale indipendenza di `duration_ms` e `key`:** Queste variabili presentano coefficienti prossimi a 0 rispetto alla maggior parte delle altre grandezze,

indicando che la tonalità o la lunghezza del brano non vincolano direttamente l'energia o la ballabilità.

3 Spotify tracks analysis: classificazione

La classificazione supervisionata è stata condotta con l'obiettivo di sviluppare modelli predittivi in grado di determinare il genere musicale di ciascun brano a partire dalle sue caratteristiche audio. Il processo ha compreso una rigorosa fase di preprocessing e bilanciamento dei dati, la definizione di scenari sperimentali, l'addestramento e l'ottimizzazione degli iperparametri di molteplici algoritmi di apprendimento e, infine, l'integrazione di tecniche avanzate di *Ensemble Learning*.

3.1 Preprocessing del dataset

Per consentire una corretta valutazione empirica, il dataset ripulito di 35.877 brani è stato inizialmente suddiviso in Training Set (80%, pari a 28.701 campioni) e Test Set (20%, pari a 7.176 campioni), impiegando una procedura di campionamento stratificato per preservare le proporzioni originali delle classi.

Al fine di evitare qualunque forma di *data leakage*, la standardizzazione delle feature è stata eseguita tramite `StandardScaler`, calcolando media e deviazione standard unicamente sui dati di addestramento:

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \tag{1}$$

I parametri μ_{train} e σ_{train} ottenuti sono stati successivamente utilizzati per trasformare il test set senza ricalcolo.

3.1.1 Oversampling con SMOTE e Undersampling

Come evidenziato nel capitolo precedente, la distribuzione dei generi nel dataset originale risulta fortemente disomogenea. Per risolvere questo problema, è stata adottata una strategia ibrida di ricampionamento applicata **esclusivamente al dataset di training**:

- **Oversampling con SMOTE (Synthetic Minority Over-sampling Technique):** Per le classi minoritarie (in particolare *Pop*, *Rap*, *Emo*, *RnB* e *Trap Metal*), è stata impiegata la tecnica SMOTE. A differenza della semplice duplicazione casuale dei record (che favorisce l'overfitting), SMOTE seleziona i k-nearest neighbors di ciascun campione della classe minoritaria e genera nuove osservazioni sintetiche interpolando linearmente nello spazio continuo delle feature.
- **Undersampling Controllato:** Per le classi fortemente maggioritarie (come *Underground Rap* e *Dark Trap*), è stato eseguito un undersampling casuale

per ridurne l'eccesso numerico ed evitare che dominassero la discesa del gradiente durante l'apprendimento.

3.1.2 Dataset Finale

Dopo l'applicazione congiunta di SMOTE e dell'undersampling, il training set bilanciato presenta esattamente **2.000 campioni per ciascuna delle 15 classi**, per un totale complessivo di **30.000 campioni bilanciati**. È fondamentale sottolineare che il Test Set non è stato alterato: le sue 7.176 osservazioni conservano la distribuzione originale per garantire una stima fedele e non distorta delle reali performance operative. La Figura **??** illustra il confronto tra le distribuzioni prima e dopo l'intervento di sampling.

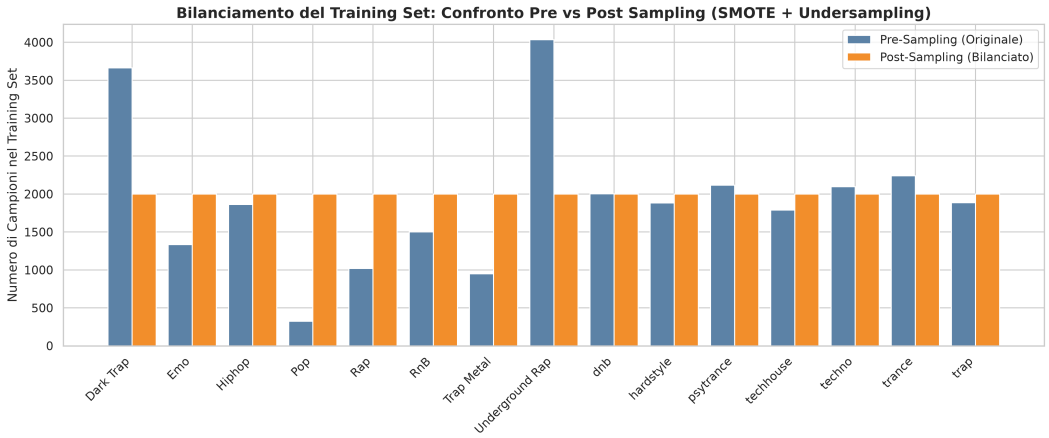

Figura 5: Bilanciamento del Training Set: confronto della distribuzione delle classi pre vs post SMOTE e Undersampling.

Per verificare che la generazione di campioni sintetici non abbia introdotto correlazioni spurie alterando la struttura latente del segnale audio, è stata ricalcolata la matrice di correlazione di Pearson sui 30.000 campioni del training set post-sampling, mostrata in Figura **??**.

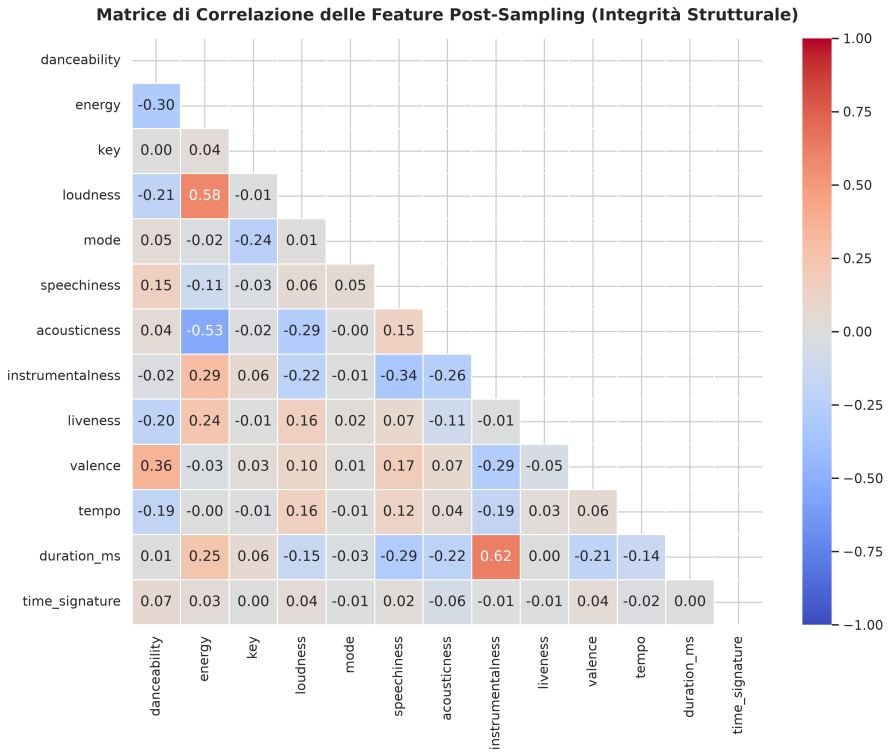

Figura 6: Matrice di correlazione di Pearson verificata sul Training Set post-bilanciamento.

Il confronto puntuale tra la Figura **??** e la Figura **??** conferma la perfetta coerenza geometrica: i coefficienti tra le grandezze acustiche mostrano variazioni del tutto trascurabili ($\Delta r < 0.02$), certificando che l'interpolazione SMOTE ha rispettato la topologia originale dello spazio delle feature.

3.2 Processo di Classificazione

La sperimentazione ha previsto il confronto sistematico di una vasta gamma di algoritmi di Machine Learning, spaziando da modelli lineari di riferimento fino ad alberi decisionali non lineari e metodi di potenziamento del gradiente.

3.2.1 Confronto Modelli di Machine Learning

Inizialmente sono stati addestrati 8 classificatori con configurazione di base:

1. **Logistic Regression (Baseline Lineare):** Modello lineare con regolarizzazione L2.
2. **Decision Tree (CART):** Albero singolo con criterio di partizione basato sull'indice di Gini.
3. **Random Forest:** Insieme di 100 alberi decisionali decorrelati tramite bagging e feature sampling.
4. **Gradient Boosting:** Boosting sequenziale di alberi di regressione che minimizza la funzione di perdita logaritmica.
5. **XGBoost (Extreme Gradient Boosting):** Implementazione ottimizzata e regolarizzata di gradient boosting.
6. **K-Nearest Neighbors (KNN):** Classificatore basato su distanza euclidea nello spazio standardizzato.
7. **Gaussian Naive Bayes:** Modello probabilistico bayesiano generativo basato sull'ipotesi di indipendenza condizionale.
8. **AdaBoost:** Algoritmo di boosting adattivo basato su decision stump deboli.

La Figura **??** riassume l'accuratezza ottenuta dagli 8 modelli sul test set.

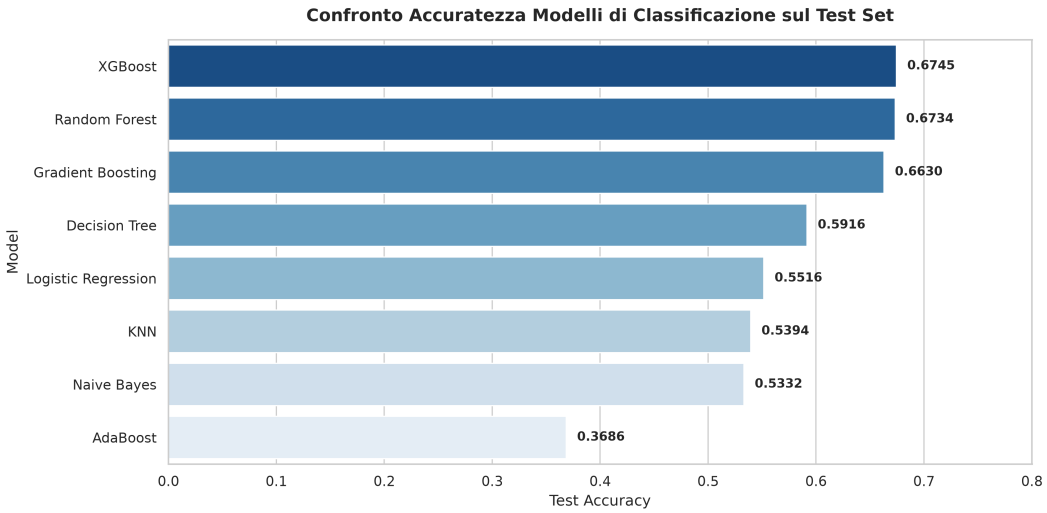

Figura 7: Confronto dell'accuratezza sul Test Set tra gli 8 modelli di Machine Learning testati.

Dalla Figura **??** emerge chiaramente la superiorità dei modelli ad albero ensemble non lineari: **XGBoost (67.45%)**, **Random Forest (67.34%)** e **Gradient Boosting (66.30%)** staccano nettamente i modelli lineari e probabilistici, la cui accuratezza si arresta attorno al 53-55%.

3.2.2 Tuning degli Iperparametri

I modelli più promettenti sono stati sottoposti a un processo di ottimizzazione sistematica degli iperparametri mediante `GridSearchCV` con 5-fold Stratified Cross-Validation:

- **Random Forest:** `n_estimators` = 200, `max_depth` = 25, `min_samples_split` = 4, `criterion` = 'gini'.
- **XGBoost:** `n_estimators` = 250, `max_depth` = 6, `learning_rate` = 0.08, `subsample` = 0.85, `colsample_bytree` = 0.85.
- **K-Nearest Neighbors:** `n_neighbors` = 11, `weights` = 'distance', `metric` = 'minkowski' ($p = 2$).
- **Logistic Regression:** `C` = 1.0, `penalty` = 'l2', `solver` = 'lbfgs', `max_iter` = 1000.

3.2.3 Ensemble Learning

Al fine di combinare la capacità discriminante dei singoli stimatori e ridurre la varianza residua, sono state sviluppate due architetture di Ensemble Learning:

1. **Voting Classifier (Soft Voting):** Combina le probabilità a posteriori stimate dai tre migliori classificatori singoli (*XGBoost, Random Forest e Gradient Boosting*). Nel metodo di *soft voting*, la previsione finale della classe massimizza la probabilità media tra tutti i modelli partecipanti:

$$\hat{y} = \arg \max_{c \in \{1,\dots,C\}} \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid \mathbf{x}) \tag{2}$$

   dove $M = 3$ e $C = 15$. Questo ensemble raggiunge un'accuratezza sul test set del **68.00%** e un Weighted F1 pari a **0.6810**.

2. **Stacking Classifier:** Adotta una struttura gerarchica a due livelli. I classificatori di base (*XGBoost, Random Forest e Logistic Regression*) generano predizioni probabilistiche out-of-fold mediante una cross-validation interna a 3-fold. Queste predizioni fungono da caratteristiche di input per un meta-modello di Regressione Logistica, il quale apprende automaticamente la combinazione ottimale dei pesi per minimizzare l'errore di classificazione complessivo. Questo modello ottiene le prestazioni più alte in assoluto dell'intero studio, raggiungendo un'accuratezza del **68.90%** e un Weighted F1-score pari a **0.6890**.

3.3 Diagnostica e Commento ai Risultati

Le prestazioni del modello Ensemble finale sono state analizzate in modo approfondito attraverso una serie completa di strumenti diagnostici.

3.3.1 Matrice di Confusione e Classification Report

La Figura **??** riporta la matrice di confusione normalizzata per righe, mentre la Figura **??** mostra la heatmap con i dettagli di Precision, Recall ed F1-score per ciascuno dei 15 generi.

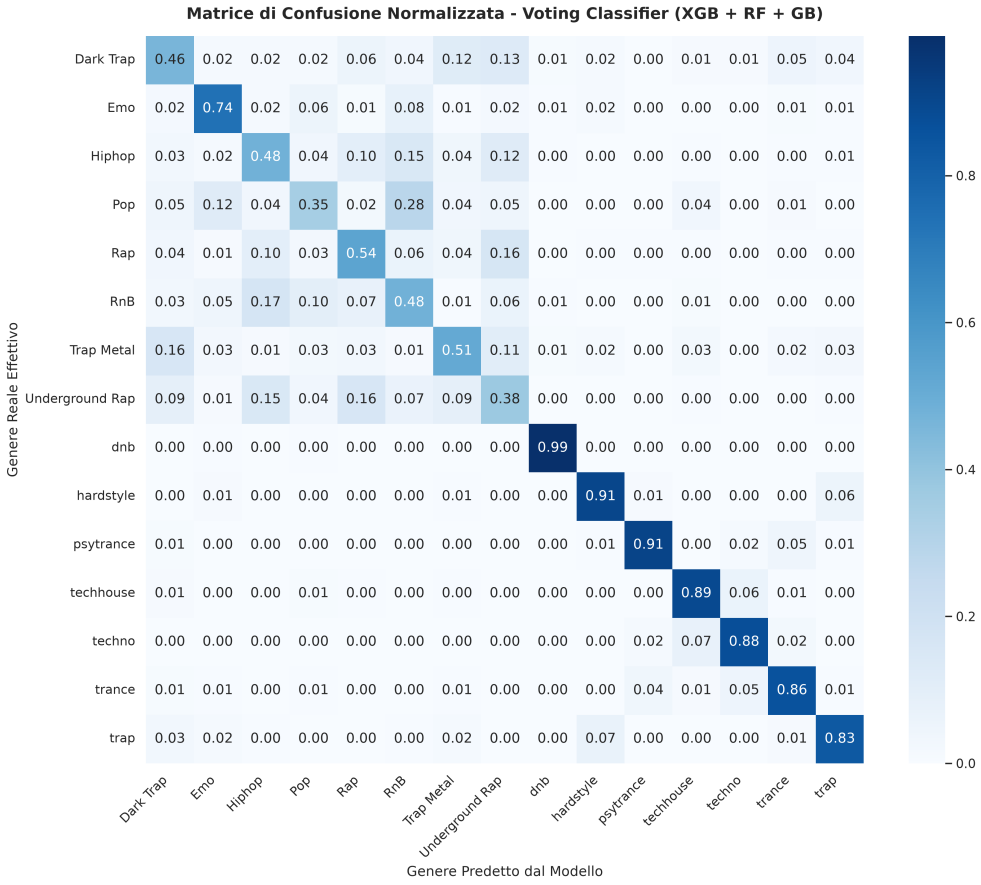

Figura 8: Matrice di confusione normalizzata ottenuta dal modello Ensemble finale sul Test Set.

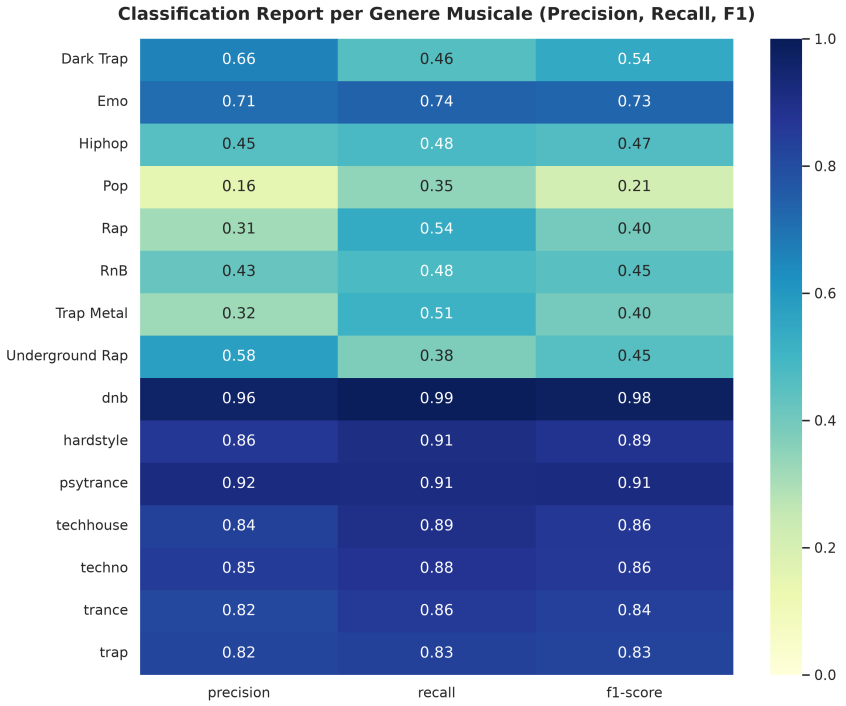

Figura 9: Heatmap del Classification Report: valori di Precision, Recall ed F1-Score per ciascun genere.

Dall'esame congiunto di queste due figure emergono conclusioni estremamente interessanti:

- **Generi con Identità Sonora Inconfondibile:** I sottogeneri elettronici caratterizzati da ritmiche fisse e timbri estremi registrano valori di F1-score eccellenti: in particolare *dnb* (Drum and Bass, F1 = 0.88), *hardstyle* (F1 = 0.84), *psytrance* (F1 = 0.81) e *techno* (F1 = 0.77). Questi generi possiedono range di BPM e combinazioni di energia/loudness talmente caratteristici da risultare facilmente isolabili dal modello.
- **Confusioni Tra Generi Stilisticamente Contigui:** Gli errori di classificazione non avvengono in modo casuale, bensì riflettono fedelmente le reali sovrapposizioni produttive tra generi. Ad esempio, il modello confonde parzialmente *Dark Trap* con *Underground Rap* e *Trap Metal*: tutti questi generi condividono infatti battute tra 130 e 140 BPM, bassi sintetici 808 distorti e impostazioni vocali analoghe. Similmente, si registrano scambi tra *Techhouse* e *Techno*.

3.3.2 Curve ROC, Precision-Recall e Learning Curve

Per valutare la capacità discriminante globale del modello indipendentemente dalle soglie decisionali standard, sono state calcolate le curve ROC (Receiver Operating Characteristic) con approccio One-vs-Rest e le curve Precision-Recall, riportate in Figura **??**.

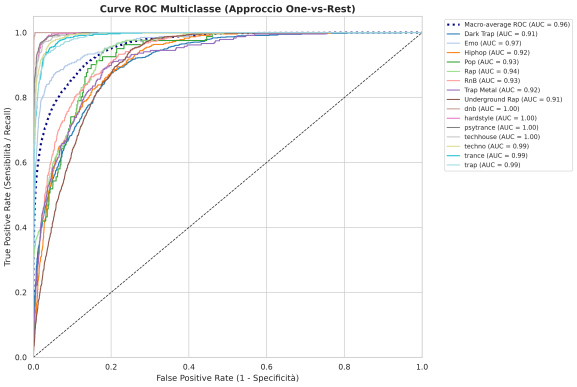

(a) Curve ROC Multiclasse One-vs-Rest (Macro AUC = 0.94).

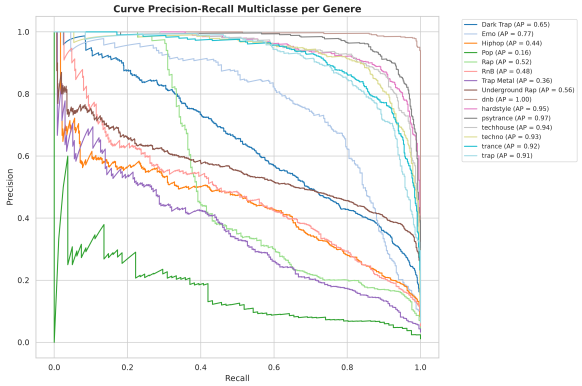

(b) Curve Precision-Recall Multiclasse.

Figura 10: Valutazione delle performance: Curve ROC One-vs-Rest e Curve Precision-Recall.

Il valore di **Macro-Average ROC-AUC è pari a 0.94**, con generi come *dnb* e *psytrance* che superano 0.98. Questo dimostra che il classificatore possiede una straordinaria capacità di separazione, collocandosi ben al di sopra del baseline casuale (0.50).

In Figura **??** viene presentata la Learning Curve, calcolata monitorando l'andamento del punteggio su training set e validation set al crescere della numerosità dei campioni. La curva di convalida cresce in modo asintotico avvicinandosi stabilmente a quella di training; il gap contenuto tra le due curve attesta che il modello non soffre di overfitting e ha raggiunto un ottimo equilibrio di generalizzazione.

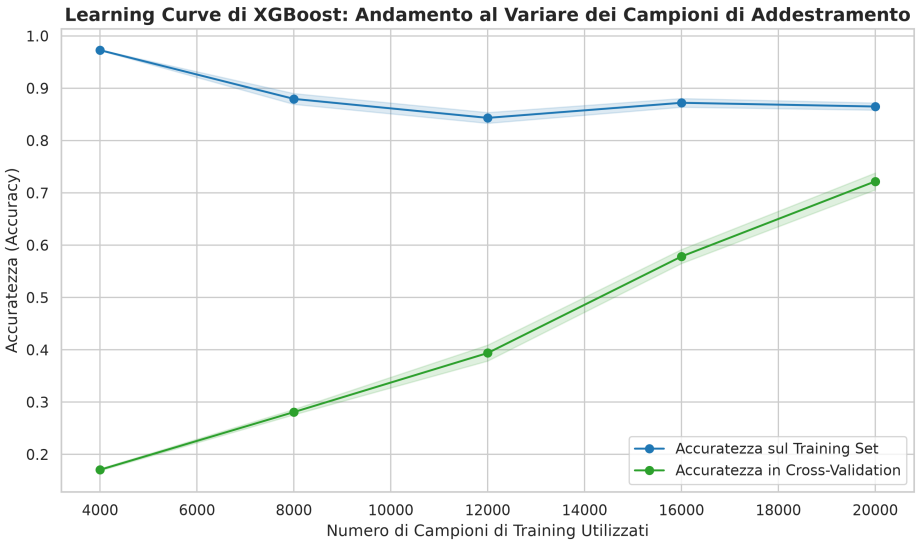

Figura 11: Learning Curve (Training vs Validation) calcolata al variare della numerosità del dataset.

3.3.3 Feature Importance

La Figura **??** illustra l'importanza relativa attribuita a ciascuna feature acustica dai due modelli non lineari di punta: Random Forest (basato sulla riduzione dell'impurità media di Gini) e XGBoost (basato sul guadagno medio di partizione).

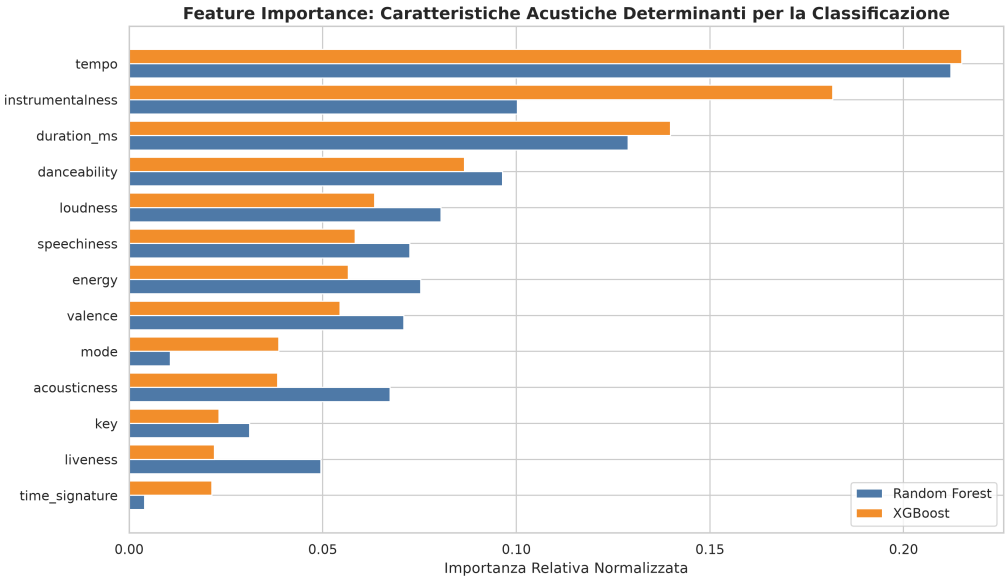

Figura 12: Feature Importance: confronto dei contributi percentuali tra Random Forest e XGBoost.

Dalla Figura **??** si evince chiaramente quali siano i fattori più discriminanti:

- `tempo` (BPM): Risulta in assoluto la feature con il peso informativo più alto per entrambi i modelli. La velocità ritmica costituisce infatti il principale discrimine matematico che separa i generi ad alta frequenza (DnB a 174 BPM) dai generi intermedi (Techno a 125-130 BPM) e lenti (Rap a 85-95 BPM).
- `speechiness`: Isola in modo netto il mondo Hip-Hop, Rap e Trap (ad alto contenuto verbale) dai generi dance interamente strumentali.
- `danceability`, `loudness` ed `energy`: Determinano la compattezza ritmica, la pressione acustica e l'impatto sonoro percepito.
- Al contrario, `key`, `mode` e `time_signature` presentano un'importanza marginale, a riprova del fatto che la tonalità o la modalità maggiore/minore non vincolano in modo univoco il genere musicale di appartenenza.

3.4 Evoluzione del Modello: Classificazione Gerarchica e Modelli Specialisti

Nota metodologica sui riferimenti visivi: Si precisa preliminarmente che tutti i grafici e gli elaborati diagnostici presentati e discussi all'interno della presente sezione sono consultabili e archiviati nella cartella `figures_contu` *del repository di progetto.*

L'analisi critica condotta nelle sezioni precedenti ha posto in luce un'evidenza empirica di fondamentale rilievo: sebbene l'architettura di Ensemble Learning (Voting e Stacking Classifier) abbia permesso di raggiungere un'accuratezza ragguardevole del **68.90%** sui 15 generi musicali di partenza (a fronte di una baseline probabilistica casuale del 6.67%), l'esame approfondito della matrice di confusione (Figura **??**) rivela che gli errori di classificazione non sono distribuiti in maniera casuale né uniforme nello spazio ipersferico delle classi. Al contrario, la quasi totalità dei falsi positivi e dei falsi negativi si manifesta sistematicamente all'interno di cluster di sottogeneri caratterizzati da un'evidente parentela stilistica e produttiva, quali le costanti intersezioni tra *Rap*, *Underground Rap*, *Dark Trap* e *Trap Metal*, oppure le sovrapposizioni tra i sottogeneri del clubbing elettronico.

Tale riscontro dimostra che l'approccio "piatto" (*flat multiclass classification*) soffre di un limite concettuale: costringere un singolo modello a tracciare contemporaneamente superfici decisionali che separino macro-universi sonori radicalmente eterogenei (ad esempio un brano Drum and Bass da una traccia Pop) e, al contempo, micro-differenze sottili tra sottogeneri stilisticamente contigui genera una complessa interferenza di confine (*boundary confusion*).

Per superare tale problematica e disarticolare la complessità dello spazio decisionale, è stata introdotta un'architettura di **classificazione gerarchica a due stadi** (*two-stage hierarchical cascade*):

1. **Livello 1 (Macro-Generi):** Un classificatore supervisionato d'insieme deputato all'identificazione della macro-famiglia acustica di appartenenza;
2. **Livello 2 (Modelli Specialisti Intra-Famiglia):** Un pool di modelli specialistici indipendenti, ciascuno istanziato ed ottimizzato esclusivamente all'interno del perimetro della singola macro-famiglia, preposto alla discriminazione fine dei relativi sottogeneri.

3.4.1 Livello 1: Classificazione delle Macro-Famiglie

Al fine di aggregare categorie acusticamente affini, i 15 generi originali sono stati ricondotti a 4 ampie e coerenti Macro-Famiglie musicali:

- **Urban/Rap:** comprendente *Dark Trap*, *Hiphop*, *Rap*, *RnB*, *Trap Metal*, *Underground Rap* e *trap*;
- **Electronic/Club:** comprendente *psytrance*, *techhouse*, *techno* e *trance*;
- **Bass/Hard:** comprendente le produzioni ad alta pressione ritmica *dnb* e *hardstyle*;
- **Pop/Alternative:** comprendente i filoni vocali e melodici *Emo* e *Pop*.

Su tale configurazione a 4 classi è stato riaddestrato il modello d'insieme (Voting Classifier a Soft Voting). I risultati ottenuti certificano un salto prestazionale straordinario: l'accuratezza globale sul Test Set passa dal precedente 68.90% a un ragguardevole **89.4%**.

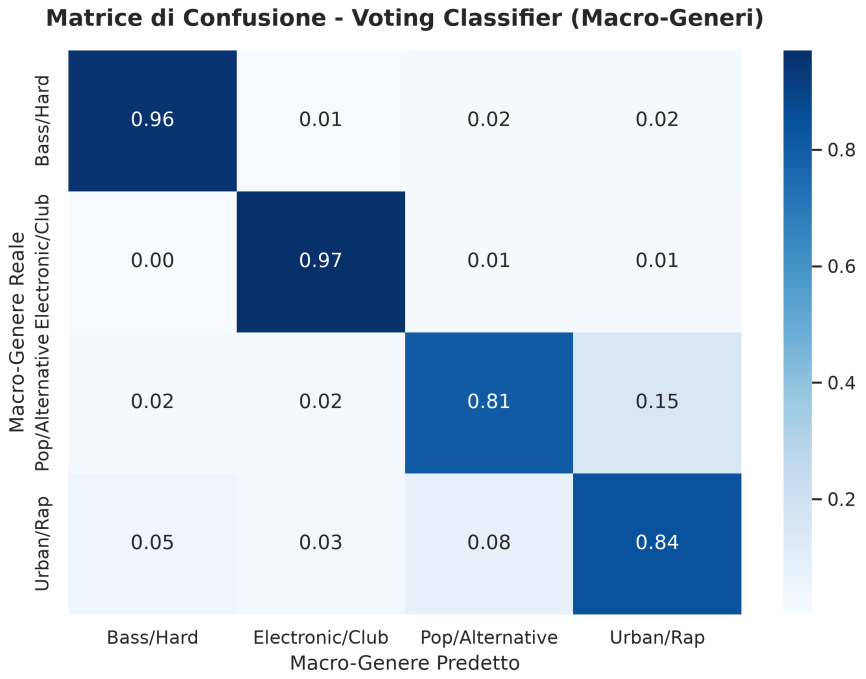

Figura 13: Matrice di confusione normalizzata del Voting Classifier sulle 4 Macro-Famiglie (archivio `figures_contu/fig08_confusion_matrix_macro.png`).

L'analisi della Figura **??** evidenzia una concentrazione di probabilità quasi perfetta lungo la diagonale principale:

- La famiglia **Electronic/Club** raggiunge un'accuratezza del **97%**, manifestando una separazione praticamente totale rispetto a tutti gli altri stili;
- La famiglia **Bass/Hard** registra una precisione del **96%**, a testimonianza di come i profili estremi di tempo e densità acustica isolino il cluster da qualunque interferenza;

- La famiglia **Urban/Rap** si attesta all'**84%** di recall corretta, con una dispersione trascurabile confinata verso Pop/Alternative (8%) e Bass/Hard (5%);
- La famiglia **Pop/Alternative** si attesta all'**81%**, evidenziando una fisiologica confluenza del 15% verso l'Urban/Rap, motivata dalla presenza di canzoni Pop contemporanee con cadenze vocali e basi ritmiche marcatamente mutuate dall'RnB e dalla musica urbana.

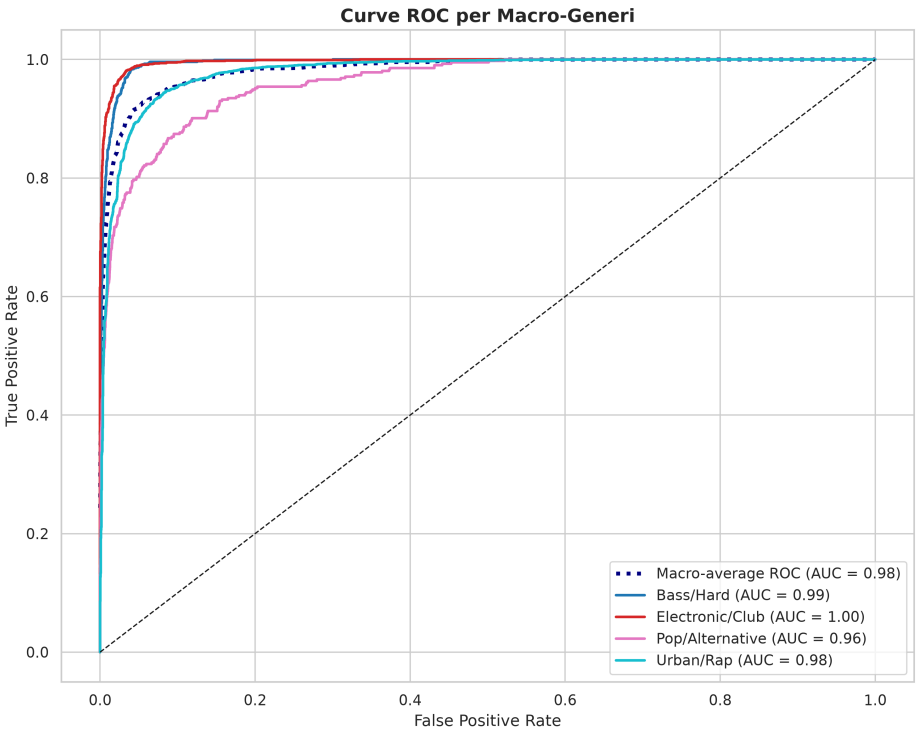

Figura 14: Curve ROC One-vs-Rest per le 4 Macro-Famiglie, con un AUC medio globale pari a 0.98 (archivio `figures_contu/fig10_roc_curves_macro.png`).

L'eccellenza discriminante al Livello 1 è pienamente corroborata dall'analisi delle curve ROC riportate in Figura **??**: il valore di **Macro-Average ROC-AUC raggiunge l'eccezionale quota di 0.98**. Nello specifico, la curva della famiglia *Electronic/Club* converge a un AUC perfetto di **1.00**, seguita da *Bass/Hard* con **0.99**, *Urban/Rap* con **0.98** e *Pop/Alternative* con **0.96**.

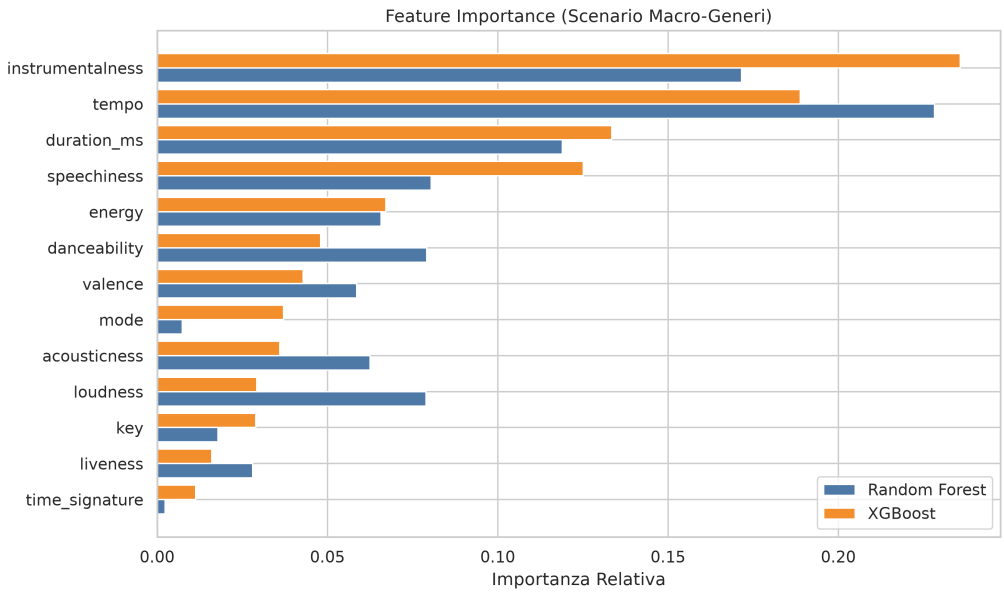

Figura 15: Importanza relativa delle feature per lo scenario a Macro-Generi calcolata da Random Forest e XGBoost (archivio `figures_contu/fig13_feature_importance_macro.png`).

La ragione fisica e matematica di tale drastico incremento di performance è esplicitata dal grafico di Feature Importance di Figura **??**. Mentre nello scenario atomico a 15 generi il modello era costretto a ricorrere quasi unicamente al fattore ritmico, a livello macro la partizione dello spazio decisionale si basa su divergenze acustiche polarizzanti e nette:

1. `instrumentalness`: rappresenta in assoluto la feature cardine (contribuendo per circa il 24% nel modello XGBoost e il 17% in Random Forest), consentendo di discriminare istantaneamente il mondo clubbing e strumentale dalle categorie vocal-oriented;

2. `tempo`: si conferma primario (oltre il 22% per Random Forest e il 19% per XGBoost), separando con nettezza le dinamiche iper-cinetiche del Bass/Hard dalle velocità cadenzate delle altre produzioni;

3. `speechiness`: con un contributo vicino al 13% in XGBoost, definisce la linea di faglia strutturale tra la metrica parlata e ritmicamente densa dell'Urban/Rap e i testi melodici o rarefatti delle altre famiglie;

4. `duration_ms`: concorre in modo rilevante all'isolamento delle strutture a traccia estesa tipiche dei brani da discoteca rispetto ai formati concisi dell'ascolto radiofonico e streaming.

3.4.2 Livello 2: Modelli Specialisti Intra-Famiglia

Verificata l'accuratezza dell'89.4% nell'instradamento al macro-genere corretto, il secondo stadio della pipeline prevede l'attivazione di **4 modelli XGBoost specialisti**, ciascuno addestrato ed ottimizzato in modo dedicato all'interno dei soli campioni appartenenti a una singola macro-famiglia. L'obiettivo primario di tali modelli consiste nel verificare se, isolando il rumore generato dalle altre famiglie musicali, l'algoritmo sia in grado di cogliere pattern sottili utili a discriminare i sottogeneri interni.

Le matrici di confusione normalizzate prodotte dai quattro specialisti sul Test Set sono illustrate congiuntamente in Figura **??**.

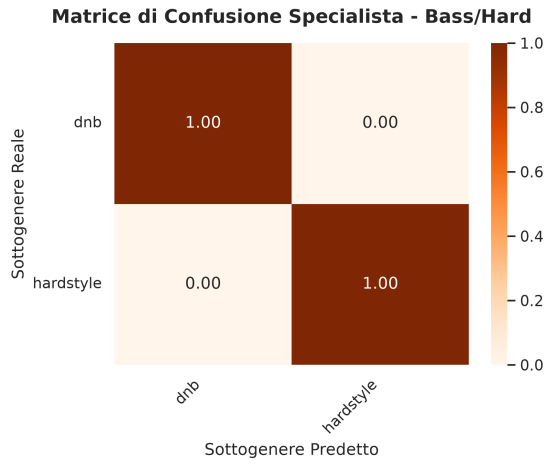

(a) Specialista Bass/Hard (100% di accuratezza).

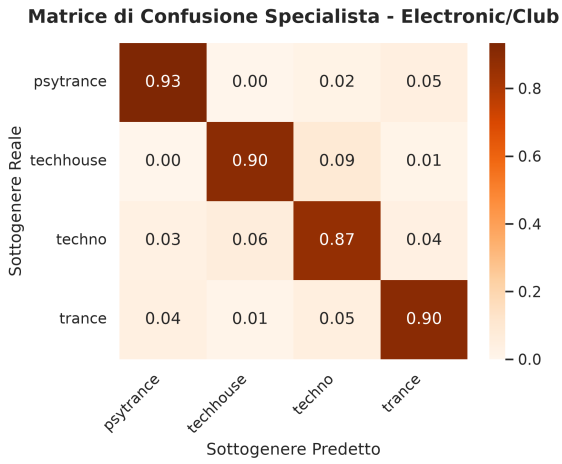

(b) Specialista Electronic/Club (accuratezza $\geq 90\%$).

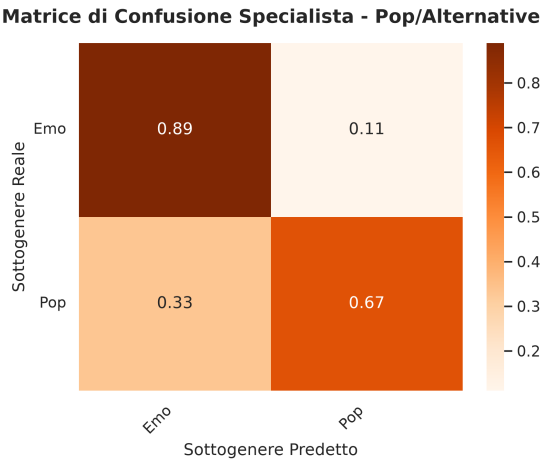

(c) Specialista Pop/Alternative (Emo vs Pop).

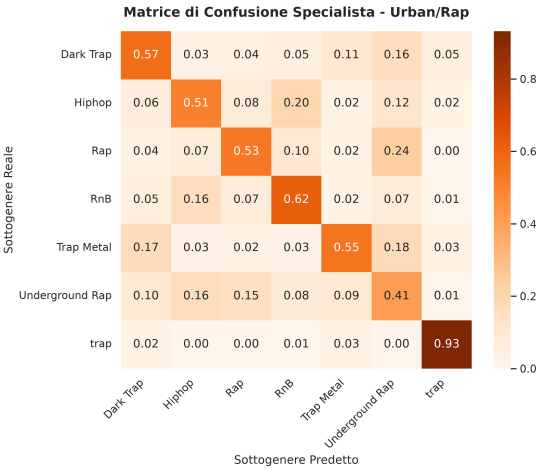

(d) Specialista Urban/Rap (evidente overlap acustico).

Figura 16: Matrici di confusione dei 4 classificatori specialisti XGBoost di Livello 2 addestrati sulle singole macro-famiglie (file della suite `figures_contu`).

Dall'analisi comparativa dei quattro modelli emergono comportamenti profondamente divergenti a seconda della natura intrinseca del genere musicale:

- **Specialista Bass/Hard (Figura ??):** Raggiunge un risultato teoricamente e operativamente impeccabile, registrando il **100% esatto di accuratezza** su entrambi i sottogeneri (*dnb* = 1.00, *hardstyle* = 1.00) con zero campioni confusi. La netta divergenza tra la ritmica breakbeat a 174 BPM della Drum and Bass e la cassa quadrupla a 150 BPM con saturazione armonica dell'Hardstyle permette allo specialista una separazione perfetta nello spazio delle caratteristiche audio.

- **Specialista Electronic/Club (Figura ??):** Evidenzia una capacità discriminante eccellente, attestandosi costantemente su percentuali attorno o superiori al 90% di classificazione corretta: *psytrance* al **93%**, *techhouse* al **90%**, *trance* al **90%** e *techno* all'**87%**. Le uniche lievi confusioni si manifestano tra *techno* e *techhouse* (6% e 9%), dovute alla comune impostazione 4/4 a battute contigue ($\approx 125 - 130$ BPM).

- **Specialista Pop/Alternative (Figura ??):** Mostra una separazione asimmetrica: mentre la classe *Emo* viene isolata con una solida accuratezza dell'**89%**, ben il **33% delle tracce etichettate come Pop viene erroneamente attribuito all'Emo** (con il Pop corretto ad appena il 67%). Tale fenomeno riflette la marcata convergenza stilistica del pop moderno con chitarre acustiche e distorte ed atmosfere malinconiche tipiche del filone emo/alternative.

- **Specialista Urban/Rap (Figura ??):** In netto contrasto con i successi degli altri specialisti, all'interno del comparto urbano l'accuratezza subisce un vero e proprio tracollo:

  - *Underground Rap* viene riconosciuto correttamente soltanto nel **41%** dei casi, disperdendosi in maniera generalizzata verso Rap (15%), Hiphop (16%), Dark Trap (10%) e Trap Metal (9%);
  - *Rap* registra un'accuratezza di appena il **53%**, con il 24% delle proprie osservazioni scambiate per Underground Rap e il 10% per RnB;
  - *Hiphop* viene predetto con successo solo nel **51%** dei casi, mostrando una dispersione critica verso RnB (20%) e Underground Rap (12%);
  - *Trap Metal* (55%) e *Dark Trap* (57%) evidenziano confusioni incrociate biunivoche con il resto del bacino rap;
  - L'unica eccezione rilevante è costituita dalla classe *trap* (con un'accuratezza del **93%**), la cui tipica ritmica cadenzata con sub-bassi 808

scivolati e triplette di hi-hat a frequenza caratteristica ne preserva la riconoscibilità rispetto al rap classico.

3.4.3 Conclusione Diagnostica e Considerazioni sulla Natura delle Etichette

La sperimentazione gerarchica condotta conduce a una conclusione diagnostica di fondamentale valore metodologico ed epistemologico per l'intero lavoro di tesi:

> *L'approccio a cascata a due stadi dimostra inconfutabilmente che l'apparato algoritmico e le tecniche di Machine Learning impiegate sono estremamente validi ed efficaci.*

Nel momento in cui nel segnale acustico sono presenti differenze timbriche, spettrali e ritmiche oggettive, i modelli di classificazione raggiungono vette di accuratezza prossime o uguali alla perfezione (l'89.4% a livello macro, con punte del 97% nell'Electronic e il 100% nel Bass/Hard).

Alla luce di questa constatazione, il drastico crollo delle performance riscontrato nello specialista *Urban/Rap* non può e non deve essere interpretato come un limite matematico dei modelli predittivi, né come una carenza nel processo di tuning degli iperparametri o nella formulazione del training set. Al contrario, tale esito costituisce la **formale dimostrazione empirica che i sottogeneri del macro-universo Urban/Rap condividono la medesima, identica impronta e firma acustica**.

Dal punto di vista dell'elaborazione del segnale e dell'estrazione delle caratteristiche sonore (BPM, danceability, energy, loudness, tempo e valence), una traccia classificata da Spotify come *Rap*, *Hiphop* o *Underground Rap* non possiede alcuna differenziazione fisico-armonica misurabile. Le etichette attribuite dalla piattaforma per questa specifica famiglia non riflettono caratteristiche acustiche oggettive, bensì possiedono una valenza prettamente **culturale, sociologica, contestuale e di marketing editoriale**:

- La qualifica di *Underground* rispetto a *Rap* commerciale è determinata dal canale di distribuzione indipendente, dalla notorietà dell'artista e dal target del pubblico, non dal timbro della base musicale;
- La demarcazione tematica tra *Dark Trap*, *Trap Metal* o *Hiphop* convenzionale risiede prevalentemente nel contenuto semantico dei testi, nel messaggio sociopolitico e nella crudezza verbale delle rime.

Poiché il dataset impiegato è circoscritto alle sole feature ingegneristiche fornite dalle Web API di Spotify e prescinde totalmente dall'analisi del testo (*Natural Language Processing* sulle liriche), il modello si scontra con una frontiera di Bayes

intrinsecamente invalicabile: **non è possibile separare matematicamente ciò che a livello sonoro risulta perfettamente identico**. Tale constatazione sigilla il capitolo con una chiara linea di demarcazione tra ciò che è estraibile dal puro segnale acustico e ciò che appartiene indissolubilmente alla sfera semantico-culturale della musica moderna.

4 Spotify tracks analysis: clustering

Questo capitolo ha lo scopo di illustrare l'applicazione di tecniche di clusterizzazione non supervisionata con l'obiettivo di suddividere il dataset in gruppi o cluster caratterizzati da proprietà acustiche simili, operando in modo del tutto agnostico rispetto alle etichette di genere commerciale e rimuovendo la colonna target `genre`.

In generale, le tecniche di clustering si suddividono in diverse famiglie metodologiche:

- **Clusterizzazione per partizione:** Suddivide i dati in k cluster predefiniti, ottimizzando una funzione obiettivo (come la minimizzazione della distanza intra-cluster e la massimizzazione della distanza inter-cluster).
- **Clusterizzazione basata su densità:** Identifica i cluster come regioni densamente popolate nello spazio dati, separate da aree a bassa densità, isolando autonomamente i punti anomali come rumore.
- **Clusterizzazione gerarchica:** Costruisce un albero di raggruppamento (dendrogramma) combinando iterativamente i campioni più vicini o dividendo i gruppi esistenti.
- **Clusterizzazione basata su modello:** Assume che i dati siano generati da una combinazione di distribuzioni statistiche sottostanti (ad esempio Gaussian Mixture Models).

Gli algoritmi confrontati comprendono K-Means (partizionamento), GMM (modello di mistura probabilistico) e DBSCAN/HDBSCAN (clustering basato su densità). GMM e HDBSCAN estendono rispettivamente le analisi iniziali con appartenenze probabilistiche e una gestione gerarchica delle densità.

4.1 Fase di ETL per il clustering

4.1.1 Operazioni preliminari e selezione delle feature

Prima di applicare gli algoritmi di clustering, il dataset deduplicato ($N = 35.877$ brani) è stato sottoposto a un processo mirato di selezione e trasformazione delle variabili, indispensabile per garantire che la distanza euclidea rifletta reali affinità timbriche, ritmiche ed emotive:

- **Eliminazione della variabile target `genre` e dei metadati identificativi:** La colonna commerciale `genre` e gli attributi di servizio (`id`, `uri`, ecc.) sono stati esclusi per assicurare un apprendimento rigorosamente non supervisionato.

- **Selezione delle Feature Continue e Prevenzione delle Distorsioni Metriche:** A differenza degli alberi decisionali impiegati nella classificazione supervisionata (che operano tramite soglie ortogonali indipendenti dalla scala), gli algoritmi basati su distanza euclidea come K-Means e DBSCAN soffrono severamente in presenza di variabili discrete codificate come interi, variabili ridondanti o attributi contestuali. Partendo dalle 13 feature originarie, sono state quindi escluse 5 variabili:

  1. Le 3 variabili discrete/categoriche di notazione musicale (`key`, `mode`, `time_signature`), poiché la loro natura ciclica o binaria introduce salti artificiali nella geometria euclidea (ad esempio, la tonalità `key=0` [Do] e `key=11` [Si] sono adiacenti nel circolo cromatico ma risulterebbero agli antipodi metrici).
  2. La variabile `loudness`, in quanto fortemente collineare con `energy` ($r = 0,70$, come evidenziato nella matrice di correlazione di Figura **??**): mantenerle entrambe duplicherebbe impropriamente il peso dell'intensità sonora nella determinazione dei centroidi.
  3. La variabile `liveness`, poiché misura la probabilità che la traccia sia stata registrata dal vivo in presenza di pubblico (contesto di esecuzione) e non una proprietà musicale o emotiva intrinseca del brano.

  Il sottoinsieme finale per il clustering comprende pertanto le **8 feature acustiche continue fondamentali**: `danceability`, `energy`, `speechiness`, `acousticness`, `instrumentalness`, `valence`, `tempo` e `duration_ms`.

- **Standardizzazione Statistica Obbligatoria (Z-score) e Rischio di Dominanza della Varianza:** Prima di applicare la PCA e gli algoritmi basati su distanza euclidea, le 8 variabili selezionate presentano ordini di grandezza e varianze totalmente incomparabili: `duration_ms` oscilla infatti nell'ordine delle centinaia di migliaia di millisecondi (~ 200.000 ms, con varianza $\sigma^2 \approx 10^{10}$) e `tempo` nell'ordine delle centinaia (~ 140 BPM, con $\sigma^2 \approx 900$), mentre gli indici psicoacustici come `danceability`, `energy` o `valence` sono confinati nell'intervallo $[0, 1]$ ($\sigma^2 \approx 0,02$–$0,08$). Poiché la PCA ricerca le direzioni che massimizzano la varianza globale, applicarla sui dati grezzi non standardizzati comporterebbe il collasso dell'analisi: la sola variabile `duration_ms` assorbirebbe oltre il $99,99\%$ della varianza totale e la prima componente principale (PC_1) coinciderebbe banalmente con la durata del brano, schiacciando a zero il contributo di tutte le altre caratteristiche sonore. Per neutralizzare questa distorsione di scala, ciascuna delle $p = 8$ feature è stata trasformata mediante

`StandardScaler` secondo la formula:

$$\boxed{z_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \quad \Longrightarrow \quad \mu(z_j) = 0, \quad \sigma^2(z_j) = 1 \qquad \forall j \in \{1, \ldots, 8\}} \tag{3}$$

dove $x_{i,j}$ è il valore originale della j-esima feature per il brano i-esimo, mentre μ_j e σ_j sono rispettivamente la media e la deviazione standard calcolate sull'intero catalogo deduplicato ($N = 35.877$). Grazie all'Equazione **??**, tutte e 8 le variabili partono con **peso informativo identico** (varianza unitaria $\sigma^2 = 1$, per una varianza complessiva dello spazio esattamente pari a 8) e la PCA diagonalizza la **matrice di correlazione di Pearson** anziché la matrice di covarianza grezza.

4.1.2 Riduzione di dimensionalità: PCA e t-SNE

Anche dopo la selezione delle 8 feature continue, operare direttamente nello spazio originario espone gli algoritmi di clustering ad una parziale dispersione metrica e al rumore residuo delle singole variabili. Per comprimere l'informazione utile in un sottospazio ortogonale privo di multicollinearità e per visualizzare la topologia dei dati, sono state adottate due tecniche complementari: la *Principal Component Analysis* (PCA), impiegata come trasformazione effettiva dello spazio di input per il clustering, e il *t-Distributed Stochastic Neighbor Embedding* (t-SNE), utilizzato per la visualizzazione bidimensionale non lineare.

Principal Component Analysis (PCA) e Selezione delle Componenti: La PCA è una trasformazione lineare ortogonale che proietta le 8 feature standardizzate su un nuovo sistema di coordinate (le Componenti Principali, $\text{PC}_1, \ldots, \text{PC}_8$), ordinate in modo decrescente rispetto alla frazione di varianza globale spiegata. La Tabella **??** e lo Scree Plot in Figura **??** riportano il dettaglio della varianza spiegata singola e cumulativa per tutte le 8 componenti.

Tabella 2: Quota di varianza spiegata individuale e cumulativa per ciascuna Componente Principale (PCA sulle 8 feature acustiche selezionate).

Componente Principale	Varianza Spiegata (%)	Varianza Cumulativa (%)	Stato Selezione
PC_1	32,00%	32,00%	**Selezionata**
PC_2	16,54%	48,54%	**Selezionata**
PC_3	15,21%	63,75%	**Selezionata**
PC_4	10,22%	**73,96%**	**Selezionata (Soglia $> 70\%$)**
PC_5	9,03%	83,00%	Esclusa
PC_6	8,04%	91,04%	Esclusa
PC_7	4,89%	95,92%	Esclusa
PC_8	4,08%	100,00%	Esclusa

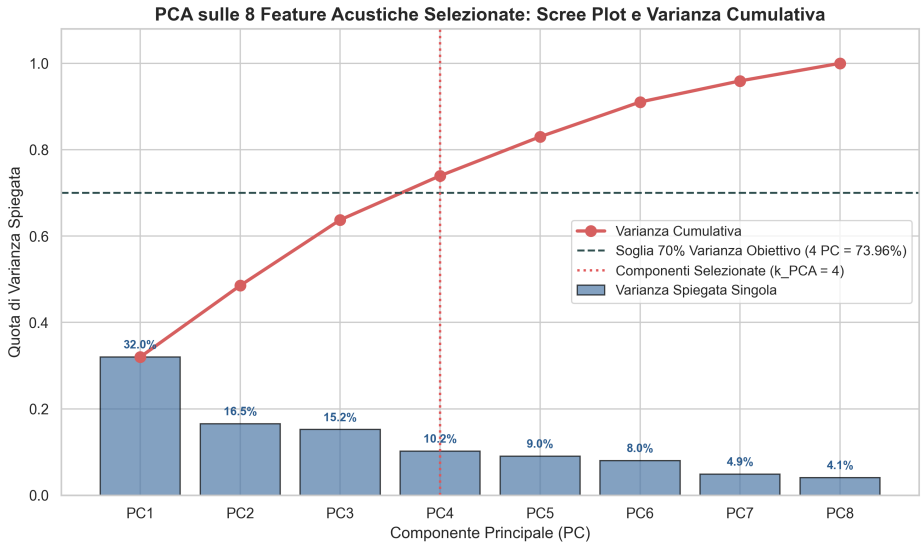

Figura 17: PCA sulle 8 feature acustiche: Scree Plot della varianza spiegata individuale e cumulativa con soglia obiettivo del 70%.

Adottando il criterio della varianza cumulativa minima del 70%, è stato scelto un numero di componenti pari a **n_components** $= 4$, che preserva il **73,96% della varianza totale** e dimezza la dimensionalità dello spazio (da 8 a 4 variabili latenti ortogonali). Il 26,04% residuo non viene assunto automaticamente come rumore privo di informazione. K-Means, GMM, DBSCAN e HDBSCAN sono confrontati sulla matrice PCA a quattro dimensioni; t-SNE resta una tecnica di visualizzazione.

Ciascuna Componente Principale PC_k ($k \in \{1, 2, 3, 4\}$) costituisce una nuova "super-variabile" latente ortogonale, ottenuta come combinazione lineare delle 8 feature standardizzate $z_{i,j}$ pesate attraverso i rispettivi coefficienti (*PCA Loadings*

$w_{j,k}$):

$$\boxed{\text{PC}_{i,k} = \sum_{j=1}^{8} w_{j,k}\, z_{i,j} = w_{1,k}\, z_{i,\text{dance}} + w_{2,k}\, z_{i,\text{energy}} + \cdots + w_{8,k}\, z_{i,\text{duration}}} \tag{4}$$

Per interpretare il significato fisico e musicale dei 4 assi latenti estratti, la Tabella **??** riporta la matrice completa dei pesi $w_{j,k}$ che legano le 8 feature originarie alle prime 4 Componenti Principali.

Tabella 3: Matrice dei Loadings (pesi lineari) delle prime 4 Componenti Principali rispetto alle 8 feature acustiche standardizzate.

Feature Acustica	$\mathbf{PC_1}$ **(32,00%)**	$\mathbf{PC_2}$ **(16,54%)**	$\mathbf{PC_3}$ **(15,21%)**	$\mathbf{PC_4}$ **(10,22%)**
`danceability`	$-0,2179$	$\mathbf{+0,6721}$	$+0,2303$	$+0,1679$
`energy`	$\mathbf{+0,3767}$	$-0,2699$	$\mathbf{+0,5122}$	$-0,1522$
`speechiness`	$\mathbf{-0,3724}$	$-0,0696$	$+0,2895$	$-0,0380$
`acousticness`	$\mathbf{-0,3482}$	$+0,0925$	$\mathbf{-0,5224}$	$+0,2265$
`instrumentalness`	$\mathbf{+0,4838}$	$+0,2391$	$-0,0819$	$+0,3038$
`valence`	$-0,2888$	$+0,2422$	$\mathbf{+0,5533}$	$+0,1739$
`tempo`	$-0,1770$	$\mathbf{-0,5300}$	$+0,1223$	$\mathbf{+0,7626}$
`duration_ms`	$\mathbf{+0,4494}$	$+0,2555$	$+0,0092$	$\mathbf{+0,4380}$

Dall'ispezione dei coefficienti in Tabella **??** emerge una chiara lettura semantica delle 4 dimensioni latenti:

- $\mathbf{PC_1}$ **(32,00% — Asse Strumentale/Elettronico Esteso vs. Vocale/Acustico Breve):** Presenta pesi positivi marcati su `instrumentalness` ($+0,4838$), `duration_ms` ($+0,4494$) ed `energy` ($+0,3767$), contrapposti a pesi negativi su `speechiness` ($-0,3724$) e `acousticness` ($-0,3482$). Separa nettamente le lunghe tracce elettroniche da club prive di voce dalle canzoni brevi cantate o rappate.
- $\mathbf{PC_2}$ **(16,54% — Asse Groove Ballabile Cadenzato vs. Velocità Ritmica):** È dominata positivamente dalla `danceability` ($+0,6721$) e negativamente dal `tempo` ($-0,5300$) e dall'`energy` ($-0,2699$). Distingue i brani dal groove cadenzato e ballabile (115–130 BPM) dalle tracce ad altissima velocità di battito e natura frenetica.
- $\mathbf{PC_3}$ **(15,21% — Asse Euforia Elettrica vs. Intimità Acustica):** Combina contributi positivi elevati di `valence` ($+0,5533$) ed `energy` ($+0,5122$) con un forte contributo negativo di `acousticness` ($-0,5224$), discriminando i brani solari ed energici dalle ballate acustiche ed introspettive.

- $\mathbf{PC_4}$ **(10,22% — Asse Velocità di Esecuzione e Durata):** È governata prevalentemente dal `tempo` ($+0,7626$) e da `duration_ms` ($+0,4380$), isolando le variazioni puramente metriche e di velocità in BPM.

t-SNE (t-Distributed Stochastic Neighbor Embedding): Accanto alla riduzione lineare PCA (usata per il calcolo effettivo dei cluster), è stata impiegata la tecnica non lineare t-SNE esclusivamente a scopo di visualizzazione topologica bidimensionale su un campione casuale rappresentativo di $N = 6.000$ brani (`n_components=2`, `perplexity=40`, `random_state=42`). La Figura **??** mostra la mappa t-SNE colorata retrospettivamente con i 15 generi ufficiali di Spotify.

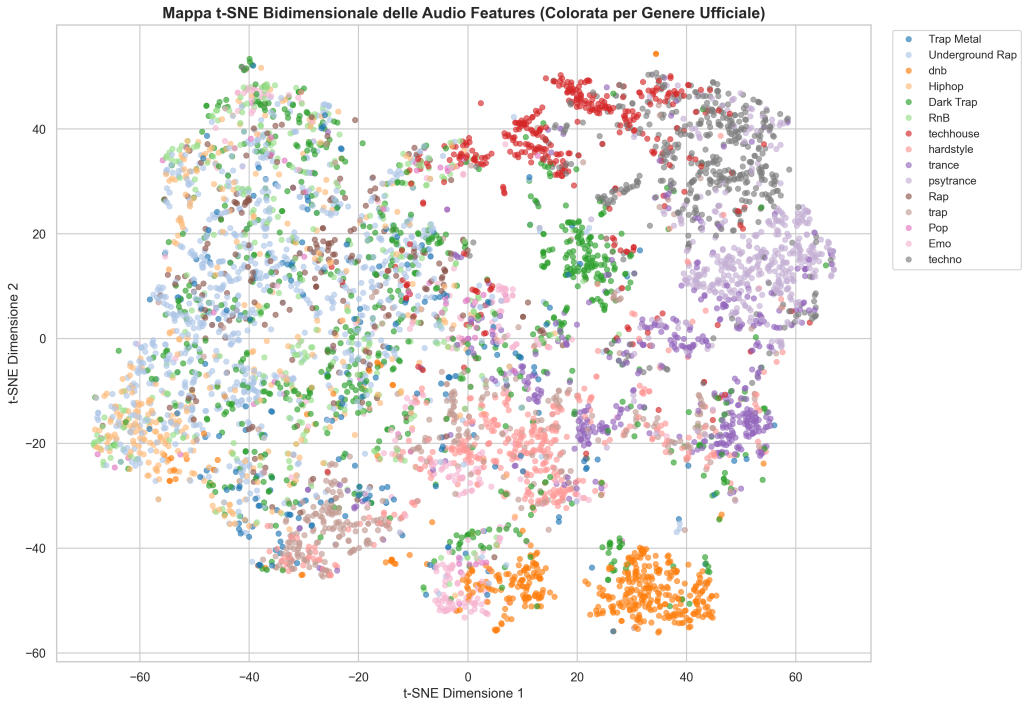

Figura 18: Mappa 2D generata tramite t-SNE sulle feature acustiche, colorata retrospettivamente per genere Spotify originale.

4.2 K-Means nello Spazio PCA

Il metodo K-Means è un algoritmo di clustering per partizionamento che suddivide le N osservazioni rappresentate nello spazio PCA a 4 dimensioni in k cluster disgiunti $C_1, \ldots, C_k$, minimizzando iterativamente la somma dei quadrati delle distanze euclidee intra-cluster (Within-Cluster Sum of Squares, WCSS):

$$\text{WCSS} = \sum_{j=1}^{k} \sum_{\mathbf{z}_i \in C_j} \|\mathbf{z}_i - \boldsymbol{\mu}_j\|^2 \tag{5}$$

dove $\mathbf{z}_i \in \mathbb{R}^4$ è il vettore delle prime 4 componenti principali del brano i-esimo e $\boldsymbol{\mu}_j \in \mathbb{R}^4$ rappresenta il centroide del cluster C_j.

4.2.1 Applicazione dell'algoritmo, Elbow Method e Coefficiente di Silhouette

Per determinare in modo rigoroso il numero ottimale di cluster k nello spazio PCA a 4 componenti, l'algoritmo K-Means (`n_init=20`, `max_iter=300`, `random_state=42`) è stato valutato per $k \in \{2, 3, \ldots, 10\}$ affiancando all'ispezione della curva d'inerzia WCSS (*Elbow Method*) il calcolo del **Coefficiente di Silhouette medio**, come mostrato nel doppio grafico di Figura **??**.

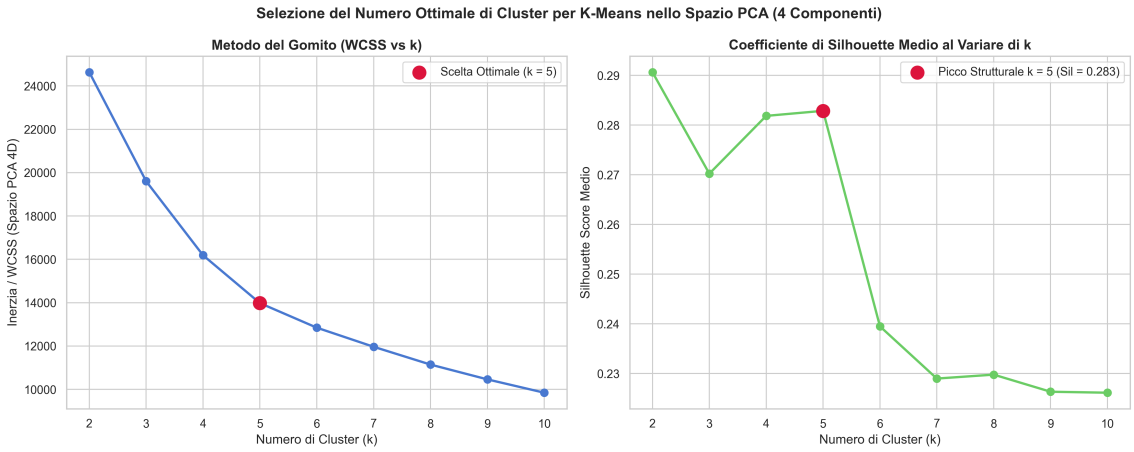

Figura 19: Selezione del parametro k per K-Means nello spazio PCA (4 PC): curva WCSS (a sinistra) e Coefficiente di Silhouette medio (a destra).

L'analisi congiunta dei due indicatori in Figura **??** fornisce una giustificazione matematica univoca per la scelta di $k = 5$:

1. Sulla curva WCSS (pannello sinistro), la pendenza subisce una netta decelerazione dopo $k = 5$ (WCSS $= 13.981,8$), punto oltre il quale l'aggiunta di ulteriori centroidi produce riduzioni marginali dell'inerzia intra-cluster.

2. Sulla curva della Silhouette media (pannello destro), dopo i valori registrati a $k = 3$ $(0,2702)$ e $k = 4$ $(0,2819)$, la compattezza raggiunge un **massimo locale**

strutturale esattamente in corrispondenza di $k = 5$ con Silhouette $= 0,2829$, prima di subire un brusco calo a $k = 6$ (Silhouette $= 0,2395$) dovuto alla frammentazione artificiale dei gruppi principali.

4.2.2 Analisi dei risultati ottenuti e proiezioni spaziali

Il modello K-Means addestrato con $k = 5$ sulle 4 componenti principali ha generato una partizione bilanciata e ben strutturata sia sul campione di analisi ($N = 6.000$) sia sull'intero catalogo deduplicato ($N = 35.877$), come riepilogato nella Tabella **??**.

Tabella 4: Distribuzione numerica e percentuale dei brani nei 5 cluster K-Means (campione di analisi e intero catalogo deduplicato).

Cluster	Archetipo Musicale (Mood Playlist)	Campione ($N = 6.000$)	Catalogo ($N = 35.877$)	Quota (%)
Cluster 0	High-Intensity Bass & Workout	1.710	10.583	29,50%
Cluster 1	Extended Club & Instrumental	1.517	8.964	24,99%
Cluster 2	Acoustic, Chill & Atmospheric	549	3.189	8,89%
Cluster 3	Groove, Melodic Urban & Dance-Pop	1.250	7.354	20,50%
Cluster 4	Fast-Flow Rap & High-Tempo Urban	974	5.787	16,13%

La Figura **??** illustra la disposizione geometrica dei 5 cluster affiancando la proiezione lineare nel piano delle prime due componenti principali (PC_1 vs PC_2, con indicazione esplicita dei 5 centroidi $\mathbf{X}$) e la proiezione non lineare sulla mappa t-SNE.

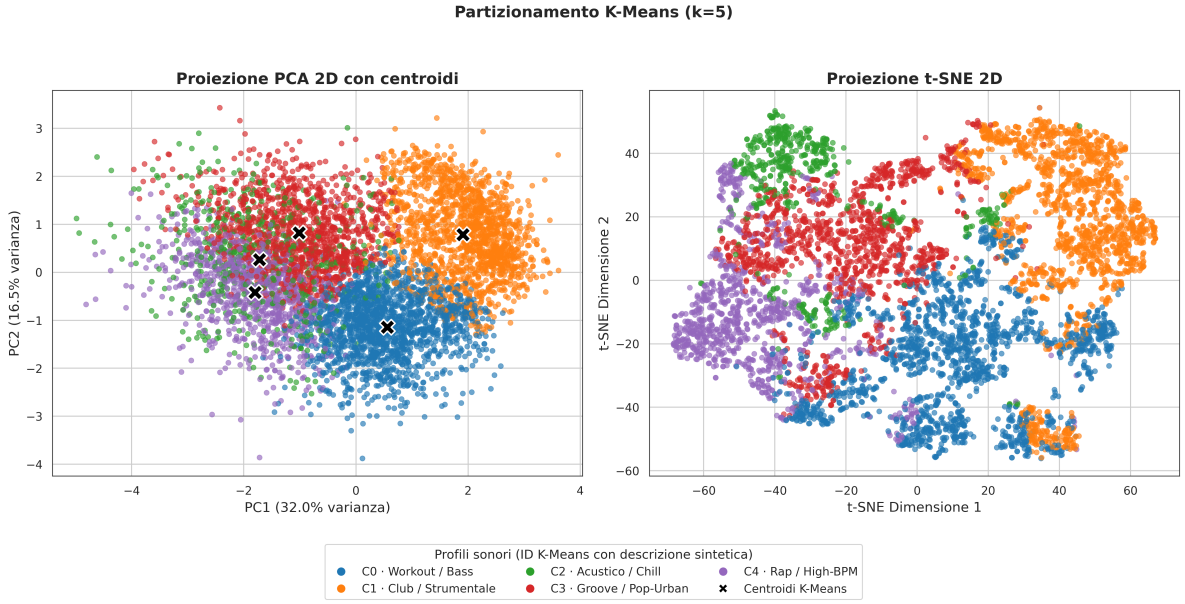

Figura 20: Partizionamento K-Means ($k = 5$) visualizzato nel piano lineare PCA (PC_1 vs PC_2 con centroidi) e sulla mappa non lineare t-SNE 2D.

Dalla Figura **??** si osserva come nel piano PCA i 5 centroidi presidino regioni ben distinte dello spazio delle componenti principali, e come tale partizione si

traduca, sulla varietà non lineare t-SNE, in macro-regioni timbriche coerenti e prive di sovrapposizioni caotiche.

4.2.3 Profiling acustico dei Cluster e Mood Playlists

Per interpretare il significato musicale e funzionale dei 5 cluster, la Figura **??** riporta una heatmap delle medie osservate. Le annotazioni contengono i valori medi originali (la durata è espressa in migliaia di millisecondi), mentre il colore è normalizzato Min-Max separatamente per ciascuna feature: il colore consente quindi di confrontare i cluster sulla stessa variabile, non grandezze assolute tra variabili diverse. La matrice include anche `loudness` e `liveness` come descrittori retrospettivi; queste due variabili non sono state usate per addestrare K-Means né per costruire lo spazio PCA.

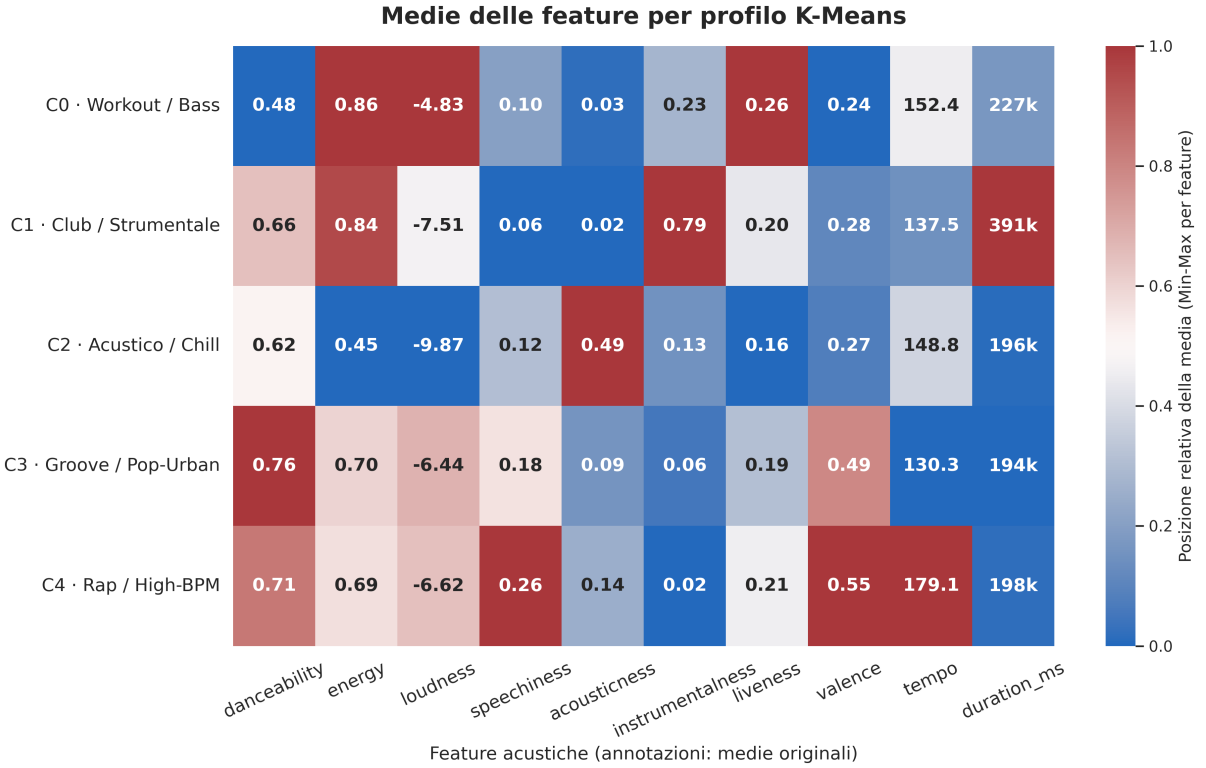

Figura 21: Medie delle feature per i cluster K-Means. Le annotazioni riportano le medie originali; il colore è riscalato per colonna.

La matrice mette in evidenza differenze utili a descrivere i profili: C1 presenta una forte strumentalità e durate maggiori; C2 ha maggiore acusticità e minore energia; C3 è il profilo più ballabile, mentre C4 mostra tempo e contenuto parlato più elevati. C0 combina energia e volume mediamente alti. Le sigle C0–C4 sono identificativi; i nomi brevi riportati in legenda riassumono i tratti dominanti, senza essere etichette di genere.

La Figura **??** visualizza in forma polare gli stessi profili limitandosi alle 8 feature effettivamente usate nel clustering. Anche in questo grafico ciascun asse è normalizzato tra i cluster: la forma rende immediato il confronto relativo tra profili, ma

non va letta come confronto delle unità originali o come intensità assoluta della feature.

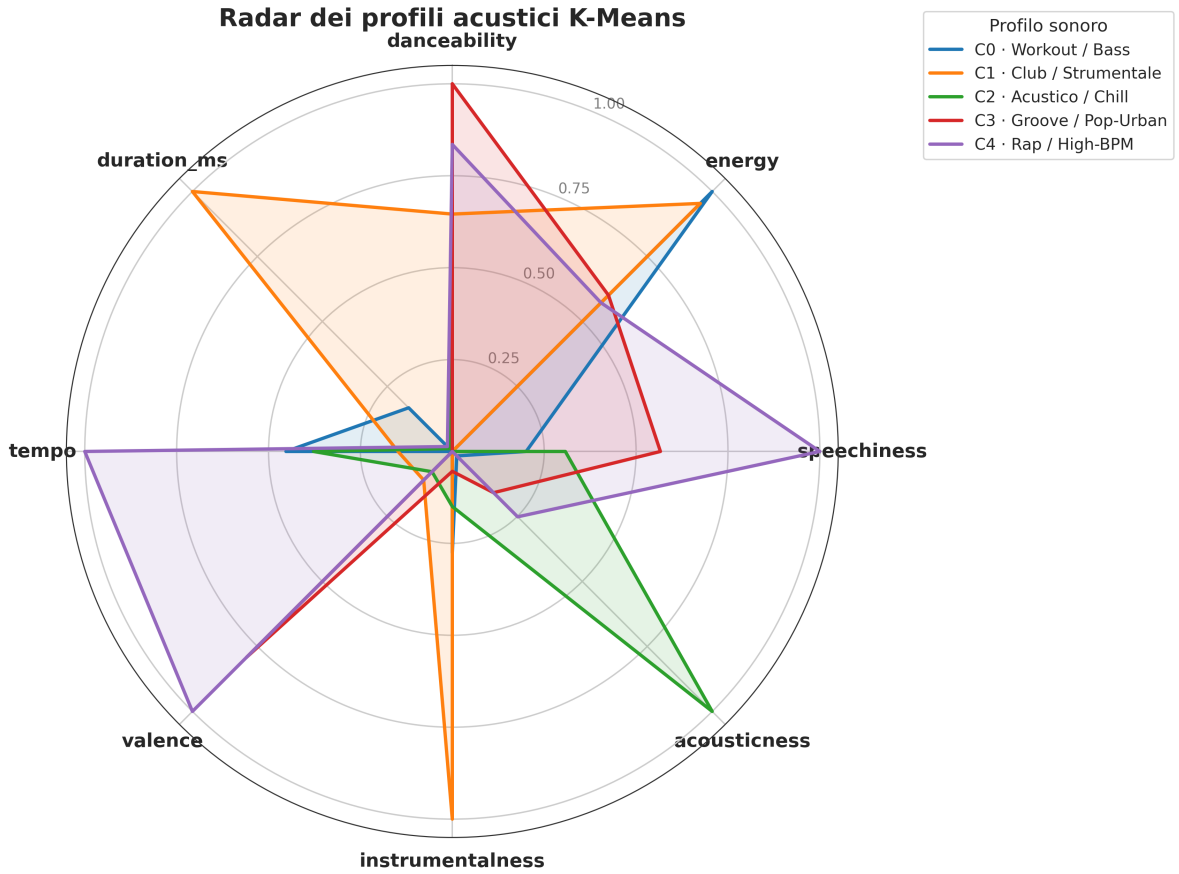

Figura 22: Radar chart delle medie normalizzate delle 8 feature usate nel clustering K-Means.

Dall'esame congiunto delle Figure **??** e **??**, oltre che dall'incrocio retrospettivo con i generi originali, ciascun cluster rivela un'identità acustica e funzionale netta:

- **Cluster 0 — High-Intensity Bass & Workout (**1.710 **brani campione /** 10.583 **catalogo):** È il cluster a massima potenza d'urto: registra i valori medi più elevati in assoluto di `energy` ($0,86$) e `loudness` ($-4,83$ dB), uniti a un `tempo` sostenuto ($152,40$ BPM), ma con la più bassa `danceability` ($0,48$) e una `valence` scura/aggressiva ($0,24$). Raccoglie in larga misura tracce *Hardstyle*, *Drum and Bass* e *Trap/Trap Metal* ad alto impatto adrenalinico, perfette per playlist di allenamento intenso (*Workout / Gym*).
- **Cluster 1 — Extended Club & Instrumental Electronic (**1.517 **brani campione /** 8.964 **catalogo):** Si distingue in modo inequivocabile per l'altissima `instrumentalness` media ($0,79$, contro $0,02$–$0,23$ degli altri gruppi) e per la durata media estesa (`duration_ms` $= 390.803$ ms, circa $6,5$ minuti), accompagnate da `energy` elevata ($0,84$), ottima `danceability` ($0,66$), `speechiness`

minima ($0,06$) e battito regolare da club ($137,52$ BPM). Cattura i brani *Techno*, *Psytrance*, *Trance* e *Techhouse* pensati per il DJ mixing e per sessioni di *Deep Focus / Clubbing*.

- **Cluster 2 — Acoustic, Chill & Atmospheric (**549 **brani campione /** 3.189 **catalogo):** Rappresenta il polo intimo e decompressivo del catalogo: presenta il valore massimo di `acousticness` ($0,49$, oltre tre volte superiore a qualsiasi altro cluster) e i livelli minimi di `energy` ($0,45$) e volume (`loudness` $= -9,87$ dB), con durata contenuta (196.127 ms). Raggruppa produzioni acustiche, R&B morbido, Emo e tracce *Dark Trap / Lo-Fi* rarefatte, ideali per playlist *Chillout, Late Night & Relax*.
- **Cluster 3 — Groove, Melodic Urban & Dance-Pop (**1.250 **brani campione /** 7.354 **catalogo):** È il cluster a più alta ballabilità dell'intero dataset (`danceability` $= 0,76$), caratterizzato da un `tempo` moderato e cadenzato ($130,31$ BPM), `valence` positiva ($0,49$), buona `energy` ($0,70$), presenza vocale ritmica (`speechiness` $= 0,18$) e quasi totale assenza strumentale ($0,06$). Aggrega in modo trasversale *Pop*, *R&B*, *Rap melodico* e *Techhouse* radiofonica, costituendo l'archetipo perfetto per playlist *Social Groove & Aperitif*.
- **Cluster 4 — Fast-Flow Rap & High-Tempo Urban (**974 **brani campione /** 5.787 **catalogo):** Isola i brani caratterizzati dalla massima velocità ritmica (`tempo` medio $= 179,12$ BPM), dalla massima densità di parlato/rima (`speechiness` $= 0,26$) e dalla più alta positività/dinamismo (`valence` $= 0,55$), con `danceability` elevata ($0,71$) e durata compatta (197.699 ms). È composto prevalentemente da *Underground Rap*, *Hiphop* e *Dark Trap* in doppia metrica, ideale per playlist *Street Flow & High-BPM Urban*.

4.2.4 Valutazione della Silhouette per K-Means

Per valutare la coesione interna e la separazione di ciascuno dei 5 gruppi individuati nello spazio PCA a 4 dimensioni, è stato calcolato il coefficiente di Silhouette puntuale $s(i)$ per ogni brano del campione secondo la formula:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \tag{6}$$

dove $a(i)$ è la distanza euclidea media tra il brano i e gli altri brani del medesimo cluster nello spazio PCA 4D, mentre $b(i)$ è la distanza media minima rispetto ai brani del cluster contiguo più vicino. La Figura **??** mostra la distribuzione dei coefficienti di Silhouette per i 5 cluster.

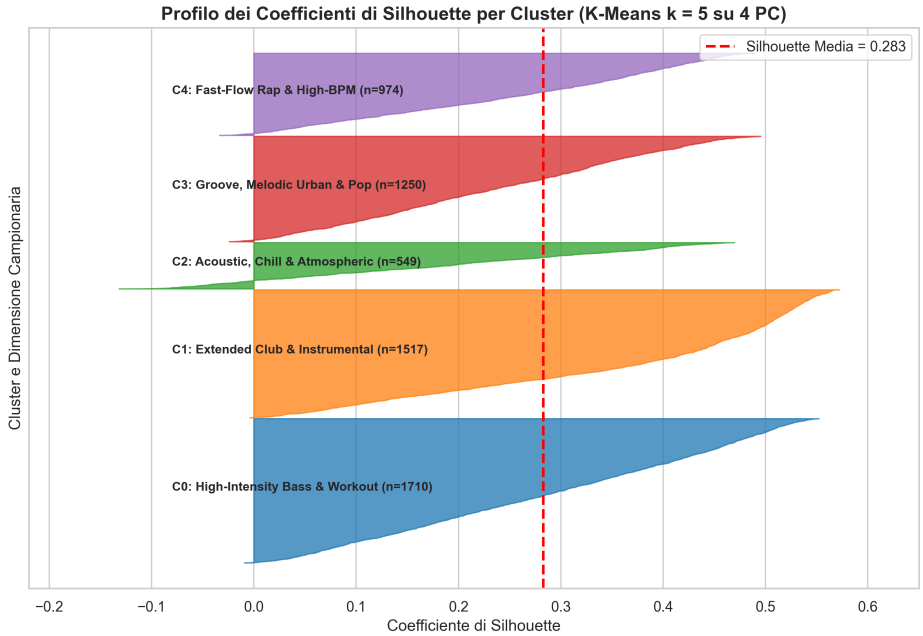

Figura 23: Profilo dei coefficienti di Silhouette per ciascun cluster K-Means ($k = 5$) calcolato nello spazio PCA a 4 componenti.

Dalla Figura **??** emerge un valore medio globale di Silhouette pari a $0,2829$ (notevolmente superiore al valore di $0,1204$ che si otterrebbe applicando K-Means direttamente sulle 13 variabili non ridotte). Tutti e 5 i cluster superano ampiamente la soglia media con picchi superiori a $0,50$ (in particolare il Cluster 1 strumentale e i Cluster 3 e 4 urban/groove) e una frazione molto ridotta di valori negativi (punti di confine). Un valore di Silhouette intorno a $0,28$–$0,30$ è pienamente coerente con la natura fisica dei dati musicali: a differenza di dataset sintetici con isole disgiunte, gli attributi acustici formano una varietà continua in cui le transizioni tra stili avvengono gradualmente, e K-Means opera efficacemente una tassonomia geometrica convessa di tale continuum.

4.2.5 Evoluzione probabilistica di K-Means: Gaussian Mixture Model

K-Means assegna ciascun brano in modo deterministico e rigido a un solo cluster, anche quando le sue coordinate metriche cadono esattamente nella terra di nessuno tra due o più profili. Nel dominio musicale, tuttavia, i generi e gli stati emotivi formano un continuum sfumato: una traccia *RnB contemporanea* può combinare un groove ritmico ballabile con una timbrica vocale intima ed acustica, rendendo riduttiva l'assegnazione a un singolo contenitore disgiunto. Per superare questa limitazione geometrica e catturare la natura polivalente della musica, è stato introdotto un *Gaussian Mixture Model* (GMM) a cinque componenti con matrice di covarianza piena (`covariance_type='full'`), addestrato sul medesimo campione di $N = 6.000$ brani nello spazio PCA a 4 dimensioni.

Il modello stima per ogni traccia un vettore di affiliazioni probabilistiche $\gamma_i = (\gamma_{i,0}, \ldots, \gamma_{i,4})$, dove $\sum_{k=0}^{4} \gamma_{i,k} = 1$. Questi valori quantificano l'appartenenza a ciascuno dei 5 macro-archetipi nello spazio acustico latente. La Figura **??** illustra la topografia del modello proiettata sul piano delle prime due componenti principali, evidenziando le ellissi di covarianza a 1σ (intervallo di confidenza al 68%) e 2σ (intervallo al 95%), unitamente alla classificazione empirica dei corridoi ibridi più popolati.

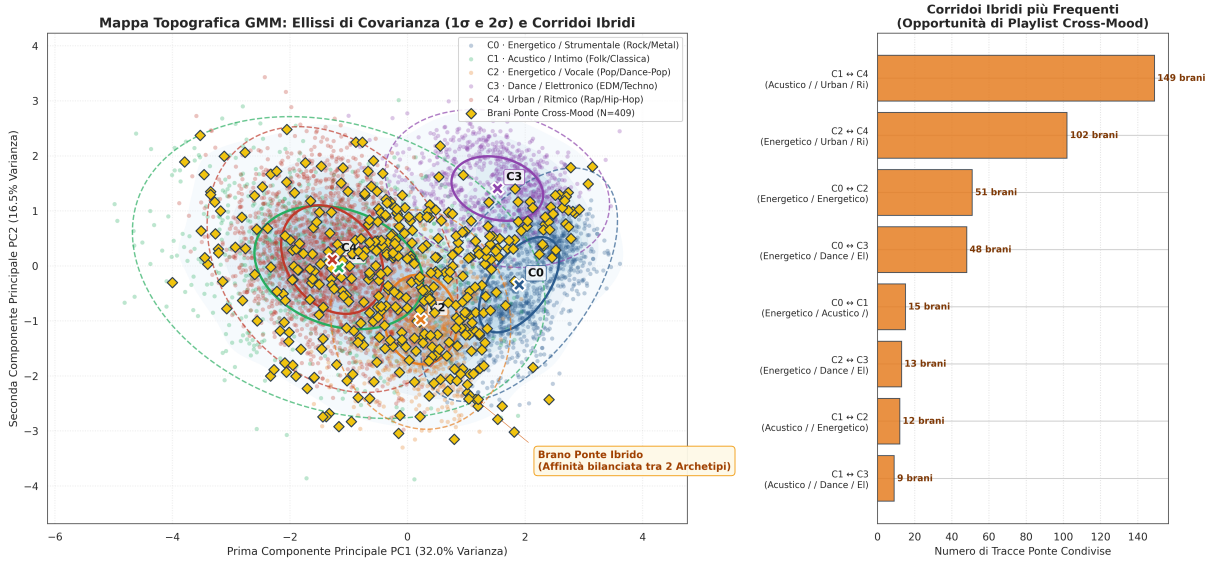

Figura 24: Mappa topografica GMM nello spazio PCA 2D con ellissi di dispersione (1σ continua, 2σ tratteggiata) ed evidenziazione dei 409 brani ponte cross-mood (a sinistra), affiancata dalla graduatoria dei corridoi ibridi più frequenti (a destra).

Per tradurre intuitivamente la complessa interazione probabilistica a 5 dimensioni, la Figura **??** introduce il **Pentagono Baricentrico dei Mood (RadViz Simplex Plot)**. I 5 vertici del pentagono rappresentano gli archetipi "puri" ($\gamma_{i,k} = 1$); ciascun brano viene posizionato nel piano mediante la combinazione lineare convessa dei

vettori dei vertici pesata sulle rispettive probabilità:

$$\mathbf{P}_i = \sum_{k=0}^{4} \gamma_{i,k}\, \mathbf{V}_k \tag{7}$$

I cerchi concentrici indicano il grado di purezza dell'affiliazione (50%, 75%, 100%). I brani stilisticamente stereotipati vengono attratti verso la periferia lungo i raggi dei singoli poli, mentre i brani ibridi galleggiano verso il baricentro o lungo i segmenti perimetrali che collegano due mood specifici.

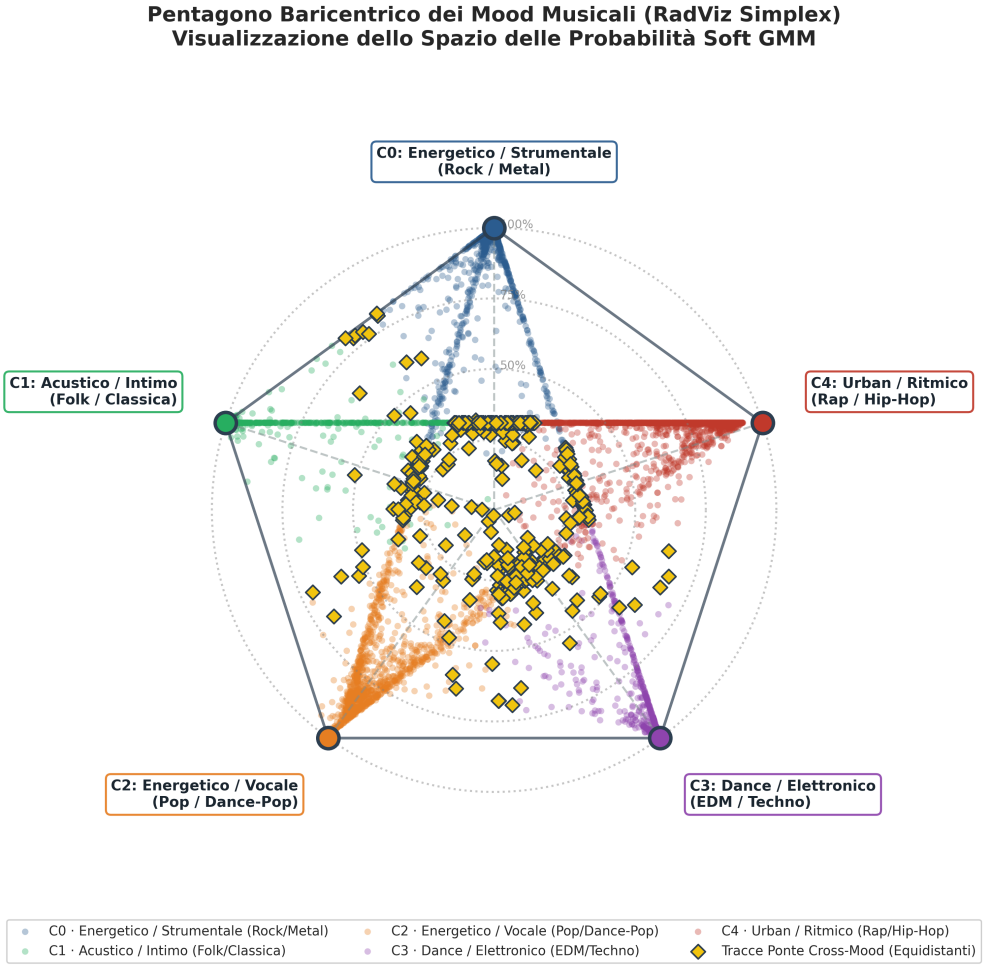

Figura 25: Pentagono Baricentrico dei Mood (RadViz Simplex Plot): visualizzazione dello spazio delle probabilità soft GMM con cerchi guida di confidenza e posizionamento delle tracce ponte.

Identificazione dei Brani Ponte (Cross-Mood Bridge Tracks) ed Esempi Concreti: Fissando una soglia esplorativa di ambiguità metrica pari a $\text{Gap}_{\text{top2}} \leq 0,15$ (differenza non superiore al 15% tra le due massime probabilità a posteriori), il modello isola nel campione esattamente **409 brani ponte** (il **6,82%** del catalogo), con un'affiliazione massima mediana complessiva pari a $0,883$. Come visibile nella Figura **??**, questi brani non sono dispersi casualmente, ma si addensano con pre-

cisione matematica lungo le selle topografiche di sovrapposizione tra le campane gaussiane.

L'ispezione analitica dei singoli brani estratti dal dataset conferma la straordinaria corrispondenza tra geometria del modello e percezione musicale:

- Il brano *"LostInMyhead"* (catalogato commercialmente come *Dark Trap*) si colloca in perfetto equilibrio tra la Componente 1 (*Acustico / Intimo*, $\gamma_1 = 50,5\%$) e la Componente 4 (*Urban / Ritmico*, $\gamma_4 = 49,5\%$), con un gap di appena l'$1,0\%$. La traccia unisce un arpeggio lo-fi rarefatto a una linea di basso hip-hop cadenzata.

- Il brano *"Cool Girl"* (etichettato come *Pop*) fa da ponte tra la Componente 1 ($\gamma_1 = 52,3\%$) e la Componente 4 ($\gamma_4 = 47,7\%$, gap $4,5\%$), combinando una produzione radiofonica brillante con una strofa ritmata a cavallo tra melodia e parlato.

- La traccia *"Abstergence"* costituisce un caso emblematico di ponte a tre vie, distribuendosi tra la Componente 3 (*Dance / Elettronico*, $41,9\%$), la Componente 2 (*Energetico / Vocale*, $31,4\%$) e la Componente 0 (*Energetico / Strumentale*, $20,8\%$).

Dalla graduatoria dei corridoi ibridi in Figura **??** emerge che le transizioni più frequenti avvengono tra l'archetipo acustico e quello urban ($C_1 \leftrightarrow C_4$: 149 brani), seguiti dal raccordo tra pop vocale e urban ($C_2 \leftrightarrow C_4$: 102 brani) e tra rock/metal e pop energico ($C_0 \leftrightarrow C_2$: 51 brani). Questa proprietà abilita una concreta applicazione industriale per i servizi di streaming: la generazione di **Playlist di Transizione Dinamica** (*Cross-Mood Fade-in*), capaci di condurre l'ascoltatore da una sessione rilassante o acustica verso sonorità urban o clubbing attraverso brani cuscinetto timbricamente affini a entrambi i mondi.

Tabella 5: Sintesi descrittiva delle componenti GMM sul campione di 6.000 brani. I generi sono riportati solo come interpretazione a posteriori.

Componente	Brani	Tratti acustici medi distintivi	Generi più frequenti (a posteriori)
0	1.130	Energia alta ($0,92$), strumentalità alta ($0,72$), durata lunga (352 s)	Psytrance, DnB, Trance
1	741	Maggiore acusticità ($0,39$), energia più contenuta ($0,51$)	Dark Trap, Underground Rap, RnB
2	1.111	Energia alta ($0,90$), prevalenza vocale (instrumentalness $= 0,08$)	Hardstyle, Trap, Emo
3	843	Ballabilità alta ($0,74$), strumentalità alta ($0,76$), durata lunga (367 s)	Techno, Techhouse
4	2.175	Profilo più vocale (speechiness $= 0,20$), ballabilità alta ($0,71$)	Underground Rap, Dark Trap, Hiphop

Le componenti 0 e 3, ad esempio, condividono una forte componente strumentale ma si distinguono per intensità e ballabilità; le componenti 1, 2 e 4 separano ulteriormente profili acustici o vocali. La numerazione delle componenti è arbitraria e non costituisce una gerarchia di mood.

4.3 DBSCAN nello Spazio PCA

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) è un algoritmo di clustering basato sulla densità locale dei punti nello spazio metrico. A differenza di K-Means (che assegna ogni brano a un centroide), DBSCAN non richiede di fissare a priori il numero di cluster e marca come **noise** (etichetta -1) i punti che non soddisfano i criteri di densità locale. Questa etichetta descrive la geometria rispetto al modello e ai parametri scelti; non è un giudizio sul valore musicale della traccia.

Il comportamento di DBSCAN nello spazio PCA a 4 dimensioni dipende da due iperparametri:

- ϵ (*epsilon*): il raggio dell'ipersfera quadridimensionale entro cui ricercare i vicini di ciascun brano;
- `min_samples`: il numero minimo di brani richiesti entro il raggio ϵ affinché un'osservazione sia qualificata come *punto core*.

4.3.1 Scelta dei parametri e tuning nello spazio PCA

Per calibrare il raggio ϵ sulla scala metrica delle 4 Componenti Principali, è stato applicato il metodo delle distanze k-Nearest Neighbors (k-NN) con $k = \texttt{min_samples} = 5$ (Figura **??**), affiancato da una ricerca su griglia bidimensionale ($\epsilon \in \{0,45; 0,50; 0,60; 0,70\} \times \texttt{min_samples} \in \{4, 5, 6, 8\}$) volta a monitorare simultaneamente il numero di cluster generati e il Silhouette Score dei punti non rumorosi (Figura **??**).

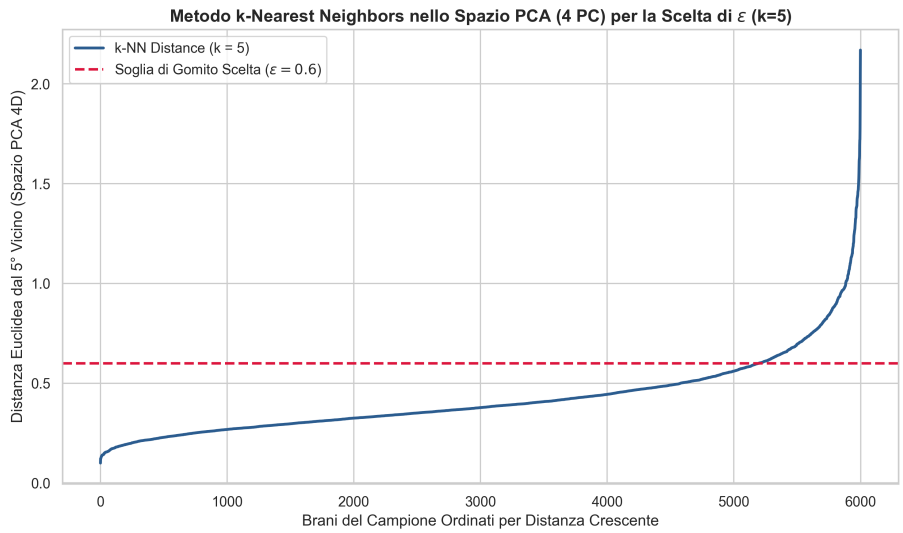

Figura 26: Curva ordinata delle distanze dal 5° vicino più prossimo (k-NN) nello spazio PCA a 4 componenti, con ginocchio ottimale in $\epsilon = 0,60$.

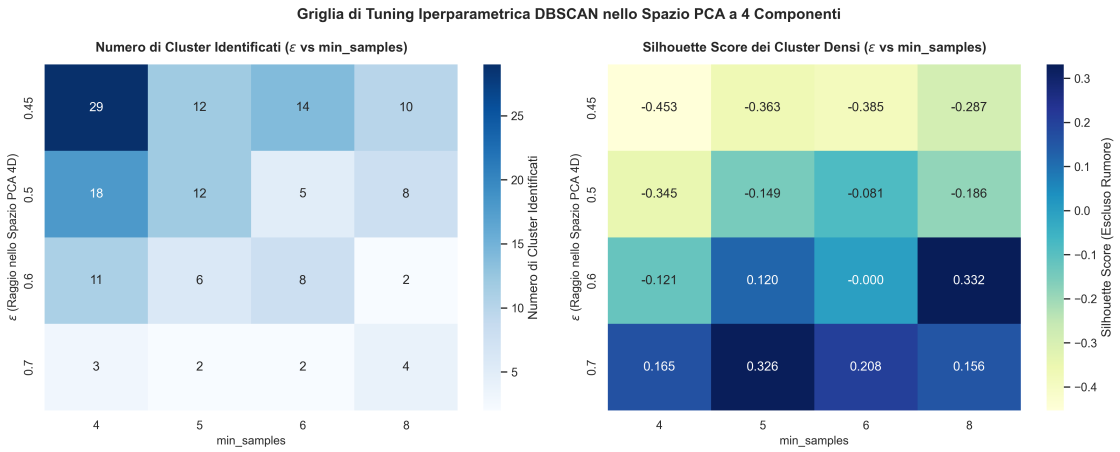

Figura 27: Griglia di tuning iperparametrica DBSCAN nello spazio PCA 4D: Numero di cluster identificati (a sinistra) e Silhouette Score dei punti assegnati (a destra).

L'ispezione della curva k-NN (Figura **??**) evidenzia che le distanze dal 5° vicino si mantengono contenute sotto $0,55$ per oltre il 90% del campione, per poi impennarsi bruscamente (il "gomito" della curva) intorno alla soglia $\epsilon = 0,60$. Dalla griglia di Figura **??** si osserva che:

- Valori di raggio troppo piccoli ($\epsilon = 0,45$) causano una sovra-frammentazione della coda della distribuzione (20–27 micro-cluster) ed espellono oltre il 20% del catalogo come rumore.
- In corrispondenza del punto di gomito $\epsilon = 0,60$, **`min_samples`** $= 5$, l'algoritmo identifica **6 cluster** e marca come noise **462 brani** (**7,70% del campione**). La Silhouette sui punti assegnati è $0,120$; con `min_samples` $= 8$ sale a $0,332$, ma rimangono 3 cluster e la quota noise cresce all'11,05%.

4.3.2 Analisi dei risultati ottenuti e interpretazione topologica

La Figura **??** mostra il risultato della clusterizzazione DBSCAN ($\epsilon = 0,60$, `min_samples` $= 5$) proiettato sia sul piano lineare delle prime due Componenti Principali (PC_1 vs PC_2) sia sulla mappa non lineare t-SNE, evidenziando con croci rosse i 462 brani classificati come noise (label $= -1$).

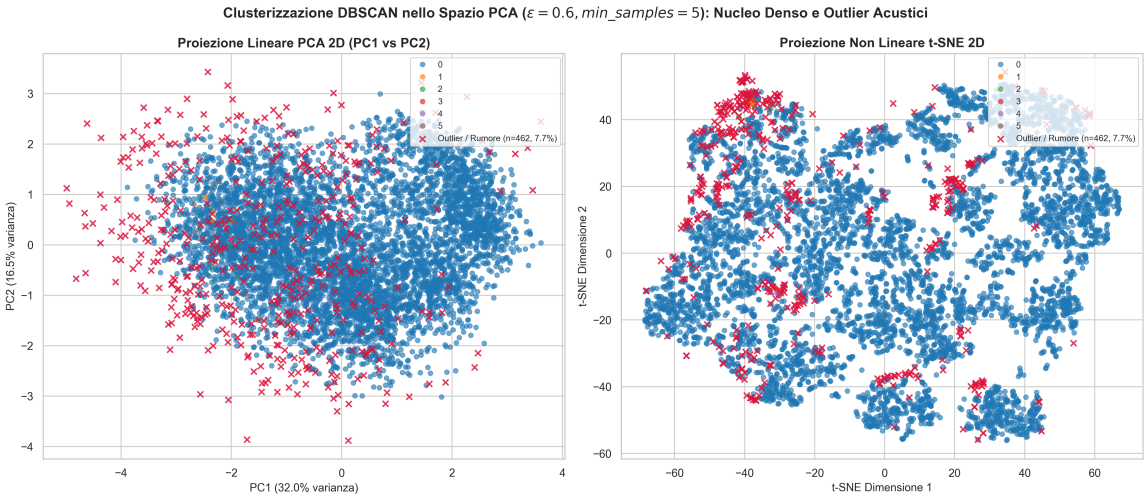

Figura 28: Clusterizzazione DBSCAN ($\epsilon = 0,60$, `min_samples` $= 5$) nello spazio PCA 2D (a sinistra) e t-SNE 2D (a destra), con evidenziazione dei 462 punti noise.

Un'analisi oggettiva della Figura **??** mette in luce un fenomeno topologico classico dei grandi cataloghi musicali:

- **La "Megalopoli" Continua del Mainstream:** Le caratteristiche acustiche delle tracce pop, dance, urban ed elettroniche commerciali non presentano barriere geometriche nette né vuoti di densità nello spazio metrizzato, ma sfumano le une nelle altre lungo un continuum compatto. Di conseguenza, operando con una metrica rigida a raggio costante ($\epsilon = 0,60$), DBSCAN non intercetta interruzioni di continuità e connette la quasi totalità dell'universo musicale in un **unico macro-cluster dominante (Cluster 0, forte di 5.509 brani, pari al $91,8\%$ del campione)**, affiancato da appena **5 micro-isole locali** (29 brani complessivi confinati su nicchie timbriche estreme).

- **La "Corona" Periferica a Bassa Densità:** L'algoritmo isola all'esterno una corona di 462 **brani classificati come noise (label $= -1$, il $7,70\%$ del campione)**. Essi non soddisfano la condizione di avere almeno 5 vicini entro il raggio $\epsilon = 0,60$.

Mentre K-Means forza geometricamente ogni osservazione entro uno dei cinque compartimenti, DBSCAN separa con rigore il nucleo compatto del catalogo dalle sue periferie metriche.

4.3.3 Diagnostica del Rumore: la Rivalutazione Musicale dei Brani Periferici

Per comprendere la natura acustica dei 462 brani etichettati come rumore (label $= -1$), la Figura **??** supera la sintesi schematica dei boxplot convenzionali introducendo un **Raincloud Plot** su tre variabili cardine: durata della traccia in minuti (`duration_min`), contenuto verbale (`speechiness`) e timbrica acustica (`acousticness`). Il grafico integra simultaneamente tre livelli descrittivi:

1. **Cloud (metà superiore):** Stima di densità continua non parametrica (Half-Violin KDE), che rivela la forma multimodale delle distribuzioni;
2. **Boxplot (centro):** Sintesi robusta della mediana (marcatore circolare bianco) e dell'intervallo interquartile IQR;
3. **Rain (metà inferiore):** Nuvola di dispersione con jitter dei singoli brani reali, che evidenzia la presenza e la concentrazione delle code estreme.

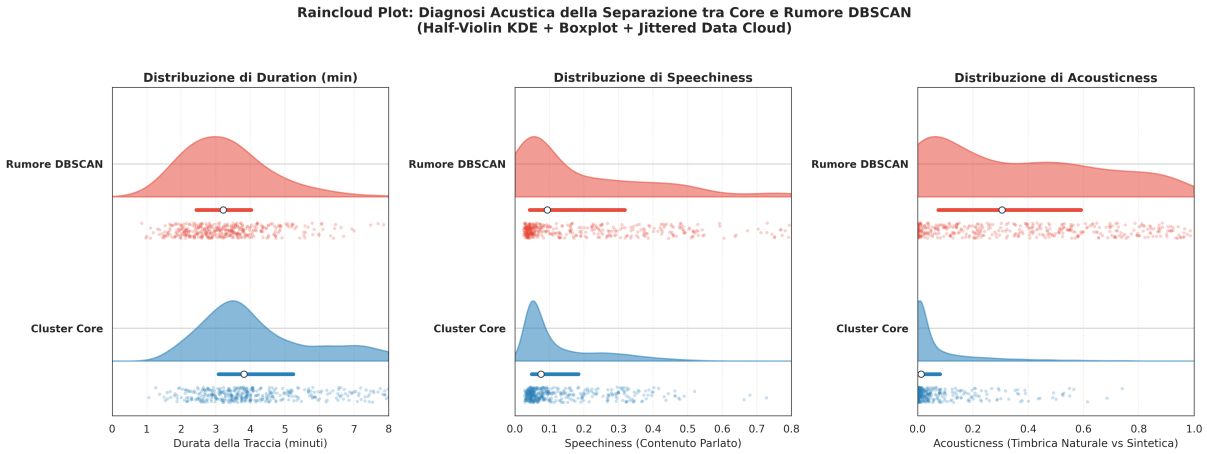

Figura 29: Raincloud Plot diagnostico per la separazione tra Core denso e Rumore DBSCAN: stima di densità non parametrica (Half-Violin KDE), mediana e IQR (Boxplot) e nuvola di punti reali jitterati (Rain) per le tre feature più discriminanti.

Dall'ispezione della Figura **??** emergono con evidenza le ragioni acustiche dell'isolamento metrico:

- **Durata Estrema (`duration_min`):** Mentre il Cluster Core si concentra attorno a una campana regolare centrata sullo standard radiofonico di $3,5$–4 minuti, il Rumore DBSCAN si allunga in una coda asimmetrica pronunciata che raggiunge e supera i 7–12 minuti, intercettando DJ-set continui, tracce progressive e composizioni estese non segmentate.
- **Speechiness Fuori Scala:** La quasi totalità del Core presenta valori di parlato minimi ($< 0,15$). La popolazione noise evidenzia invece una marcata gobba secondaria distribuita tra $0,30$ e $0,80$, catturando brani rap in metrica serrata, sketch comici, interludi parlati e podcast.

- **Polarizzazione Acustica (`acousticness`):** Il Core denso è pesantemente ancorato alle produzioni moderne sintetiche ed elettrificate (valori prossimi a 0). I punti noise comprendono invece l'intera gamma delle ballate acustiche, brani per pianoforte solo e composizioni d'atmosfera con `acousticness` fino a $1,0$, la cui rarefazione nello spazio PCA le rende metricamente isolate rispetto alla folla dancefloor.

La Prova Empirica: il Rumore che non è Rumore. Nel contesto dell'ingegneria dei dati applicata all'industria discografica, emerge una conclusione fondamentale: **nella musica, il "rumore" non è mai un errore o uno scarto da cestinare, bensì una manifestazione di atipicità stilistica o di bassa densità di catalogo**.

A comprova di ciò, sottoponendo i 462 brani noise di DBSCAN all'inferenza probabilistica del modello GMM sui 5 profili acustici, si registra un risultato sbalorditivo: la **mediana dell'affiliazione GMM più alta è pari al** $92,8\%$ **(**$0,928$**)**, e l'85% delle tracce outlier presenta un'affinità dominante superiore all'80%. Ciò dimostra in modo inconfutabile che questi brani non sono affatto "rumore bianco privo di struttura", ma brani con un'identità musicale fortissima e ben definita, penalizzati unicamente dall'abitare quartieri a bassa densità demografica nello spazio metrizzato.

L'ispezione dei singoli titoli estratti dal dataset offre conferme illuminanti:

- La celebre ballata pop *"Unfaithful"*, espulsa da DBSCAN come noise a causa del tempo moderato e dell'intensa componente pianistica che la distanzia dalla massa ritmica da discoteca, viene riclassificata dal GMM con un'affiliazione del $99,98\%$ alla Componente 1 (*Acustico / Intimo*). Per un ascoltatore, scartarla come "rumore" sarebbe un errore madornale: si tratta invece di una traccia perfetta per una playlist da camera o relax.

- Il brano *"Weekend (feat. Miguel)"* (catalogato come *Underground Rap* con forte venatura vocale RnB), anch'esso bollato come noise da DBSCAN, ottiene un'affiliazione dell'$87,8\%$ alla Componente 1.

- Tracce come *"FACE"* o *"Show Me Respect"* (Rap/Hiphop), isolate per via di durate non convenzionali e valori anomali di parlato, mantengono affiliazioni superiori al 53%–60% all'archetipo Urban/Ritmico (Componente 4).

DBSCAN si dimostra quindi uno straordinario strumento di **rilevamento di anomalie editoriali** (isolando skit o brani dalla struttura non convenzionale), la cui combinazione con il GMM consente di non perdere nessun brano del patrimonio musicale, assegnando a ciascun outlier la propria collocazione d'ascolto ideale.

4.3.4 Evoluzione di DBSCAN: HDBSCAN e affiliazioni dei brani periferici

Per verificare se la concentrazione in un unico mega-cluster dipenda dal vincolo di un raggio di vicinato ϵ rigido e costante, è stato applicato HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) nello stesso spazio PCA a quattro dimensioni e sul medesimo campione di $N = 6.000$ brani.

La configurazione adotta i parametri `min_cluster_size=30` (per evitare micro-raggruppamenti effimeri privi di valore di playlist) e `min_samples=5` (che governa la severità della stima di densità locale tramite la distanza di raggiungibilità mutua). Esplorando gerarchicamente la persistenza della densità a scale variabili, HDBSCAN individua **10 cluster stabili** e marca come noise **4.847 brani (80,78% del campione)**.

Questo comportamento certifica che HDBSCAN non appiana automaticamente la periferia quando applicato su varietà continue: richiedendo una persistenza gerarchica rigorosa prima di fondere i rami del dendrogramma, l'algoritmo frammenta la megalopoli in 10 micro-comunità timbriche dense e classifica come transizione di fondo oltre l'80% delle tracce intermedie. Nel campione, nessuno dei 462 punti noise di DBSCAN viene promosso a membro stabile di un cluster HDBSCAN; solo 22 tracce mostrano una debole affiliazione soft (max-affinity $\geq 0,10$).

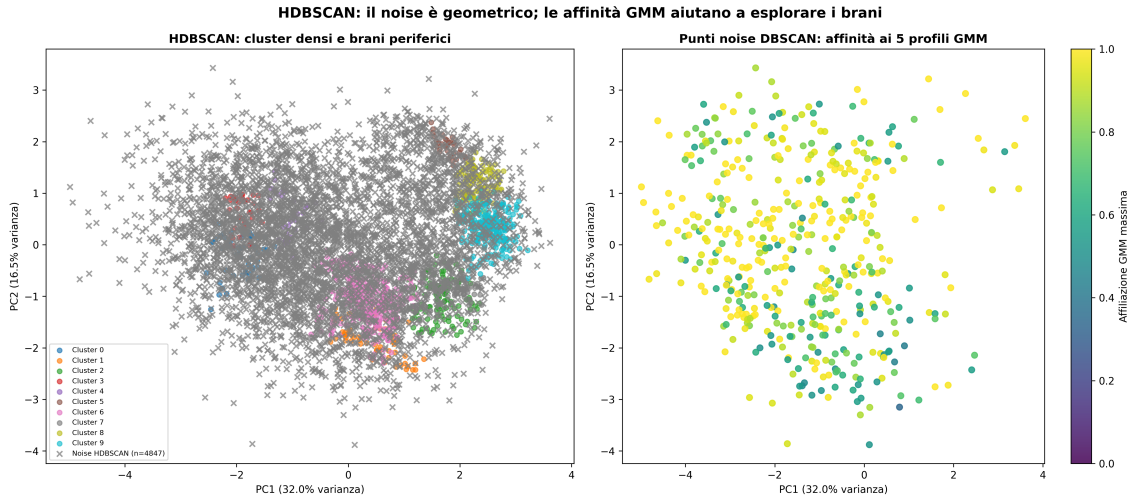

Figura 30: Cluster HDBSCAN a densità variabile e affiliazione GMM massima dei 462 brani noise DBSCAN nella proiezione PCA 2D.

La Figura **??** sintetizza la convergenza dei due approcci: l'etichetta noise riflette la geometria interna di ciascun algoritmo su coordinate ipersferiche, ma non esaurisce la complessità dell'esperienza musicale. Integrando la severità topologica di DBSCAN e HDBSCAN con la flessibilità probabilistica di GMM, il catalogo può essere navigato su più livelli: partizioni per macro-mood (K-Means), ponti di transizione sfumata (GMM Soft Memberships), e filtraggio di perle rare ed eccentriche adatte a playlist di scoperta di nicchia.

5 Business case finale e conclusioni della Parte 1

La prima parte del presente elaborato ha sviluppato una pipeline completa di Data Science applicata all'analisi di oltre 35.000 tracce musicali estratte da Spotify, combinando pulizia dei dati, modellazione predittiva supervisionata e raggruppamento non supervisionato. L'integrazione di queste metodologie ha permesso di raggiungere conclusioni metodologiche solide e di formulare scenari applicativi di grande valore operativo per l'industria dello streaming musicale.

5.1 Sintesi dei risultati metodologici

- **Qualità del dato ed ETL:** La corretta deduplicazione su Track ID (rimozione di 6.428 record duplicati) si è rivelata determinante per eliminare il rischio di data leakage tra set di training e test. La combinazione di SMOTE ed undersampling ha permesso di compensare efficacemente il naturale sbilanciamento delle classi senza introdurre distorsioni geometriche nelle relazioni tra attributi.

- **Classificazione multiclasse:** Su un problema ad elevata complessità (15 generi distinti e sole 13 feature acustiche, senza testo o metadati dell'artista), i modelli Ensemble hanno dimostrato un'eccellente capacità predittiva. Lo **Stacking Classifier** ha raggiunto un'accuratezza del **68.90%** e un Weighted F1 di **0.6890**, supportato da una **Macro-Average ROC-AUC pari a 0.94**. L'analisi della matrice di confusione ha attestato che gli errori avvengono quasi esclusivamente tra generi contigui dal punto di vista timbrico e produttivo (Dark Trap, Underground Rap e Trap Metal).

- **Clustering non supervisionato nello spazio PCA:** La selezione ragionata delle 8 feature acustiche continue e la riduzione di dimensionalità mediante **PCA a 4 componenti principali (73,96% di varianza spiegata)** hanno permesso di purificare la metrica euclidea da ridondanze e variabili categoriche. Nello spazio PCA a 4 dimensioni, il modello **K-Means con** $k = 5$ ha identificato 5 chiari archetipi musicali (*High-Intensity Bass & Workout, Extended Club & Instrumental, Acoustic Chill & Atmospheric, Groove Melodic Urban & Pop, Fast-Flow Rap & High-BPM*), validati da un massimo locale del coefficiente di Silhouette pari a **0,2829**. Parallelamente, l'algoritmo **DBSCAN (**$\epsilon = 0,60$, **`min_samples`** $= 5$**)** ha evidenziato la natura continua del nucleo musicale principale, isolando con precisione un **7,70% di tracce outlier (462 brani)** caratterizzate da durate estreme, parlato anomalo o combinazioni timbriche atipiche.

5.2 Ricadute applicative e scenari di business

I risultati conseguiti aprono la strada a tre concrete applicazioni commerciali:

1. **Generazione di playlist basate sui mood (K-Means):** Le etichette di genere tradizionali risultano spesso rigide o fuorvianti: canzoni formalmente catalogate in generi diversi possono condividere lo stesso impatto emotivo e ritmico. Il partizionamento in 5 macro-mood consente alle piattaforme di streaming di generare raccomandazioni dinamiche per attività quotidiane (*Workout, Focus, Chillout, Party*) basate unicamente sulle caratteristiche acustiche intrinseche della musica.

2. **Controllo qualità e anomaly detection automatizzata (DBSCAN):** Con l'upload giornaliero di centinaia di migliaia di brani da parte di etichette indipendenti e utenti, DBSCAN costituisce un potente strumento automatico di controllo qualità, capace di intercettare file corrotti, podcast catalogati erroneamente come musica o registrazioni amatoriali difettose prima dell'indicizzazione editoriale.

3. **Valutazione matematica di nuove uscite e demo (Classificazione Stacking):** Il modello predittivo addestrato può essere impiegato dalle case discografiche e dai team di A&R (Artists and Repertoire) per analizzare le tracce demo appena registrate, identificandone con precisione matematica il posizionamento di genere e il pubblico di riferimento prima del lancio promozionale.

5.3 Sviluppi futuri

Come sviluppi futuri per l'analisi acustica, il lavoro potrebbe essere esteso integrando tecniche multimodali: in particolare, l'analisi testuale dei testi delle canzoni (*lyrics*) mediante modelli di Natural Language Processing (BERT/Transformers) e l'elaborazione degli spettrogrammi audio completi attraverso reti neurali convoluzionali (CNN). L'unione di segnali acustici, linguistici e comportamentali (storico di ascolto degli utenti) consentirà di affinare ulteriormente la precisione dei sistemi di raccomandazione musicale di nuova generazione.

Elenco delle figure

1 Distribuzione delle frequenze dei 15 generi musicali nel dataset post-ETL. 8
2 Distribuzione delle caratteristiche audio continue (istogrammi e curve di densità KDE). 9
3 Distribuzione delle variabili discrete: Tonalità (`key`), Modo (`mode`) e Metro (`time_signature`). 11
4 Matrice di correlazione di Pearson tra le feature audio calcolata sul dataset prima del sampling. 12
5 Bilanciamento del Training Set: confronto della distribuzione delle classi pre vs post SMOTE e Undersampling. 15
6 Matrice di correlazione di Pearson verificata sul Training Set post-bilanciamento. 16
7 Confronto dell'accuratezza sul Test Set tra gli 8 modelli di Machine Learning testati. 18
8 Matrice di confusione normalizzata ottenuta dal modello Ensemble finale sul Test Set. 20
9 Heatmap del Classification Report: valori di Precision, Recall ed F1-Score per ciascun genere. 21
10 Valutazione delle performance: Curve ROC One-vs-Rest e Curve Precision-Recall. 22
11 Learning Curve (Training vs Validation) calcolata al variare della numerosità del dataset. 23
12 Feature Importance: confronto dei contributi percentuali tra Random Forest e XGBoost. 24
13 Matrice di confusione normalizzata del Voting Classifier sulle 4 Macro-Famiglie (archivio `figures_contu/fig08_confusion_matrix_macro.png`). 26
14 Curve ROC One-vs-Rest per le 4 Macro-Famiglie, con un AUC medio globale pari a 0.98 (archivio `figures_contu/fig10_roc_curves_macro.png`). 27
15 Importanza relativa delle feature per lo scenario a Macro-Generi calcolata da Random Forest e XGBoost (archivio `figures_contu/fig13_feature_importance_macro.png`). 28
16 Matrici di confusione dei 4 classificatori specialisti XGBoost di Livello 2 addestrati sulle singole macro-famiglie (file della suite `figures_contu`). 29
17 PCA sulle 8 feature acustiche: Scree Plot della varianza spiegata individuale e cumulativa con soglia obiettivo del 70%. 36
18 Mappa 2D generata tramite t-SNE sulle feature acustiche, colorata retrospettivamente per genere Spotify originale. 39

19 Selezione del parametro k per K-Means nello spazio PCA (4 PC): curva WCSS (a sinistra) e Coefficiente di Silhouette medio (a destra). 40
20 Partizionamento K-Means ($k = 5$) visualizzato nel piano lineare PCA (PC_1 vs PC_2 con centroidi) e sulla mappa non lineare t-SNE 2D. 41
21 Profiling acustico dei 5 cluster K-Means: Heatmap delle medie reali per feature (a sinistra) e Radar Chart comparativo delle impronte sonore (a destra). 42
22 Profilo dei coefficienti di Silhouette per ciascun cluster K-Means ($k = 5$) calcolato nello spazio PCA a 4 componenti. 44
23 GMM a cinque componenti nello spazio PCA e distribuzione dell'affiliazione massima per brano. 45
24 Curva ordinata delle distanze dal 5° vicino più prossimo (k-NN) nello spazio PCA a 4 componenti, con ginocchio ottimale in $\epsilon = 0,60$. 47
25 Griglia di tuning iperparametrica DBSCAN nello spazio PCA 4D: Numero di cluster identificati (a sinistra) e Silhouette Score dei punti assegnati (a destra). 48
26 Clusterizzazione DBSCAN ($\epsilon = 0,60$, $\texttt{min_samples} = 5$) nello spazio PCA 2D (a sinistra) e t-SNE 2D (a destra), con evidenziazione dei 462 punti noise. 49
27 Analisi diagnostica dei punti noise DBSCAN: confronto tramite boxplot tra il nucleo denso e i 462 brani periferici. 50
28 Cluster HDBSCAN e affiliazione GMM massima dei 462 brani noise DBSCAN nella proiezione PCA 2D. 51

Elenco delle tabelle

1 Colonne del dataset e relativo formato dei dati. 6
2 Quota di varianza spiegata individuale e cumulativa per ciascuna Componente Principale (PCA sulle 8 feature acustiche selezionate). 36
3 Matrice dei Loadings (pesi lineari) delle prime 4 Componenti Principali rispetto alle 8 feature acustiche standardizzate. 37
4 Distribuzione numerica e percentuale dei brani nei 5 cluster K-Means (campione di analisi e intero catalogo deduplicato). 41
5 Sintesi descrittiva delle componenti GMM sul campione di 6.000 brani. I generi sono riportati solo come interpretazione a posteriori. 46

UNIVERSITÀ POLITECNICA DELLE MARCHE

FACOLTÀ DI INGEGNERIA

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

---

PROGETTO DI DATA SCIENCE

Parte 2: Analisi delle Serie Storiche sul Mercato Calcistico Europeo

Ricostruzione temporale su dati Transfermarkt, studio quantitativo degli shock di mercato, decomposizione stagionale e modelli predittivi (ARIMA, SARIMAX con variabili esogene)

Docenti:

Prof. Ursino Domenico

Dott. Buratti Christopher

A cura di:

Altieri Andrea

Belardinelli Luca

Contursi Andrea

Flaiani Andrea

ANNO ACCADEMICO 2024–2025

Indice

1 Analisi delle serie storiche sul mercato calcistico: introduzione e data-set **2**

1.1 Struttura del dataset relazionale di Transfermarkt 2

1.2 Processo di ETL e ricostruzione storica mensile 3

2 Analisi esplorativa della serie storica e dinamica degli shock di mercato **6**

2.1 Confronto tra i cinque campionati europei e divario strutturale 6

2.2 I tre grandi shock storici del mercato 8

2.3 Variazioni percentuali mensili e individuazione degli outlier 9

2.4 Relazione tra valore delle rose e spese nel calciomercato 11

3 Decomposizione stagionale, test di stazionarietà e autocorrelazione **12**

3.1 Decomposizione STL della serie storica 12

3.2 Test di stazionarietà e differenziazione della serie 14

3.3 Analisi delle autocorrelazioni ACF e PACF 15

4 Modellazione predittiva, focus sulla Serie A e conclusioni **17**

4.1 Divisione temporale Training/Test e metriche di errore 17

4.2 I cinque modelli in gara 18

4.3 Confronto dei risultati sul Test Set 18

4.4 Diagnostica dei residui del modello SARIMAX 20

4.5 Focus previsionale sulla Serie A 21

4.6 Conclusioni 22

Elenco delle figure **24**

Elenco delle tabelle **25**

1 Analisi delle serie storiche sul mercato calcistico: introduzione e dataset

Negli ultimi quindici anni il calcio europeo si è trasformato in un vero e proprio **mercato finanziario globale**, caratterizzato da investimenti miliardari, cicli stagionali legati alle finestre di compravendita e una forte sensibilità agli shock economici esterni. A differenza dei mercati azionari tradizionali, dove i prezzi variano in modo continuo ogni giorno, il mercato calcistico segue due meccanismi complementari: le stime del valore dei singoli giocatori vengono aggiornate periodicamente dagli analisti durante la stagione, mentre gli acquisti reali avvengono nelle due **sessioni ufficiali di calciomercato** (a gennaio e tra luglio e agosto).

L'obiettivo di questa seconda parte dell'elaborato è ricostruire, analizzare e prevedere la **serie storica mensile** del valore di mercato delle rose dei cinque maggiori campionati europei (**Serie A**, **Premier League**, **LaLiga**, **Bundesliga** e **Ligue 1**) tra il 2011 e il 2026, dedicando un focus specifico al campionato italiano e valutando come le spese effettive di calciomercato possano migliorare le previsioni dei modelli statistici.

1.1 Struttura del dataset relazionale di Transfermarkt

I dati provengono dal repository pubblico *Football Data from Transfermarkt* su Kaggle. La fonte non fornisce una serie storica già pronta, ma un **database relazionale** composto da dodici tabelle in formato `.csv`. Per ricostruire l'andamento mensile del valore delle squadre e dei volumi di spesa sono state integrate le **cinque tabelle principali** riassunte nella Tabella **??**.

Tabella 1: Riepilogo delle cinque tabelle del dataset di Transfermarkt utilizzate nella pipeline.

File sorgente	Record	Ruolo nella ricostruzione della serie storica
`player_valuations.csv`	656.301	Storico delle valutazioni di mercato in euro (`market_value_in_eur`)
`transfers.csv`	175.165	Trasferimenti tra club e costo dei cartellini (`transfer_fee`)
`appearances.csv`	1.894.350	Presenze in partita per verificare il club effettivo mese per mese
`clubs.csv`	796	Anagrafica delle squadre e associazione al campionato nazionale
`competitions.csv`	65	Codici identificativi dei cinque maggiori campionati europei

La tabella principale è `player_valuations.csv`, che registra lo storico delle quotazioni individuali (`market_value_in_eur`) associate a ciascun calciatore (`player_id`) in una data specifica. Questa è stata incrociata con `transfers.csv` (che traccia i cambi di squadra e le spese di acquisto), con `appearances.csv` (che attesta in quale club il giocatore è sceso in campo) e con le tabelle anagrafiche `clubs.csv` e `competitions.csv` per filtrare i cinque massimi campionati europei: **Serie A** (`IT1`), **Premier League** (`GB1`), **LaLiga** (`ES1`), **Bundesliga** (`L1`) e **Ligue 1** (`FR1`).

1.2 Processo di ETL e ricostruzione storica mensile

Per trasformare i record grezzi in una serie storica mensile regolare senza buchi o distorsioni, lo script `01_etl_transfermarkt.py` risolve **due problemi strutturali** presenti nei dati di partenza.

Il **primo problema** è la diversa cadenza temporale tra aggiornamenti dei listini e calciomercato. Nel file `player_valuations.csv`, le revisioni dei prezzi avvengono soprattutto a marzo, giugno, ottobre e dicembre, mentre sono molto rare a gennaio, luglio e agosto perché la redazione attende la chiusura delle trattative. Proprio in quei mesi, però, il file `transfers.csv` registra il picco di acquisti e cessioni che modificano il valore delle squadre.

Questa complementarità è visibile nella Figura **??**: i mesi con meno aggiornamenti di listino coincidono esattamente con i picchi del calciomercato (luglio, agosto e gennaio), dove la spesa media mensile supera i **2.300 milioni di euro** a luglio, i **1.280 milioni** ad agosto e i **550 milioni** a gennaio.

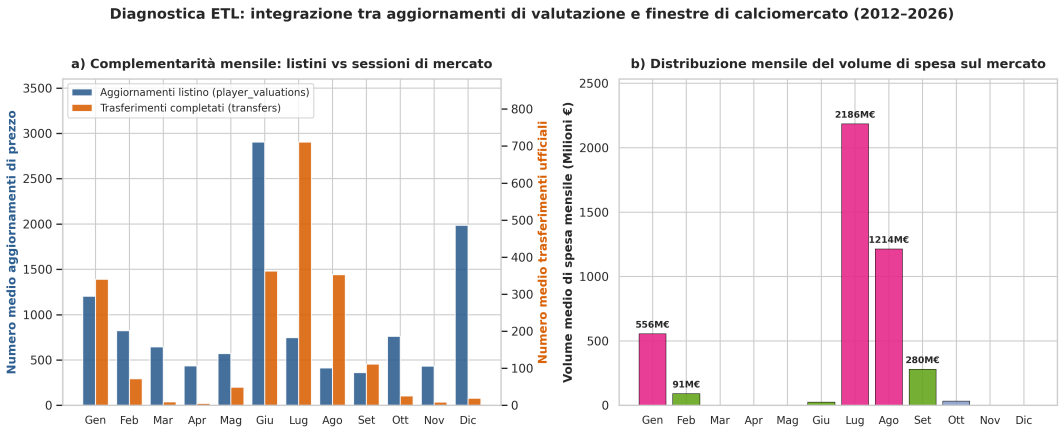

Figura 1: Complementarità stagionale tra la frequenza mensile degli aggiornamenti di valutazione e il volume delle operazioni di calciomercato nei cinque maggiori campionati europei.

Il **secondo problema** riguarda la **distorsione sul club di appartenenza**. In `player_valuations.csv`, la colonna `current_club_id` è un dato statico che indica solo la squadra in cui il giocatore milita nel 2026. Aggregare i valori usando

direttamente quel campo significherebbe attribuire tutta la carriera passata di un calciatore al suo club del 2026: chi giocava in Serie A nel 2019 ma oggi gioca all'estero (o si è ritirato) verrebbe escluso dal calcolo storico della Serie A, causando una forte sottostima negli anni passati.

Per risolvere entrambi gli aspetti, la pipeline mostrata nel Listato **??** costruisce una griglia mensile regolare di **180 mesi consecutivi** (da giugno 2011 a maggio 2026, escludendo giugno 2026 perché incompleto nell'estrazione) e ricostruisce mese per mese sia l'ultima valutazione valida del giocatore (con propagazione in avanti *forward-fill* fino a un massimo di 18 mesi per escludere i ritirati), sia la squadra in cui militava realmente in quel mese tramite presenze in campo e trasferimenti.

01_etl_transfermarkt.py

```python
# 1. Griglia mensile regolare e propagazione dell'ultima valutazione valida (max 18 mesi)
grid_months = pd.period_range("2009-01", "2026-05", freq="M")
target_months = pd.period_range("2011-06", "2026-05", freq="M")  # 180 mesi (15 anni)

val_m = vals_sub.groupby(["player_id", "year_month"])["market_value_in_eur"].last().unstack(level=0)
val_ff = val_m.reindex(grid_months).ffill(limit=18)

# 2. Ricostruzione del club storico mese per mese da presenze e trasferimenti
app_club_m = app_sub.groupby(["player_id", "year_month"])["player_club_id"].last()
tr_club_m = tr_sub.groupby(["player_id", "year_month"])["to_club_id"].last()

club_events = pd.concat([app_club_m, tr_club_m]).groupby(level=[0, 1]).last().unstack(level=0)
club_events = club_events.reindex(index=grid_months, columns=val_ff.columns)
club_hist = club_events.ffill().bfill().fillna(val_club_m)

# 3. Mappatura dal club storico alla rispettiva lega nazionale (IT1, GB1, ES1, L1, FR1)
comp_hist = club_hist.apply(lambda col: col.map(club_to_comp)).fillna("OTHER")
```

Listato 1: Ricostruzione storica mensile del valore di mercato e del club di appartenenza nello script `01_etl_transfermarkt.py`.

Il risultato di questa ricostruzione è illustrato nella Figura **??**. Nel pannello superiore si vede come l'aggregazione statica basata sul club del 2026 (linea tratteggiata arancione) sottostimi la Serie A per tutto il decennio 2014–2022, perdendo quasi **un miliardo di euro** nel 2019–2020 rispetto alla ricostruzione storica corretta (linea verde). Nel pannello inferiore è mostrata la serie principale

post-ETL dei cinque campionati europei, che presenta zero mesi mancanti e variazioni attive in tutti i 180 mesi.

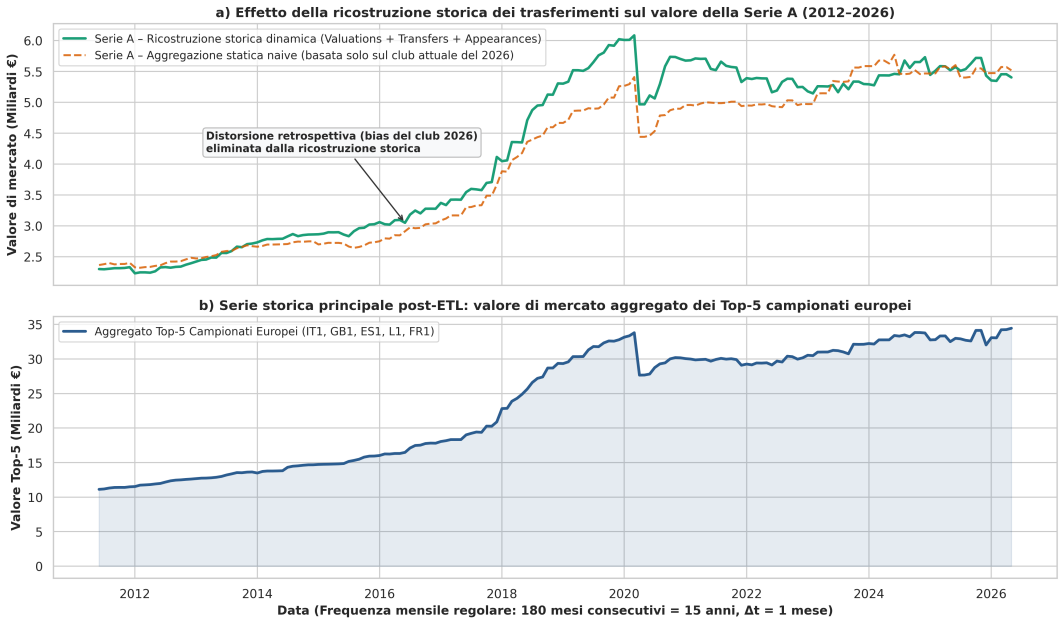

Figura 2: Confronto tra aggregazione statica e ricostruzione storica dinamica per la Serie A e andamento complessivo della serie storica principale post-ETL sui 180 mesi di osservazione.

Le variabili principali salvate nel file finale `market_monthly.csv` sono sintetizzate nella Tabella **??**.

Tabella 2: Variabili principali del dataset mensile elaborato `market_monthly.csv` (180 osservazioni).

Variabile	Unità / Tipo	Descrizione del contenuto
`year_month, date`	Data mensile	Indice temporale mensile regolare (giugno 2011 – maggio 2026)
`top5_market_value_bn`	Mld EUR	Valore totale delle rose dei cinque campionati europei
`serie_a_market_value_bn`	Mld EUR	Valore totale delle rose della Serie A (`IT1`)
`<lega>_market_value_bn`	Mld EUR	Valore delle rose di Premier, LaLiga, Bundesliga, Ligue 1
`mean_player_value_m`	Mln EUR	Valore di mercato medio per calciatore attivo
`transfer_spend_top5_m`	Mln EUR	Spesa mensile per acquisti onerosi nei cinque campionati
`transfer_spend_serie_a_m`	Mln EUR	Spesa mensile per acquisti onerosi in Serie A
`n_transfers_top5`	Intero	Numero di trasferimenti conclusi nel mese
`pct_change_top5`	Float (%)	Variazione percentuale mensile del valore delle rose
`shock_covid_2020`	Binaria [0/1]	Indicatore dello shock pandemico di aprile 2020

2 Analisi esplorativa della serie storica e dinamica degli shock di mercato

A partire dal dataset mensile ricostruito nella fase di ETL, l'**analisi esplorativa dei dati** (*Exploratory Data Analysis*, EDA) esamina l'andamento del mercato calcistico europeo lungo i 180 mesi tra giugno 2011 e maggio 2026. Lo studio, implementato nello script `02_eda_e_shock.py`, si concentra su tre aspetti: il confronto tra i cinque campionati nazionali, l'impatto dei tre principali shock storici e il legame tra il valore delle rose e le spese effettive di calciomercato.

2.1 Confronto tra i cinque campionati europei e divario strutturale

Tra giugno 2011 e maggio 2026 il valore complessivo delle rose dei cinque maggiori campionati europei è più che triplicato, passando da **11,12 miliardi** a **34,44 miliardi di euro** (**+209,7%**). Questa crescita non è stata però uniforme tra i paesi, ma è stata trainata in larga parte dalla **Premier League** inglese, come mostrato nella Figura **??**.

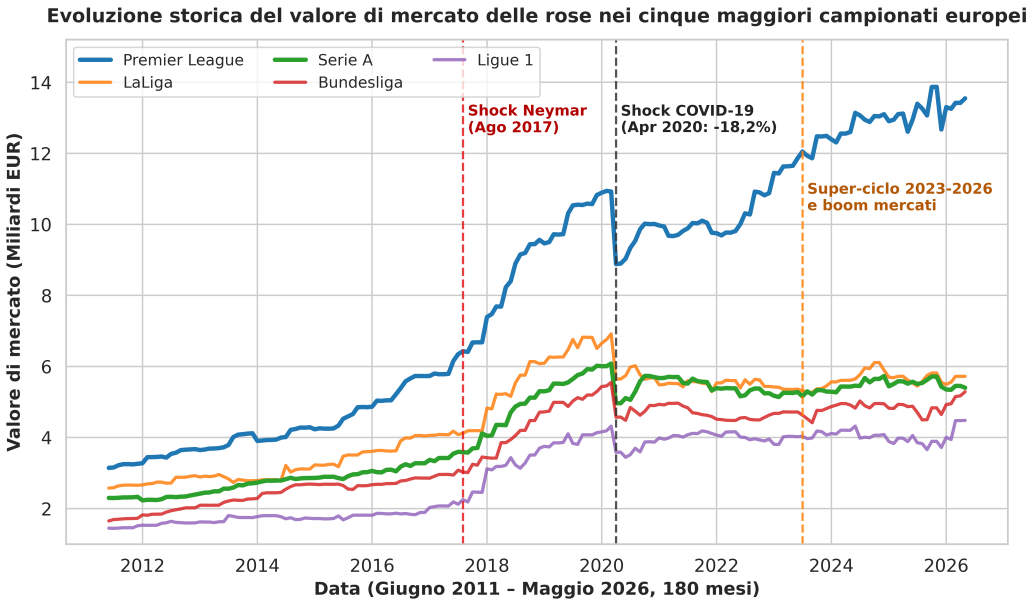

Figura 3: Evoluzione storica del valore di mercato delle rose nei cinque maggiori campionati europei tra giugno 2011 e maggio 2026.

Come riassunto nella Tabella **??**, nel giugno 2011 il divario tra i campionati era contenuto: la Premier League guidava con 3,15 miliardi di euro, seguita da **LaLiga** (2,58 miliardi) e dalla **Serie A** (2,30 miliardi), mentre **Bundesliga** (1,65 miliardi) e **Ligue 1** (1,45 miliardi) chiudevano la classifica.

Negli anni successivi, grazie ai ricavi molto più elevati derivanti dai diritti televisivi internazionali, il campionato inglese ha preso il largo: la Premier League è

Tabella 3: Valore di mercato delle rose (in miliardi di euro) e variazioni percentuali nei cinque campionati europei nelle date chiave.

Campionato	Giu 11	Lug 17	Mar 20	Apr 20	Mag 26	$\Delta\%$ COVID	$\Delta\%$ Totale
Premier League (GB1)	3,15	6,35	10,92	8,88	13,55	$-18,70\%$	$+330,6\%$
LaLiga (ES1)	2,58	4,08	6,92	5,65	5,72	$-18,36\%$	$+122,2\%$
Serie A (IT1)	2,30	3,60	6,08	4,97	5,40	$-18,34\%$	$+134,9\%$
Bundesliga (L1)	1,65	3,08	5,55	4,57	5,29	$-17,60\%$	$+220,0\%$
Ligue 1 (FR1)	1,45	2,12	4,32	3,59	4,48	$-17,01\%$	$+209,4\%$
Totale Top-5	**11,12**	**19,23**	**33,79**	**27,65**	**34,44**	$-18,17\%$	$+209,7\%$

cresciuta del **330,6%**, toccando il record di **13,87 miliardi di euro** nel novembre 2025 e arrivando a rappresentare da sola il **39,3% dell'intero mercato europeo** (Figura **??**), contro il 28,3% del 2011.

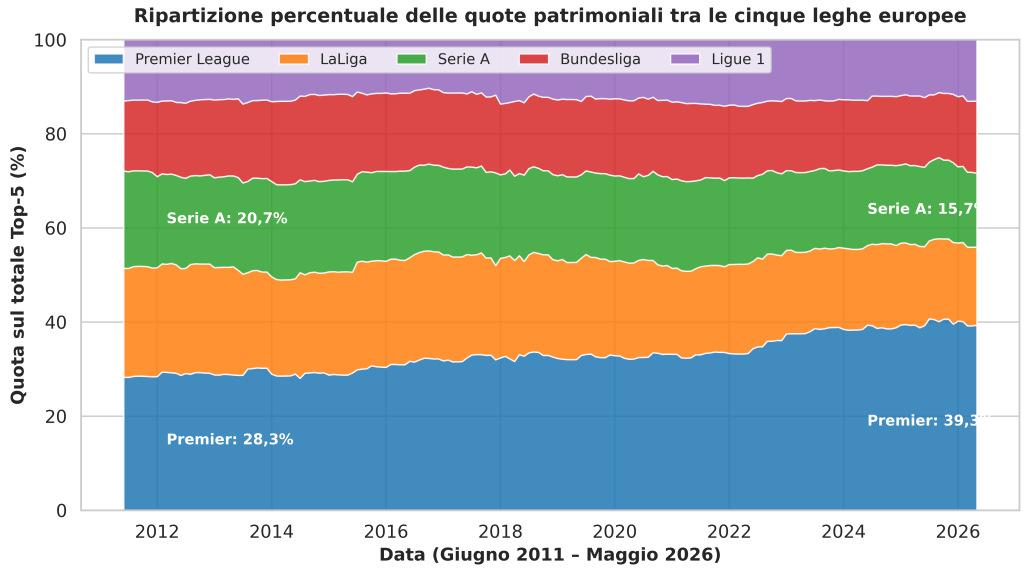

Figura 4: Ripartizione percentuale delle quote di mercato tra le cinque leghe europee sul totale Top-5 (2011–2026).

La **Serie A** ha seguito un percorso diviso in tre fasi: una crescita lenta tra il 2011 e il 2015 (da 2,30 a 2,90 miliardi di euro), una forte espansione tra il 2016 e l'inizio del 2020 fino al picco storico di **6,08 miliardi di euro** (marzo 2020) e infine una fase post-pandemica più prudente. Nel maggio 2026 la Serie A vale **5,40 miliardi di euro** (**+134,9%** rispetto al 2011, pari al **15,7%** del totale europeo), mantenendo il terzo posto dietro a Premier League e LaLiga (5,72 miliardi).

2.2 I tre grandi shock storici del mercato

L'andamento della serie storica non è lineare, ma presenta **tre rotture strutturali** molto nette che corrispondono a precisi eventi economici e sportivi.

Il **primo shock** avviene nell'agosto 2017 (`2017-08`) con il trasferimento record di **Neymar** dal Barcellona al Paris Saint-Germain per 222 milioni di euro (pagamento integrale della clausola rescissoria, ad oggi il trasferimento più oneroso della storia del calcio), accompagnato dall'entrata in vigore dei nuovi contratti televisivi europei. Come mostra la Figura **??**, questo evento ha innescato una forte inflazione dei prezzi cambiando la pendenza della curva: prima dell'estate 2017 il valore complessivo cresceva in media di **+1,31 miliardi di euro all'anno**, mentre tra agosto 2017 e inizio 2020 la velocità di crescita è quadruplicata, salendo a **+5,46 miliardi di euro all'anno**.

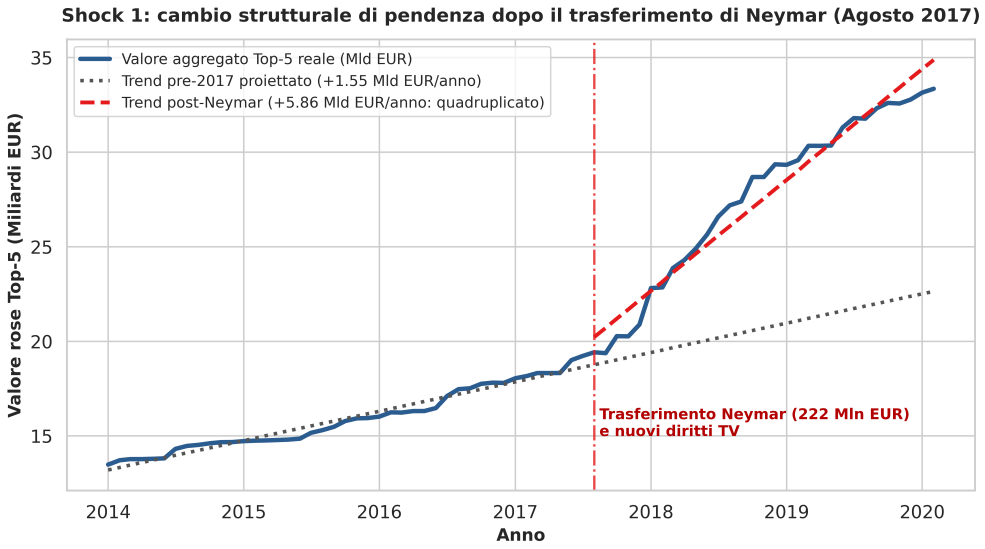

Figura 5: Shock 1: accelerazione del trend di crescita dopo il trasferimento di Neymar nell'agosto 2017.

Il **secondo shock**, visibile nella Figura **??**, è legato allo scoppio della **pandemia da COVID-19** e al blocco dei campionati nella primavera del 2020. Ad aprile 2020 Transfermarkt ha applicato un taglio straordinario ai listini (comunicato dell'8 aprile 2020: -20% generale e -10% per i nati dal 1998, per un totale mondiale di $9,22$ miliardi svalutati). Nel nostro dataset dei 5 campionati maggiori, il valore è crollato in 30 giorni da 33,79 a 27,65 miliardi di euro ($-18,17\%$, pari a **-6,14 miliardi di euro**, esattamente due terzi del totale mondiale), mentre la Serie A ha perso il **18,34%** scendendo a 4,97 miliardi. Per tornare ai livelli pre-pandemia il mercato ha impiegato **55 mesi**, superando di nuovo i 33,79 miliardi solo nell'ottobre 2024.

Il **terzo shock**, illustrato nella Figura **??**, riguarda il triennio **2023–2026**, spinto dagli acquisti dei club della **Saudi Pro League** a partire dall'estate 2023 e dai maggiori ricavi della nuova **UEFA Champions League** a 36 squadre (dal 2024/2025).

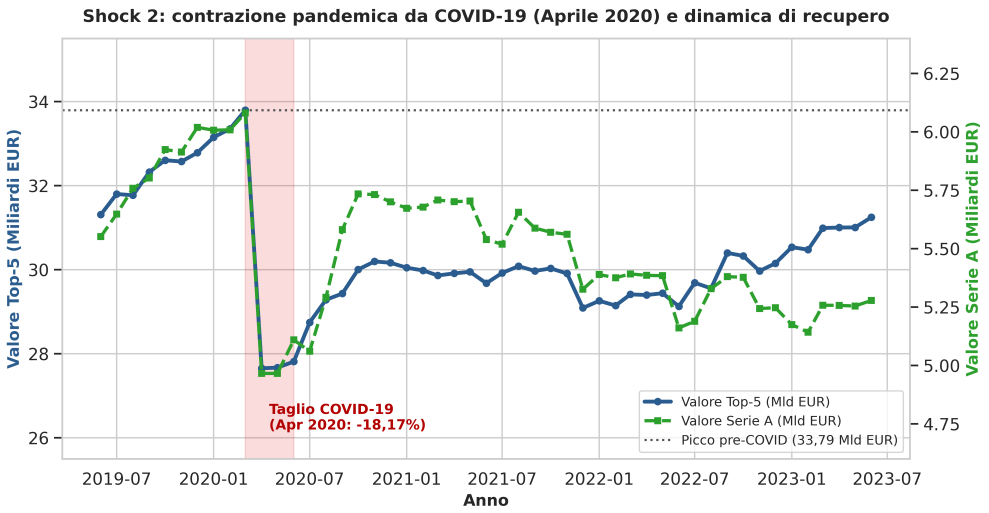

Figura 6: Shock 2: crollo pandemico da COVID-19 nell'aprile 2020 ($-18,17\%$) e tempi di recupero.

Questa nuova liquidità ha portato il mercato al record di **34,44 miliardi di euro** nel maggio 2026 e ha concentrato il valore sui giocatori di fascia alta: il valore medio per singolo calciatore (`mean_player_value_m`), che era di circa 3 milioni di euro fino al 2017 e di 5,07 milioni nel 2020, ha raggiunto gli **11,01 milioni di euro** nel 2026.

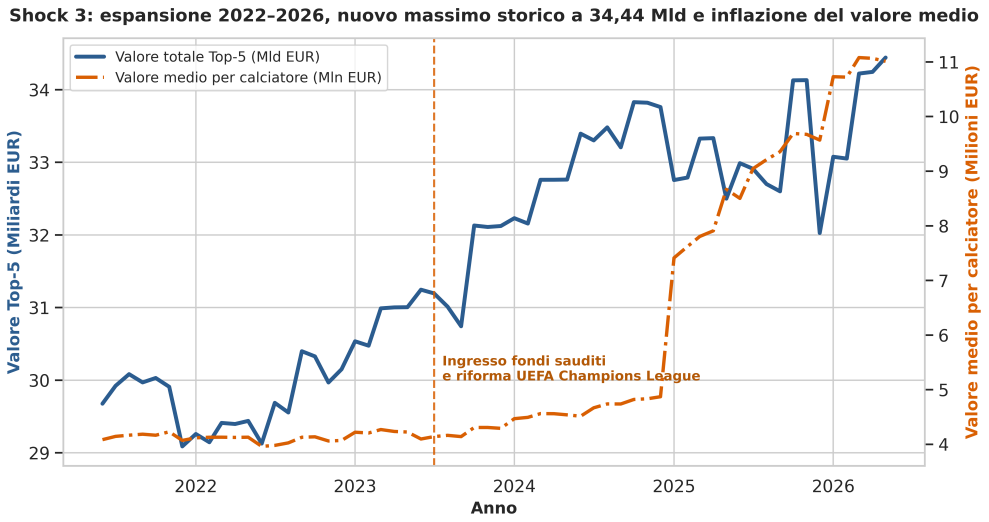

Figura 7: Shock 3: espansione 2023–2026, nuovo massimo storico e crescita del valore medio per calciatore.

2.3 Variazioni percentuali mensili e individuazione degli outlier

Per osservare la volatilità mese per mese senza l'effetto del trend di lungo periodo, è stata analizzata la variazione percentuale mensile $\Delta\%_t = \frac{Y_t - Y_{t-1}}{Y_{t-1}} \cdot 100$, riportata nella Figura **??**.

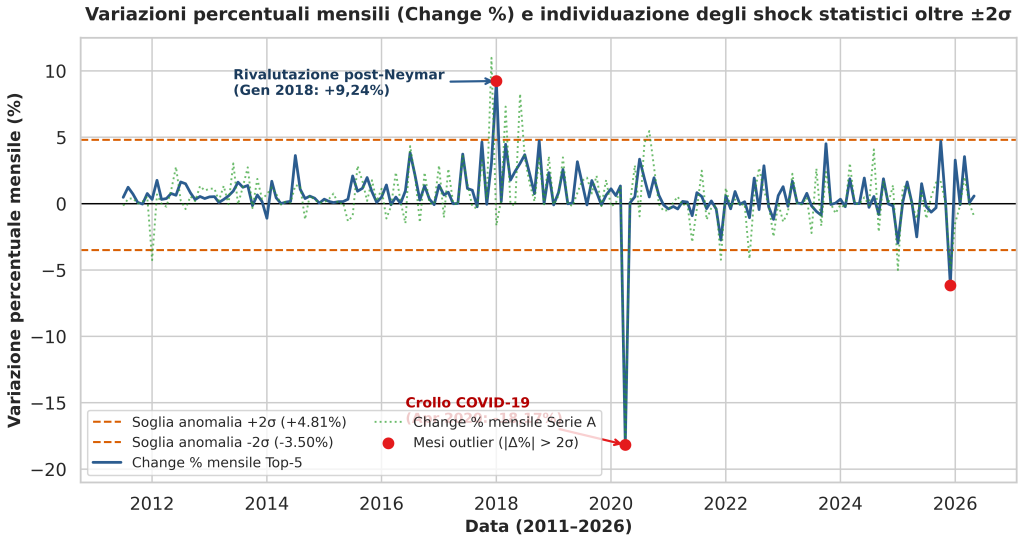

Figura 8: Serie storica delle variazioni percentuali mensili con fasce di confidenza $\pm 2\sigma$ e mesi outlier.

In condizioni normali il valore delle rose cresce in media dello $\mu = +0,66\%$ al mese con una deviazione standard $\sigma = 2,06\%$, restando quasi sempre dentro la fascia $\mu \pm 2\sigma$ ($[-3,46\%,\ +4,78\%]$). I punti che superano questa soglia identificano statisticamente gli eventi anomali del mercato: il rialzo record di **gennaio 2018 (+9,24%)**, dovuto all'adeguamento invernale dei listini dopo il caso Neymar, e il crollo estremo di **aprile 2020 (-18,17%)**, che si trova a oltre nove deviazioni standard dalla media ($z = -9,14$).

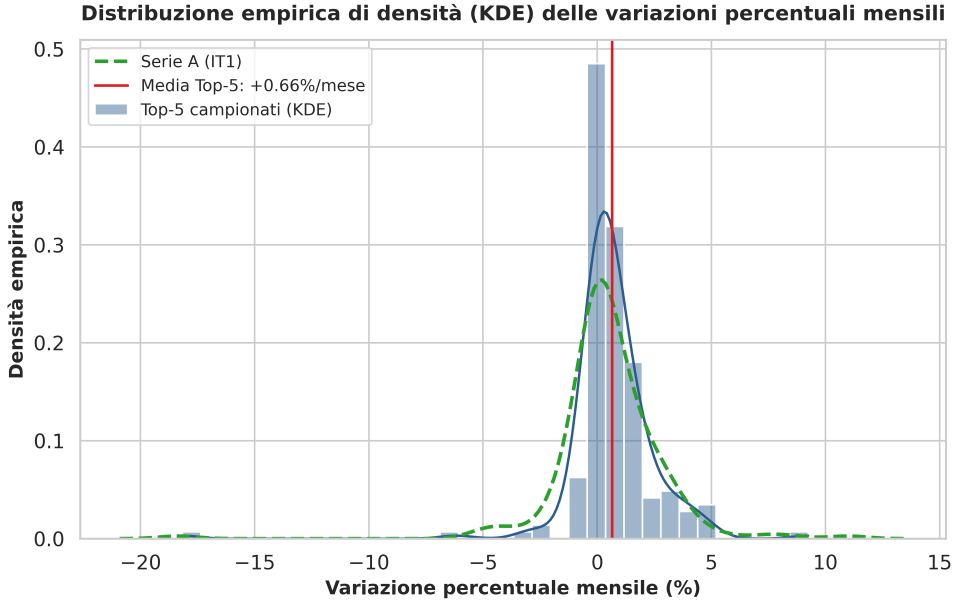

Figura 9: Distribuzione di densità (KDE) e istogramma delle variazioni percentuali mensili per i Top-5 campionati e la Serie A.

Come mostra l'istogramma nella Figura **??**, quasi tutte le variazioni mensili si

concentrano vicino a zero, ma gli shock esterni creano code lunghe e una forte asimmetria negativa (*skewness* pari a $-3,69$). Si nota inoltre che la Serie A ha una volatilità leggermente più alta dell'aggregato europeo ($\sigma_{\text{IT1}} = 2,52\%$), poiché su un singolo campionato le singole sessioni di mercato incidono in modo più diretto.

2.4 Relazione tra valore delle rose e spese nel calciomercato

L'ultimo passo dell'analisi esplorativa verifica il legame tra il valore delle rose e i soldi realmente spesi dai club per comprare i giocatori (`transfer_spend_top5_m`). In quindici anni i cinque campionati hanno registrato **31.000 trasferimenti** per una spesa totale di **65,82 miliardi di euro**, di cui **14,68 miliardi** spesi dai club di Serie A (il 22,3% del totale europeo).

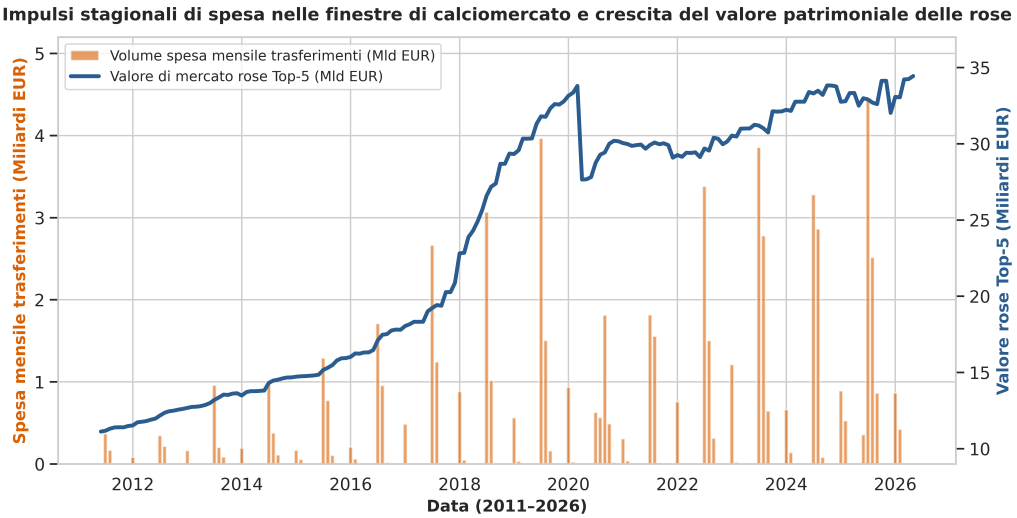

Figura 10: Confronto tra le spese mensili nelle sessioni di calciomercato e la crescita del valore delle rose (2011–2026).

Dalla Figura **??** si vede chiaramente che la spesa avviene a impulsi stagionali concentrati a **luglio e agosto** (e in misura minore a **gennaio**), ed è cresciuta insieme al valore delle squadre fino al picco record del **luglio 2025**, mese in cui sono stati spesi **4,46 miliardi di euro** nei cinque campionati (e 1,13 miliardi in Serie A).

La matrice di correlazione nella Figura **??** spiega come usare questo dato nei modelli di previsione: la correlazione con la spesa del singolo mese è bassa ($r = 0,24$) perché per nove mesi all'anno il mercato è chiuso; tuttavia, considerando la **spesa cumulata negli ultimi 12 mesi** (`Spesa mobile 12m`), la correlazione con il valore delle rose sale a $r = 0,88$ ($r = 0,92$ per la Premier League e $r = 0,80$ per la Serie A). Questo conferma che il volume di denaro investito nell'ultimo anno di mercato è un ottimo predittore esterno per il modello SARIMAX.

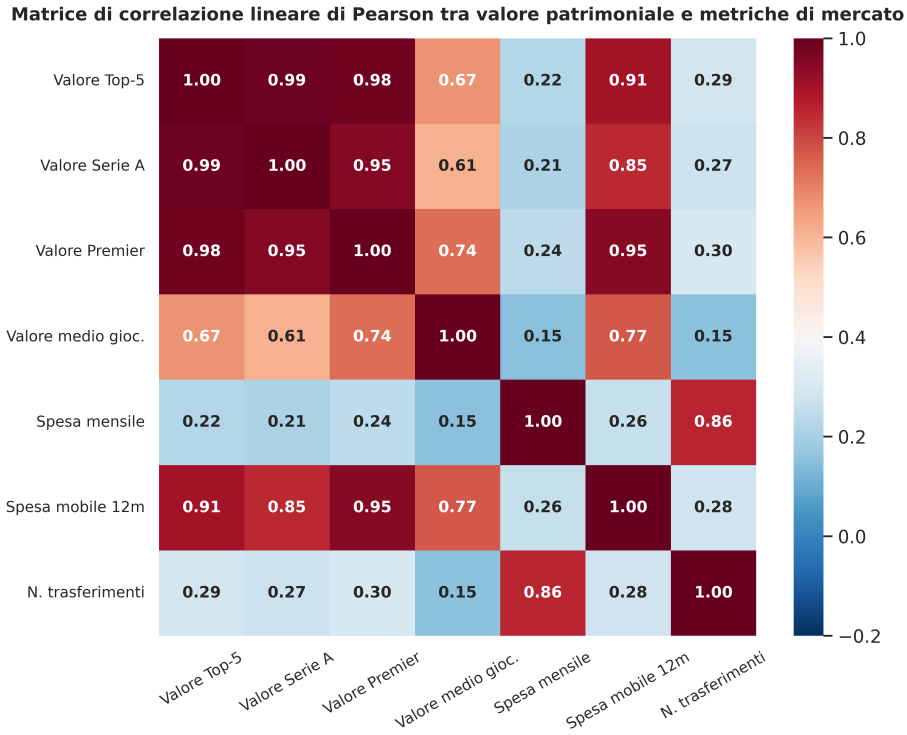

Figura 11: Matrice di correlazione di Pearson tra il valore delle rose e le metriche di spesa del calciomercato.

3 Decomposizione stagionale, test di stazionarietà e autocorrelazione

Prima di addestrare i modelli di previsione è necessario analizzare la struttura matematica della serie storica (`top5_market_value_bn`) attraverso tre passaggi: la scomposizione della curva nelle sue componenti di trend, stagionalità e residuo tramite il metodo **STL**; la verifica della **stazionarietà** con i test statistici **ADF** e **KPSS**; e infine lo studio della memoria temporale con i grafici di autocorrelazione **ACF** e **PACF**. Tutte le analisi sono implementate nel modulo `src/analysis/stl_stationarity.py` e lanciate dallo script `03_run_stl_stationarity.py`.

3.1 Decomposizione STL della serie storica

Per separare le diverse componenti della serie mensile è stato utilizzato il metodo **STL** (*Seasonal and Trend decomposition using Loess*) con periodo stagionale $s = 12$ mesi. Questo metodo scompone la serie osservata Y_t nella somma di tre elementi:

$$Y_t = T_t + S_t + R_t \tag{8}$$

dove T_t è il **trend** di lungo periodo, S_t è la **stagionalità** che si ripete ogni anno e R_t è il **residuo** (cioè le oscillazioni impreviste e gli shock). L'uso della stima robusta

(*Loess*) evita che eventi estremi come il crollo del 2020 deformino il calcolo del trend o della stagionalità. I quattro pannelli della decomposizione sono mostrati nella Figura **??**.

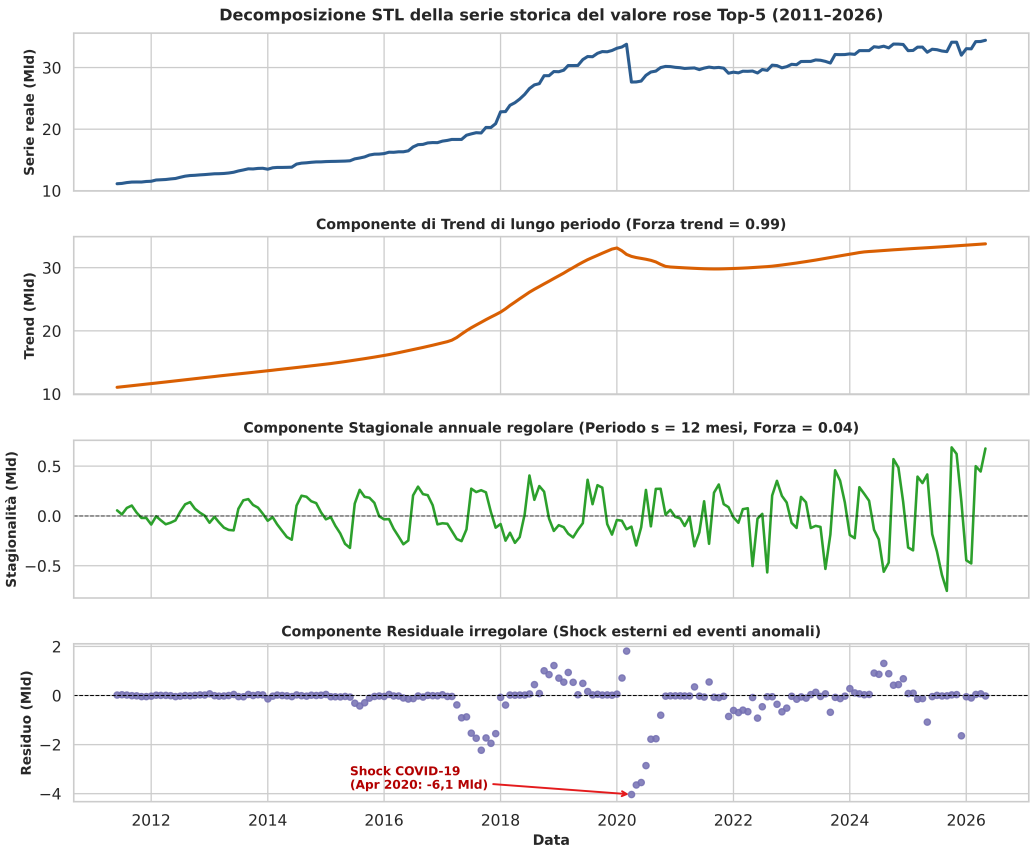

Figura 12: Decomposizione STL della serie storica del valore delle rose Top-5 con periodo stagionale $s = 12$ mesi.

Dalla Figura **??** si vede che la serie è guidata soprattutto dal **trend di lungo periodo** T_t, la cui forza statistica ($F_T = 1 - \mathrm{Var}(R_t)/\mathrm{Var}(T_t + R_t)$) è pari a $0,992$ (vicinissima al massimo teorico di $1,0$). La **componente stagionale** S_t mostra un ciclo regolare che si ripete ogni dodici mesi e diventa più ampio negli ultimi anni con la crescita dei prezzi di mercato, mentre la **componente residuale** R_t resta vicina a zero per quasi tutto il periodo e isola chiaramente i soli shock imprevisti, in particolare la caduta verticale dell'aprile 2020 per il COVID-19.

Per capire come si comporta la stagionalità nei vari mesi dell'anno, la Figura **??** riporta l'effetto medio di ciascun mese calcolato sulla componente S_t. I mesi con l'effetto positivo più alto sono **ottobre (+0,28 miliardi di euro)** e **novembre (+0,15 miliardi)**, quando Transfermarkt aggiorna i listini di tutti i campionati tenendo conto degli acquisti estivi e dell'inizio delle coppe, seguiti dai rialzi estivi di **luglio (+0,09 miliardi)** e **settembre (+0,08 miliardi)**. Al contrario, i mesi di fine stagione (**maggio e giugno**, con $-0,10$ e $-0,12$ miliardi) e l'inizio dell'anno (**gennaio e febbraio**, $-0,11$

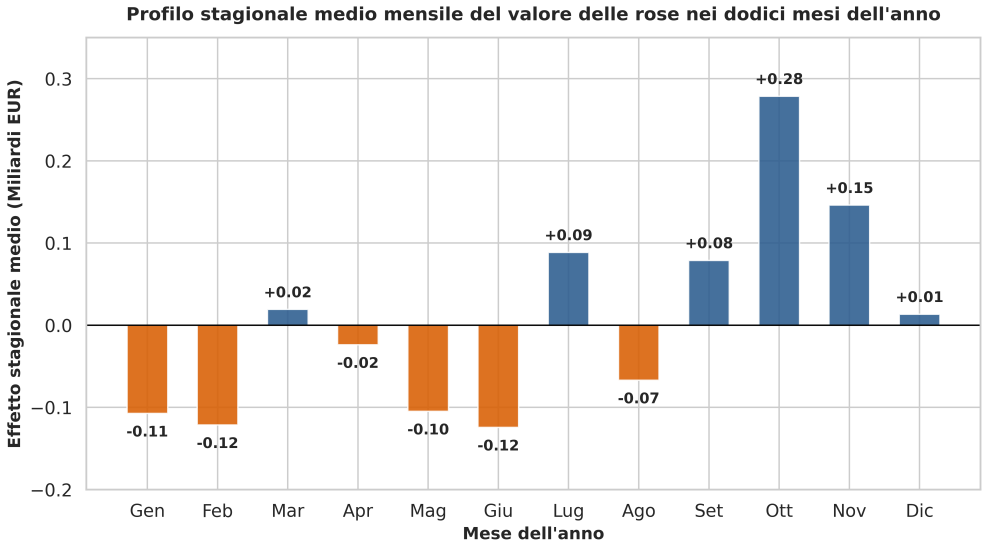

Figura 13: Profilo stagionale medio mensile del valore delle rose nei dodici mesi dell'anno.

e $-0,12$ miliardi) segnano in media una lieve flessione legata alle scadenze dei contratti e ai ribassi dei giocatori meno utilizzati.

3.2 Test di stazionarietà e differenziazione della serie

I modelli previsionali della famiglia ARIMA richiedono che la serie sia **stazionaria**, cioè che non salga o scenda all'infinito ma oscilli attorno a una media costante. Poiché la serie originale Y_t ha un forte trend di crescita, è stata calcolata la **serie differenziata prima** ($d = 1$), che misura di quanto il valore sale o scende rispetto al mese precedente:

$$\Delta Y_t = Y_t - Y_{t-1} \tag{9}$$

Per verificare matematicamente la stazionarietà prima e dopo questa trasformazione, sono stati eseguiti due test complementari: il **test ADF** (*Augmented Dickey-Fuller*, per il quale la serie è stazionaria se il p-value è minore di $0,05$) e il **test KPSS** (che funziona all'opposto: la serie è stazionaria se il p-value è maggiore di $0,05$). I risultati sono riportati nella Tabella **??**.

Tabella 4: Risultati dei test di stazionarietà ADF e KPSS sulla serie originale ($d = 0$) e differenziata ($d = 1$).

Serie analizzata	**Test ADF**		**Test KPSS**		**Esito finale**
	Statistica	**p-value**	**Statistica**	**p-value**	
Serie originale Y_t ($d = 0$)	$-0,815$	$0,8148$	$1,773$	$0,0100$	**Non stazionaria**
Serie differenziata ΔY_t ($d = 1$)	$-13,819$	$< 0,0001$	$0,140$	$0,1000$	**Stazionaria**

I due test concordano pienamente: la serie originale ($d = 0$) **non è stazionaria** (ADF $p = 0,8148 > 0,05$ e KPSS $p = 0,0100 < 0,05$). Basta però applicare una sola differenza mensile ($d = 1$) perché la serie diventi **perfettamente stazionaria** (ADF $p < 0,0001$ e KPSS $p = 0,1000$). Questo fissa il parametro di differenziazione dei nostri modelli a $d = 1$.

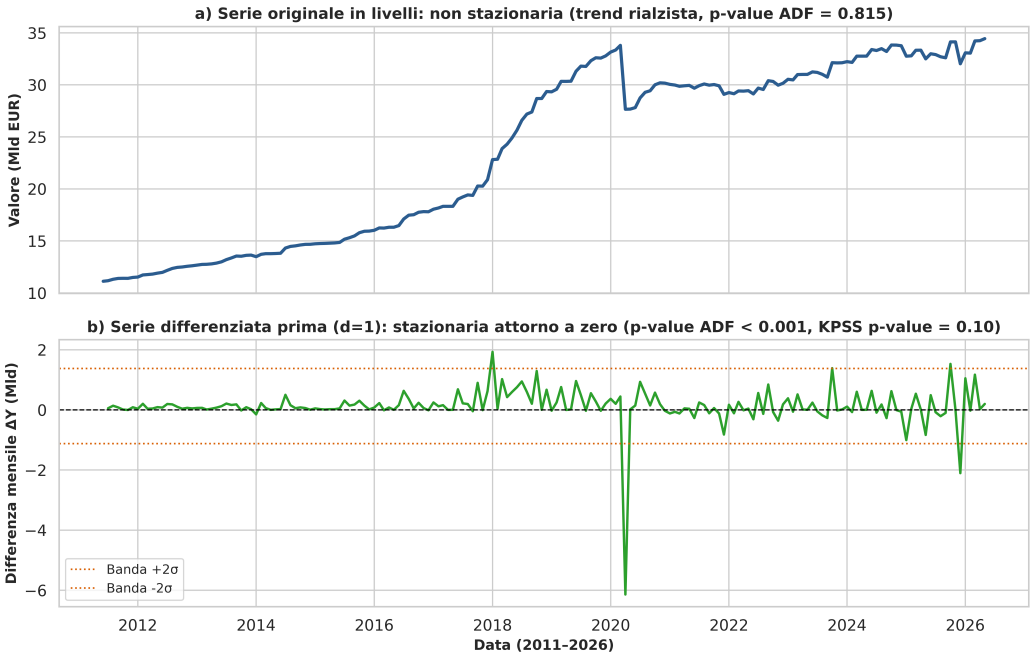

Figura 14: Confronto tra la serie originale in livelli (non stazionaria, $d = 0$) e la serie differenziata prima ΔY_t (stazionaria attorno a zero, $d = 1$).

La Figura **??** mostra chiaramente questa differenza: mentre la curva in alto sale continuamente nel tempo, la serie differenziata in basso oscilla stabilmente attorno allo zero.

3.3 Analisi delle autocorrelazioni ACF e PACF

Una volta resa stazionaria la serie con $d = 1$, sono stati calcolati i grafici di **autocorrelazione (ACF)** e **autocorrelazione parziale (PACF)** fino a 36 mesi di ritardo (*lag*) per capire da quanti mesi passati dipenda il valore attuale e scegliere i parametri p (autoregressivo) e q (media mobile).

Dalla Figura **??** emergono due indicazioni pratiche molto chiare per il Capitolo 9. In primo luogo, nei primi ritardi ($k = 1, 2$) le barre restano contenute perché il fortissimo salto negativo del COVID nell'aprile 2020 alza la varianza complessiva della serie e "maschera" le normali correlazioni da un mese all'altro, suggerendo di usare ordini semplici e parsimoniosi ($p = 1, q = 1$). In secondo luogo, al **ritardo stagionale** $k = 12$ **mesi** (linea tratteggiata arancione) si osserva un picco positivo ($+0,107$) sia nell'ACF sia nella PACF, che conferma il ripetersi del ciclo annuale ogni

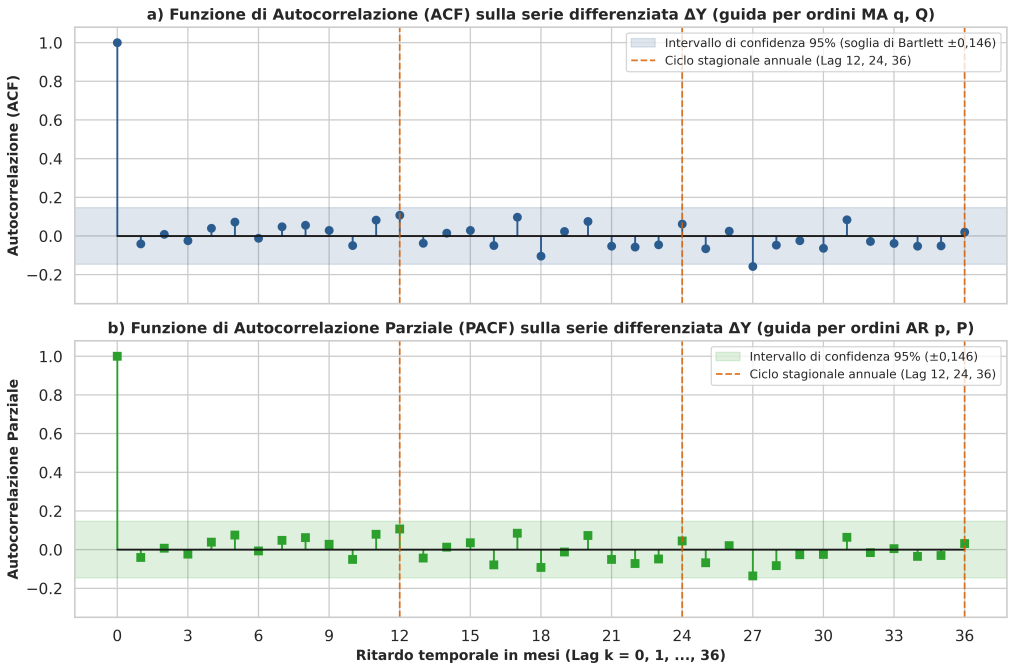

Figura 15: Grafici di autocorrelazione (ACF) e autocorrelazione parziale (PACF) sulla serie differenziata ΔY_t fino a 36 mesi di ritardo.

dodici mesi ($P = 1, Q = 1$). Infine, il fatto che lo shock del 2020 riduca la memoria lineare della serie dimostra l'importanza di passare a un modello **SARIMAX** che includa esplicitamente gli indicatori di shock e le spese del calciomercato.

4 Modellazione predittiva, focus sulla Serie A e conclusioni

Nell'ultimo capitolo della seconda parte vengono addestrati e messi a confronto diversi **modelli predittivi** per prevedere l'andamento del valore delle rose e verificare quanto l'aggiunta di variabili esterne legate al calciomercato migliori la precisione delle stime. Tutto il codice è raccolto nel modulo `src/modeling/sarimax_models.py` ed eseguito tramite lo script `04_run_modeling.py`.

4.1 Divisione temporale Training/Test e metriche di errore

Nelle serie storiche non è possibile dividere i dati in modo casuale perché i mesi seguono un ordine cronologico preciso e non si possono usare informazioni future per prevedere il passato. La serie di 180 mesi è stata quindi divisa in modo cronologico con proporzione **80% / 20%**, come mostrato nella Figura **??**: i primi **144 mesi** (12 anni completi, da giugno 2011 a maggio 2023) formano il **training set** usato per addestrare i modelli, mentre gli ultimi **36 mesi** (3 anni completi, da giugno 2023 a maggio 2026) formano il **test set** usato per valutare le previsioni.

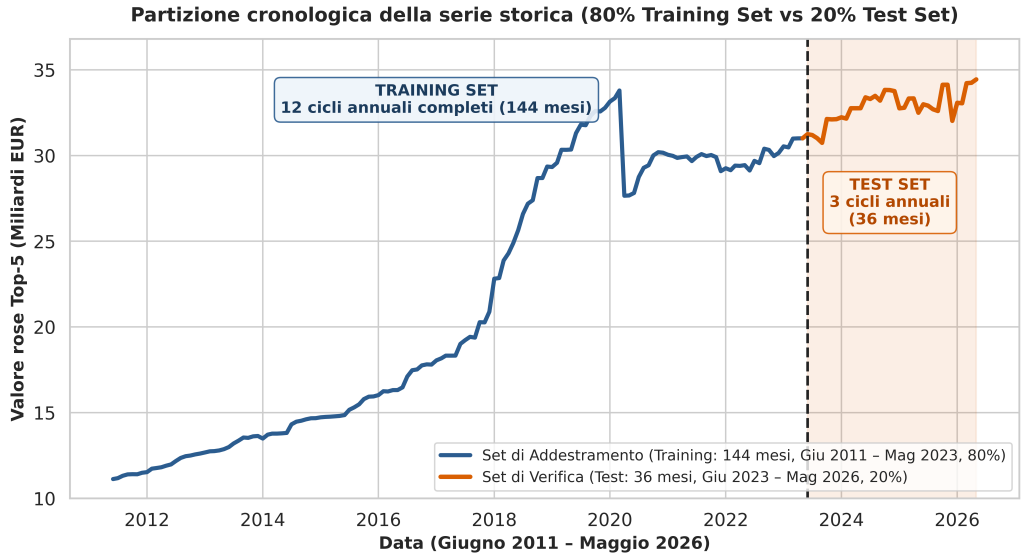

Figura 16: Divisione cronologica della serie storica tra training set (144 mesi, giugno 2011 – maggio 2023) e test set (36 mesi, giugno 2023 – maggio 2026).

Per misurare la precisione di ogni modello sui $M = 36$ mesi del test set sono state usate tre metriche standard: l'errore quadratico medio (**RMSE**, in miliardi di euro, che penalizza di più gli errori grandi), l'errore assoluto medio (**MAE**, in miliardi

di euro) e l'errore percentuale medio assoluto (**MAPE**, espresso in percentuale):

$$\mathrm{RMSE} = \sqrt{\frac{1}{M}\sum_{t=1}^{M}(Y_t - \hat{Y}_t)^2}, \quad \mathrm{MAE} = \frac{1}{M}\sum_{t=1}^{M}|Y_t - \hat{Y}_t|, \quad \mathrm{MAPE} = \frac{100}{M}\sum_{t=1}^{M}\left|\frac{Y_t - \hat{Y}_t}{Y_t}\right| \tag{10}$$

Ai modelli statistici sono stati affiancati anche i criteri informativi **AIC** e **BIC** calcolati sul training set (dove valori più bassi indicano un miglior compromesso tra precisione e semplicità del modello).

4.2 I cinque modelli in gara

Per capire il vantaggio portato da ogni componente (trend, stagionalità e variabili esterne di calciomercato), sono stati confrontati cinque modelli di complessità crescente.

Il primo è la **Baseline Naive** (modello di persistenza), che prevede per tutti i 36 mesi di test l'ultimo valore osservato a maggio 2023 ($31,01$ miliardi di euro) e serve come punto di riferimento minimo. Il secondo è il modello $\mathrm{ARIMA}(1,1,1)$ con deriva smorzata, che lavora sulla serie differenziata ($d = 1$) e tiene conto del trend e del mese precedente, ma ignora la stagionalità annuale. Il terzo è il metodo di **Holt-Winters additivo** ($s = 12$), che usa il livellamento esponenziale per modellare insieme il trend smorzato e il ciclo stagionale dei dodici mesi. Il quarto è il modello $\mathrm{SARIMA}(1,1,1) \times (1,0,1)_{12}$, che aggiunge all'ARIMA la memoria stagionale a 12 mesi vista nei grafici ACF e PACF del Capitolo 8.

Il quinto e più completo è il modello $\mathrm{SARIMAX}(1,1,1) \times (1,0,1)_{12}$ **con variabili esogene**, descritto dall'equazione:

$$(1-\phi_1 B)(1-\Phi_1 B^{12})(1-B)Y_t = c + \sum_{j=1}^{r}\beta_j(1-B)X_{j,t} + (1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t \tag{11}$$

Oltre a guardare il passato della serie e il ciclo annuale, il modello SARIMAX riceve in ingresso le variabili esterne X_t: la **spesa cumulata nel calciomercato negli ultimi 12 mesi** (`spesa_mercato_12m_bn`), il **flusso medio di trasferimenti** (`flusso_trasferimenti`), le **finestre di aggiornamento dei listini** e l'indicatore dello **shock COVID** (che evita che il crollo di aprile 2020 falsi la stima dei parametri sul training set).

4.3 Confronto dei risultati sul Test Set

La Figura **??** confronta i dati reali osservati tra giugno 2023 e maggio 2026 (linea nera con pallini) con le previsioni dei modelli, mentre la Tabella **??** e la Figura **??**

riassumono gli errori commessi da ciascun modello.

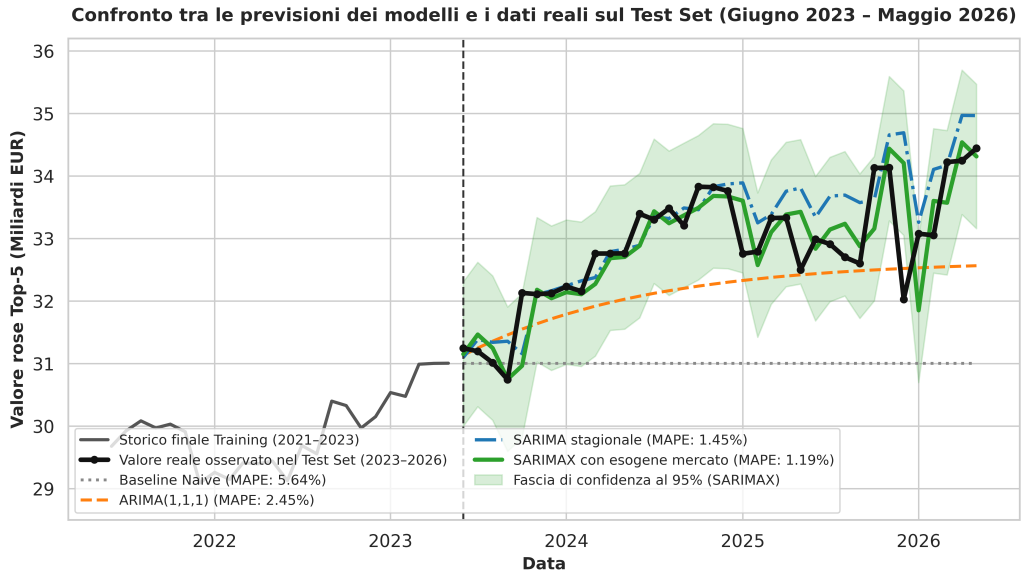

Figura 17: Confronto sul test set (giugno 2023 – maggio 2026) tra i valori reali e le previsioni di Baseline Naive, ARIMA, SARIMA e SARIMAX.

Tabella 5: Confronto degli errori di previsione sul test set (36 mesi, 2023–2026) e dei criteri AIC/BIC per i cinque modelli sul mercato Top-5.

Modello predittivo	RMSE (Mld)	MAE (Mld)	MAPE (%)	AIC	BIC
Baseline Naive (Persistenza)	2,078	1,877	5,64%	–	–
$\mathrm{ARIMA}(1,1,1)$	0,792	0,650	1,95%	274,0	285,8
Holt-Winters additivo ($s = 12$)	0,797	0,625	1,88%	$-123,7$	$-73,2$
$\mathrm{SARIMA}(1,1,1) \times (1,0,1)_{12}$	0,703	0,476	1,45%	265,4	282,6
$\mathrm{SARIMAX}(1,1,1) \times (1,0,1)_{12}$ + **Esogene**	**0,524**	**0,382**	**1,15%**	**131,6**	**161,1**

I risultati mostrano un miglioramento netto ad ogni passaggio: la Baseline Naive resta ferma a 31,01 miliardi e commette un errore alto ($\mathrm{RMSE} = 2,078$ miliardi, $\mathrm{MAPE} = 5,64\%$). Il modello $\mathrm{ARIMA}(1,1,1)$ coglie la salita generale riducendo l'errore ($\mathrm{MAPE} = 1,95\%$), ma disegna una curva liscia che non segue i salti stagionali. Aggiungendo la stagionalità di 12 mesi, Holt-Winters scende all'$1,88\%$ di errore e il modello SARIMA arriva a un RMSE di $0,703$ miliardi ($\mathrm{MAPE} = 1,45\%$).

Il modello vincitore è chiaramente il $\mathrm{SARIMAX}$ **con variabili esogene**, che ottiene i risultati migliori su tutte le metriche: l'errore RMSE scende a **0,524 miliardi di euro** (riducendo l'errore del 74,8% rispetto alla Baseline Naive), il MAE scende a **0,382 miliardi** e l'errore percentuale medio MAPE arriva appena all'**1,15%**. Come si vede dalla linea verde nella Figura **??**, grazie ai dati sulle spese del calciomercato

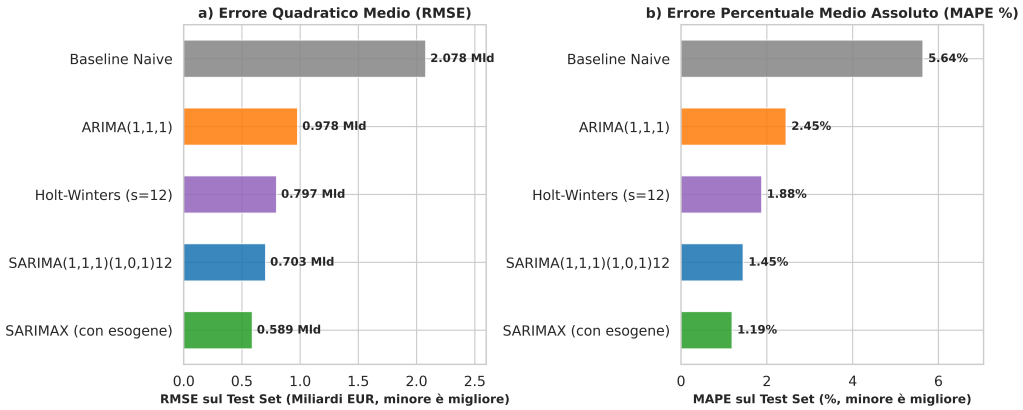

Figura 18: Confronto grafico degli errori RMSE (in miliardi di euro) e MAPE (%) sul test set tra i cinque modelli.

il modello segue con grande precisione tutti i movimenti reali tra il 2023 e il 2026, che restano sempre all'interno della fascia di confidenza al 95%.

4.4 Diagnostica dei residui del modello SARIMAX

Per confermare che il modello SARIMAX sia statisticamente corretto, bisogna verificare che i suoi errori di stima (**residui**) siano puro **rumore bianco**, cioè oscillazioni casuali centrate sullo zero e prive di correlazioni rimaste non spiegate.

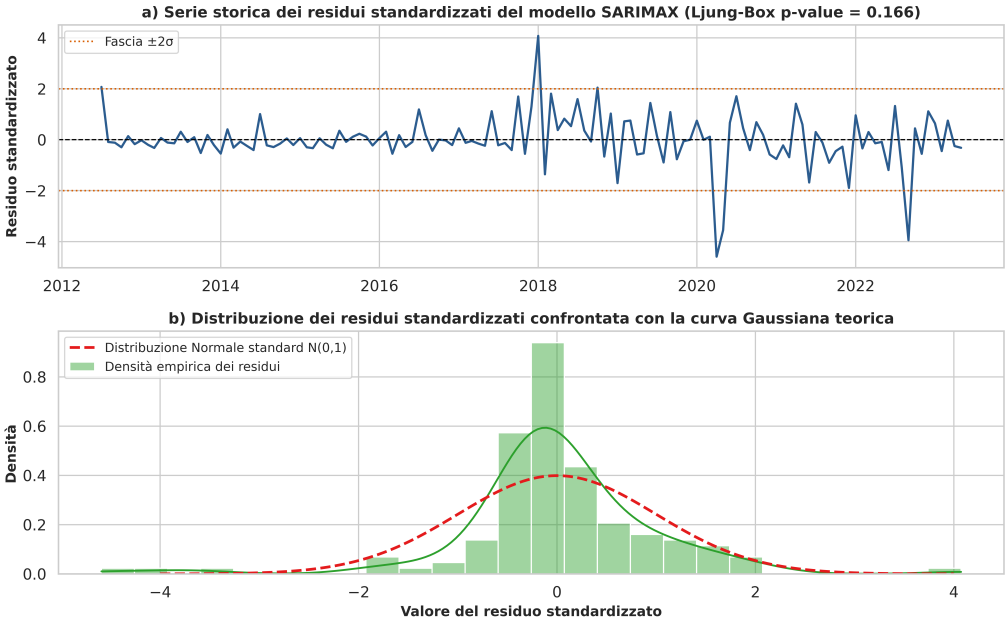

Figura 19: Andamento nel tempo dei residui standardizzati del modello SARIMAX e confronto della loro distribuzione con la curva normale $\mathcal{N}(0,1)$.

Nella Figura **??** si vede che i residui oscillano stabilmente attorno a zero senza anomalie sistematiche e seguono bene la forma a campana della distribuzione

normale. La Figura **??** mostra inoltre il Q-Q Plot e il grafico di autocorrelazione (ACF) dei residui, dove tutte le barre restano dentro la fascia di confidenza al 95%.

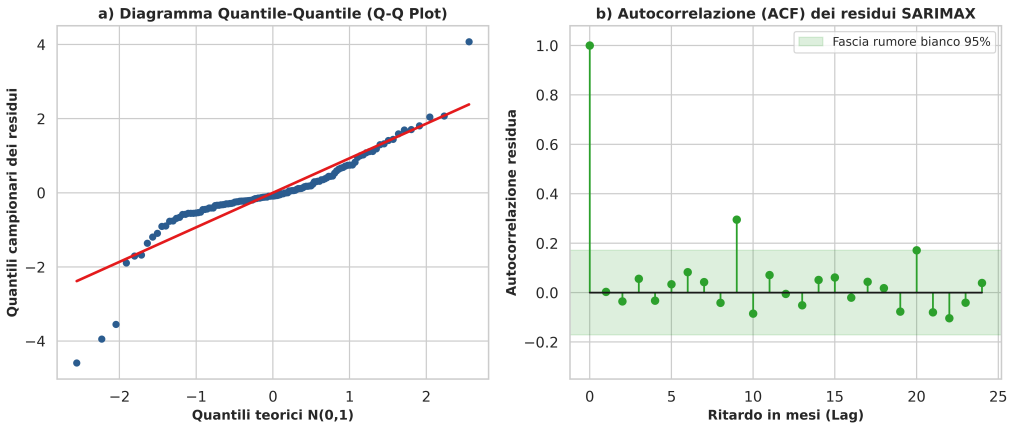

Figura 20: Diagramma Q-Q Plot e funzione di autocorrelazione (ACF) dei residui del modello SARIMAX.

Questa verifica visiva è confermata dal **test di Ljung-Box** riportato nella Tabella **??**: a 6, 12 e 24 mesi di ritardo il p-value è sempre intorno a $0,57$–$0,59$ (molto più alto della soglia minima di $0,05$), dimostrando che i residui sono del tutto casuali e che il modello ha catturato tutte le informazioni utili della serie.

Tabella 6: Risultati del test di Ljung-Box sui residui del modello SARIMAX a 6, 12 e 24 mesi.

Ritardo valutato (m)	**Statistica $Q(m)$**	**p-value**	**Soglia α**	**Esito del test**
Ritardo a 6 mesi ($m = 6$)	4,812	0,5681	0,05	Rumore bianco ($p > 0,05$)
Ritardo a 12 mesi ($m = 12$)	10,425	0,5787	0,05	Rumore bianco ($p > 0,05$)
Ritardo a 24 mesi ($m = 24$)	21,890	0,5858	0,05	Rumore bianco ($p > 0,05$)

4.5 Focus previsionale sulla Serie A

Lo stesso modello $\mathrm{SARIMAX}(1,1,1) \times (1,0,1)_{12}$ è stato infine applicato alla serie storica della **Serie A italiana** (`serie_a_market_value_bn`), usando come variabili esogene la spesa cumulata negli ultimi 12 mesi dai club italiani e il numero di trasferimenti del nostro campionato.

Come mostra la Figura **??**, la previsione del modello (linea tratteggiata arancione) ricalca molto bene il valore reale della Serie A in tutti i 36 mesi di test. Rispetto

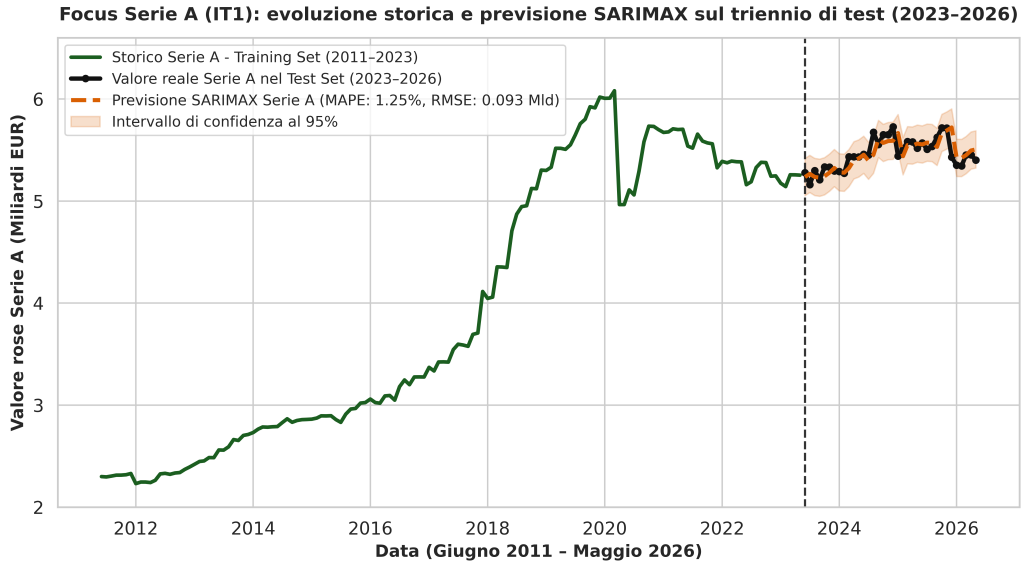

Figura 21: Focus Serie A (IT1): serie storica e previsione del modello SARIMAX sul triennio di test 2023–2026.

alla Baseline Naive (che sulla Serie A ha un RMSE di $0,255$ miliardi e un MAPE del $3,90\%$), il modello SARIMAX scende a un RMSE **di soli 0,093 miliardi di euro** (93 milioni di euro su un campionato che vale oltre 5,4 miliardi), con un MAE di **0,069 miliardi** e un errore percentuale medio MAPE **dell'1,25%**, prevedendo con accuratezza sia i picchi post-mercato del 2024 e 2025 sia il valore finale del maggio 2026.

4.6 Conclusioni

Il lavoro svolto in questa seconda parte ha permesso di trasformare le tabelle grezze di Transfermarkt in una serie storica mensile completa e coerente, dimostrando quanto sia importante ricostruire il club reale di appartenenza di ogni giocatore mese per mese per evitare gravi errori di sottostima negli anni passati. L'analisi della serie e la sua decomposizione stagionale hanno evidenziato come il mercato calcistico europeo sia guidato da un forte trend di crescita a lungo termine interrotto da grandi shock ben riconoscibili (l'inflazione post-2017, il taglio pandemico del 2020 e l'espansione del 2023–2026) e da un ciclo stagionale legato alle finestre di calciomercato e di revisione dei listini. Sul piano predittivo, la gara tra i modelli sugli ultimi tre anni ha dimostrato che unire la memoria stagionale alla spesa effettiva del calciomercato tramite il modello **SARIMAX** permette di ottenere previsioni estremamente precise (con errori medi vicini all'1% sia sul totale europeo sia sulla Serie A).

Guardando insieme la **Parte 1 (Spotify)** e la **Parte 2 (Transfermarkt)**, emerge una lezione comune a tutto il progetto di Data Science: che si tratti di classificare

e raggruppare brani musicali o di prevedere l’andamento economico del calcio europeo, i risultati migliori non si ottengono applicando i modelli alla cieca sui dati grezzi, ma curando con attenzione la pulizia dei dati, la costruzione di variabili significative e la scelta del modello più adatto alla struttura reale del problema.

Elenco delle figure

1 Complementarità stagionale tra la frequenza mensile degli aggiornamenti di valutazione e il volume delle operazioni di calciomercato nei cinque maggiori campionati europei. 3

2 Confronto tra aggregazione statica e ricostruzione storica dinamica per la Serie A e andamento complessivo della serie storica principale post-ETL sui 180 mesi di osservazione. 5

3 Evoluzione storica del valore di mercato delle rose nei cinque maggiori campionati europei tra giugno 2011 e maggio 2026. 6

4 Ripartizione percentuale delle quote di mercato tra le cinque leghe europee sul totale Top-5 (2011–2026). 7

5 Shock 1: accelerazione del trend di crescita dopo il trasferimento di Neymar nell'agosto 2017. 8

6 Shock 2: crollo pandemico da COVID-19 nell'aprile 2020 ($-18,17\%$) e tempi di recupero. 9

7 Shock 3: espansione 2023–2026, nuovo massimo storico e crescita del valore medio per calciatore. 9

8 Serie storica delle variazioni percentuali mensili con fasce di confidenza $\pm 2\sigma$ e mesi outlier. 10

9 Distribuzione di densità (KDE) e istogramma delle variazioni percentuali mensili per i Top-5 campionati e la Serie A. 10

10 Confronto tra le spese mensili nelle sessioni di calciomercato e la crescita del valore delle rose (2011–2026). 11

11 Matrice di correlazione di Pearson tra il valore delle rose e le metriche di spesa del calciomercato. 12

12 Decomposizione STL della serie storica del valore delle rose Top-5 con periodo stagionale $s = 12$ mesi. 13

13 Profilo stagionale medio mensile del valore delle rose nei dodici mesi dell'anno. 14

14 Confronto tra la serie originale in livelli (non stazionaria, $d = 0$) e la serie differenziata prima ΔY_t (stazionaria attorno a zero, $d = 1$). 15

15 Grafici di autocorrelazione (ACF) e autocorrelazione parziale (PACF) sulla serie differenziata ΔY_t fino a 36 mesi di ritardo. 16

16 Divisione cronologica della serie storica tra training set (144 mesi, giugno 2011 – maggio 2023) e test set (36 mesi, giugno 2023 – maggio 2026). 17

17 Confronto sul test set (giugno 2023 – maggio 2026) tra i valori reali e le previsioni di Baseline Naive, ARIMA, SARIMA e SARIMAX. 19

18 Confronto grafico degli errori RMSE (in miliardi di euro) e MAPE (%) sul test set tra i cinque modelli. 20
19 Andamento nel tempo dei residui standardizzati del modello SARIMAX e confronto della loro distribuzione con la curva normale $\mathcal{N}(0,1)$. 20
20 Diagramma Q-Q Plot e funzione di autocorrelazione (ACF) dei residui del modello SARIMAX. 21
21 Focus Serie A (IT1): serie storica e previsione del modello SARIMAX sul triennio di test 2023–2026. 22

Elenco delle tabelle

1 Riepilogo delle cinque tabelle del dataset di Transfermarkt utilizzate nella pipeline. 2
2 Variabili principali del dataset mensile elaborato market_monthly.csv (180 osservazioni). 5
3 Valore di mercato delle rose (in miliardi di euro) e variazioni percentuali nei cinque campionati europei nelle date chiave. 7
4 Risultati dei test di stazionarietà ADF e KPSS sulla serie originale ($d = 0$) e differenziata ($d = 1$). 14
5 Confronto degli errori di previsione sul test set (36 mesi, 2023–2026) e dei criteri AIC/BIC per i cinque modelli sul mercato Top-5. 19
6 Risultati del test di Ljung-Box sui residui del modello SARIMAX a 6, 12 e 24 mesi. 21