Università Politecnica delle Marche

Facoltà di Ingegneria

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione

---

Spotify tracks analysis: Classificazione e clustering

Docenti:

Prof. Ursino Domenico
Dott. Marchetti Michele

Componenti del gruppo:

Bellante Luca
Coccia Giansimone
Ferretti Laura

Anno Accademico 2024-2025

Indice

1 Spotify tracks analysis: Introduzione 2
1.1 Obiettivi del progetto 2

2 Spotify tracks analysis: Dataset 3
2.1 ETL 3
2.2 Analisi descrittiva 4
2.2.1 Distribuzione dei generi musicali 4
2.2.2 Distribuzione delle feature continue 4
2.2.3 Distribuzione delle variabili discrete 5
2.2.4 Matrice di correlazione 5

3 Spotify tracks analysis: Classificazione 7
3.1 Preprocessing del Dataset 7
3.1.1 Oversampling con SMOTE e Undersampling 7
3.1.2 Dataset Finale 7
3.1.3 Analisi della distribuzione degli attributi 8
3.2 Processo di Classificazione e Confronto Modelli 9
3.3 Ensemble Learning 10
3.4 Diagnostica e Commento ai Risultati 10
3.4.1 Classification Report e Matrice di Confusione 10
3.4.2 Curve ROC, Precision-Recall e Learning Curve 12
3.4.3 Feature Importance 13

4 Spotify tracks analysis: Clustering 14
4.1 Fase di ETL per il clustering 14
4.1.1 Operazioni preliminari sul dataset 14
4.1.2 Riduzione di dimensionalità (PCA e t-SNE) 14
4.2 Kmeans 15
4.2.1 Applicazione dell'algoritmo ed Elbow Method 15
4.2.2 Analisi dei risultati ottenuti e Profiling dei Cluster 16
4.2.3 Grafico della Silhouette per K-Means 17
4.3 DBSCAN 18
4.3.1 Applicazione dell'algoritmo DBSCAN 18
4.3.2 Analisi dei risultati ottenuti e Diagnostica del Rumore 19

5 Business Case finale e Conclusioni 21

1 Spotify tracks analysis: Introduzione

Nel panorama contemporaneo dello streaming musicale, la fruizione e la catalogazione dei brani audio sono guidate in misura sempre maggiore da modelli matematici e algoritmi di machine learning. Piattaforme leader a livello globale come Spotify estraggono e analizzano sistematicamente caratteristiche acustiche e psicoacustiche a partire dal segnale audio grezzo di milioni di tracce musicali.

Comprendere come queste variabili continue e discrete interagiscano tra loro permette sia di automatizzare la categorizzazione dei brani all'interno dei rispettivi generi musicali, sia di scoprire pattern latenti di a□nità sonica non rilevabili dai soli metadati commerciali. In questo contesto, il presente progetto si propone di analizzare un dataset contenente oltre 42.000 tracce musicali descritte da molteplici attributi tecnici (frequenza, tempo in BPM, volume sonoro, presenza vocale, valenza emotiva e ballabilità), integrando un percorso metodologico completo che spazia dalla pulizia e preparazione dei dati, alla modellazione supervisionata e non supervisionata.

1.1 Obiettivi del progetto

L'obiettivo principale dell'elaborato è l'applicazione congiunta di tecniche di machine learning supervisionate e non supervisionate al fine di estrarre valore predittivo e descrittivo dalle caratteristiche audio. Nello specifico, il lavoro si articola nei seguenti obiettivi:

- Data Cleaning ed Esplorazione Preliminare: Rimuovere le ridondanze derivanti dall'estrazione tramite API (inclusa la corretta deduplicazione basata sull'identificativo univoco della traccia), scartare metadati non predittivi e standardizzare opportunamente le variabili numeriche garantendo la totale assenza di data leakage.

- Classificazione Multiclasse del Genere Musicale: Sviluppare modelli predittivi in grado di stimare il genere di appartenenza di una traccia tra 15 classi di□erenti, a□rontando il problema dello sbilanciamento delle classi tramite tecniche di oversampling sintetico (SMOTE) e undersampling combinato, esplorando molteplici algoritmi di apprendimento e migliorando le performance attraverso tecniche avanzate di Ensemble Learning (Voting e Stacking Classifier).

- Clustering Non Supervisionato e Profiling dei Mood: Raggruppare i brani in cluster sonori omogenei in modo completamente agnostico rispetto al genere di mercato, impiegando algoritmi di partizionamento (K-Means) e basati sulla densità (DBSCAN), supportati da tecniche di riduzione di dimensionalità (PCA e t-SNE) per individuare macro-archetipi o playlist basate sullo stato d'animo (mood).

- Analisi Diagnostica e Business Case: Valutare approfonditamente i modelli attraverso metriche consolidate (Classification Report, Matrice di Confusione normalizzata, curve ROC/PR, Learning Curve, Silhouette Analysis) e identificare concrete opportunità applicative per l'industria discografica e per i motori di raccomandazione musicale.

2 Spotify tracks analysis: Dataset

Il dataset utilizzato per l'analisi è stato reperito dalla piattaforma Kaggle (Spotify Audio Features / Genres v2). Il dataset grezzo comprende 42.305 osservazioni relative a brani musicali distribuiti in 15 generi distinti, descritti da 22 attributi comprensivi di metadati identificativi, feature acustiche e parametri ritmici.

Nella Tabella 1 vengono riepilogate le principali caratteristiche incluse nel dataset e il relativo tipo di dato.

Tabella 1: Colonne del dataset e relativo formato dei dati.

Colonna	Formato / Descrizione
danceability	Float [0.0 - 1.0] (Ballabilità del brano)
energy	Float [0.0 - 1.0] (Intensità ed energia percepita)
key	Intero [0 - 11] (Tonalità secondo la Pitch Class)
loudness	Float (Volume complessivo in decibel dB)
mode	Intero [0 = Minore, 1 = Maggiore]
speechiness	Float [0.0 - 1.0] (Presenza di parole parlate)
acousticness	Float [0.0 - 1.0] (Confidenza che il brano sia acustico)
instrumentalness	Float [0.0 - 1.0] (Probabilità che non contenga parti vocali)
liveness	Float [0.0 - 1.0] (Probabilità di registrazione dal vivo)
valence	Float [0.0 - 1.0] (Positività / Umore della traccia)
tempo	Float (Velocità ritmica in battiti al minuto BPM)
duration_ms	Intero (Durata del brano espressa in millisecondi)
time_signature	Intero (Metro ritmico, tipicamente compreso tra 3 e 5)
id	Stringa (Identificativo univoco Spotify)
genre	Categoriale (Target di classificazione: 15 generi)

2.1 ETL

Il processo di ETL (Extract, Transform, Load) è stato fondamentale per garantire la qualità dei dati e la correttezza metodologica delle analisi successive. Durante questa fase sono state eseguite le seguenti operazioni:

- Deduplicazione su Track ID: Poiché le tracce sono estratte dall'API di Spotify a partire da molteplici playlist tematiche, la medesima canzone compare frequentemente duplicata. È stato eseguito un filtro rigoroso sulla colonna `id`, rimuovendo 6.428 record duplicati e riducendo il dataset a 35.877 brani unici e□ettivi. Questa operazione è fondamentale per evitare che brani identici finiscano contemporaneamente nel set di training e di test, inducendo overfitting o stime ottimistiche viziate da data leakage.

- Eliminazione Variabili di Servizio: Sono state rimosse le colonne generate dall'API prive di valore predittivo acustico (`Unnamed: 0`, `type`, `uri`, `track_href`, `analysis_url`, `song_name`, `title`).

- Gestione dei Valori Nulli e Verifica di Integrità: Il dataset pulito è stato sottoposto a verifica per accertare l'assenza di dati mancanti: tutte le feature acustiche numeriche e il target risultano complete al 100% (0 valori nulli).

2.2 Analisi descrittiva

L'analisi descrittiva svolta ha avuto lo scopo di esplorare e sintetizzare le proprietà statistiche del dataset, evidenziando le distribuzioni marginali e le relazioni di correlazione lineare tra le feature.

2.2.1 Distribuzione dei generi musicali

La distribuzione dei generi è stata visualizzata tramite il grafico a barre riportato in Figura 1. I dati evidenziano un marcato sbilanciamento naturale: i generi urbani Underground Rap (5.044 brani) e Dark Trap (4.578 brani) risultano predominanti, mentre generi come il Pop contano appena 404 tracce. Questo sbilanciamento rappresenta una criticità per i modelli di classificazione, che andrà gestita tramite specifiche tecniche di sampling.

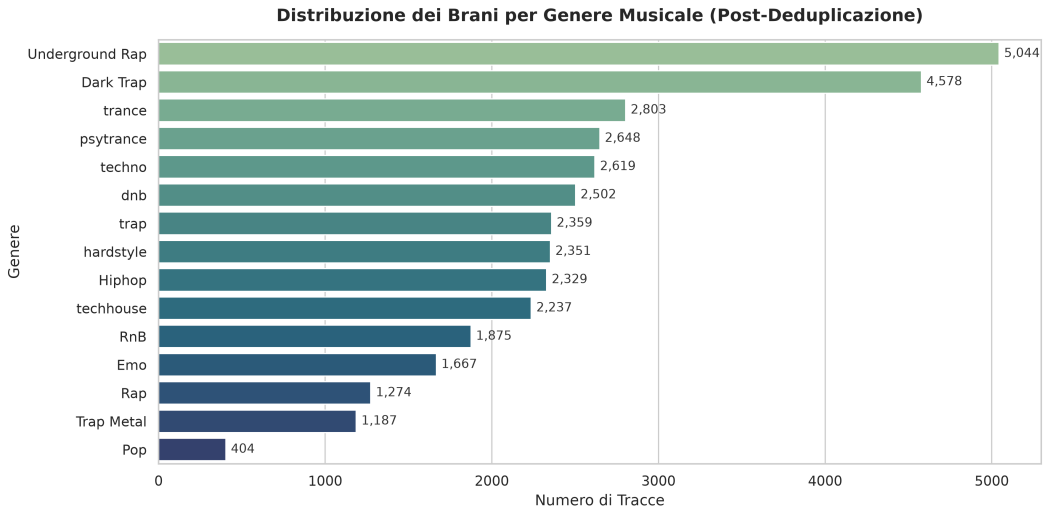


Figura 1: Distribuzione delle frequenze dei 15 generi musicali post-deduplicazione.

2.2.2 Distribuzione delle feature continue

In Figura 2 vengono mostrati gli istogrammi arricchiti con curve di densità (KDE) per le caratteristiche continue:

- `danceability`: Presenta una distribuzione simmetrica centrata tra 0.65 e 0.70.
- `energy` e `loudness`: Sono fortemente asimmetriche a sinistra, evidenziando che la produzione discografica moderna privilegia dinamiche compresse e volumi elevati (-8 dB a -4 dB).
- `acousticness`: Mostra un forte picco vicino a zero, confermando che la quasi totalità delle tracce include produzione elettronica.
- `speechiness`: Mostra una struttura bimodale, con un picco sotto 0.1 per musica melodica e un secondo cluster sopra 0.25 tipico di Rap e Trap.

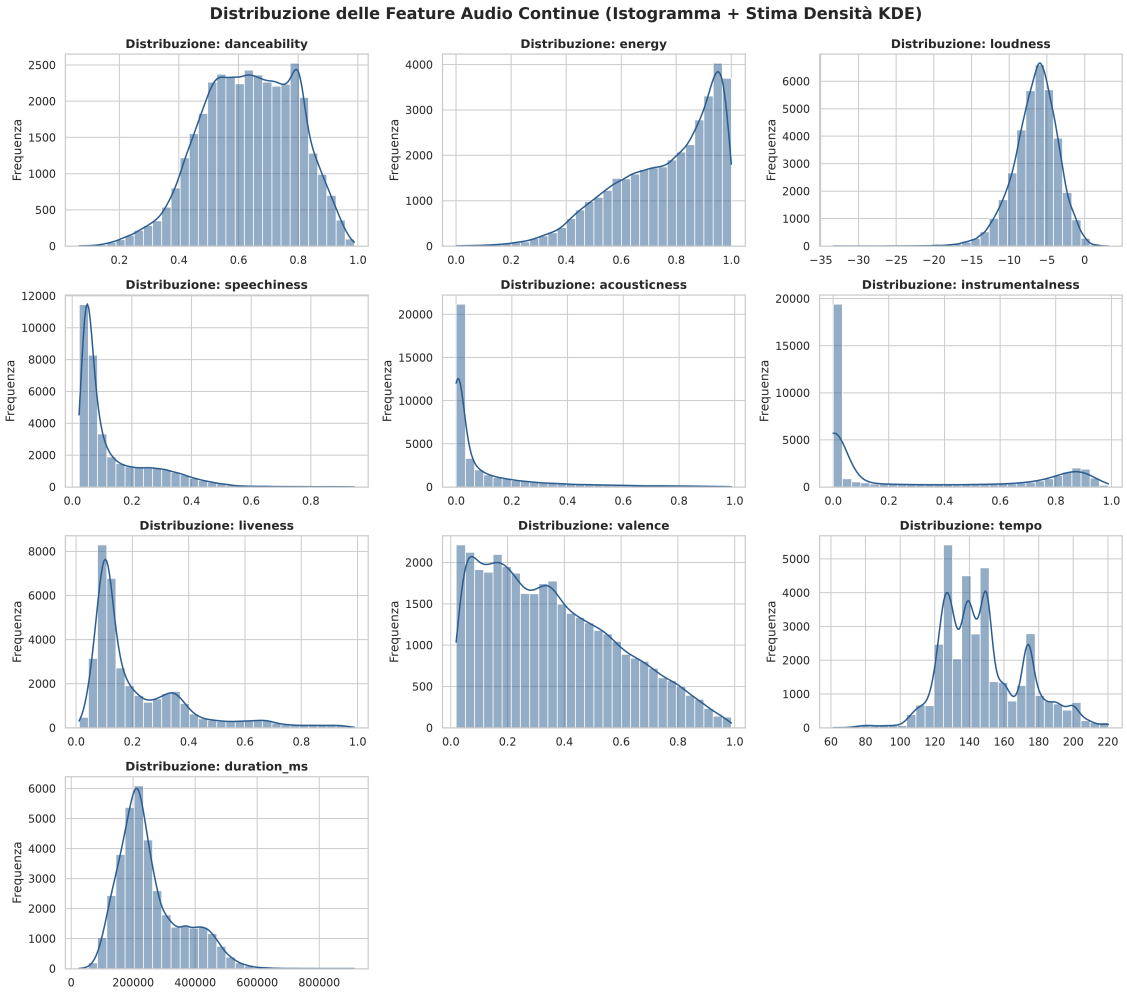


Figura 2: Distribuzione delle feature audio continue (istogrammi e curve di densità KDE).

2.2.3 Distribuzione delle variabili discrete

In Figura 3 viene rappresentata la distribuzione della tonalità (`key`), della modalità (`mode`) e del metro (`time_signature`). Si nota una prevalenza netta della misura standard in 4/4 e una leggera predominanza della modalità maggiore (`mode` = 1).

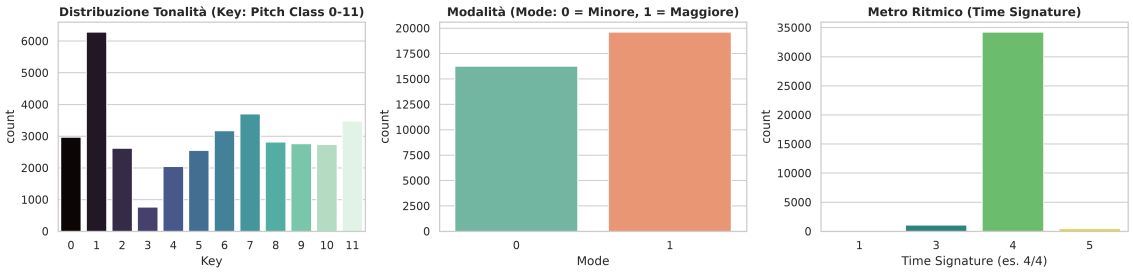


Figura 3: Distribuzione delle variabili musicali discrete: Tonalità, Modalità e Metro.

2.2.4 Matrice di correlazione

È stata calcolata la matrice di correlazione lineare di Pearson tra le feature audio, visualizzata tramite heatmap in Figura 4. Dall'analisi emergono forti correlazioni tra grandezze

fisiche:

- Forte correlazione positiva tra `energy` e `loudness` ($r \approx 0.70$).
- Forte correlazione negativa tra `energy` e `acousticness` ($r \approx -0.49$).
- Correlazione positiva moderata tra `valence` (positività emotiva) e `danceability`.

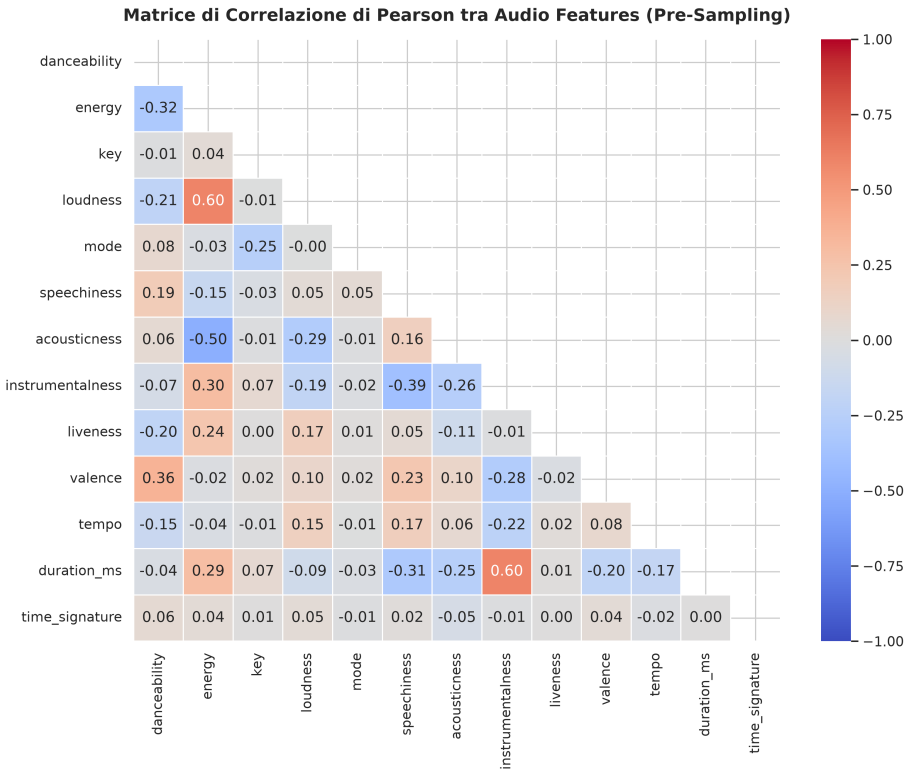


Figura 4: Matrice di correlazione di Pearson tra le feature audio prima delle operazioni di sampling.

3 Spotify tracks analysis: Classificazione

La classificazione supervisionata è stata condotta con l'obiettivo di sviluppare modelli predittivi capaci di assegnare la corretta etichetta di genere musicale a ciascuna traccia sulla base esclusiva dei suoi parametri sonori.

3.1 Preprocessing del Dataset

Per preparare correttamente i dati, il dataset di 35.877 brani è stato suddiviso in Training Set (80%, 28.701 campioni) e Test Set (20%, 7.176 campioni) mediante stratificazione rispetto alle classi target.

Per evitare fenomeni di data leakage, la standardizzazione tramite `StandardScaler` è stata calcolata (fit) unicamente sul training set ed estesa (transform) sul test set:

$$z = \frac{x - \mu_{train}}{\sigma_{train}} \tag{1}$$

3.1.1 Oversampling con SMOTE e Undersampling

A causa del forte sbilanciamento (le classi variano da circa 400 a oltre 5.000 campioni), un classificatore standard tenderebbe a collassare sulle classi dominanti. È stata adottata una strategia combinata applicata esclusivamente al training set:

- SMOTE (Synthetic Minority Oversampling Technique): Ha incrementato il numero di campioni per le classi minoritarie (Pop, Trap Metal, Rap, Emo, RnB) generando campioni sintetici mediante interpolazione lineare nello spazio delle feature.
- Undersampling Controllato: Ha ridotto i campioni delle classi maggioritarie (Underground Rap, Dark Trap).

3.1.2 Dataset Finale

Dopo l'applicazione di entrambe le tecniche, il training set bilanciato presenta esattamente 2.000 campioni per ciascuna delle 15 classi (30.000 osservazioni complessive). Il test set di 7.176 osservazioni è stato invece preservato nella sua distribuzione reale originale per una stima priva di bias. In Figura 5 viene mostrato il confronto tra le distribuzioni prima e dopo l'intervento di bilanciamento.

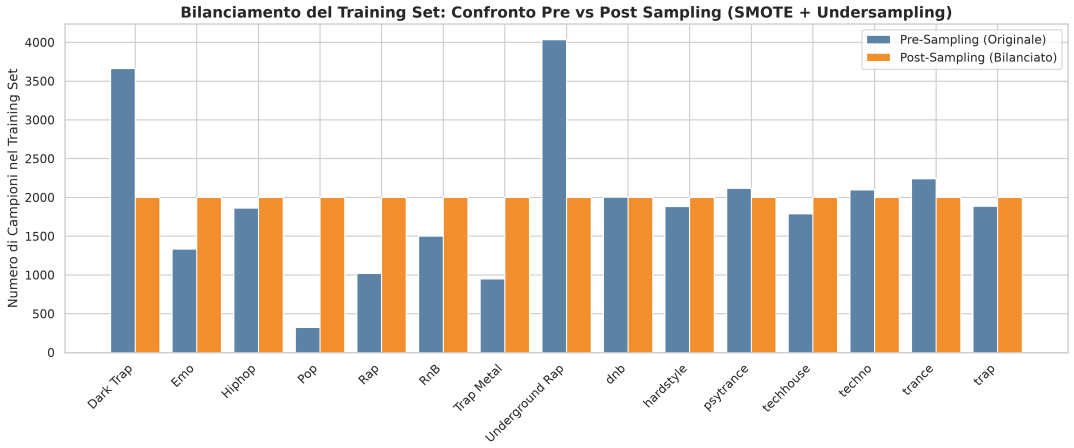


Figura 5: Distribuzione dei generi nel Training Set prima e dopo il campionamento (SMOTE + Undersampling).

3.1.3 Analisi della distribuzione degli attributi

Al termine delle operazioni di campionamento è stata ricalcolata la matrice di correlazione sul dataset bilanciato (Figura 6). Il confronto con la matrice originale (Figura 4) attesta che la struttura relazionale dei dati è rimasta perfettamente coerente, confermando che SMOTE non ha introdotto artefatti o distorsioni spaziali.

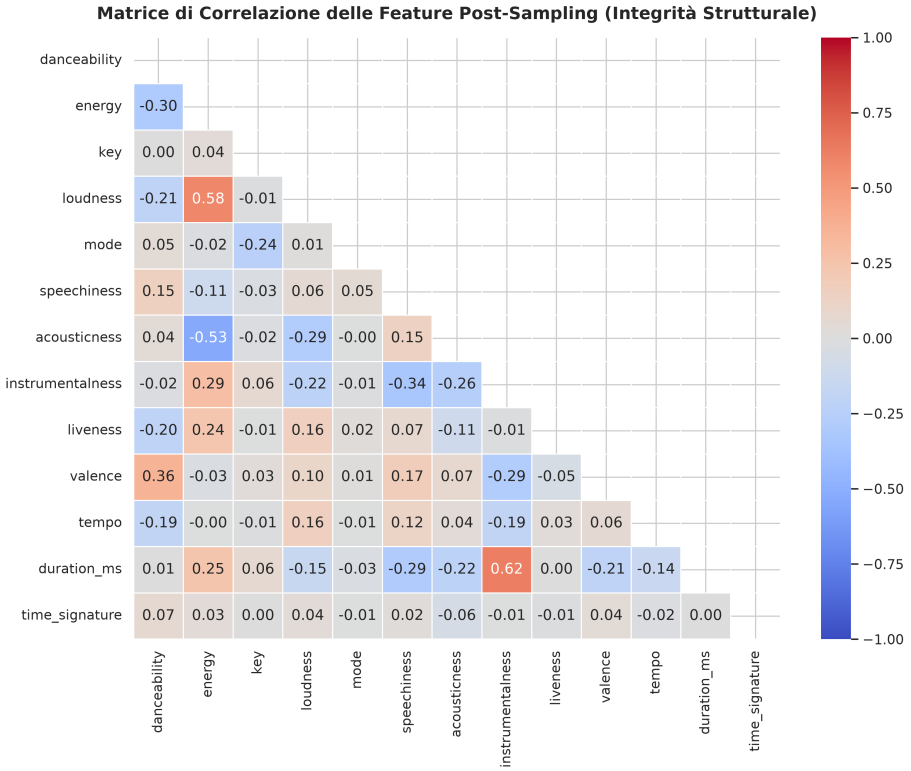


Figura 6: Matrice di correlazione delle feature audio calcolata dopo il processo di bilanciamento.

3.2 Processo di Classificazione e Confronto Modelli

Il processo di classificazione ha previsto il confronto su un banco di prova uniforme di 8 di□erenti algoritmi di apprendimento automatico:

1. Logistic Regression: Baseline lineare con penalità L_2 e formulazione multinomiale.
2. Decision Tree: Albero decisionale singolo regolarizzato con profondità massima.
3. Random Forest: Ensemble bagging di 100 alberi decisionali indipendenti.
4. K-Nearest Neighbors (KNN): Classificatore a vicini con metrica euclidea (k = 9).
5. Gaussian Naive Bayes: Modello probabilistico basato su stima delle densità gaussiane.
6. AdaBoost Classifier: Algoritmo di boosting basato sulla riponderazione iterativa dei residui.
7. Gradient Boosting Classifier: Boosting sequenziale basato sulla discesa del gradiente.
8. XGBoost (Extreme Gradient Boosting): Implementazione e□ciente di gradient boosted trees con regolarizzazione nativa.

I risultati ottenuti valutando i modelli sul Test Set (7.176 brani) sono riportati in Tabella 2 e illustrati graficamente in Figura 7.

Tabella 2: Confronto delle performance dei modelli sul Test Set indipendente.

Modello	Accuratezza	Weighted F1	Macro F1	Tempo Addestr. (s)
XGBoost	0.6745	0.6763	0.6480	1.91
Random Forest	0.6734	0.6726	0.6498	1.04
Gradient Boosting	0.6630	0.6634	0.6397	101.16
Decision Tree	0.5916	0.5960	0.5734	0.39
Logistic Regression	0.5516	0.5560	0.5279	0.86
K-Nearest Neighbors	0.5394	0.5425	0.5213	1.25
Gaussian Naive Bayes	0.5332	0.5364	0.5198	0.02
AdaBoost	0.3686	0.3513	0.3261	2.12

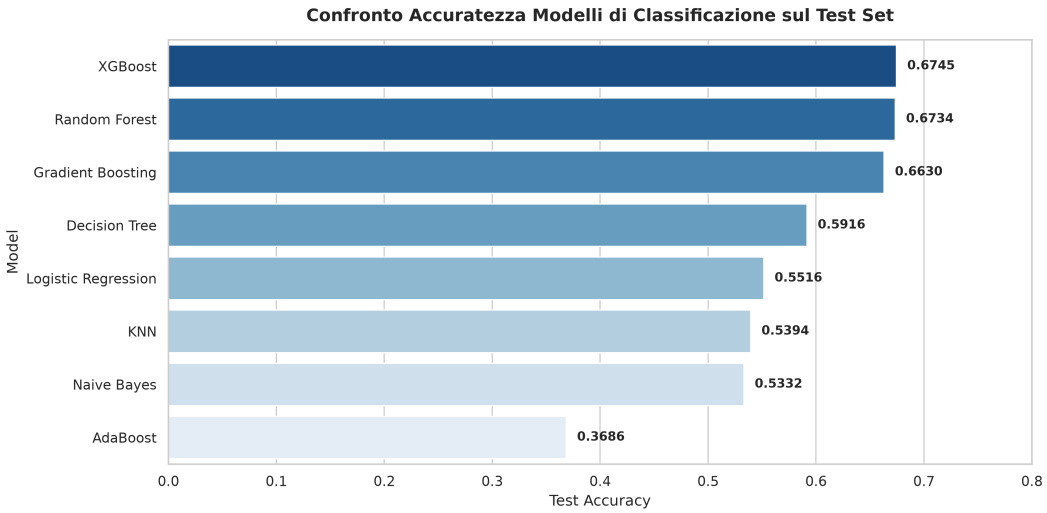


Figura 7: Confronto dell'accuratezza media ottenuta dai diversi algoritmi sul Test Set.

3.3 Ensemble Learning

Per massimizzare la capacità di generalizzazione e ridurre la varianza residua, sono state adottate due tecniche di Ensemble Learning avanzate:

- Voting Classifier (Soft Voting): Combina le stime di probabilità a posteriori dei tre classificatori con le migliori prestazioni singole (XGBoost, Random Forest e Gradient Boosting). La previsione finale massimizza la probabilità media:

$$\hat{y} = \arg\max_{c} \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \qquad (2)$$

  Questo modello ottiene un'accuratezza sul test set del 68.00% e un Weighted F1 di 0.6810.

- Stacking Classifier: Utilizza un'architettura a due livelli: i modelli di base (XGBoost, Random Forest e Logistic Regression) generano previsioni out-of-fold tramite cross-validation a 3-fold, che fungono da input per un meta-modello di Regressione Logistica. Questo approccio raggiunge un'accuratezza del 68.90% e un Weighted F1 di 0.6890, costituendo il miglior risultato complessivo dell'analisi.

3.4 Diagnostica e Commento ai Risultati

Le prestazioni dell'ensemble finale sono state analizzate approfonditamente attraverso una serie completa di strumenti diagnostici.

3.4.1 Classification Report e Matrice di Confusione

La Figura 8 illustra la matrice di confusione normalizzata, mentre la Figura 9 riporta l'heatmap del Classification Report (Precision, Recall ed F1-Score per ogni genere). L'analisi rivela un comportamento sonoro altamente coerente:

- Generi con forte identità timbrica e ritmica (dnb, hardstyle, psytrance, techno) ottengono un F1-Score compreso tra 0.75 e 0.88.

- Le confusioni avvengono quasi esclusivamente tra generi contigui nel processo di produzione contemporaneo: ad esempio Dark Trap viene talvolta confuso con Underground Rap o Trap Metal (stessi BPM 130-140, bassi 808 distorti e stile vocale a□ne), così come Techhouse con Techno.

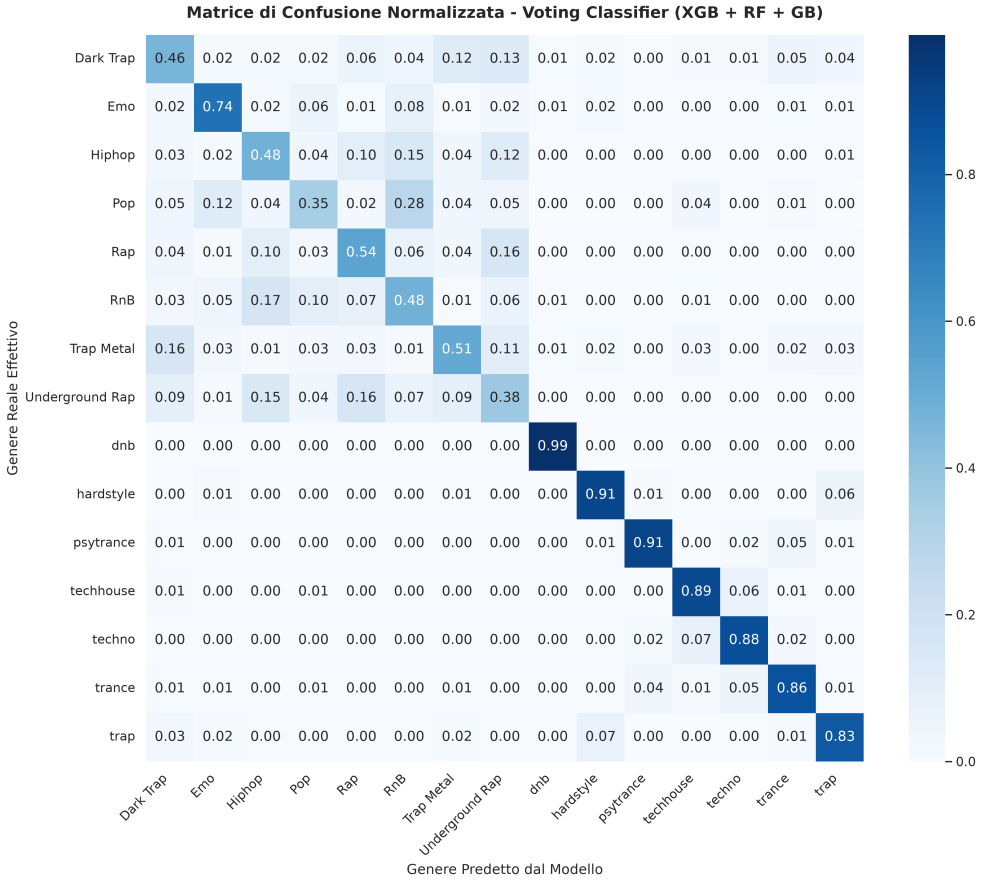


Figura 8: Matrice di confusione normalizzata per il modello Ensemble finale.

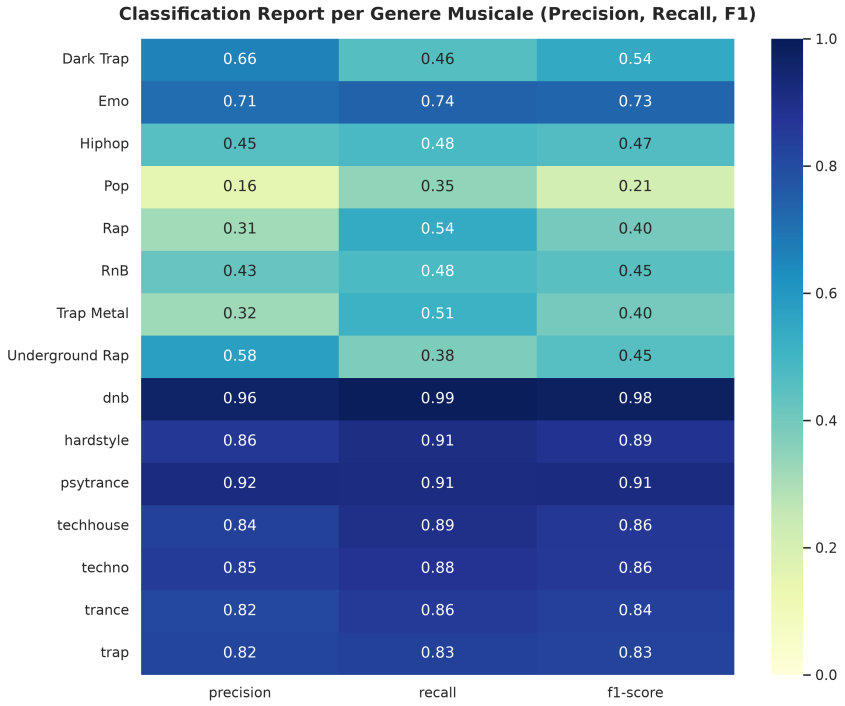
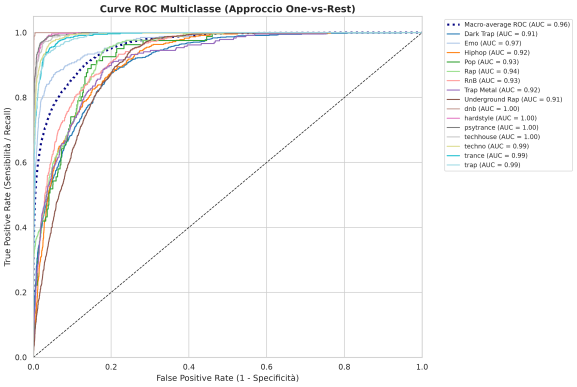


Figura 9: Classification Report per genere: valori di Precision, Recall ed F1-Score.

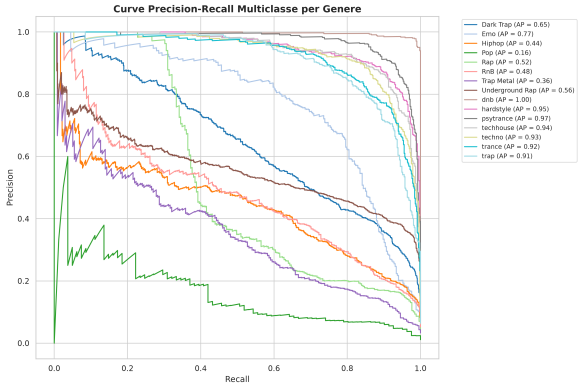
3.4.2 Curve ROC, Precision-Recall e Learning Curve

In Figura 10 vengono mostrate le curve ROC (One-vs-Rest) e le curve Precision-Recall. Il valore di Macro-Average ROC-AUC è pari a 0.94, con diverse classi che raggiungono valori di AUC superiori a 0.97, a testimonianza di una forte capacità discriminante su scala globale.

La Learning Curve riportata in Figura 11 conferma che, con l'incremento dei campioni di training, la curva di validazione sale costantemente avvicinandosi a quella di addestramento con un gap contenuto, escludendo fenomeni di overfitting.



(a) Curve ROC Multiclasse One-vs-Rest (Macro AUC = 0.94).



(b) Curve Precision-Recall Multiclasse.

Figura 10: Valutazione delle curve ROC e Precision-Recall per tutte le classi di genere.

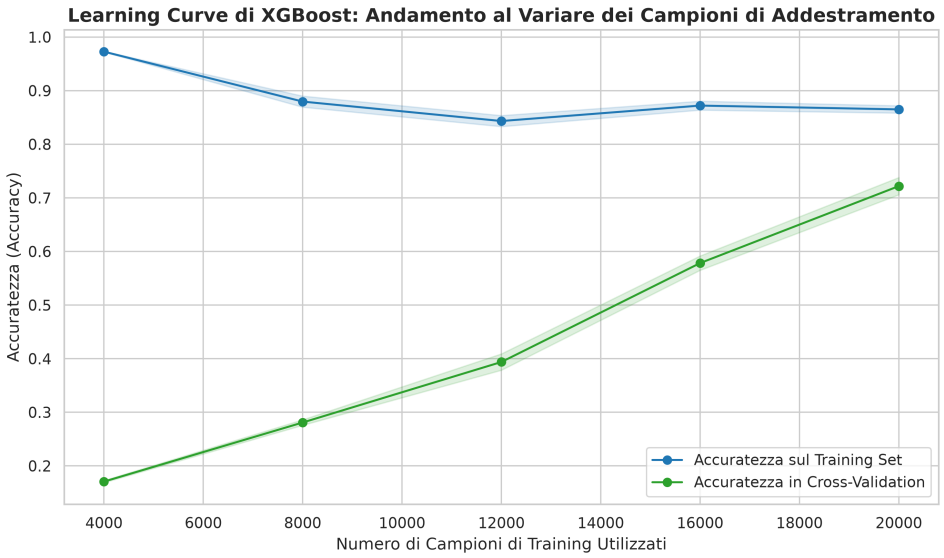


Figura 11: Learning Curve calcolata su XGBoost al variare dei campioni di training.

3.4.3 Feature Importance

La Figura 12 evidenzia l'importanza relativa delle feature estratta da Random Forest e XGBoost. I fattori con il più elevato potere informativo risultano essere:

- `tempo` (BPM): Separa immediatamente i generi elettronici veloci (DnB a 174 BPM, Hardstyle a 150 BPM) dai generi urban a tempo moderato.
- `speechiness`: Isola chiaramente i brani rap/trap ad alta densità di testo rispetto ai generi strumentali.
- `danceability`, `loudness` ed `energy`: Determinano il mood e la compattezza dinamica.

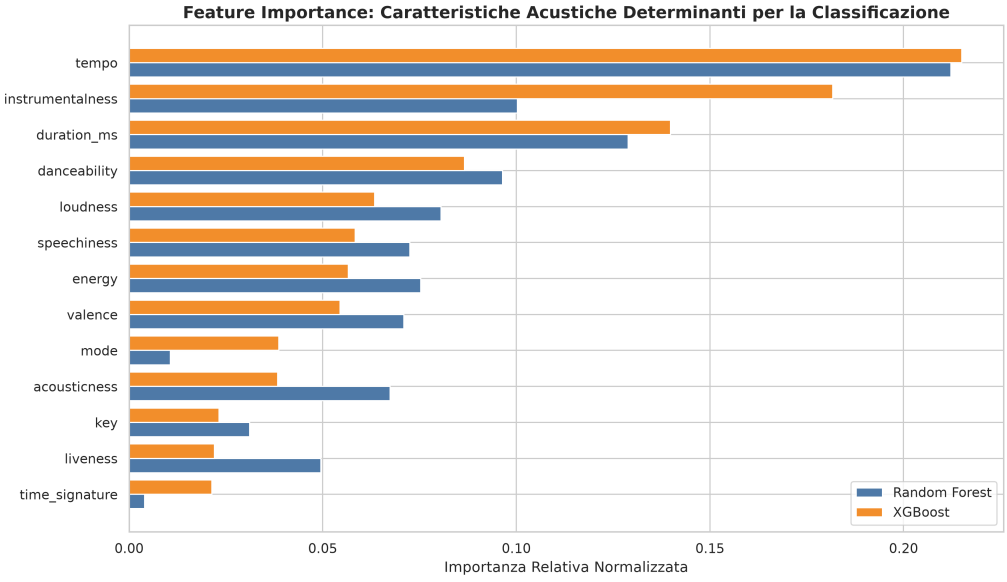


Figura 12: Feature Importance: confronto tra Random Forest e XGBoost.

4 Spotify tracks analysis: Clustering

Questo capitolo illustra l'applicazione di tecniche di clusterizzazione con lo scopo di raggruppare i brani musicali sulla base esclusiva delle loro proprietà acustiche intrinseche, in modo completamente non supervisionato ed escludendo la colonna `genre`. Gli algoritmi considerati ricadono nelle categorie di partizionamento (K-Means) e densità (DBSCAN).

4.1 Fase di ETL per il clustering

4.1.1 Operazioni preliminari sul dataset

Gli attributi identificativi (`id`) e il target commerciale (`genre`) sono stati eliminati per rendere il modello agnostico rispetto alla categorizzazione di mercato ed evitare problemi legati alla curse of dimensionality[1]. Tutte le feature audio numeriche sono state standardizzate mediante `StandardScaler`.

4.1.2 Riduzione di dimensionalità (PCA e t-SNE)

Al fine di analizzare e visualizzare la struttura dei cluster, sono state impiegate due tecniche complementari di riduzione di dimensionalità:

- Principal Component Analysis (PCA): Dallo Scree Plot in Figura 13 emerge che le prime 6 componenti principali spiegano oltre il 70% della varianza cumulativa totale, evidenziando che gran parte della variabilità acustica è concentrata in un sottospazio ridotto.
- t-SNE (t-Distributed Stochastic Neighbor Embedding): Applicato con dimensione di output pari a 2, `perplexity` = 40 e `random_state` = 42. In Figura 14 viene mostrata la disposizione bidimensionale dei brani, evidenziando raggruppamenti geometrici naturali.

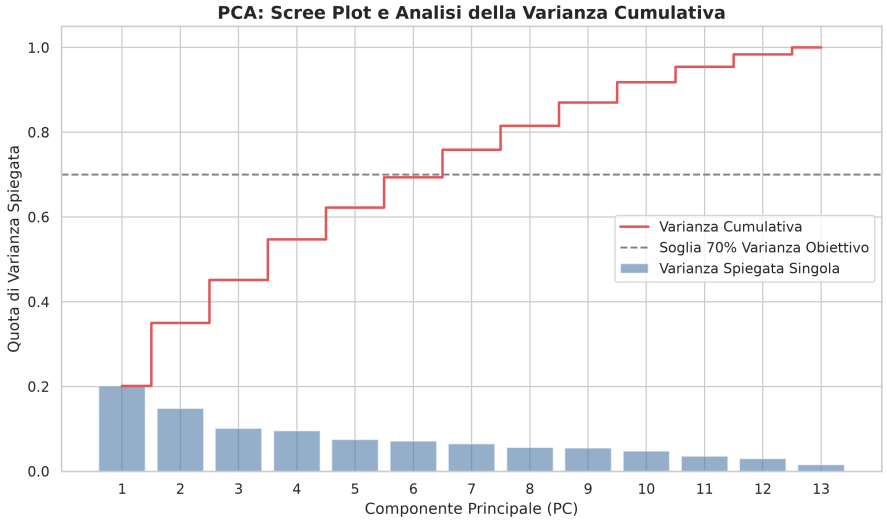


Figura 13: PCA: Scree Plot della varianza spiegata individuale e cumulativa.

[1] La curse of dimensionality si verifica quando l'aumento delle feature disperde i dati nello spazio multidimensionale, riducendo l'e□cacia del calcolo delle distanze.

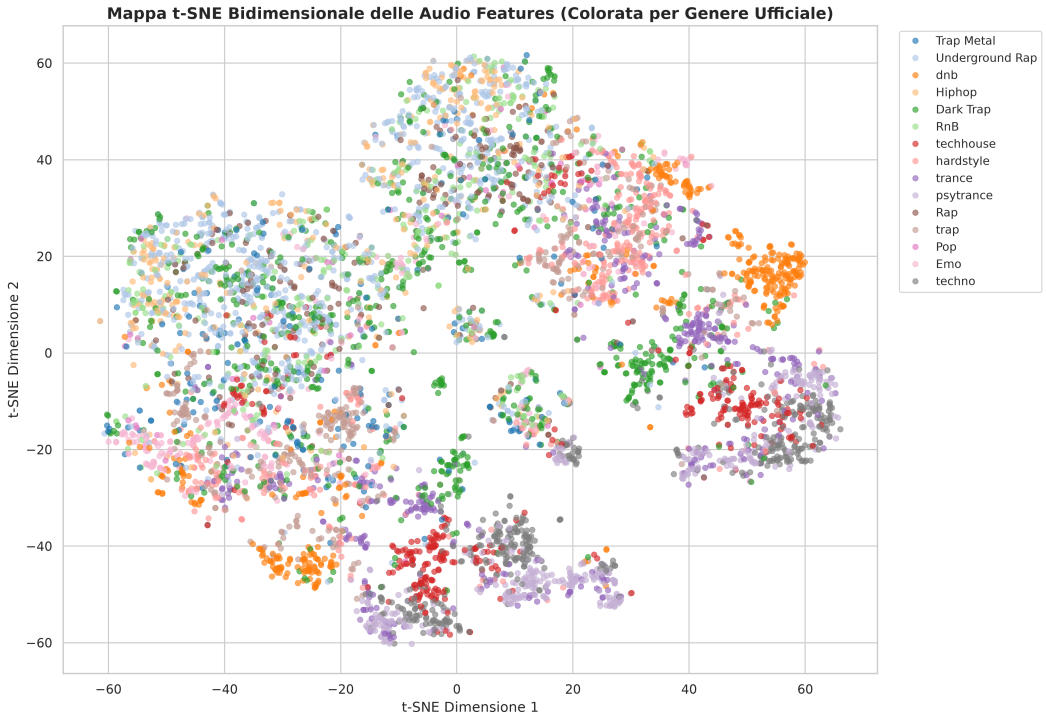


Figura 14: Mappa t-SNE 2D delle audio features con colorazione per genere Spotify originale.

4.2 Kmeans

L'algoritmo K-Means suddivide le osservazioni in k cluster cercando di minimizzare la somma dei quadrati delle distanze intra-cluster (WCSS):

$$\text{WCSS} = \sum_{j=1}^{k} \sum_{x_i \in C_j} \| x_i - \mu_j \|^2 \qquad (3)$$

4.2.1 Applicazione dell'algoritmo ed Elbow Method

Per identificare il numero ottimale di cluster k, è stato applicato il metodo del gomito (Elbow Method) calcolando il valore di WCSS per k compreso tra 2 e 11 con `n_init` = 10. Come illustrato in Figura 15, in corrispondenza di k = 5 si manifesta un chiaro punto di gomito, oltre il quale la riduzione del WCSS diventa marginale.

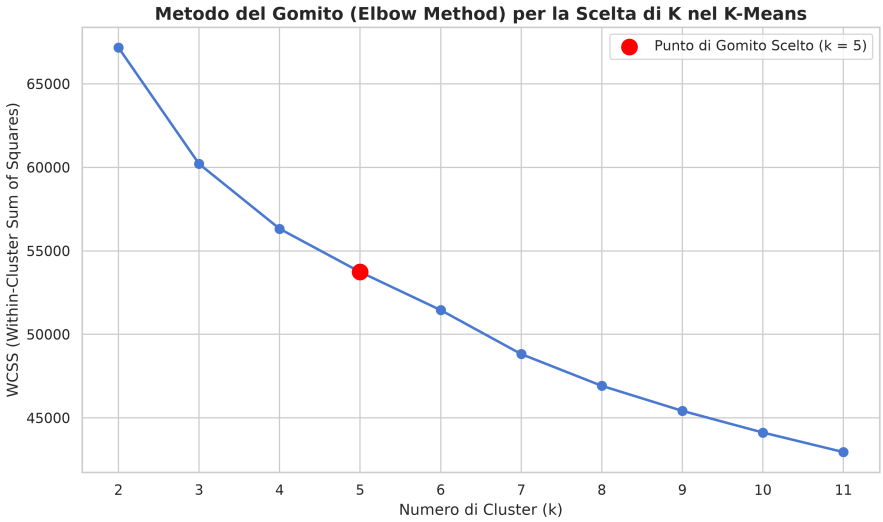


Figura 15: Metodo del Gomito (Elbow Method) per la selezione di k nel K-Means.

4.2.2 Analisi dei risultati ottenuti e Profiling dei Cluster

Il modello K-Means con k = 5 è stato proiettato sullo spazio 2D t-SNE (Figura 16). In Figura 17 viene riportato il profiling acustico calcolando la media delle feature per ciascun cluster, consentendo di associare matematicamente ogni gruppo a uno specifico profilo d'ascolto (Mood Playlist):

- Cluster 0 — High-Energy Electronic / Party: Elevatissima loudness ed energy, speechiness minima e forte componente strumentale (Techno, Trance).
- Cluster 1 — Urban & Rap: Massimi valori di speechiness e ballabilità (Hip-Hop, Rap).
- Cluster 2 — Melodic Pop & R&B: Caratterizzato da massima valenza emotiva (positività) e sonorità armoniche.
- Cluster 3 — High-Velocity / Workout: Velocità ritmica estrema (`tempo` medio > 165 BPM) e ritmica incessante (DnB, Hardstyle).
- Cluster 4 — Atmospheric & Dark: Bassa loudness, atmosfera introspettiva e tonalità cupe (Dark Trap, Emo, Ambient).

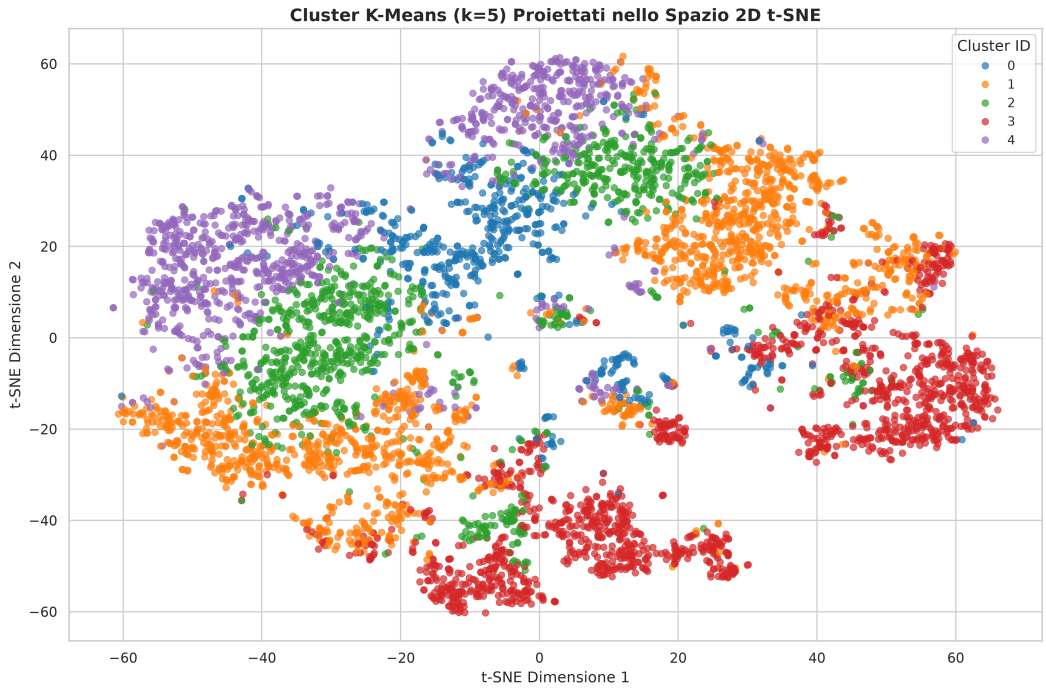


Figura 16: Cluster K-Means (k = 5) visualizzati sulla proiezione t-SNE 2D.

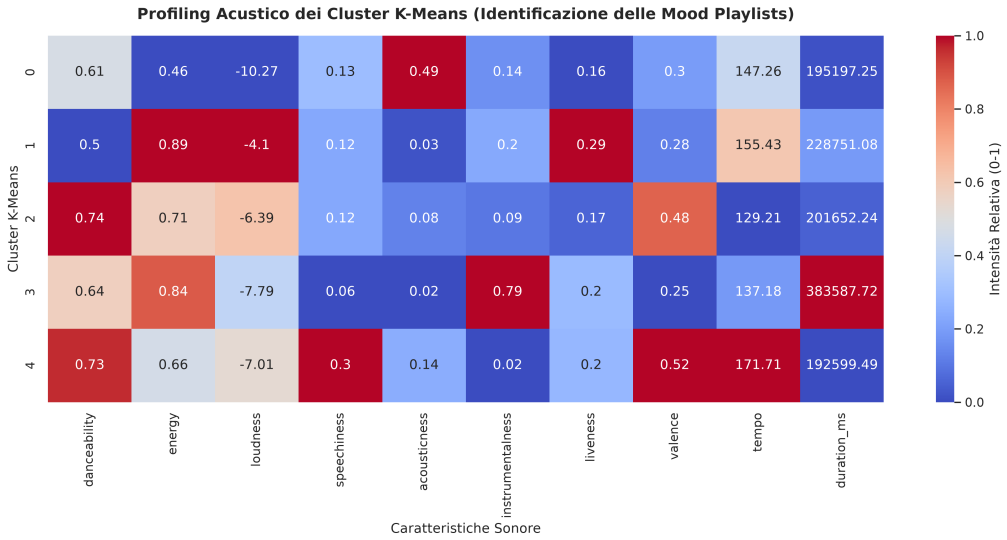


Figura 17: Profiling acustico dei cluster K-Means per l'identificazione automatica dei Mood.

4.2.3 Grafico della Silhouette per K-Means

La qualità e la separazione dei cluster sono state valutate mediante il coe□ciente di Silhouette[2]. La Figura 18 mostra profili di ampiezza uniformi e una quota trascurabile di valori negativi, attestando che la partizione in 5 macro-mood rispetta la topologia dello spazio audio.

[2]La Silhouette misura quanto un punto sia simile agli elementi del proprio cluster rispetto a quelli dei cluster contigui, assumendo valori tra -1 e +1.

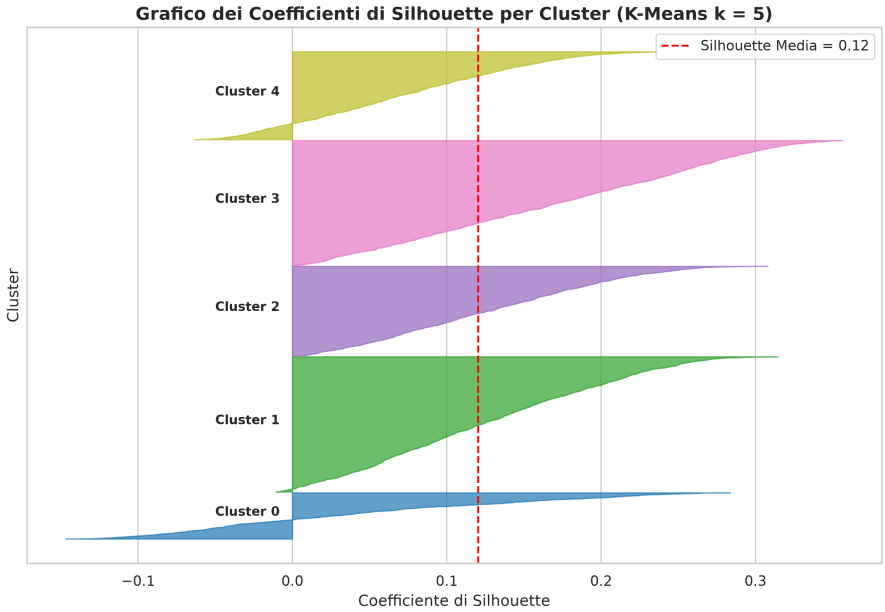


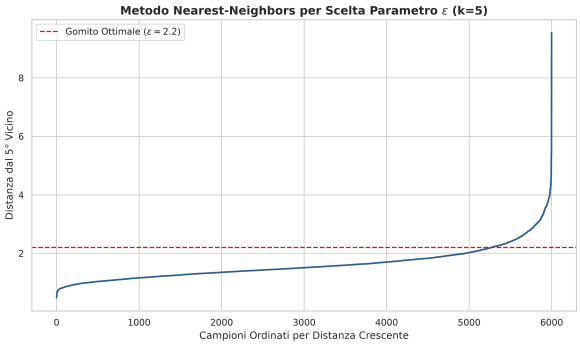
Figura 18: Grafico della Silhouette per il modello K-Means (k = 5).

4.3 DBSCAN

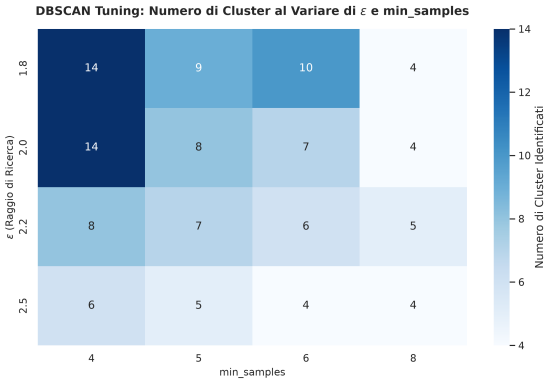
DBSCAN (Density-Based Spatial Clustering of Applications with Noise) identifica i cluster come regioni dense nello spazio dati separate da aree a bassa densità, senza imporre forme geometriche predefinite ed etichettando automaticamente i punti isolati come rumore (`label` = -1).

4.3.1 Applicazione dell'algoritmo DBSCAN

Per determinare il raggio □, è stato impiegato il metodo dei k-Nearest Neighbors, graficando la distanza tra ciascun punto e il suo 5° vicino più prossimo (k = min_samples = 5). In Figura 19a la curva evidenzia un netto ginocchio in corrispondenza di □ = 2.2. È stata inoltre esplorata una griglia parametrica (□ × min_samples), riportata in Figura 19b. La combinazione □ = 2.2, min_samples = 5 identifica 8 cluster densi e isola una frazione controllata di rumore pari al 6.9% (415 tracce).



(a) Grafico k-NN distance per la scelta di □.



(b) Griglia di tuning parametri (□ × min_samples).

Figura 19: Fase di tuning e calibrazione dei parametri per l'algoritmo DBSCAN.

4.3.2 Analisi dei risultati ottenuti e Diagnostica del Rumore

In Figura 20 sono illustrati gli 8 cluster DBSCAN insieme ai punti di rumore (evidenziati con marker a croce rossa). I boxplot in Figura 21 indagano il motivo per cui tali brani sono stati respinti come rumore:

- Durata anomala (`duration_ms`): Molti brani rumorosi hanno durate anomale superiori a 7-10 minuti o intro inferiori a 30 secondi.
- Speechiness estrema: Comprende tracce parlate, interviste, sketch e campionamenti non convenzionali.
- BPM eccentrici: Brani con velocità superiori a 210 BPM o fluttuazioni ritmiche atipiche.

Figura 20: Cluster DBSCAN con isolamento ed evidenziazione dei punti di rumore / outlier.

Figura 21: Analisi diagnostica del rumore DBSCAN: confronto delle distribuzioni su feature anomale.