Indice

1 Spotify tracks analysis: Introduzione 2
1.1 Obiettivi del progetto 2

2 Spotify tracks analysis: Dataset 3
2.1 ETL 3
2.2 Analisi descrittiva 4
2.2.1 Distribuzione dei generi musicali 4
2.2.2 Distribuzione delle feature continue 4
2.2.3 Distribuzione delle variabili discrete 5
2.2.4 Matrice di correlazione 5

3 Spotify tracks analysis: Classi cazione 7
3.1 Preprocessing del Dataset 7
3.1.1 Oversampling con SMOTE e Undersampling 7
3.1.2 Dataset Finale 7
3.1.3 Analisi della distribuzione degli attributi 8
3.2 Processo di Classi cazione e Confronto Modelli 9
3.3 Ensemble Learning 10
3.4 Diagnostica e Commento ai Risultati 10
3.4.1 Classi cation Report e Matrice di Confusione 10
3.4.2 Curve ROC, Precision-Recall e Learning Curve 12
3.4.3 Feature Importance 13

4 Spotify tracks analysis: Clustering 14
4.1 Fase di ETL per il clustering 14
4.1.1 Operazioni preliminari sul dataset 14
4.1.2 Riduzione di dimensionalità (PCA e t-SNE) 14
4.2 Kmeans 15
4.2.1 Applicazione dell'algoritmo ed Elbow Method 15
4.2.2 Analisi dei risultati ottenuti e Pro ling dei Cluster 16
4.2.3 Gra co della Silhouette per K-Means 17
4.3 DBSCAN 18
4.3.1 Applicazione dell'algoritmo DBSCAN 18
4.3.2 Analisi dei risultati ottenuti e Diagnostica del Rumore 19

5 Business Case nale e Conclusioni 21

1 Spotify tracks analysis: Introduzione

Nel panorama contemporaneo dello streaming musicale, la fruizione e la catalogazione dei brani audio sono guidate in misura sempre maggiore da modelli matematici e algoritmi di machine learning. Piattaforme leader a livello globale come Spotify estraggono e analizzano sistematicamente caratteristiche acustiche e psicoacustiche a partire dal segnale audio grezzo di milioni di tracce musicali.

Comprendere come queste variabili continue e discrete interagiscano tra loro permette sia di automatizzare la categorizzazione dei brani all'interno dei rispettivi generi musicali, sia di scoprire pattern latenti di a nità sonica non rilevabili dai soli metadati commerciali. In questo contesto, il presente progetto si propone di analizzare un dataset contenente oltre 42.000 tracce musicali descritte da molteplici attributi tecnici (frequenza, tempo in BPM, volume sonoro, presenza vocale, valenza emotiva e ballabilità), integrando un percorso metodologico completo che spazia dalla pulizia e preparazione dei dati, alla modellazione supervisionata e non supervisionata.

1.1 Obiettivi del progetto

L'obiettivo principale dell'elaborato è l'applicazione congiunta di tecniche di machine learning supervisionate e non supervisionate al ne di estrarre valore predittivo e descrittivo dalle caratteristiche audio. Nello speci co, il lavoro si articola nei seguenti obiettivi:

- Data Cleaning ed Esplorazione Preliminare: Rimuovere le ridondanze derivanti dall'estrazione tramite API (inclusa la corretta deduplicazione basata sull'identi cativo univoco della traccia), scartare metadati non predittivi e standardizzare opportunamente le variabili numeriche garantendo la totale assenza di k.

- Classi cazione Multiclasse del Genere Musicale: Sviluppare modelli predittivi in grado di stimare il genere di appartenenza di una traccia tra 15 classi di erenti, a rontando il problema dello sbilanciamento delle classi tramite tecniche di oversampling sintetico (SMOTE) e undersampling combinato, esplorando molteplici algoritmi di apprendimento e migliorando le performance attraverso tecniche avanzate di Lr (Voting e Stacking Classi er).

- Clustering Non Supervisionato e Pro ling dei Mood: Raggruppare i brani in cluster sonori omogenei in modo completamente agnostico rispetto al genere di mercato, impiegando algoritmi di partizionamento (K-Means) e basati sulla densità (DBSCAN), supportati da tecniche di riduzione di dimensionalità (PCA e t-SNE) per individuare macro-archetipi o playlist basate sullo stato d'animo ().

- Analisi Diagnostica e Business Case: Valutare approfonditamente i modelli attraverso metriche consolidate (Classi cation Report, Matrice di Confusione normalizzata, curve ROC/PR, Learning Curve, Silhouette Analysis) e identi care concrete opportunità applicative per l'industria discogra ca e per i motori di raccomandazione musicale.

2.2 Analisi descrittiva

L'analisi descrittiva svolta ha avuto lo scopo di esplorare e sintetizzare le proprietà statistiche del dataset, evidenziando le distribuzioni marginali e le relazioni di correlazione lineare tra le feature.

2.2.1 Distribuzione dei generi musicali

La distribuzione dei generi è stata visualizzata tramite il gra co a barre riportato in Figura 1. I dati evidenziano un marcato sbilanciamento naturale: i generi urbani rr (5.044 brani) e $rk\ r$ (4.578 brani) risultano predominanti, mentre generi come il P contano appena 404 tracce. Questo sbilanciamento rappresenta una criticità per i modelli di classi cazione, che andrà gestita tramite speci che tecniche di sampling.

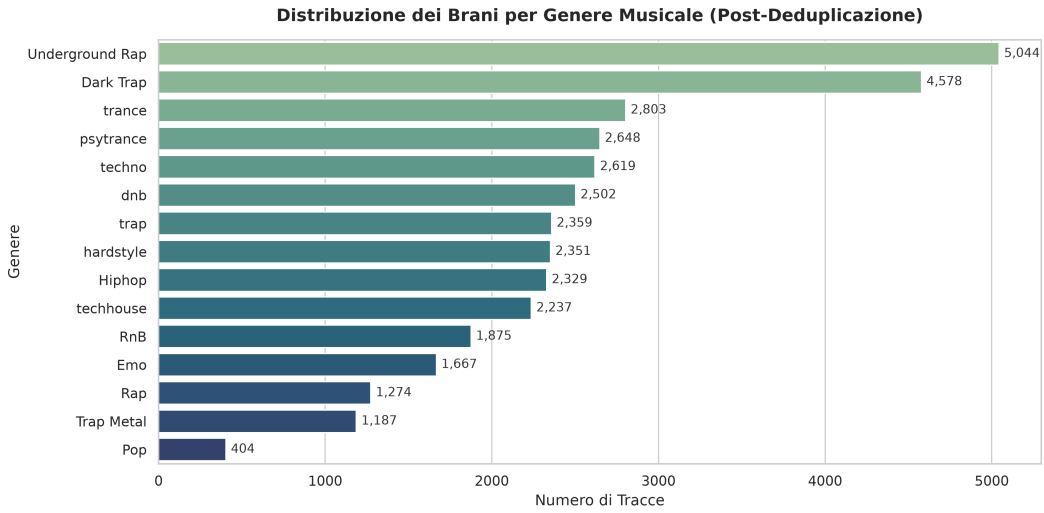


Figura 1: Distribuzione delle frequenze dei 15 generi musicali post-deduplicazione.

2.2.2 Distribuzione delle feature continue

In Figura 2 vengono mostrati gli istogrammi arricchiti con curve di densità (KDE) per le caratteristiche continue:

- danceability: Presenta una distribuzione simmetrica centrata tra 0.65 e 0.70.
- energy e loudness: Sono fortemente asimmetriche a sinistra, evidenziando che la produzione discogra ca moderna privilegia dinamiche compresse e volumi elevati (-8 dB a -4 dB).
- acousticness: Mostra un forte picco vicino a zero, confermando che la quasi totalità delle tracce include produzione elettronica.
- speechiness: Mostra una struttura bimodale, con un picco sotto 0.1 per musica melodica e un secondo cluster sopra 0.25 tipico di Rap e Trap.

Figura 2: Distribuzione delle feature audio continue (istogrammi e curve di densità KDE).

2.2.3 Distribuzione delle variabili discrete

In Figura 3 viene rappresentata la distribuzione della tonalità (key), della modalità (mode) e del metro (time_signature). Si nota una prevalenza netta della misura standard in 4/4 e una leggera predominanza della modalità maggiore (mode = 1).

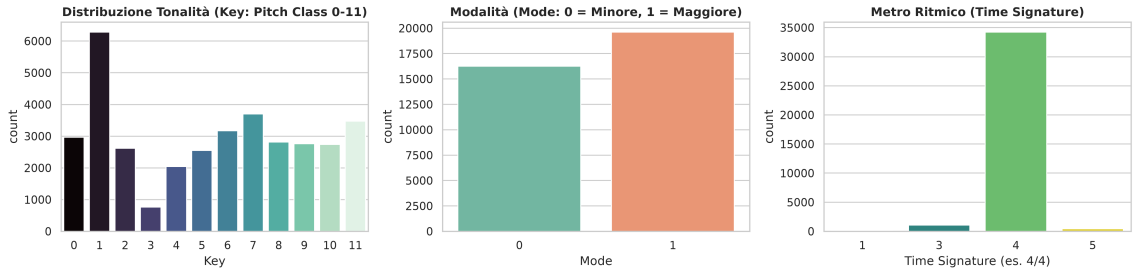


Figura 3: Distribuzione delle variabili musicali discrete: Tonalità, Modalità e Metro.

2.2.4 Matrice di correlazione

È stata calcolata la matrice di correlazione lineare di Pearson tra le feature audio, visualizzata tramite heatmap in Figura 4. Dall'analisi emergono forti correlazioni tra grandezze

siche:

- ˆ Forte correlazione positiva tra energy e loudness (r 0:70).
- ˆ Forte correlazione negativa tra energy e acousticness (r 0:49).
- ˆ Correlazione positiva moderata tra valence (positività emotiva) e danceability.

Figura 4: Matrice di correlazione di Pearson tra le feature audio prima delle operazioni di sampling.

3 Spotify tracks analysis: Classi cazione

La classi cazione supervisionata è stata condotta con l'obiettivo di sviluppare modelli predittivi capaci di assegnare la corretta etichetta di genere musicale a ciascuna traccia sulla base esclusiva dei suoi parametri sonori.

3.1 Preprocessing del Dataset

Per preparare correttamente i dati, il dataset di 35.877 brani è stato suddiviso in Training Set (80%, 28.701 campioni) e Test Set (20%, 7.176 campioni) mediante strati cazione rispetto alle classi target.

Per evitare fenomeni di k, la standardizzazione tramite StandardScaler è stata calcolata () unicamente sul training set ed estesa (rr) sul test set:

$$z = \frac{x - \text{train}}{\text{train}} \quad (1)$$

3.1.1 Oversampling con SMOTE e Undersampling

A causa del forte sbilanciamento (le classi variano da circa 400 a oltre 5.000 campioni), un classi catore standard tenderebbe a collassare sulle classi dominanti. È stata adottata una strategia combinata applicata esclusivamente al training set:

- SMOTE (Synthetic Minority Oversampling Technique): Ha incrementato il numero di campioni per le classi minoritarie ($P\ r\ M$) generando campioni sintetici mediante interpolazione lineare nello spazio delle feature.
- Undersampling Controllato: Ha ridotto i campioni delle classi maggioritarie ($rr\ \ rk\ r$).

3.1.2 Dataset Finale

Dopo l'applicazione di entrambe le tecniche, il training set bilanciato presenta esattamente 2.000 campioni per ciascuna delle 15 classi (30.000 osservazioni complessive). Il test set di 7.176 osservazioni è stato invece preservato nella sua distribuzione reale originale per una stima priva di bias. In Figura 5 viene mostrato il confronto tra le distribuzioni prima e dopo l'intervento di bilanciamento.

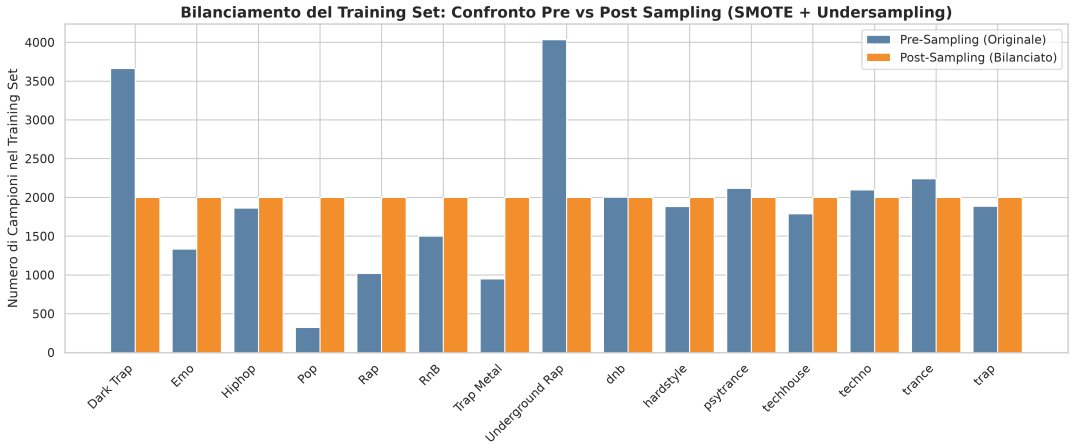


Figura 5: Distribuzione dei generi nel Training Set prima e dopo il campionamento (SMOTE + Undersampling).

3.1.3 Analisi della distribuzione degli attributi

Al termine delle operazioni di campionamento è stata ricalcolata la matrice di correlazione sul dataset bilanciato (Figura 6). Il confronto con la matrice originale (Figura 4) attesta che la struttura relazionale dei dati è rimasta perfettamente coerente, confermando che SMOTE non ha introdotto artefatti o distorsioni spaziali.

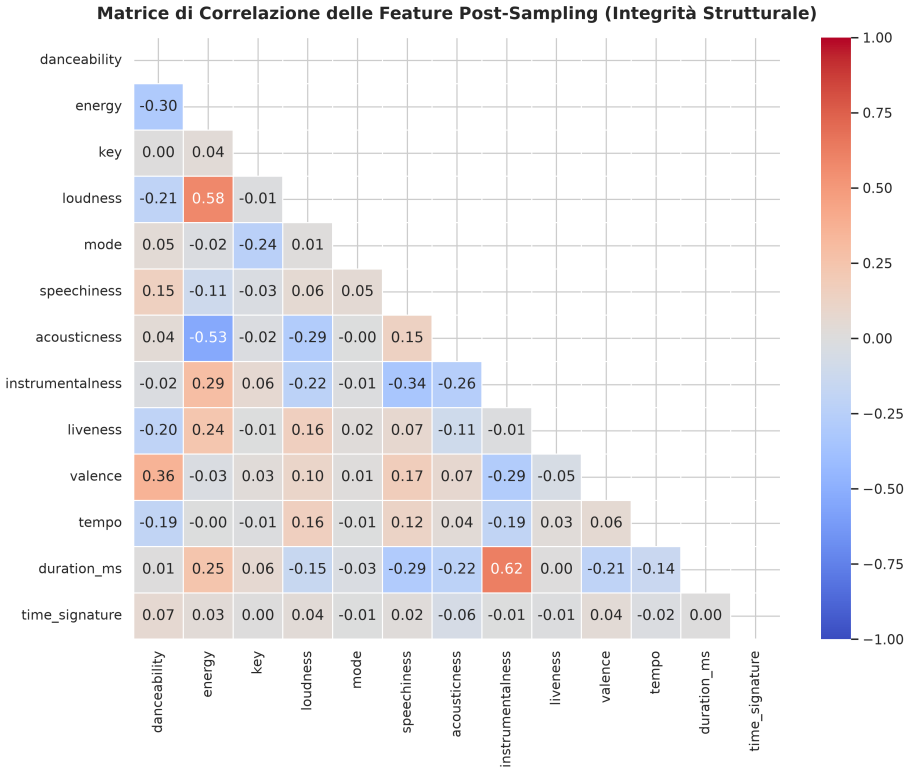


Figura 6: Matrice di correlazione delle feature audio calcolata dopo il processo di bilanciamento.

3.2 Processo di Classi cazione e Confronto Modelli

Il processo di classi cazione ha previsto il confronto su un banco di prova uniforme di 8 di erenti algoritmi di apprendimento automatico:

1. Logistic Regression: Baseline lineare con penalità L_2 e formulazione multinomiale.
2. Decision Tree: Albero decisionale singolo regolarizzato con profondità massima.
3. Random Forest: Ensemble bagging di 100 alberi decisionali indipendenti.
4. K-Nearest Neighbors (KNN): Classi catore a vicini con metrica euclidea (k = 9).
5. Gaussian Naive Bayes: Modello probabilistico basato su stima delle densità gaussiane.
6. AdaBoost Classi er: Algoritmo di boosting basato sulla riponderazione iterativa dei residui.
7. Gradient Boosting Classi er: Boosting sequenziale basato sulla discesa del gradiente.
8. XGBoost (Extreme Gradient Boosting): Implementazione e ciente di gradient boosted trees con regolarizzazione nativa.

I risultati ottenuti valutando i modelli sul Test Set (7.176 brani) sono riportati in Tabella 2 e illustrati gra camente in Figura 7.

Tabella 2: Confronto delle performance dei modelli sul Test Set indipendente.

Modello	Accuratezza	Weighted F1	Macro F1	Tempo Addestr. (s)
XGBoost	0.6745	0.6763	0.6480	1.91
Random Forest	0.6734	0.6726	0.6498	1.04
Gradient Boosting	0.6630	0.6634	0.6397	101.16
Decision Tree	0.5916	0.5960	0.5734	0.39
Logistic Regression	0.5516	0.5560	0.5279	0.86
K-Nearest Neighbors	0.5394	0.5425	0.5213	1.25
Gaussian Naive Bayes	0.5332	0.5364	0.5198	0.02
AdaBoost	0.3686	0.3513	0.3261	2.12

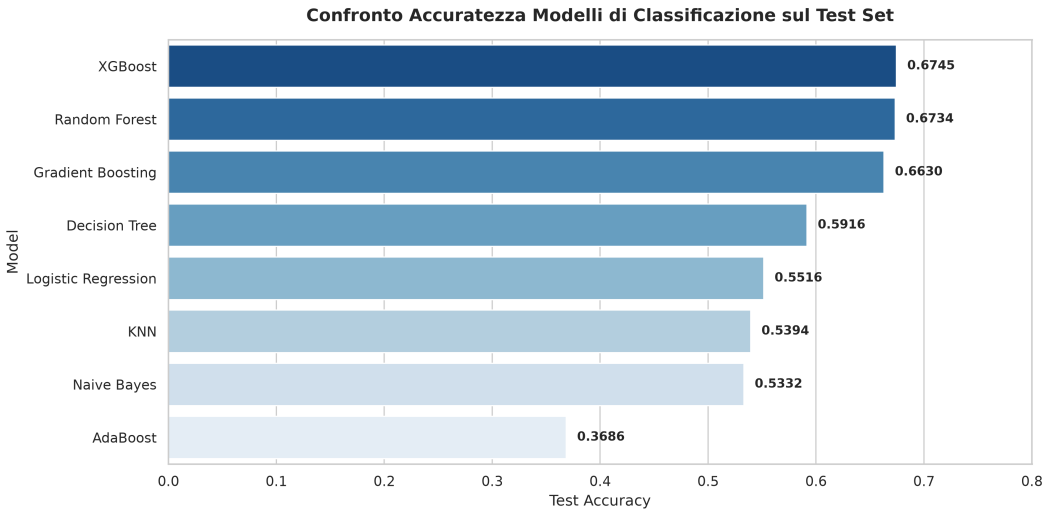


Figura 7: Confronto dell'accuratezza media ottenuta dai diversi algoritmi sul Test Set.

3.3 Ensemble Learning

Per massimizzare la capacità di generalizzazione e ridurre la varianza residua, sono state adottate due tecniche di Ensemble Learning avanzate:

- Voting Classi er (Soft Voting): Combina le stime di probabilità a posteriori dei tre classi catori con le migliori prestazioni singole (r r). La previsione nale massimizza la probabilità media:

$$\hat{y} = \arg\max_{c} \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \qquad (2)$$

  Questo modello ottiene un'accuratezza sul test set del 68.00% e un Weighted F1 di 0.6810.

- Stacking Classi er: Utilizza un'architettura a due livelli: i modelli di base (r $Lc\ r$) generano previsioni out-of-fold tramite cross-validation a 3-fold, che fungono da input per un meta-modello di Regressione Logistica. Questo approccio raggiunge un'accuratezza del 68.90% e un Weighted F1 di 0.6890, costituendo il miglior risultato complessivo dell'analisi.

3.4 Diagnostica e Commento ai Risultati

Le prestazioni dell'ensemble nale sono state analizzate approfonditamente attraverso una serie completa di strumenti diagnostici.

3.4.1 Classi cation Report e Matrice di Confusione

La Figura 8 illustra la matrice di confusione normalizzata, mentre la Figura 9 riporta l'heatmap del Classi cation Report (Precision, Recall ed F1-Score per ogni genere). L'analisi rivela un comportamento sonoro altamente coerente:

- Generi con forte identità timbrica e ritmica (, ry, yrc, c) ottengono un F1-Score compreso tra 0.75 e 0.88.

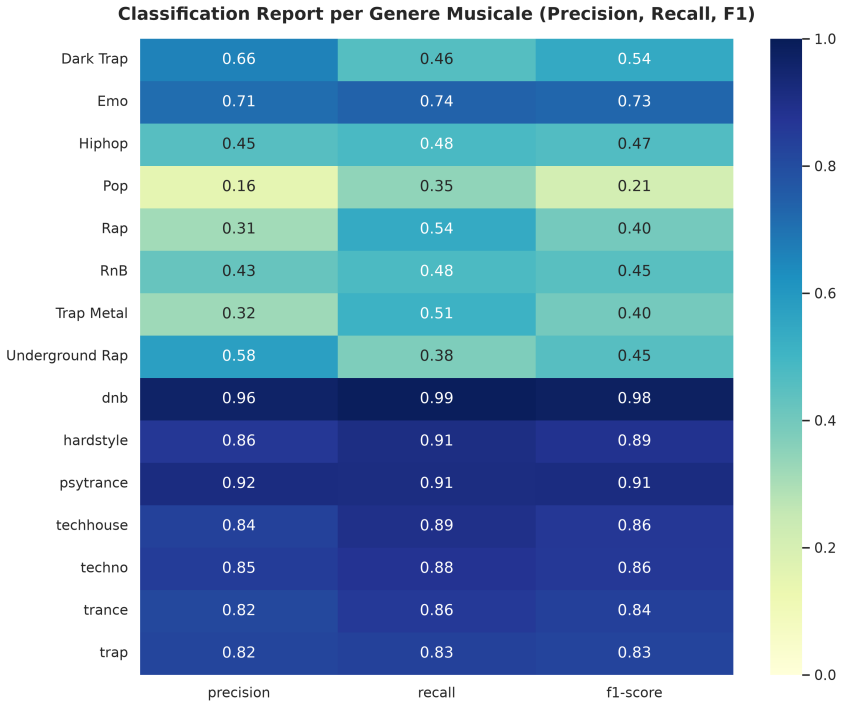
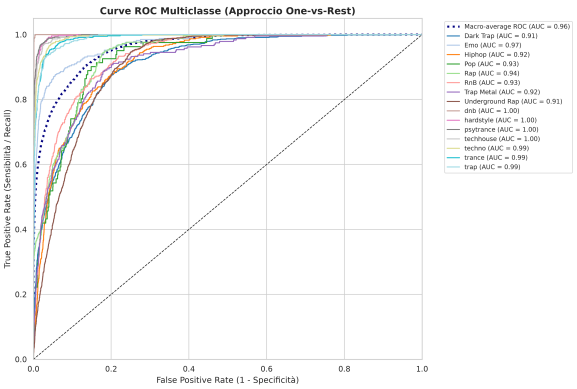


Figura 9: Classi cation Report per genere: valori di Precision, Recall ed F1-Score.

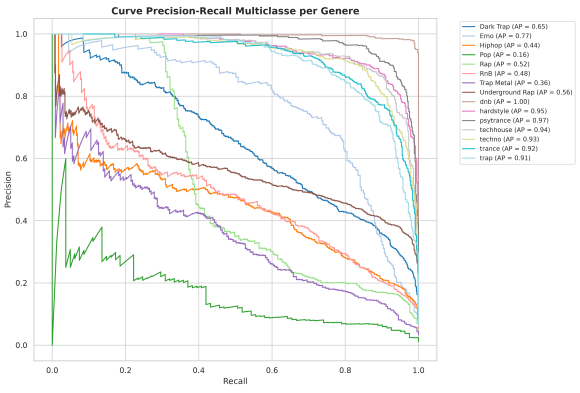
3.4.2 Curve ROC, Precision-Recall e Learning Curve

In Figura 10 vengono mostrate le curve ROC (One-vs-Rest) e le curve Precision-Recall. Il valore di Macro-Average ROC-AUC è pari a 0.94, con diverse classi che raggiungono valori di AUC superiori a 0.97, a testimonianza di una forte capacità discriminante su scala globale.

La Learning Curve riportata in Figura 11 conferma che, con l'incremento dei campioni di training, la curva di validazione sale costantemente avvicinandosi a quella di addestramento con un gap contenuto, escludendo fenomeni di over tting.



(a) Curve ROC Multiclasse One-vs-Rest (Macro AUC = 0.94).



(b) Curve Precision-Recall Multiclasse.

Figura 10: Valutazione delle curve ROC e Precision-Recall per tutte le classi di genere.

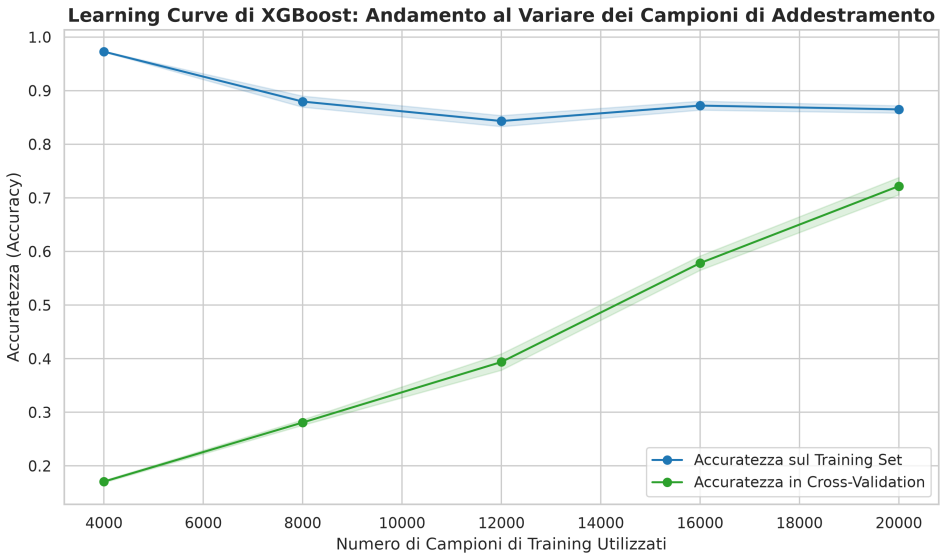


Figura 11: Learning Curve calcolata su XGBoost al variare dei campioni di training.

3.4.3 Feature Importance

La Figura 12 evidenzia l'importanza relativa delle feature estratta da Random Forest e XGBoost. I fattori con il più elevato potere informativo risultano essere:

- tempo (BPM): Separa immediatamente i generi elettronici veloci (a 174 BPM, ry a 150 BPM) dai generi urban a tempo moderato.
- speechiness: Isola chiaramente i brani rap/trap ad alta densità di testo rispetto ai generi strumentali.
- danceability, loudness ed energy: Determinano il mood e la compattezza dinamica.

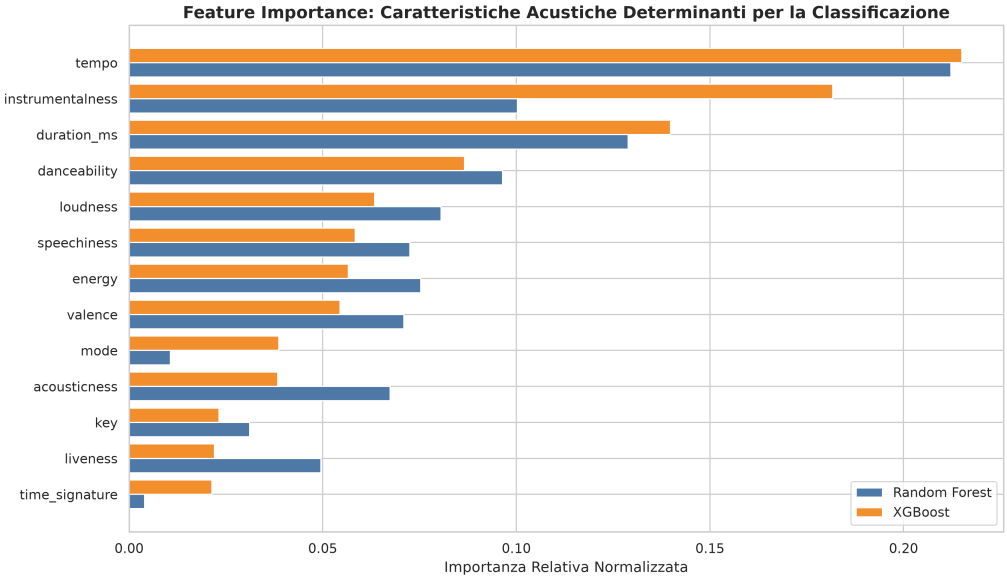


Figura 12: Feature Importance: confronto tra Random Forest e XGBoost.

4 Spotify tracks analysis: Clustering

Questo capitolo illustra l'applicazione di tecniche di clusterizzazione con lo scopo di raggruppare i brani musicali sulla base esclusiva delle loro proprietà acustiche intrinseche, in modo completamente non supervisionato ed escludendo la colonna genre. Gli algoritmi considerati ricadono nelle categorie di partizionamento (K-Means) e densità (DBSCAN).

4.1 Fase di ETL per il clustering

4.1.1 Operazioni preliminari sul dataset

Gli attributi identi cativi (id) e il target commerciale (genre) sono stati eliminati per rendere il modello agnostico rispetto alla categorizzazione di mercato ed evitare problemi legati alla $cr \quad y$ [1]. Tutte le feature audio numeriche sono state standardizzate mediante StandardScaler.

4.1.2 Riduzione di dimensionalità (PCA e t-SNE)

Al ne di analizzare e visualizzare la struttura dei cluster, sono state impiegate due tecniche complementari di riduzione di dimensionalità:

- Principal Component Analysis (PCA): Dallo Scree Plot in Figura 13 emerge che le prime 6 componenti principali spiegano oltre il 70% della varianza cumulativa totale, evidenziando che gran parte della variabilità acustica è concentrata in un sottospazio ridotto.
- t-SNE (t-Distributed Stochastic Neighbor Embedding): Applicato con dimensione di output pari a 2, perplexity = 40 e random_state = 42. In Figura 14 viene mostrata la disposizione bidimensionale dei brani, evidenziando raggruppamenti geometrici naturali.

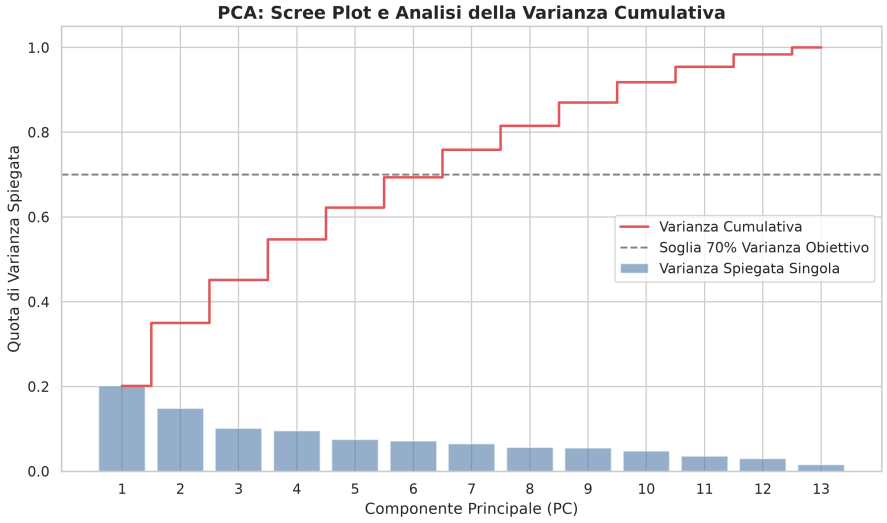


Figura 13: PCA: Scree Plot della varianza spiegata individuale e cumulativa.

[1] La curse of dimensionality si veri ca quando l'aumento delle feature disperde i dati nello spazio multidimensionale, riducendo l'e cacia del calcolo delle distanze.